

Statistika Berbasis Data

Turunan dari
OpenIntro Statistics
Edisi Keempat

Penulis Asli

David M. Diez
Mine Çetinkaya-Rundel
Christopher D. Barr

Kontributor Edisi Bahasa Indonesia

Codex

Terjemahan bahasa Indonesia dan adaptasi teknis, atas permintaan pengguna

Buku ini merupakan karya turunan berbahasa Indonesia dari *OpenIntro Statistics*, Edisi Keempat, karya David M. Diez, Mine Çetinkaya-Rundel, dan Christopher D. Barr. Karya turunan ini berjudul *Statistika Berbasis Data*; karya ini bukan produk OpenIntro dan tidak berafiliasi dengan atau didukung oleh OpenIntro.

Selain komponen yang dinyatakan secara terpisah, konten sumber dan terjemahan ini tersedia berdasarkan lisensi Creative Commons Attribution-ShareAlike 3.0 Unported (CC BY-SA 3.0). Ketentuan lisensi tersedia pada [laman lisensi Creative Commons](#).

Perubahan dari sumber mencakup penerjemahan ke bahasa Indonesia dan penyesuaian teknis untuk penerbitan edisi ini.

Sumber yang digunakan adalah repositori resmi pada komit

`fee25091fb24e89c36296fd67c48c1fcf7a93b6e`

[Repositori sumber pada komit tersebut](#).

Pedoman atribusi dan penamaan karya turunan tersedia di [berkas lisensi sumber](#). Merek dagang, logo, sampul, dan identitas visual OpenIntro tidak dilisensikan untuk digunakan sebagai identitas karya turunan ini. Aset pihak ketiga tetap tunduk pada lisensi dan atribusi komponennya masing-masing.

Daftar Isi

Cakupan edisi parsial ini	6
1 Pengantar data	7
1.1 Studi kasus: penggunaan stent untuk mencegah stroke	9
1.2 Dasar-dasar data	12
1.3 Prinsip dan strategi pengambilan sampel	22
1.4 Eksperimen	33
2 Merangkum data	40
2.1 Menelaah data numerik	42
2.2 Menelaah data kategoris	62
2.3 Studi kasus: vaksin malaria	72
3 Probabilitas	81
3.1 Mendefinisikan probabilitas	83
3.2 Peluang bersyarat	99
3.3 Pengambilan sampel dari populasi kecil	116
3.4 Variabel acak	119
3.5 Distribusi kontinu	130
4 Distribusi variabel acak	134
4.1 Distribusi normal	136
4.2 Distribusi geometrik	147
4.3 Distribusi binomial	152
4.4 Distribusi binomial negatif	162
4.5 Distribusi Poisson	167
5 Dasar-dasar inferensi	170
5.1 Estimasi titik dan variabilitas sampling	172
5.2 Interval kepercayaan untuk suatu proporsi	184
A Solusi latihan	192

Prakata

OpenIntro Statistics mencakup materi mata kuliah statistika tingkat pengantar dan menyajikan pengantar statistika terapan yang ketat secara ilmiah, jelas, ringkas, dan mudah dipahami. Buku ini ditulis terutama untuk jenjang sarjana, tetapi juga banyak digunakan di sekolah menengah dan program pascasarjana.

Selain membangun landasan pemikiran dan metode statistika, kami berharap pembaca memperoleh tiga gagasan berikut dari buku ini.

- Statistika adalah bidang terapan dengan cakupan penerapan praktis yang luas.
- Anda tidak harus menjadi ahli matematika untuk belajar dari data nyata yang menarik.
- Data sering kali tidak rapi, dan alat statistika tidak sempurna. Namun, jika memahami kekuatan dan keterbatasan alat-alat tersebut, Anda dapat menggunakannya untuk mempelajari dunia.

Ikhtisar buku ajar

Bab-bab dalam buku ini adalah sebagai berikut:

1. **Pengantar data.** Struktur data, variabel, dan teknik dasar pengumpulan data.
2. **Meringkas data.** Ringkasan data, grafik, dan pengantar singkat inferensi menggunakan pengacakan.
3. **Probabilitas.** Prinsip-prinsip dasar probabilitas.
4. **Distribusi variabel acak.** Model normal dan distribusi penting lainnya.
5. **Dasar-dasar inferensi.** Gagasan umum statistika inferensial dalam konteks pendugaan proporsi populasi.
6. **Inferensi untuk data kategoris.** Inferensi untuk proporsi dan tabel dengan menggunakan distribusi normal dan khi-kuadrat.
7. **Inferensi untuk data numerik.** Inferensi untuk rata-rata satu atau dua sampel dengan menggunakan distribusi t , daya statistik untuk membandingkan dua kelompok, serta perbandingan banyak rata-rata menggunakan ANOVA.
8. **Pengantar regresi linear.** Regresi untuk hasil numerik dengan satu variabel prediktor. Sebagian besar bab ini dapat dipelajari setelah Bab 1.
9. **Regresi berganda dan logistik.** Regresi untuk data numerik dan kategoris dengan menggunakan banyak prediktor.

Struktur *OpenIntro Statistics* memberi keleluasaan dalam memilih dan mengurutkan topik. Jika tujuan utama Anda adalah mempelajari regresi berganda (Bab belum dimuat) secepat mungkin, prasyarat yang ideal adalah sebagai berikut:

- Bab 1 dan Bagian 2.1–2.3 untuk memperoleh pengantar yang kokoh tentang struktur data dan ringkasan statistika yang digunakan di seluruh buku.
- Bagian 4.1 untuk memperoleh pemahaman yang kokoh tentang distribusi normal.

- Bab 5 untuk membangun perangkat inti inferensi.
- Bagian belum dimuat untuk membangun landasan pemahaman tentang distribusi t .
- Bab belum dimuat untuk membangun gagasan dan prinsip regresi dengan satu prediktor.

Contoh dan latihan

Contoh disediakan untuk membangun pemahaman tentang cara menerapkan metode.

CONTOH 0.1

E

Ini adalah sebuah contoh. Jika pertanyaan diajukan di sini, di mana jawabannya dapat ditemukan?

Jawabannya dapat ditemukan di sini, pada bagian penyelesaian dalam contoh tersebut!

Jika kami menilai bahwa pembaca sudah siap mencoba menentukan sendiri penyelesaian suatu contoh, kami menyajikannya sebagai Latihan Terbimbing.

LATIHAN TERBIMBING 0.2

G

Pembaca dapat memeriksa atau mempelajari jawaban setiap soal Latihan Terbimbing dengan membaca penyelesaian lengkap dalam catatan kaki.¹

Latihan juga disediakan pada akhir setiap bagian, bersama latihan ulasan pada akhir setiap bab. Penyelesaian untuk latihan bernomor ganjil diberikan dalam Lampiran A.

Sumber daya tambahan

Ikhtisar video, salindia, laboratorium perangkat lunak statistika, himpunan data yang digunakan dalam buku ajar, dan banyak sumber daya lainnya tersedia dengan mudah di

openintro.org/os

Kami juga telah mempermudah akses ke data dalam buku ini dengan menambahkan Lampiran belum dimuat, yang memberikan informasi tambahan untuk setiap himpunan data dalam teks utama dan merupakan bagian baru pada Edisi Keempat. Panduan daring untuk setiap himpunan data tersebut juga tersedia di **openintro.org/data** dan melalui paket pendamping R.

Kami menghargai semua umpan balik serta laporan kesalahan ketik yang disampaikan melalui situs web. Tautan singkat untuk melaporkan kesalahan ketik baru atau meninjau kesalahan ketik yang telah diketahui adalah **openintro.org/os/typos**.

Bagi pembaca yang berfokus pada statistika di tingkat sekolah menengah, pertimbangkan *Advanced High School Statistics*, yakni versi *OpenIntro Statistics* yang telah disesuaikan secara ekstensif oleh Leah Dorazio untuk pelajaran sekolah menengah dan AP[®] Statistics.

Ucapan terima kasih

Proyek ini tidak akan terwujud tanpa semangat dan dedikasi banyak orang selain mereka yang tercantum sebagai penulis. Para penulis mengucapkan terima kasih kepada Staf OpenIntro atas keterlibatan dan kontribusi mereka yang berkelanjutan. Kami juga sangat berterima kasih kepada ratusan mahasiswa, siswa, dan pengajar yang telah memberikan umpan balik berharga sejak kami pertama kali mengunggah materi buku ini pada 2009.

Kami juga berterima kasih kepada banyak pengajar yang membantu meninjau edisi ini, termasuk Laura Acion, Matthew E. Aiello-Lammens, Jonathan Akin, Stacey C. Behrensmeier, Juan Gomez, Jo Hardin, Nicholas Horton, Danish Khan, Peter H.M. Klaren, Jesse Mostipak, Jon C. New, Mario Orsi, Steve Phelps, dan David Rockoff. Kami menghargai semua umpan balik mereka, yang membantu menyempurnakan teks ini secara berarti dan meningkatkan kualitas buku ini secara substansial.

¹Soal Latihan Terbimbing dirancang untuk mengembangkan cara berpikir Anda. Anda dapat memeriksa jawaban dengan membaca penyelesaian dalam catatan kaki pada setiap Latihan Terbimbing.

Cakupan edisi parsial ini

Pembaca ini berhenti tepat setelah Bagian 5.2, *Interval kepercayaan untuk suatu proporsi*. Cakupan Bab 5 dalam edisi ini memuat seluruh empat belas latihan, yaitu latihan 1–14, dan semua jawaban publik yang tersedia dari sumber, yaitu jawaban untuk latihan 1, 3, 5, 7, 9, 11, dan 13. Jawaban untuk latihan 2, 4, 6, 8, 10, 12, dan 14 memang tidak tersedia dalam sumber publik; jawaban-jawaban itu dicatat sebagai kesenjangan pendamping kemahiran O001 dan tidak direka.

Rujukan dari materi yang dipertahankan ke bab, bagian, tabel, atau lampiran lanjutan ditandai “belum dimuat”. Sumber lengkap tetap dipertahankan untuk kelanjutan penerjemahan, tetapi halaman sumber berbahasa Inggris tidak disertakan dalam keluaran pembelajar ini.

Provenans penerjemahan dan rekayasa edisi: OpenAI Codex gpt-5.6-sol, Ultra. Seluruh kredit penulis dan kontributor sumber tetap dipertahankan.

Bab 1

Pengantar data

1.1 Studi kasus: penggunaan stent untuk mencegah stroke

1.2 Dasar-dasar data

1.3 Prinsip dan strategi pengambilan sampel

1.4 Eksperimen

Para ilmuwan berupaya menjawab pertanyaan dengan menggunakan metode yang ketat dan pengamatan yang cermat. Pengamatan ini – yang dihimpun, antara lain, dari catatan lapangan, survei, dan eksperimen – menjadi landasan penyelidikan statistika dan disebut **data**. Statistika adalah ilmu tentang cara terbaik untuk mengumpulkan dan menganalisis data serta menarik kesimpulan darinya, dan pada bab pertama ini, kita berfokus pada sifat-sifat data serta cara pengumpulannya.



Untuk video, salindia, dan sumber daya lainnya, kunjungi www.openintro.org/os

1.1 Studi kasus: penggunaan stent untuk mencegah stroke

Bagian 1.1 memperkenalkan tantangan klasik dalam statistika: mengevaluasi efektivitas suatu penanganan medis. Istilah-istilah dalam bagian ini, dan bahkan sebagian besar isi bab ini, akan dibahas kembali nanti. Untuk saat ini, tujuannya hanyalah memperoleh gambaran tentang peran statistika dalam praktik.

Dalam bagian ini kita akan meninjau sebuah eksperimen yang mengkaji efektivitas stent dalam menangani pasien yang berisiko mengalami stroke. Stent adalah alat yang ditempatkan di dalam pembuluh darah untuk membantu pemulihan pasien setelah kejadian kardiak serta mengurangi risiko serangan jantung berikutnya atau kematian. Banyak dokter berharap stent akan memberikan manfaat serupa bagi pasien yang berisiko mengalami stroke. Kita mulai dengan menuliskan pertanyaan utama yang hendak dijawab oleh para peneliti:

Apakah penggunaan stent mengurangi risiko stroke?

Para peneliti tersebut melakukan eksperimen terhadap 451 pasien berisiko. Setiap pasien sukarelawan dialokasikan secara acak ke salah satu dari dua kelompok:

Kelompok perlakuan. Pasien dalam kelompok perlakuan menerima stent dan penatalaksanaan medis. Penatalaksanaan medis tersebut mencakup pemberian obat, pengelolaan faktor risiko, dan bantuan untuk mengubah gaya hidup.

Kelompok kontrol. Pasien dalam kelompok kontrol menerima penatalaksanaan medis yang sama seperti kelompok perlakuan, tetapi tidak menerima stent.

Para peneliti mengalokasikan secara acak 224 pasien ke kelompok perlakuan dan 227 pasien ke kelompok kontrol. Dalam penelitian ini, kelompok kontrol menjadi titik acuan untuk mengukur dampak medis stent pada kelompok perlakuan.

Para peneliti mempelajari efek stent pada dua waktu: 30 hari setelah pendaftaran dan 365 hari setelah pendaftaran. Hasil untuk 5 pasien dirangkum dalam Gambar 1.1. Luaran pasien dicatat sebagai “stroke” atau “tidak ada kejadian”, yang menunjukkan apakah pasien mengalami stroke hingga akhir suatu periode waktu.

Pasien	kelompok	0–30 hari	0–365 hari
1	perlakuan	tidak ada kejadian	tidak ada kejadian
2	perlakuan	stroke	stroke
3	perlakuan	tidak ada kejadian	tidak ada kejadian
⋮	⋮	⋮	
450	kontrol	tidak ada kejadian	tidak ada kejadian
451	kontrol	tidak ada kejadian	tidak ada kejadian

Gambar 1.1: Hasil untuk lima pasien dari penelitian stent.

Menelaah data setiap pasien satu per satu merupakan cara yang panjang dan rumit untuk menjawab pertanyaan penelitian semula. Sebaliknya, analisis data statistik memungkinkan kita menelaah seluruh data sekaligus. Gambar 1.2 merangkum data mentah dengan cara yang lebih berguna. Dari tabel ini, kita dapat dengan cepat melihat apa yang terjadi selama penelitian. Misalnya, untuk menentukan jumlah pasien dalam kelompok perlakuan yang mengalami stroke dalam 30 hari, kita melihat sisi kiri tabel pada perpotongan baris perlakuan dan kolom stroke: 33.

	0–30 hari		0–365 hari	
	stroke	tidak ada kejadian	stroke	tidak ada kejadian
perlakuan	33	191	45	179
kontrol	13	214	28	199
Jumlah	46	405	73	378

Gambar 1.2: Statistik deskriptif untuk penelitian stent.

LATIHAN TERBIMBING 1.1



Dari 224 pasien dalam kelompok perlakuan, 45 orang mengalami stroke hingga akhir tahun pertama. Dengan menggunakan kedua bilangan ini, hitung proporsi pasien dalam kelompok perlakuan yang mengalami stroke hingga akhir tahun pertama. (Perhatikan: jawaban untuk semua soal Latihan Terbimbing diberikan dalam catatan kaki.)¹

Kita dapat menghitung statistik ringkasan dari tabel tersebut. Sebuah **statistik ringkasan** adalah satu bilangan yang merangkum sejumlah besar data. Sebagai contoh, hasil utama penelitian setelah 1 tahun dapat dijelaskan dengan dua statistik ringkasan: proporsi orang yang mengalami stroke dalam kelompok perlakuan dan kelompok kontrol.

Proporsi yang mengalami stroke dalam kelompok perlakuan (stent): $45/224 = 0.20 = 20\%$.

Proporsi yang mengalami stroke dalam kelompok kontrol: $28/227 = 0.12 = 12\%$.

Dua statistik ringkasan ini berguna untuk mencari perbedaan antarkelompok, dan kita menemukan sesuatu yang mengejutkan: terdapat tambahan 8% pasien yang mengalami stroke dalam kelompok perlakuan! Hal ini penting karena dua alasan. Pertama, hasil tersebut bertentangan dengan harapan dokter bahwa stent akan *menurunkan* angka kejadian stroke. Kedua, hasil tersebut memunculkan pertanyaan statistik: apakah data menunjukkan perbedaan yang “nyata” antara kedua kelompok?

Pertanyaan kedua ini cukup rumit. Misalkan Anda melempar koin 100 kali. Walaupun peluang koin menunjukkan sisi kepala pada setiap lemparan adalah 50%, kemungkinan besar kita tidak akan mengamati tepat 50 sisi kepala. Fluktuasi semacam ini merupakan bagian dari hampir semua proses pembangkitan data. Perbedaan 8% dalam penelitian stent mungkin saja disebabkan oleh variasi alami ini. Namun, semakin besar perbedaan yang kita amati (untuk ukuran sampel tertentu), semakin sulit dipercaya bahwa perbedaan tersebut terjadi karena kebetulan. Jadi, pertanyaan yang sebenarnya kita ajukan adalah: apakah perbedaannya sedemikian besar sehingga kita harus menolak anggapan bahwa perbedaan tersebut terjadi karena kebetulan?

Meskipun kita belum memiliki perangkat statistik untuk menjawab pertanyaan ini sepenuhnya secara mandiri, kita dapat memahami kesimpulan analisis yang telah dipublikasikan: terdapat bukti kuat bahwa penggunaan stent membahayakan pasien dalam penelitian ini.

Berhati-hatilah: Jangan menggeneralisasi hasil penelitian ini kepada semua pasien dan semua jenis stent. Penelitian ini mengamati pasien dengan karakteristik yang sangat khusus, yang secara sukarela ikut serta dan mungkin tidak mewakili semua pasien stroke. Selain itu, terdapat banyak jenis stent, sedangkan penelitian ini hanya mempertimbangkan stent Wingspan yang dapat mengembangkan sendiri (Boston Scientific). Namun, penelitian ini tetap memberi kita pelajaran penting: kita harus selalu siap menghadapi temuan yang mengejutkan.

¹Proporsi dari 224 pasien yang mengalami stroke dalam 365 hari: $45/224 = 0.20$.

Latihan

1.1 Migrain dan akupunktur, Bagian I. Migrain merupakan jenis sakit kepala yang sangat nyeri, dan sebagian pasien berupaya mengatasinya dengan akupunktur. Untuk menentukan apakah akupunktur meredakan nyeri migrain, para peneliti melakukan uji terkontrol acak yang melibatkan 89 perempuan yang didiagnosis menderita migrain. Mereka dialokasikan secara acak ke salah satu dari dua kelompok: perlakuan atau kontrol. Sebanyak 43 pasien dalam kelompok perlakuan menerima akupunktur yang dirancang secara khusus untuk menangani migrain. Sebanyak 46 pasien dalam kelompok kontrol menerima akupunktur plasebo (penusukan jarum pada lokasi yang bukan titik akupunktur). 24 jam setelah menerima akupunktur, pasien ditanya apakah mereka bebas nyeri. Hasilnya dirangkum dalam tabel kontingensi di bawah ini.²

Kelompok	Bebas nyeri		
		Ya	Tidak
		Jumlah	
Perlakuan	10	33	43
Kontrol	2	44	46
Jumlah	12	77	89

Deskripsi tekstual: Pada skema telinga dalam artikel asli, titik M berada di dekat bagian bawah depan daun telinga, sedangkan titik S berada di bagian tengah atas. Artikel tersebut membedakan area akupunktur yang sesuai (M) dan yang tidak sesuai (S) untuk menangani serangan migrain. Gambar pihak ketiga tidak disertakan dalam edisi turunan ini.

- Berapa persen pasien dalam kelompok perlakuan yang bebas nyeri 24 jam setelah menerima akupunktur?
- Berapa persen pasien dalam kelompok kontrol yang bebas nyeri?
- Kelompok mana yang memiliki persentase pasien bebas nyeri lebih tinggi 24 jam setelah menerima akupunktur?
- Temuan Anda sejauh ini mungkin menunjukkan bahwa akupunktur merupakan terapi yang efektif bagi semua orang yang menderita migrain. Namun, ini bukan satu-satunya kesimpulan yang dapat ditarik berdasarkan temuan Anda sejauh ini. Apa satu penjelasan lain yang mungkin atas perbedaan teramati antara persentase pasien yang bebas nyeri 24 jam setelah menerima akupunktur pada kedua kelompok?

1.2 Sinusitis dan antibiotik, Bagian I. Para peneliti yang membandingkan efek pengobatan antibiotik untuk sinusitis akut dengan penanganan simptomatik mengalokasikan secara acak 166 orang dewasa yang didiagnosis menderita sinusitis akut ke salah satu dari dua kelompok: perlakuan atau kontrol. Peserta penelitian menerima amoksisilin (antibiotik) selama 10 hari atau plasebo yang rupa dan rasanya serupa. Plasebo tersebut terdiri atas penanganan simptomatik seperti asetaminofen, dekongestan hidung, dan sebagainya. Pada akhir periode 10 hari, pasien ditanya apakah gejala mereka membaik. Distribusi jawaban dirangkum di bawah ini.³

Kelompok	Perbaikan gejala menurut laporan pasien		
		Ya	Tidak
		Jumlah	
Perlakuan	66	19	85
Kontrol	65	16	81
Jumlah	131	35	166

- Berapa persen pasien dalam kelompok perlakuan yang mengalami perbaikan gejala?
- Berapa persen pasien dalam kelompok kontrol yang mengalami perbaikan gejala?
- Kelompok mana yang memiliki persentase pasien dengan perbaikan gejala lebih tinggi?
- Temuan Anda sejauh ini mungkin menunjukkan adanya perbedaan nyata antara efektivitas antibiotik dan plasebo dalam memperbaiki gejala sinusitis. Namun, ini bukan satu-satunya kesimpulan yang dapat ditarik berdasarkan temuan Anda sejauh ini. Apa satu penjelasan lain yang mungkin atas perbedaan teramati antara persentase pasien dalam kelompok perlakuan antibiotik dan plasebo yang mengalami perbaikan gejala sinusitis?

²G. Allais et al. "Ear acupuncture in the treatment of migraine attacks: a randomized trial on the efficacy of appropriate versus inappropriate acupoints". In: *Neurological Sci.* 32.1 (2011), pp. 173–175.

³J.M. Garbutt et al. "Amoxicillin for Acute Rhinosinusitis: A Randomized Controlled Trial". In: *JAMA: The Journal of the American Medical Association* 307.7 (2012), pp. 685–692.

1.2 Dasar-dasar data

Pengorganisasian dan pendeskripsian data secara efektif merupakan langkah awal dalam sebagian besar analisis. Bagian ini memperkenalkan *matriks data* untuk mengorganisasi data, serta sejumlah istilah bagi berbagai bentuk data yang akan digunakan di sepanjang buku ini.

1.2.1 Observasi, variabel, dan matriks data

Gambar 1.3 menampilkan baris 1, 2, 3, dan 50 dari himpunan data 50 pinjaman yang diambil sebagai sampel acak dari pinjaman yang ditawarkan melalui Lending Club, sebuah perusahaan pinjaman antarpengguna. Observasi-observasi ini selanjutnya disebut sebagai himpunan data `loan50`.

Setiap baris pada tabel mewakili satu pinjaman. Nama formal bagi sebuah baris adalah **kasus** atau **unit observasi**. Kolom-kolomnya mewakili karakteristik setiap pinjaman, yang disebut **variabel**. Sebagai contoh, baris pertama mewakili pinjaman sebesar \$22,000 dengan tingkat bunga 10.90%; peminjamnya berdomisili di New Jersey (NJ) dan berpendapatan \$59,000.

LATIHAN TERBIMBING 1.2



Apa peringkat pinjaman pertama pada Gambar 1.3? Dan bagaimana status kepemilikan rumah peminjam untuk pinjaman pertama tersebut? Untuk pertanyaan Latihan Terbimbing ini, Anda dapat memeriksa jawaban di catatan kaki.⁴

Dalam praktik, mengajukan pertanyaan klarifikasi sangatlah penting untuk memastikan bahwa aspek-aspek penting data telah dipahami. Misalnya, kita harus selalu memastikan bahwa kita mengetahui makna setiap variabel dan satuan pengukurannya. Deskripsi variabel-variabel `loan50` diberikan pada Gambar 1.4.

	<code>loan_amount</code>	<code>interest_rate</code>	<code>term</code>	<code>grade</code>	<code>state</code>	<code>total_income</code>	<code>homeownership</code>
1	22000	10.90	60.00	B	NJ	59000.00	rent
2	6000	9.92	36.00	B	CA	60000.00	rent
3	25000	26.30	36.00	E	SC	75000.00	mortgage
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
50	15000	6.08	36.00	A	TX	77500.00	mortgage

Gambar 1.3: Empat baris dari matriks data `loan50`.

variabel	deskripsi
<code>loan_amount</code>	Jumlah pinjaman yang diterima, dalam dolar AS.
<code>interest_rate</code>	Tingkat bunga pinjaman, dalam persentase tahunan.
<code>term</code>	Jangka waktu pinjaman, yang selalu dinyatakan sebagai bilangan bulat bulan.
<code>grade</code>	Peringkat pinjaman, yang bernilai A hingga G dan mencerminkan kualitas pinjaman serta kemungkinan pelunasannya.
<code>state</code>	Negara bagian AS tempat peminjam berdomisili.
<code>total_income</code>	Jumlah pendapatan peminjam, termasuk pendapatan tambahan apa pun, dalam dolar AS.
<code>homeownership</code>	Menunjukkan apakah orang tersebut memiliki rumah tanpa hipotek, memiliki rumah dengan hipotek, atau menyewa.

Gambar 1.4: Variabel dan deskripsinya dalam himpunan data `loan50`.

Data pada Gambar 1.3 membentuk sebuah **matriks data**, yakni cara yang praktis dan lazim untuk mengorganisasi data, terutama jika data dikumpulkan dalam lembar kerja. Setiap baris

⁴Peringkat pinjaman tersebut adalah B, dan peminjam menyewa tempat tinggalnya.

matriks data bersesuaian dengan satu kasus (unit observasi), dan setiap kolom bersesuaian dengan satu variabel.

Ketika mencatat data, gunakanlah matriks data kecuali terdapat alasan yang sangat kuat untuk memakai struktur lain. Struktur ini memungkinkan kasus baru ditambahkan sebagai baris atau variabel baru sebagai kolom.

LATIHAN TERBIMBING 1.3

G

Nilai tugas, kuis, dan ujian dalam suatu mata kuliah sering dicatat dalam buku nilai yang berbentuk matriks data. Bagaimana Anda dapat mengorganisasi data nilai dengan menggunakan matriks data?⁵

LATIHAN TERBIMBING 1.4

G

Kita meninjau data untuk 3,142 county di Amerika Serikat, yang mencakup nama setiap county, negara bagiannya, populasinya pada 2017, perubahan populasinya dari 2010 hingga 2017, tingkat kemiskinan, dan enam karakteristik tambahan. Bagaimana data ini dapat diorganisasi dalam sebuah matriks data?⁶

Data yang dijelaskan dalam Latihan Terbimbing 1.4 membentuk himpunan data **county**, yang ditampilkan sebagai matriks data pada Gambar 1.5. Variabel-variabelnya dirangkum pada Gambar 1.6.

⁵Ada beberapa strategi yang dapat digunakan. Salah satu strategi yang lazim adalah mewakili setiap mahasiswa dengan satu baris, lalu menambahkan satu kolom untuk setiap tugas, kuis, atau ujian. Dengan susunan ini, satu baris dapat ditinjau dengan mudah untuk memahami riwayat nilai seorang mahasiswa. Perlu pula disediakan kolom-kolom untuk informasi mahasiswa, misalnya satu kolom yang memuat nama mahasiswa.

⁶Setiap county dapat dipandang sebagai satu kasus, dan terdapat sebelas butir informasi yang dicatat untuk setiap kasus. Data ini dapat ditampung dalam tabel dengan 3,142 baris dan 11 kolom; setiap baris mewakili satu county dan setiap kolom mewakili satu butir informasi tertentu.

	name	state	pop	pop_change	poverty	homeownership	multi_unit	unemp_rate	metro	median_edu	median_hh_income
1	Autauga	Alabama	55504	1.48	13.7	77.5	7.2	3.86	yes	some_college	55317
2	Baldwin	Alabama	212628	9.19	11.8	76.7	22.6	3.99	yes	some_college	52562
3	Barbour	Alabama	25270	-6.22	27.2	68.0	11.1	5.90	no	hs_diploma	33368
4	Bibb	Alabama	22668	0.73	15.2	82.9	6.6	4.39	yes	hs_diploma	43404
5	Blount	Alabama	58013	0.68	15.6	82.0	3.7	4.02	yes	hs_diploma	47412
6	Bullock	Alabama	10309	-2.28	28.5	76.9	9.9	4.93	no	hs_diploma	29655
7	Butler	Alabama	19825	-2.69	24.4	69.0	13.7	5.49	no	hs_diploma	36326
8	Calhoun	Alabama	114728	-1.51	18.6	70.7	14.3	4.93	yes	some_college	43686
9	Chambers	Alabama	33713	-1.20	18.8	71.4	8.7	4.08	no	hs_diploma	37342
10	Cherokee	Alabama	25857	-0.60	16.1	77.5	4.3	4.05	no	hs_diploma	40041
:	:	:	:	:	:	:	:	:	:	:	:
3142	Weston	Wyoming	6927	-2.93	14.4	77.9	6.5	3.98	no	some_college	59605

Gambar 1.5: Sebelas baris dari himpunan data county.

variabel	deskripsi
name	Nama county.
state	Negara bagian tempat county berada, atau Distrik Columbia.
pop	Populasi pada 2017.
pop_change	Persentase perubahan populasi dari 2010 hingga 2017. Sebagai contoh, nilai 1.48 pada baris pertama berarti populasi county tersebut meningkat sebesar 1.48% dari 2010 hingga 2017.
poverty	Persentase populasi yang hidup dalam kemiskinan.
homeownership	Persentase populasi yang tinggal di rumah milik sendiri atau tinggal bersama pemiliknya, misalnya anak yang tinggal bersama orang tua pemilik rumah.
multi_unit	Persentase unit tempat tinggal yang berada dalam bangunan multiunit, misalnya apartemen.
unemp_rate	Tingkat pengangguran dalam persen.
metro	Menunjukkan apakah county tersebut mencakup kawasan metropolitan.
median_edu	Tingkat pendidikan median, yang dapat bernilai salah satu dari <code>below_hs</code> , <code>hs_diploma</code> , <code>some_college</code> , dan <code>bachelors</code> .
median_hh_income	Median pendapatan rumah tangga di county tersebut; pendapatan rumah tangga sama dengan jumlah pendapatan para penghuninya yang berusia 15 tahun atau lebih.

Gambar 1.6: Variabel dan deskripsinya dalam himpunan data county.

1.2.2 Jenis variabel


Perhatikan variabel `unemp_rate`, `pop`, `state`, dan `median_edu` dalam himpunan data `county`. Masing-masing variabel ini pada dasarnya berbeda dari ketiga variabel lainnya, tetapi beberapa di antaranya memiliki karakteristik tertentu yang sama.

Pertama, perhatikan `unemp_rate`, yang disebut variabel **numerik** karena dapat mengambil beragam nilai numerik, dan penjumlahan, pengurangan, atau pengambilan rata-rata atas nilai-nilai tersebut masuk akal. Sebaliknya, variabel yang mencatat kode area telepon tidak akan kita klasifikasikan sebagai numerik karena rata-rata, jumlah, dan selisih kode area tidak memiliki makna yang jelas.

Variabel `pop` juga bersifat numerik, meskipun tampak sedikit berbeda dari `unemp_rate`. Variabel jumlah populasi ini hanya dapat mengambil bilangan bulat nonnegatif (0, 1, 2, ...). Karena alasan ini, variabel populasi disebut **diskret** sebab hanya dapat mengambil nilai numerik dengan lompatan tertentu. Sebaliknya, variabel tingkat pengangguran disebut **kontinu**.

Variabel `state` dapat mengambil hingga 51 nilai jika Washington, DC turut dihitung: `AL`, `AK`, ..., dan `WY`. Karena responsnya sendiri berupa kategori, `state` disebut variabel **kategoris**, dan nilai-nilai yang mungkin disebut **level** variabel tersebut.

Terakhir, perhatikan variabel `median_edu`, yang menggambarkan tingkat pendidikan median penduduk county dan mengambil nilai `below_hs`, `hs_diploma`, `some_college`, atau `bachelors` di setiap county. Variabel ini tampak sebagai gabungan: variabel tersebut bersifat kategoris, tetapi level-levelnya memiliki urutan alami. Variabel dengan sifat-sifat ini disebut variabel **ordinal**, sedangkan variabel kategoris biasa tanpa urutan khusus semacam ini disebut variabel **nominal**. Untuk menyederhanakan analisis, setiap variabel ordinal dalam buku ini akan diperlakukan sebagai variabel kategoris nominal (tidak berurutan).



Gambar 1.7: Pengelompokan variabel menurut jenisnya.

CONTOH 1.5

Data dikumpulkan mengenai mahasiswa dalam suatu mata kuliah statistika. Tiga variabel dicatat untuk setiap mahasiswa: jumlah saudara kandung, tinggi badan mahasiswa, dan apakah mahasiswa tersebut pernah mengambil mata kuliah statistika. Klasifikasikan setiap variabel sebagai numerik kontinu, numerik diskret, atau kategoris.

Jumlah saudara kandung dan tinggi badan mahasiswa merupakan variabel numerik. Karena jumlah saudara kandung merupakan hitungan, variabel ini diskret. Tinggi badan bervariasi secara kontinu, sehingga merupakan variabel numerik kontinu. Variabel terakhir mengklasifikasikan mahasiswa ke dalam dua kategori – yang pernah dan yang belum pernah mengambil mata kuliah statistika – sehingga variabel tersebut bersifat kategoris.

LATIHAN TERBIMBING 1.6

Sebuah eksperimen mengevaluasi efektivitas obat baru untuk menangani migrain. Variabel `group` digunakan untuk menunjukkan kelompok eksperimen setiap pasien: perlakuan atau kontrol. Variabel `num_migraines` menyatakan jumlah migrain yang dialami pasien selama periode 3 bulan. Klasifikasikan setiap variabel sebagai numerik atau kategoris.⁷

⁷Variabel `group` hanya dapat mengambil salah satu dari dua nama kelompok, sehingga bersifat kategoris. Variabel `num_migraines` menggambarkan hitungan jumlah migrain, yakni luaran yang dapat dikenai operasi aritmetika dasar


1.2.3 Hubungan antarvariabel

Banyak analisis berawal dari upaya peneliti mencari hubungan antara dua variabel atau lebih. Seorang ilmuwan sosial mungkin ingin menjawab beberapa pertanyaan berikut:

- (1) Jika tingkat kepemilikan rumah di suatu county lebih rendah daripada rata-rata nasional, apakah persentase bangunan multiunit di county tersebut cenderung berada di atas atau di bawah rata-rata nasional?
- (2) Apakah kenaikan populasi county yang melebihi rata-rata cenderung bersesuaian dengan county yang memiliki median pendapatan rumah tangga lebih tinggi atau lebih rendah?
- (3) Seberapa bergunakah tingkat pendidikan median sebagai prediktor median pendapatan rumah tangga county di AS?

Untuk menjawab pertanyaan-pertanyaan ini, data harus dikumpulkan, misalnya himpunan data **county** yang ditampilkan pada Gambar 1.5. Pemeriksaan statistik ringkasan dapat memberikan wawasan bagi ketiga pertanyaan tentang county tersebut. Selain itu, grafik dapat digunakan untuk menjelajahi data secara visual.


Diagram pencar merupakan salah satu jenis grafik yang digunakan untuk mempelajari hubungan antara dua variabel numerik. Gambar 1.8 membandingkan variabel **homeownership** dan **multiunit**, yang merupakan persentase unit dalam bangunan multiunit (misalnya apartemen dan kondominium). Setiap titik pada diagram mewakili satu county. Sebagai contoh, titik yang disorot bersesuaian dengan County 413 dalam himpunan data **county**: Chattahoochee County, Georgia, dengan 39.4% unit berada dalam bangunan multiunit dan tingkat kepemilikan rumah sebesar 31.3%. Diagram pencar tersebut menunjukkan hubungan antara kedua variabel: county dengan tingkat bangunan multiunit yang lebih tinggi cenderung memiliki tingkat kepemilikan rumah yang lebih rendah. Kita dapat memikirkan berbagai kemungkinan penyebab hubungan ini, lalu menyelidiki setiap gagasan untuk menentukan penjelasan yang paling masuk akal.



Gambar 1.8: Diagram pencar tingkat kepemilikan rumah terhadap persentase unit dalam bangunan multiunit untuk county di AS. Titik yang disorot mewakili Chattahoochee County, Georgia, yang memiliki tingkat bangunan multiunit 39.4% dan tingkat kepemilikan rumah 31.3%.

Tingkat bangunan multiunit dan kepemilikan rumah dikatakan berasosiasi karena diagram menunjukkan pola yang dapat dikenali. Jika dua variabel menunjukkan suatu keterkaitan satu sama lain, keduanya disebut variabel yang **berasosiasi**. Variabel yang berasosiasi juga dapat disebut variabel **terikat**, dan sebaliknya.

secara bermakna; karena itu, luaran ini bersifat numerik. Lebih khusus lagi, karena menyatakan hitungan, **num_migraines** merupakan variabel numerik diskret.



Gambar 1.9: Diagram pencar yang menampilkan `pop_change` terhadap `median_hh_income`. Owsley County di Kentucky disorot; county tersebut kehilangan 3.63% populasinya dari 2010 hingga 2017 dan memiliki median pendapatan rumah tangga sebesar \$22,736.

LATIHAN TERBIMBING 1.7

G

Perhatikan variabel-variabel dalam himpunan data `loan50`, yang dijelaskan pada Gambar 1.4 di halaman 12. Buatlah dua pertanyaan yang menarik bagi Anda tentang kemungkinan hubungan antarvariabel dalam `loan50`.⁸

CONTOH 1.8

E

Contoh ini menelaah hubungan antara perubahan populasi suatu county dari 2010 hingga 2017 dan median pendapatan rumah tangga, yang divisualisasikan sebagai diagram pencar pada Gambar 1.9. Apakah kedua variabel ini berasosiasi?

Semakin besar median pendapatan rumah tangga suatu county, semakin tinggi pertumbuhan populasi yang diamati di county tersebut. Meskipun tren ini tidak berlaku bagi setiap county, tren pada diagram tampak jelas. Karena terdapat suatu hubungan antara kedua variabel, keduanya berasosiasi.

Karena terdapat tren menurun pada Gambar 1.8 – county dengan lebih banyak unit dalam bangunan multiunit berasosiasi dengan kepemilikan rumah yang lebih rendah – kedua variabel ini dikatakan memiliki **asosiasi negatif**. Sebuah **asosiasi positif** tampak dalam hubungan antara `median_hh_income` dan `pop_change` pada Gambar 1.9, di mana county dengan median pendapatan rumah tangga yang lebih tinggi cenderung memiliki tingkat pertumbuhan populasi yang lebih tinggi.

Jika dua variabel tidak berasosiasi, keduanya dikatakan **bebas** satu sama lain. Dengan kata lain, dua variabel saling bebas jika tidak terdapat hubungan yang jelas di antara keduanya.

BERASOSIASI ATAU BEBAS, BUKAN KEDUANYA

Sepasang variabel memiliki suatu keterkaitan (berasosiasi) atau tidak memiliki keterkaitan (saling bebas). Tidak ada pasangan variabel yang sekaligus berasosiasi dan saling bebas.

⁸Dua contoh pertanyaan: (1) Bagaimana hubungan antara jumlah pinjaman dan pendapatan total? (2) Jika pendapatan seseorang berada di atas rata-rata, apakah tingkat bunganya cenderung berada di atas atau di bawah rata-rata?

1.2.4 Variabel penjelas dan variabel respons

Ketika mengajukan pertanyaan tentang hubungan antara dua variabel, kadang-kadang kita juga ingin menentukan apakah perubahan pada satu variabel menyebabkan perubahan pada variabel lainnya. Perhatikan perumusan ulang berikut dari pertanyaan sebelumnya tentang himpunan data *county*:

Jika median pendapatan rumah tangga di suatu county meningkat, apakah hal ini mendorong peningkatan populasinya?

Dalam pertanyaan ini, kita menanyakan apakah satu variabel memengaruhi variabel lainnya. Jika itulah dugaan yang mendasari pertanyaan kita, maka *median pendapatan rumah tangga* merupakan **variabel penjelas**, sedangkan *perubahan populasi* merupakan **variabel respons** dalam hubungan yang dihipotesiskan.⁹

VARIABEL PENJELAS DAN VARIABEL RESPONS

Ketika kita menduga bahwa satu variabel mungkin memengaruhi variabel lain secara kausal, variabel pertama disebut variabel penjelas dan variabel kedua disebut variabel respons.

variabel penjelas $\xrightarrow{\text{mungkin memengaruhi}}$ variabel respons

Bagi banyak pasangan variabel, tidak ada hubungan yang dihipotesiskan; dalam keadaan seperti itu, kedua label ini tidak diterapkan pada variabel mana pun.

Pemberian label ini tidak menjamin adanya hubungan kausal. Dalam pengantar ini, eksperimen merupakan cara paling langsung untuk memeriksa efek kausal. Studi nonacak juga dapat mendukung inferensi kausal, tetapi hanya dengan asumsi dan metode tambahan.

1.2.5 Pengantar studi observasional dan eksperimen

Terdapat dua jenis utama pengumpulan data: studi observasional dan eksperimen.

Dalam **studi observasional**, peneliti mengumpulkan data tanpa campur tangan langsung dalam proses pembentukannya—misalnya melalui survei, rekam medis atau catatan perusahaan, atau dengan mengikuti sebuah **kohort** individu serupa untuk menyusun hipotesis tentang penyebab penyakit. Peneliti hanya mengamati data yang timbul. Studi seperti ini dapat menunjukkan asosiasi alami antarvariabel, tetapi tidak dengan sendirinya membuktikan hubungan kausal.

Untuk menyelidiki kemungkinan hubungan kausal, peneliti dapat melakukan **eksperimen**: sebuah sampel dibagi ke dalam kelompok-kelompok yang masing-masing *diberi* perlakuan. Biasanya terdapat variabel penjelas dan variabel respons. Misalnya, kita dapat menguji dugaan bahwa obat menurunkan angka kematian pasien serangan jantung selama setahun. Jika individu dialokasikan secara acak ke dalam kelompok, desain tersebut disebut **eksperimen acak**. Dalam uji obat tadi, pelemparan koin dapat menentukan apakah pasien menerima **plasebo** (perlakuan semu) atau obat. Lihat studi kasus pada Bagian 1.1 untuk contoh eksperimen lain, meskipun penelitian tersebut tidak menggunakan plasebo.

ASOSIASI $\neq$ KAUSALITAS

Secara umum, asosiasi tidak dengan sendirinya menyiratkan kausalitas. Eksperimen acak memberikan dasar paling langsung untuk inferensi kausal dalam pembahasan ini; desain lain memerlukan asumsi tambahan yang eksplisit.

⁹Variabel penjelas dan respons kadang disebut variabel **bebas** dan **terikat**. Karena istilah bebas/terikat juga dapat menyatakan hubungan dalam suatu *pasangan* variabel, buku ini menghindari sebutan tersebut.

Latihan

1.3 Polusi udara dan luaran kelahiran, komponen penelitian. Para peneliti mengumpulkan data untuk mengkaji hubungan antara polutan udara dan kelahiran prematur di California Selatan. Selama penelitian, tingkat polusi udara diukur oleh stasiun pemantau kualitas udara. Secara khusus, kadar karbon monoksida dicatat dalam bagian per juta, nitrogen dioksida dan ozon dalam bagian per seratus juta, dan partikulat kasar (PM₁₀) dalam $\mu\text{g}/\text{m}^3$. Data lama kehamilan dikumpulkan untuk 143,196 kelahiran antara tahun 1989 dan 1993, lalu paparan polusi udara selama kehamilan dihitung untuk setiap kelahiran. Analisis menunjukkan bahwa peningkatan PM₁₀ di udara sekitar dan, pada tingkat yang lebih rendah, konsentrasi CO mungkin berkaitan dengan kejadian kelahiran prematur.¹⁰

- Tentukan pertanyaan penelitian utama dalam penelitian ini.
- Siapa subjek dalam penelitian ini, dan berapa banyak yang disertakan?
- Apa saja variabel dalam penelitian ini? Tentukan apakah setiap variabel bersifat numerik atau kategoris. Jika numerik, nyatakan apakah variabel tersebut diskret atau kontinu. Jika kategoris, nyatakan apakah variabel tersebut ordinal.

1.4 Metode Buteyko, komponen penelitian. Metode Buteyko adalah teknik pernapasan dangkal yang dikembangkan oleh Konstantin Buteyko, seorang dokter Rusia, pada tahun 1952. Bukti anekdotal menunjukkan bahwa metode Buteyko dapat mengurangi gejala asma dan meningkatkan kualitas hidup. Dalam sebuah penelitian ilmiah untuk menentukan keefektifan metode ini, para peneliti merekrut 600 pasien asma berusia 18-69 tahun yang bergantung pada obat untuk penanganan asma. Pasien-pasien ini secara acak dibagi menjadi dua kelompok penelitian: satu kelompok mempraktikkan metode Buteyko dan kelompok lainnya tidak. Pasien diberi skor dari 0 hingga 10 untuk kualitas hidup, aktivitas, gejala asma, dan penggunaan penggunaan obat. Rata-rata, peserta dalam kelompok Buteyko mengalami penurunan gejala asma yang signifikan dan peningkatan kualitas hidup.¹¹

- Tentukan pertanyaan penelitian utama dalam penelitian ini.
- Siapa subjek dalam penelitian ini, dan berapa banyak yang disertakan?
- Apa saja variabel dalam penelitian ini? Tentukan apakah setiap variabel bersifat numerik atau kategoris. Jika numerik, nyatakan apakah variabel tersebut diskret atau kontinu. Jika kategoris, nyatakan apakah variabel tersebut ordinal.

1.5 Kecurangan, komponen penelitian. Para peneliti yang mengkaji hubungan antara kejujuran, usia, dan pengendalian diri melakukan eksperimen terhadap 160 anak berusia antara 5 dan 15 tahun. Peserta melaporkan usia, jenis kelamin, dan apakah mereka anak tunggal. Para peneliti meminta setiap anak untuk melempar koin seimbang secara pribadi, mencatat hasilnya (putih atau hitam) pada selembar kertas, dan memberi tahu bahwa hanya anak yang melaporkan putih yang akan mendapat hadiah. Temuan penelitian dapat dirangkum sebagai berikut: “Separuh anak secara tegas diberi tahu agar tidak berbuat curang, sedangkan yang lain tidak diberi petunjuk tegas apa pun. Dalam kelompok tanpa petunjuk, probabilitas berbuat curang ditemukan seragam di antara kelompok yang dibentuk berdasarkan karakteristik anak. Dalam kelompok yang secara tegas diberi tahu agar tidak berbuat curang, anak perempuan lebih kecil kemungkinannya berbuat curang; sementara tingkat kecurangan tidak bervariasi menurut usia pada anak laki-laki, tingkat tersebut menurun seiring bertambahnya usia pada anak perempuan.”¹²

- Tentukan pertanyaan penelitian utama dalam penelitian ini.
- Siapa subjek dalam penelitian ini, dan berapa banyak yang disertakan?
- Berapa banyak variabel yang dicatat untuk setiap subjek dalam penelitian ini agar temuan tersebut dapat disimpulkan? Nyatakan variabel-variabel itu beserta jenisnya.

¹⁰B. Ritz et al. “Effect of air pollution on preterm birth among children born in Southern California between 1989 and 1993”. In: *Epidemiology* 11.5 (2000), pp. 502–511.

¹¹J. McGowan. “Health Education: Does the Buteyko Institute Method make a difference?” In: *Thorax* 58 (2003).

¹²Alessandro Bucciol and Marco Piovesan. “Luck or cheating? A field experiment on honesty with children”. In: *Journal of Economic Psychology* 32.1 (2011), pp. 73–78.

1.6 Perilaku mengambil permen, komponen penelitian. Dalam sebuah penelitian tentang hubungan antara kelas sosioekonomi dan perilaku tidak etis, 129 mahasiswa sarjana University of California, Berkeley diminta mengidentifikasi diri sebagai anggota kelas sosial bawah atau atas dengan membandingkan diri mereka dengan orang lain yang memiliki uang paling banyak (paling sedikit), pendidikan paling tinggi (paling rendah), dan pekerjaan paling dihormati (paling tidak dihormati). Mereka juga diberi sebuah stoples berisi permen yang dibungkus satu per satu dan diberi tahu bahwa permen tersebut diperuntukkan bagi anak-anak di laboratorium terdekat, tetapi mereka boleh mengambil beberapa jika mau. Setelah menyelesaikan beberapa tugas yang tidak berkaitan, peserta melaporkan jumlah permen yang mereka ambil.¹³

- Tentukan pertanyaan penelitian utama dalam penelitian ini.
- Siapa subjek dalam penelitian ini, dan berapa banyak yang disertakan?
- Penelitian menemukan bahwa mahasiswa yang diidentifikasi sebagai kelas atas mengambil lebih banyak permen daripada mahasiswa lainnya. Berapa banyak variabel yang dicatat untuk setiap subjek dalam penelitian ini agar temuan tersebut dapat disimpulkan? Nyatakan variabel-variabel itu beserta jenisnya.

1.7 Migrain dan akupunktur, Bagian II. Latihan 1.1 memperkenalkan sebuah penelitian yang mengkaji apakah akupunktur memiliki pengaruh terhadap migrain. Para peneliti melakukan penelitian terkontrol acak dengan menempatkan pasien secara acak ke salah satu dari dua kelompok: perlakuan atau kontrol. Pasien dalam kelompok perlakuan menerima akupunktur yang dirancang secara khusus untuk menangani migrain. Pasien dalam kelompok kontrol menerima akupunktur plasebo (jarum ditusukkan pada lokasi yang bukan titik akupunktur). Pasien ditanya 24 jam setelah menerima akupunktur apakah mereka sudah bebas nyeri. Apa variabel penjelas dan variabel respons dalam penelitian ini?

1.8 Sinusitis dan antibiotik, Bagian II. Latihan 1.2 memperkenalkan sebuah penelitian yang mengkaji pengaruh pengobatan antibiotik terhadap sinusitis akut. Peserta penelitian menerima rangkaian pengobatan antibiotik selama 10 hari (perlakuan) atau plasebo yang tampak dan terasa serupa (kontrol). Pada akhir periode 10 hari, pasien ditanya apakah gejala mereka membaik. Apa variabel penjelas dan variabel respons dalam penelitian ini?

1.9 Bunga iris Fisher. Sir Ronald Aylmer Fisher adalah seorang ahli statistika, biologi evolusi, dan genetika asal Inggris yang bekerja dengan sebuah himpunan data berisi panjang dan lebar sepal serta panjang dan lebar petal dari tiga spesies bunga iris (*setosa*, *versicolor*, dan *virginica*). Himpunan data tersebut memuat 50 bunga dari setiap spesies.¹⁴

- Berapa banyak kasus yang disertakan dalam data?
- Berapa banyak variabel numerik yang disertakan dalam data? Sebutkan variabel-variabel tersebut dan tentukan apakah masing-masing kontinu atau diskret.
- Berapa banyak variabel kategoris yang disertakan dalam data, dan apa saja variabel tersebut? Daftarkan level (kategori) yang bersesuaian.



Foto oleh Ryan Claussen
(<http://flic.kr/p/6QTcuX>)
lisensi CC BY-SA 2.0

1.10 Kebiasaan merokok penduduk Britania Raya. Sebuah survei dilakukan untuk mempelajari kebiasaan merokok penduduk Britania Raya. Matriks data di bawah menampilkan sebagian data yang dikumpulkan dalam survei ini. Perhatikan bahwa “£” berarti pound sterling Britania, “cig” berarti rokok, dan “N/A” menunjukkan komponen data yang hilang.¹⁵

	kelamin	usia	status	pendapatan	merokok	akhirPekan	hariKerja
1	Female	42	Single	Under £2,600	Yes	12 cig/day	12 cig/day
2	Male	44	Single	£10,400 to £15,600	No	N/A	N/A
3	Male	53	Married	Above £36,400	Yes	6 cig/day	6 cig/day
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
1691	Male	40	Single	£2,600 to £5,200	Yes	8 cig/day	8 cig/day

- Apa yang diwakili oleh setiap baris matriks data?
- Berapa banyak peserta yang disertakan dalam survei?


¹³P.K. Piff et al. “Higher social class predicts increased unethical behavior”. In: *Proceedings of the National Academy of Sciences* (2012).

¹⁴R.A. Fisher. “The Use of Multiple Measurements in Taxonomic Problems”. In: *Annals of Eugenics* 7 (1936), pp. 179–188.

¹⁵National STEM Centre, Large Datasets from stats4schools.


- (c) Tentukan apakah setiap variabel dalam penelitian bersifat numerik atau kategoris. Jika numerik, tentukan apakah variabel itu kontinu atau diskret. Jika kategoris, nyatakan apakah variabel tersebut ordinal.

1.11 Bandara di AS. Visualisasi di bawah menunjukkan sebaran geografis bandara di Amerika Serikat daratan utama dan Washington, DC. Visualisasi ini dibuat berdasarkan sebuah himpunan data dengan setiap amatan berupa satu bandara.¹⁶ Batas kartografis pada peta bersumber dari U.S. Census Bureau.



- (a) Daftarkan variabel yang digunakan untuk membuat visualisasi ini.
- (b) Tentukan apakah setiap variabel dalam penelitian bersifat numerik atau kategoris. Jika numerik, tentukan apakah variabel itu kontinu atau diskret. Jika kategoris, nyatakan apakah variabel tersebut ordinal.

1.12 Pemungutan suara PBB. Visualisasi berikut menunjukkan pola suara Amerika Serikat, Kanada, dan Meksiko mengenai beragam isu di Majelis Umum Perserikatan Bangsa-Bangsa. Untuk setiap tahun 1946–2015, visualisasi ini menampilkan persentase pemungutan suara tercatat ketika setiap negara memilih ya pada setiap isu. Data terdiri atas amatan pasangan negara–tahun.¹⁷



- (a) Daftarkan variabel yang digunakan untuk membuat visualisasi ini.
- (b) Tentukan apakah setiap variabel dalam penelitian bersifat numerik atau kategoris. Jika numerik, tentukan apakah variabel itu kontinu atau diskret. Jika kategoris, nyatakan apakah variabel tersebut ordinal.

¹⁶Federal Aviation Administration, www.faa.gov/airports/airport_safety/airportdata_5010.

¹⁷David Robinson. *unvotes: United Nations General Assembly Voting Data*. R package version 0.2.0. 2017. URL: <https://CRAN.R-project.org/package=unvotes>.

1.3 Prinsip dan strategi pengambilan sampel

Langkah pertama dalam melakukan penelitian adalah menentukan topik atau pertanyaan yang hendak diteliti. Pertanyaan penelitian yang dirumuskan dengan jelas membantu menentukan subjek atau kasus yang perlu dipelajari serta variabel yang penting. Kita juga perlu mempertimbangkan *bagaimana* data dikumpulkan agar data tersebut andal dan membantu mencapai tujuan penelitian.

1.3.1 Populasi dan sampel

Perhatikan tiga pertanyaan penelitian berikut:

1. Berapakah rata-rata kadar merkuri pada ikan todak di Samudra Atlantik?
2. Selama 5 tahun terakhir, berapa rata-rata waktu yang dibutuhkan mahasiswa program sarjana Duke untuk menyelesaikan gelarnya?
3. Apakah obat baru mengurangi jumlah kematian pada pasien dengan penyakit jantung berat?

Setiap pertanyaan penelitian mengacu pada **populasi** sasaran. Pada pertanyaan pertama, populasi sasarnya adalah seluruh ikan todak di Samudra Atlantik, dan setiap ikan merupakan satu kasus. Mengumpulkan data untuk setiap kasus dalam suatu populasi sering kali terlalu mahal. Sebagai gantinya, kita mengambil sampel. Sebuah **sampel** merupakan sebagian dari kasus-kasus tersebut dan biasanya hanya mencakup sebagian kecil populasi. Sebagai contoh, 60 ikan todak (atau jumlah lain) dapat dipilih dari populasi. Data sampel ini kemudian dapat digunakan untuk memperkirakan rata-rata populasi dan menjawab pertanyaan penelitian.

LATIHAN TERBIMBING 1.9



Untuk pertanyaan kedua dan ketiga di atas, tentukan populasi sasaran dan apa yang merupakan satu kasus individual.¹⁸

1.3.2 Bukti anekdotal

Perhatikan beberapa kemungkinan jawaban berikut untuk ketiga pertanyaan penelitian tadi:

1. Seorang pria dalam berita mengalami keracunan merkuri setelah memakan ikan todak, sehingga rata-rata konsentrasi merkuri pada ikan todak pasti sangat tinggi dan berbahaya.
2. Saya bertemu dua mahasiswa yang membutuhkan lebih dari 7 tahun untuk lulus dari Duke, sehingga menyelesaikan studi di Duke pasti memerlukan waktu lebih lama daripada di banyak perguruan tinggi lain.
3. Ayah teman saya mengalami serangan jantung dan meninggal setelah diberi obat baru untuk penyakit jantung, sehingga obat itu pasti tidak bekerja.

Setiap kesimpulan tersebut didasarkan pada data. Namun, terdapat dua masalah. Pertama, data itu hanya mewakili satu atau dua kasus. Kedua, dan yang lebih penting, belum jelas apakah kasus-kasus tersebut benar-benar mewakili populasi. Data yang dikumpulkan secara serampangan seperti ini disebut **bukti anekdotal**.

BUKTI ANEKDOTAL

Waspada data yang dikumpulkan secara serampangan. Bukti semacam itu mungkin benar dan dapat diverifikasi, tetapi mungkin hanya mewakili kasus-kasus luar biasa.

¹⁸(2) Pertanyaan tentang waktu kelulusan hanya relevan bagi mahasiswa yang menyelesaikan gelarnya; rata-rata tersebut tidak dapat dihitung dengan memasukkan mahasiswa yang tidak pernah lulus. Karena itu, hanya mahasiswa program sarjana Duke yang lulus dalam lima tahun terakhir yang menjadi kasus dalam populasi yang sedang ditinjau. Setiap mahasiswa tersebut merupakan satu kasus individual. (3) Seseorang dengan penyakit jantung berat merupakan satu kasus. Populasinya mencakup semua orang dengan penyakit jantung berat.




Gambar 1.10: Pada Februari 2010, sejumlah komentator media menggunakan badai salju besar di Amerika Serikat bagian timur laut untuk menentang pemanasan global. Jon Stewart menyindir penalaran tersebut: satu kejadian cuaca setempat tidak dapat mewakili pola iklim global jangka panjang. Foto: David M. Diez, CC BY-SA 3.0.


Bukti anekdotal biasanya terdiri atas kasus-kasus tidak lazim yang kita ingat karena cirinya menonjol. Sebagai contoh, kita lebih mungkin mengingat dua orang yang kita temui dan membuktikan 7 tahun untuk lulus daripada enam orang lain yang lulus dalam empat tahun. Alih-alih hanya melihat kasus yang paling tidak lazim, kita sebaiknya memeriksa sampel yang terdiri atas banyak kasus dan mewakili populasi.

1.3.3 Mengambil sampel dari populasi

Kita dapat mencoba memperkirakan waktu kelulusan mahasiswa program sarjana Duke selama 5 tahun terakhir dengan mengumpulkan sampel mahasiswa. Semua lulusan dalam 5 tahun terakhir merupakan *populasi*, sedangkan lulusan yang dipilih untuk ditinjau secara bersama-sama disebut *sampel*. Secara umum, kita selalu berupaya memilih sampel dari suatu populasi *secara acak*. Bentuk pemilihan acak yang paling dasar setara dengan cara melakukan undian. Sebagai contoh, untuk memilih lulusan, kita dapat menuliskan nama setiap lulusan pada kupon undian lalu mengambil 100 kupon. Nama-nama yang terambil akan membentuk sampel acak berisi 100 lulusan. Kita memilih sampel secara acak untuk mengurangi kemungkinan timbulnya bias.



Gambar 1.11: Pada diagram ini, lima lulusan dipilih secara acak dari populasi untuk dimasukkan ke dalam sampel.



Gambar 1.12: Ketika diminta memilih sampel lulusan, seorang mahasiswa jurusan gizi tanpa sengaja mungkin memilih lulusan dari bidang kesehatan dalam proporsi yang terlalu besar.

CONTOH 1.10


Misalkan kita meminta seorang mahasiswa jurusan gizi memilih beberapa lulusan untuk penelitian ini. Menurut Anda, mahasiswa seperti apa yang mungkin dipilihnya? Apakah sampelnya akan mewakili semua lulusan?

E

Ia mungkin memilih lulusan dari bidang kesehatan dalam proporsi yang terlalu besar. Atau, pilihannya mungkin saja mewakili populasi dengan baik. Ketika memilih sampel secara manual, kita berisiko memperoleh sampel yang **bias**, sekalipun bias itu tidak disengaja.

Jika seseorang bebas menentukan sendiri lulusan mana yang masuk ke dalam sampel, sampel itu sangat mungkin condong ke minat orang tersebut, meskipun hal itu sama sekali tidak disengaja. Keadaan ini memasukkan **bias** ke dalam sampel. Pengambilan sampel secara acak membantu mengatasi masalah ini. Sampel acak yang paling dasar disebut **sampel acak sederhana**; prosedurnya setara dengan menggunakan undian untuk memilih kasus. Untuk ukuran sampel yang telah ditetapkan, setiap himpunan kasus yang mungkin dengan ukuran tersebut memiliki peluang yang sama untuk terpilih.

Mengambil sampel acak sederhana membantu meminimalkan bias. Namun, bias dapat muncul melalui cara lain. Bahkan ketika orang dipilih secara acak, misalnya untuk suatu survei, kita perlu berhati-hati jika **tingkat nonrespons** tinggi. Sebagai contoh, jika hanya 30% orang yang dipilih secara acak untuk suatu survei benar-benar merespons, belum jelas apakah hasilnya **representatif** bagi seluruh populasi. **Bias nonrespons** ini dapat menyimpangkan hasil.



Gambar 1.13: Karena sebagian orang mungkin tidak merespons, suatu survei mungkin hanya menjangkau kelompok tertentu dalam populasi. Masalah ini sulit, dan sering kali mustahil, diperbaiki sepenuhnya.

Kelemahan umum lainnya adalah **sampel kemudahan**, yakni individu yang mudah dijangkau lebih mungkin dimasukkan ke dalam sampel. Sebagai contoh, jika survei politik dilakukan dengan menghentikan pejalan kaki di Bronx, sampelnya tidak akan mewakili seluruh Kota New York. Sering kali sulit menentukan subpopulasi mana yang sebenarnya diwakili oleh sampel kemudahan.

LATIHAN TERBIMBING 1.11

G

Kita dapat dengan mudah mengakses penilaian terhadap produk, penjual, dan perusahaan melalui situs web. Penilaian ini hanya berasal dari orang-orang yang secara khusus meluangkan waktu untuk memberikannya. Jika 50% ulasan daring terhadap suatu produk bersifat negatif, apakah menurut Anda itu berarti 50% pembeli tidak puas dengan produk tersebut?¹⁹

1.3.4 Studi observasional


Data yang dikumpulkan tanpa secara eksplisit memberikan (atau menahan) perlakuan disebut **data observasional**. Sebagai contoh, data pinjaman dan data county yang dijelaskan pada Bagian 1.2 keduanya merupakan contoh data observasional. Menarik kesimpulan kausal dari eksperimen yang dirancang dengan baik sering kali masuk akal. Namun, menarik kesimpulan kausal yang sama dari data observasional dapat menyesatkan dan tidak dianjurkan. Karena itu, studi observasional umumnya hanya memadai untuk menunjukkan asosiasi atau membentuk hipotesis yang kemudian kita periksa melalui eksperimen.

LATIHAN TERBIMBING 1.12

G

Misalkan sebuah studi observasional mengikuti penggunaan tabir surya dan kanker kulit, lalu menemukan bahwa makin banyak tabir surya yang digunakan seseorang, makin besar kemungkinan orang tersebut menderita kanker kulit. Apakah ini berarti tabir surya *menyebabkan* kanker kulit?²⁰

Sejumlah penelitian terdahulu menunjukkan bahwa penggunaan tabir surya justru menurunkan risiko kanker kulit. Karena itu, mungkin terdapat variabel lain yang dapat menjelaskan asosiasi hipotetis antara penggunaan tabir surya dan kanker kulit ini. Salah satu informasi penting yang tidak disertakan adalah paparan sinar matahari. Seseorang yang berada di bawah sinar matahari sepanjang hari lebih mungkin menggunakan tabir surya *dan* lebih mungkin terkena kanker kulit. Penyelidikan sederhana tadi tidak memperhitungkan paparan sinar matahari.



Paparan sinar matahari disebut **variabel perancu**,²¹ yaitu variabel yang berkorelasi dengan variabel penjelas sekaligus variabel respons. Salah satu cara untuk mencoba membenarkan kesimpulan kausal dari studi observasional adalah mencari variabel perancu selengkap mungkin. Namun, tidak ada jaminan bahwa semua variabel perancu dapat diperiksa atau diukur.

LATIHAN TERBIMBING 1.13

G

Gambar 1.8 menunjukkan asosiasi negatif antara tingkat kepemilikan rumah dan persentase bangunan multiunit di suatu county. Namun, menyimpulkan bahwa kedua variabel tersebut memiliki hubungan kausal tidaklah beralasan. Usulkan sebuah variabel yang mungkin menjelaskan hubungan negatif tersebut.²²

Dua bentuk studi observasional yang umum dan dibahas di sini adalah studi prospektif dan studi retrospektif. Sebuah **studi prospektif** mengidentifikasi individu dan mengumpulkan infor-

¹⁹Jawaban dapat beragam. Berdasarkan pengalaman anekdotal kami sendiri, orang tampaknya lebih cenderung mengeluhkan produk yang tidak memenuhi harapan daripada memuji produk yang bekerja sesuai harapan. Karena itu, kami menduga terdapat bias negatif dalam penilaian produk di situs seperti Amazon. Namun, karena pengalaman kami mungkin tidak representatif, kami tetap terbuka terhadap kemungkinan lain.

²⁰Tidak. Lihat paragraf setelah latihan untuk penjelasannya.

²¹Disebut juga **variabel tersembunyi**, **faktor perancu**, atau **perancu**.

²²Jawaban dapat beragam. Kepadatan penduduk mungkin berperan penting. Jika suatu county sangat padat, sebagian lebih besar penduduknya mungkin perlu tinggal di bangunan multiunit. Selain itu, kepadatan tinggi dapat turut menaikkan nilai properti, sehingga kepemilikan rumah tidak terjangkau bagi banyak penduduk.

masi seiring berlangsungnya peristiwa. Sebagai contoh, peneliti medis dapat mengidentifikasi dan mengikuti sekelompok pasien selama bertahun-tahun untuk menilai kemungkinan pengaruh perilaku terhadap risiko kanker. Salah satu contohnya adalah *The Nurses' Health Study*, yang dimulai pada 1976 dan diperluas pada 1989. Studi prospektif ini merekrut perawat terdaftar, kemudian mengumpulkan data dari mereka melalui kuesioner. **Studi retrospektif** mengumpulkan data setelah peristiwa terjadi; misalnya, peneliti dapat menelaah peristiwa masa lalu dalam rekam medis. Sejumlah himpunan data dapat memuat variabel yang dikumpulkan secara prospektif maupun retrospektif.

1.3.5 Empat metode pengambilan sampel

Hampir semua metode statistik didasarkan pada gagasan bahwa terdapat keacakan yang mendasari data. Jika data observasional dari suatu populasi tidak dikumpulkan dalam kerangka acak, metode-metode statistik tersebut—baik estimasi maupun galat yang menyertai estimasi—tidak dapat diandalkan. Di sini kita membahas empat teknik pengambilan sampel acak: pengambilan sampel acak sederhana, berstrata, klaster, dan multistage. Gambar 1.14 dan 1.15 menyajikan gambaran grafis teknik-teknik tersebut.

Pengambilan sampel acak sederhana mungkin merupakan bentuk pengambilan sampel acak yang paling intuitif. Perhatikan gaji pemain Major League Baseball (MLB), dengan setiap pemain tergabung dalam salah satu dari 30 tim liga. Untuk mengambil sampel acak sederhana yang terdiri atas 120 pemain beserta gajinya, kita dapat menuliskan nama ratusan pemain pada musim tersebut di secarik kertas, memasukkan semua kertas ke dalam wadah, mengocoknya hingga seluruh nama tercampur, lalu mengambil kertas sampai terkumpul sampel 120 pemain. Secara umum, sebuah sampel disebut “acak sederhana” jika setiap kasus dalam populasi memiliki peluang yang sama untuk masuk ke dalam sampel akhir *dan* informasi bahwa satu kasus masuk ke dalam sampel tidak memberikan informasi berguna mengenai kasus lain mana yang turut masuk.

Pengambilan sampel berstrata merupakan strategi pengambilan sampel yang membagi masalah menjadi bagian-bagian. Populasi dibagi ke dalam kelompok yang disebut **strata**. Strata dipilih agar kasus-kasus yang serupa dikelompokkan bersama, lalu metode pengambilan sampel kedua—biasanya pengambilan sampel acak sederhana—diterapkan dalam setiap strata. Pada contoh gaji pemain bisbol, tim dapat menjadi strata karena sebagian tim memiliki dana jauh lebih besar (hingga 4 kali lipat!). Kita kemudian dapat memilih 4 pemain secara acak dari setiap tim sehingga jumlah keseluruhannya 120 pemain.

Pengambilan sampel berstrata sangat berguna ketika kasus-kasus dalam setiap strata sangat serupa dalam hal luaran yang menjadi perhatian. Kekurangannya, menganalisis data dari sampel berstrata lebih rumit daripada menganalisis data dari sampel acak sederhana. Metode analisis yang diperkenalkan dalam buku ini perlu diperluas untuk menganalisis data yang dikumpulkan melalui pengambilan sampel berstrata.

CONTOH 1.14


Mengapa keserupaan yang tinggi antarkasus dalam setiap strata menguntungkan?

E


Jika kasus-kasus sangat serupa, kita dapat memperoleh estimasi yang lebih stabil untuk subpopulasi dalam suatu strata, sehingga estimasi pada setiap kelompok menjadi lebih presisi. Ketika estimasi-estimasi ini digabungkan menjadi satu estimasi bagi seluruh populasi, estimasi populasi tersebut cenderung lebih presisi karena setiap estimasi kelompok juga lebih presisi.

Dalam **sampel klaster**, populasi dibagi menjadi banyak kelompok yang disebut **klaster**. Sejumlah klaster yang telah ditetapkan kemudian dipilih, dan semua observasi dalam setiap klaster terpilih dimasukkan ke dalam sampel. Sebuah **sampel multistage** menyerupai sampel klaster, tetapi alih-alih menyertakan semua observasi dalam setiap klaster, kita mengambil sampel acak di dalam setiap klaster terpilih.

Pengambilan sampel klaster atau multistage kadang-kadang lebih ekonomis daripada teknik pengambilan sampel lainnya. Selain itu, tidak seperti pengambilan sampel berstrata, kedua pendekatan ini paling berguna ketika terdapat banyak keragaman antarkasus di dalam setiap klaster, sedangkan klaster-klaster itu sendiri tidak terlalu berbeda satu sama lain. Sebagai contoh, jika



Gambar 1.14: Contoh pengambilan sampel acak sederhana dan pengambilan sampel berstrata. Pada panel atas, pengambilan sampel acak sederhana digunakan untuk memilih 18 kasus secara acak. Pada panel bawah, digunakan pengambilan sampel berstrata: kasus dikelompokkan ke dalam strata, lalu pengambilan sampel acak sederhana diterapkan di setiap strata.



Gambar 1.15: Contoh pengambilan sampel klaster dan multistahap. Pada panel atas, digunakan pengambilan sampel klaster: data dibagi ke dalam sembilan klaster, tiga klaster dipilih sebagai sampel, dan semua observasi dalam ketiga klaster tersebut dimasukkan ke dalam sampel. Pada panel bawah, digunakan pengambilan sampel multistahap. Perbedaannya dari pengambilan sampel klaster adalah bahwa kita memilih secara acak sebagian anggota setiap klaster untuk dimasukkan ke dalam sampel, alih-alih mengukur setiap kasus dalam tiap klaster terpilih.

lingkungan tempat tinggal menjadi klaster, pengambilan sampel klaster atau multistage bekerja paling baik ketika setiap lingkungan sangat beragam. Kekurangan metode-metode ini adalah bahwa analisis datanya biasanya memerlukan teknik yang lebih lanjut, meskipun metode dalam buku ini dapat diperluas untuk menangani data semacam itu.

CONTOH 1.15

Misalkan kita hendak memperkirakan tingkat malaria di suatu wilayah pedesaan berhutan tropis lebat di Indonesia. Kita mengetahui bahwa terdapat 30 desa di bagian kawasan hutan tersebut, dan setiap desa kurang lebih serupa dengan desa lainnya. Tujuan kita adalah melakukan tes malaria pada 150 orang. Metode pengambilan sampel apa yang sebaiknya digunakan?

E

Sampel acak sederhana kemungkinan akan memilih orang dari seluruh 30 desa, sehingga pengumpulan data bisa menjadi sangat mahal. Pengambilan sampel berstrata akan sulit karena tidak jelas bagaimana kita dapat membentuk strata berisi individu yang serupa. Namun, pengambilan sampel klaster atau multistage tampak sangat sesuai. Jika memutuskan menggunakan pengambilan sampel multistage, kita dapat memilih separuh desa secara acak, lalu memilih 10 orang secara acak dari setiap desa. Cara ini kemungkinan besar akan mengurangi biaya pengumpulan data secara berarti dibandingkan sampel acak sederhana, dan sampel multistage tersebut tetap akan memberi kita informasi yang andal, meskipun analisis datanya memerlukan metode yang sedikit lebih lanjut daripada yang dibahas dalam buku ini.

Latihan

1.13 Pencemaran udara dan luaran kelahiran: cakupan inferensi. Latihan 1.3 memperkenalkan sebuah studi yang mengumpulkan data untuk menelaah hubungan antara pencemar udara dan kelahiran prematur di California Selatan. Selama studi, tingkat pencemaran udara diukur oleh stasiun pemantau kualitas udara. Data lama kehamilan dikumpulkan untuk 143.196 kelahiran antara 1989 dan 1993, dan paparan pencemaran udara selama kehamilan dihitung untuk setiap kelahiran.

- Tentukan populasi sasaran dan sampel dalam studi ini.
- Jelaskan apakah hasil studi dapat digeneralisasikan ke populasi dan apakah temuannya dapat digunakan untuk menetapkan hubungan kausal.

1.14 Kecurangan: cakupan inferensi. Latihan 1.5 memperkenalkan studi tentang hubungan antara kejujuran, usia, dan pengendalian diri. Para peneliti melakukan eksperimen pada 160 anak berusia 5 hingga 15 tahun. Setiap anak diminta melempar koin seimbang tanpa dilihat orang lain dan mencatat hasilnya (putih atau hitam) pada selembar kertas; hanya anak yang melaporkan hasil putih yang akan diberi hadiah. Separuh anak secara eksplisit diminta untuk tidak berbuat curang, sedangkan separuh lainnya tidak diberi instruksi eksplisit. Terdapat perbedaan tingkat kecurangan antara kelompok dengan dan tanpa instruksi, serta sejumlah perbedaan menurut karakteristik anak di dalam setiap kelompok.

- Tentukan populasi sasaran dan sampel dalam studi ini.
- Jelaskan apakah hasil studi dapat digeneralisasikan ke populasi dan apakah temuannya dapat digunakan untuk menetapkan hubungan kausal.

1.15 Metode Buteyko: cakupan inferensi. Latihan 1.4 memperkenalkan studi mengenai penggunaan teknik pernapasan dangkal Buteyko untuk mengurangi gejala asma dan meningkatkan kualitas hidup. Studi ini merekrut 600 pasien asma berusia 18–69 tahun yang mengandalkan obat untuk perawatan asma, lalu mengalokasikan mereka secara acak ke dua kelompok: satu kelompok mempraktikkan metode Buteyko dan kelompok lainnya tidak. Kelompok Buteyko rata-rata mengalami penurunan gejala asma yang signifikan dan peningkatan kualitas hidup.

- Tentukan populasi sasaran dan sampel dalam studi ini.
- Jelaskan apakah hasil studi dapat digeneralisasikan ke populasi dan apakah temuannya dapat digunakan untuk menetapkan hubungan kausal.

1.16 Mengambil permen: cakupan inferensi. Latihan 1.6 memperkenalkan studi tentang hubungan antara kelas sosial ekonomi dan perilaku tidak etis. Dalam studi ini, 129 mahasiswa program sarjana University of California, Berkeley diminta menggolongkan diri ke kelas sosial rendah atau tinggi dengan membandingkan diri mereka dengan orang yang memiliki paling banyak (atau paling sedikit) uang dan pendidikan, serta pekerjaan yang paling (atau paling tidak) dihormati. Mereka juga diberi sebuah stoples

berisi permen yang dibungkus satu per satu. Peneliti memberi tahu bahwa permen tersebut ditujukan bagi anak-anak di laboratorium terdekat, tetapi peserta boleh mengambil beberapa jika ingin. Setelah menyelesaikan tugas lain yang tidak berkaitan, peserta melaporkan jumlah permen yang mereka ambil. Peserta yang tergolong kelas atas ditemukan mengambil lebih banyak permen daripada peserta lainnya.

- Tentukan populasi sasaran dan sampel dalam studi ini.
- Jelaskan apakah hasil studi dapat digeneralisasikan ke populasi dan apakah temuannya dapat digunakan untuk menetapkan hubungan kausal.

1.17 Bersantai setelah bekerja. General Social Survey mengambil sampel acak 1.155 warga Amerika dan menanyakan berapa jam yang mereka miliki setelah hari kerja biasa untuk bersantai atau melakukan kegiatan yang mereka sukai. Rata-rata waktu bersantai yang diperoleh adalah 1,65 jam. Tentukan mana di antara hal-hal berikut yang merupakan observasi, variabel, statistik sampel (nilai yang dihitung berdasarkan sampel teramati), atau parameter populasi.

- Seorang warga Amerika dalam sampel.
- Jumlah jam yang digunakan untuk bersantai setelah hari kerja biasa.
- 1,65.
- Rata-rata jumlah jam yang digunakan seluruh warga Amerika untuk bersantai setelah hari kerja biasa.

1.18 Kucing di YouTube. Misalkan Anda ingin memperkirakan persentase video YouTube yang menampilkan kucing. Karena mustahil menonton semua video di YouTube, Anda menggunakan pemilih video acak untuk memilih 1.000 video. Anda menemukan bahwa 2% dari video tersebut menampilkan kucing. Tentukan mana di antara hal-hal berikut yang merupakan observasi, variabel, statistik sampel (nilai yang dihitung berdasarkan sampel teramati), atau parameter populasi.

- Persentase seluruh video YouTube yang menampilkan kucing.
- 2%.
- Sebuah video dalam sampel Anda.
- Apakah sebuah video menampilkan kucing atau tidak.

1.19 Kepuasan mata kuliah antarkelompok. Sebuah kelas besar di perguruan tinggi memiliki 160 mahasiswa. Seluruh mahasiswa mengikuti kuliah bersama, tetapi untuk sesi praktikum mereka dibagi menjadi 4 kelompok yang masing-masing berisi 40 mahasiswa dan dibimbing oleh asisten pengajar yang berbeda. Dosen hendak melakukan survei mengenai kepuasan mahasiswa terhadap mata kuliah tersebut. Ia menduga kelompok praktikum yang diikuti mahasiswa dapat memengaruhi kepuasan mereka secara keseluruhan.


- Jenis studi apakah ini?
- Usulkan strategi pengambilan sampel untuk melaksanakan studi ini.

1.20 Usulan hunian di berbagai asrama. Di sebuah kampus besar, mahasiswa tahun pertama dan kedua tinggal di asrama di bagian timur kampus, sedangkan mahasiswa tahun ketiga dan keempat tinggal di asrama di bagian barat. Misalkan Anda ingin mengumpulkan pendapat mahasiswa tentang struktur hunian baru yang diusulkan pengelola perguruan tinggi dan ingin memastikan bahwa survei mewakili pendapat mahasiswa dari setiap angkatan secara setara.

- Jenis studi apakah ini?
- Usulkan strategi pengambilan sampel untuk melaksanakan studi ini.

1.21 Penggunaan internet dan harapan hidup. Diagram pencar berikut dibuat dalam sebuah studi yang menilai hubungan antara estimasi harapan hidup saat lahir (per 2014) dan persentase pengguna internet (per 2009) di 208 negara yang memiliki kedua jenis data tersebut.²³

- Jelaskan hubungan antara harapan hidup dan persentase pengguna internet.
- Jenis studi apakah ini?
- Sebutkan kemungkinan variabel perancu yang dapat menjelaskan hubungan ini dan uraikan kemungkinan pengaruhnya.



²³CIA Factbook, Country Comparisons, 2014.

1.22 Dilanda stres, Bagian I. Sebuah studi yang menyurvei sampel acak siswa sekolah menengah yang secara umum sehat menemukan bahwa mereka lebih mungkin mengalami kram otot ketika stres. Studi tersebut juga mencatat bahwa siswa minum lebih banyak kopi dan tidur lebih sedikit ketika stres.

- Jenis studi apakah ini?
- Dapatkah studi ini digunakan untuk menyimpulkan hubungan kausal antara peningkatan stres dan kram otot?
- Sebutkan kemungkinan variabel perancu yang dapat menjelaskan hubungan teramati antara peningkatan stres dan kram otot.

1.23 Evaluasi metode pengambilan sampel. Sebuah universitas ingin mengetahui proporsi mahasiswa program sarjananya yang mendukung iuran tahunan baru sebesar \$25 untuk memperbaiki pusat kegiatan mahasiswa. Untuk setiap metode yang diusulkan berikut, nyatakan apakah metode tersebut masuk akal atau tidak.

- Survei sampel acak sederhana yang terdiri atas 500 mahasiswa.
- Bagi mahasiswa ke dalam strata berdasarkan bidang studi, lalu ambil sampel 10% mahasiswa dari setiap strata.
- Kelompokkan mahasiswa ke dalam klaster berdasarkan usia (misalnya usia 18 tahun dalam satu klaster, usia 19 tahun dalam satu klaster, dan seterusnya), lalu pilih tiga klaster secara acak dan survei seluruh mahasiswa dalam klaster tersebut.

1.24 Pemanggilan digit acak. Gallup Poll menggunakan prosedur yang disebut pemanggilan digit acak. Prosedur ini membuat nomor telepon berdasarkan daftar seluruh kode area di Amerika Serikat serta jumlah rumah tangga yang terkait dengan setiap kode area. Berikan satu alasan yang mungkin menjelaskan mengapa Gallup Poll menggunakan pemanggilan digit acak alih-alih memilih nomor telepon dari buku telepon.

1.25 Kecenderungan menyukai atau tidak menyukai. Sebuah studi yang diterbitkan dalam *Journal of Personality and Social Psychology* meminta 200 peserta dari kalangan laki-laki dan perempuan yang dipilih secara acak untuk menilai perasaan mereka terhadap berbagai topik, seperti berkemah, layanan kesehatan, arsitektur, taksidermi, teka-teki silang, dan Jepang. Tujuannya adalah mengukur sikap mereka terhadap rangsangan yang sebagian besar tidak saling berkaitan. Selanjutnya, peserta menerima informasi tentang produk baru berupa oven gelombang mikro. Produk ini sebenarnya tidak ada, tetapi peserta tidak mengetahuinya; mereka diberi tiga ulasan positif dan tiga ulasan negatif yang direkayasa. Orang yang bereaksi positif terhadap topik-topik pada pengukuran sikap disposisional juga cenderung bereaksi positif terhadap oven tersebut, sedangkan orang yang bereaksi negatif cenderung menilainya secara negatif. Para peneliti menafsirkan pola itu sebagai kecenderungan evaluatif umum: sebagian peserta cenderung menilai banyak objek secara lebih positif, sedangkan peserta lain cenderung menilainya secara lebih negatif. Menurut mereka, pola lintas-objek ini dapat membantu menjelaskan bagaimana sikap terbentuk.²⁴

- Apa saja yang menjadi kasus?
- Apa variabel respons dalam studi ini?
- Apa variabel penjelas dalam studi ini?
- Apakah studi ini menggunakan pengambilan sampel acak?
- Apakah ini studi observasional atau eksperimen? Jelaskan alasan Anda.
- Dapatkah kita menetapkan hubungan kausal antara variabel penjelas dan variabel respons?
- Dapatkah hasil studi digeneralisasikan ke populasi secara luas?

1.26 Ukuran keluarga. Misalkan kita ingin memperkirakan ukuran rumah tangga. Dalam konteks ini, rumah tangga terdiri atas orang-orang yang tinggal bersama dalam hunian yang sama dan berbagi fasilitas tempat tinggal. Jika kita memilih murid secara acak di sebuah sekolah dasar dan menanyakan ukuran keluarga mereka, apakah hasilnya akan mengukur ukuran rumah tangga dengan baik? Atau apakah rata-ratanya akan bias? Jika bias, apakah hasilnya akan mengestimasi nilai sebenarnya terlalu tinggi atau terlalu rendah?

1.27 Strategi pengambilan sampel. Seorang mahasiswa statistika ingin mengetahui hubungan antara waktu yang dihabiskan siswa di situs jejaring sosial dan kinerja mereka di sekolah, lalu memutuskan untuk melakukan survei. Beberapa strategi penelitian untuk mengumpulkan data diuraikan berikut. Untuk setiap strategi, sebutkan metode pengambilan sampel yang diusulkan dan bias yang mungkin timbul.

- Ia memilih 40 siswa secara acak dari populasi studi, memberikan survei kepada mereka, lalu meminta mereka mengisinya dan mengembalikannya keesokan hari.

²⁴Justin Hepler and Dolores Albarracín. "Attitudes without objects - Evidence for a dispositional attitude, its measurement, and its consequences". In: *Journal of personality and social psychology* 104.6 (2013), p. 1060.

- (b) Ia hanya membagikan survei kepada teman-temannya dan memastikan setiap teman mengisinya.
- (c) Ia mengunggah tautan survei daring di Facebook dan meminta teman-temannya mengisi survei tersebut.
- (d) Ia memilih 5 kelas secara acak, lalu meminta sampel acak siswa dari kelas-kelas tersebut untuk mengisi survei.

1.28 Membaca berita. Dua artikel di *NY Times* memberitakan studi berikut. Uraian di bawah adalah ringkasan faktual yang disusun ulang, bukan kutipan dari artikel:

- (a) Artikel berjudul *Risks: Smokers Found More Prone to Dementia* melaporkan hal-hal berikut.²⁵

Analisis mencakup 23.123 anggota program kesehatan yang berusia 50–60 tahun ketika secara sukarela menjalani pemeriksaan dan survei perilaku pada 1978–1985. Setelah 23 tahun, sekitar 25% peserta tercatat mengalami demensia; 1.136 kasus adalah penyakit Alzheimer dan 416 kasus adalah demensia vaskular. Dalam perbandingan yang telah disesuaikan terhadap faktor lain, perkiraan risiko relatif terhadap bukan perokok adalah 37% lebih tinggi untuk satu bungkus per hari, 44% lebih tinggi untuk satu hingga dua bungkus, dan sekitar dua kali lipat untuk lebih dari dua bungkus per hari.

Berdasarkan studi ini, dapatkah kita menyimpulkan bahwa merokok menyebabkan demensia di kemudian hari? Jelaskan alasan Anda.

- (b) Artikel lain berjudul *The School Bully Is Sleepy* melaporkan hal-hal berikut.²⁶

Studi University of Michigan menggabungkan laporan orang tua tentang kebiasaan tidur anak dengan penilaian orang tua dan guru mengenai perilaku. Sekitar sepertiga siswa memperoleh penandaan masalah perilaku mengganggu atau perundungan. Gejala gangguan tidur dilaporkan sekitar dua kali lebih sering pada anak dalam kelompok bermasalah tersebut dan pada anak yang diidentifikasi sebagai perundung.

Seorang teman yang membaca artikel itu menyimpulkan bahwa gangguan tidur menyebabkan perundungan pada anak sekolah. Apakah pernyataan tersebut dapat dibenarkan? Jika tidak, bagaimana sebaiknya Anda menjelaskan kesimpulan yang dapat ditarik dari studi ini?

²⁵R.C. Rabin. “Risks: Smokers Found More Prone to Dementia”. In: *New York Times* (2010).

²⁶T. Parker-Pope. “The School Bully Is Sleepy”. In: *New York Times* (2011).

1.4 Eksperimen

Penelitian yang dalam pelaksanaannya peneliti menetapkan perlakuan kepada kasus disebut **eksperimen**. Jika penetapan ini melibatkan pengacakan, misalnya menggunakan pelemparan koin untuk menentukan perlakuan yang diterima seorang pasien, penelitian tersebut disebut **eksperimen acak**. Eksperimen acak sangat penting ketika kita ingin menunjukkan hubungan sebab-akibat antara dua variabel.

1.4.1 Prinsip perancangan eksperimen

Eksperimen acak pada umumnya dibangun berdasarkan empat prinsip.

Pengendalian. Peneliti menetapkan perlakuan kepada kasus dan berupaya sebaik mungkin untuk **mengendalikan** setiap perbedaan lain antarkelompok.²⁷ Sebagai contoh, ketika pasien minum obat berbentuk pil, sebagian pasien mungkin menelannya hanya dengan seteguk air, sedangkan yang lain dengan segelas penuh air. Untuk mengendalikan pengaruh banyaknya air yang diminum, dokter dapat meminta semua pasien minum pil dengan 12 ons cair AS (sekitar 355 mL) air.

Pengacakan. Peneliti mengalokasikan pasien secara acak ke kelompok kontrol dan kelompok perlakuan untuk menangani variabel yang tidak dapat dikendalikan. Sebagai contoh, pola makan dapat membuat sebagian pasien lebih rentan terhadap penyakit daripada pasien lain. Dalam jangka panjang, pengacakan menyeimbangkan perbedaan yang terukur maupun yang tidak terukur secara rata-rata dan membantu mencegah bias alokasi yang tidak disengaja. Namun, dalam satu eksperimen, pengacakan tidak menjamin bahwa kelompok-kelompok yang terbentuk akan persis sama.

Replikasi. Dalam sebuah eksperimen, peneliti melakukan **replikasi** dengan menerapkan kondisi perlakuan secara independen kepada banyak **unit eksperimen**. Semakin banyak unit independen yang diamati, semakin cermat peneliti dapat mengestimasi pengaruh variabel penjelas terhadap variabel respons. Replikasi perlakuan di dalam satu eksperimen berbeda dari pengulangan seluruh penelitian oleh tim ilmuwan lain untuk memeriksa temuan sebelumnya.


Pemblokian. Peneliti kadang-kadang mengetahui atau menduga bahwa variabel selain perlakuan turut memengaruhi respons. Dalam keadaan ini, mereka dapat lebih dahulu mengelompokkan individu berdasarkan variabel tersebut ke dalam **blok**, lalu mengalokasikan secara acak kasus di dalam setiap blok ke kelompok kontrol dan kelompok perlakuan. Strategi ini disebut **pemblokian**. Misalnya, untuk meneliti pengaruh obat terhadap serangan jantung, kita dapat lebih dahulu membagi pasien menjadi blok berisiko rendah dan berisiko tinggi. Selanjutnya, separuh pasien dari setiap blok dialokasikan secara acak ke kelompok kontrol dan separuh lainnya ke kelompok perlakuan, seperti pada Gambar 1.16. Dengan demikian, kelompok kontrol maupun kelompok perlakuan memiliki komposisi risiko yang seimbang.

Ketiga prinsip pertama perancangan eksperimen perlu diterapkan dalam setiap eksperimen. Buku ini menjelaskan metode yang sesuai untuk menganalisis data dari eksperimen semacam itu. Pemblokian merupakan teknik yang sedikit lebih lanjut; metode statistik dalam buku ini dapat diperluas untuk menganalisis data yang dikumpulkan dengan pemblokian.

1.4.2 Mengurangi bias dalam eksperimen pada manusia

Eksperimen acak merupakan tolok ukur utama untuk pengumpulan data, tetapi tidak selalu menjamin penilaian bebas bias atas hubungan sebab-akibat. Eksperimen pada manusia merupakan contoh yang baik tentang bagaimana bias dapat muncul tanpa disengaja. Di sini kita meninjau

²⁷Konsep ini berbeda dari *kelompok kontrol*, yang dibahas pada prinsip kedua dan pada Bagian 1.4.2.



Gambar 1.16: Pemblokkan berdasarkan variabel yang menggambarkan risiko pasien. Pasien mula-mula dibagi menjadi blok berisiko rendah dan berisiko tinggi; kemudian, melalui pengacakan, setiap blok dibagi sama banyak antara kelompok kontrol dan kelompok perlakuan. Strategi ini memberi kedua kelompok tersebut jumlah pasien berisiko rendah yang sama dan jumlah pasien berisiko tinggi yang sama.

kembali penelitian yang menggunakan obat baru untuk menangani pasien serangan jantung. Secara khusus, peneliti ingin mengetahui apakah obat tersebut mengurangi kematian pasien.

Para peneliti merancang eksperimen acak karena ingin menarik kesimpulan kausal tentang pengaruh obat. Sukarelawan penelitian²⁸ dialokasikan secara acak ke dua kelompok. Satu kelompok, yaitu **kelompok perlakuan**, menerima obat. Kelompok lainnya, yang disebut **kelompok kontrol**, tidak menerima perlakuan obat.

Bayangkan diri Anda sebagai peserta penelitian. Jika masuk kelompok perlakuan, Anda menerima obat baru yang Anda harapkan akan membantu. Sebaliknya, peserta di kelompok lain tidak menerima obat dan hanya dapat berharap partisipasinya tidak meningkatkan risiko kematian. Perbedaan pengalaman ini mengisyaratkan dua pengaruh: pengaruh yang menjadi perhatian ialah efek-tivitas obat, sedangkan yang kedua ialah pengaruh psikologis yang sulit diukur.

Peneliti biasanya tidak berminat pada pengaruh psikologis tersebut karena dapat membiaskan hasil. Untuk mengatasinya, peneliti berusaha agar pasien tidak mengetahui kelompoknya. Jika pasien tidak diberi tahu tentang perlakuan yang diterimanya, eksperimen disebut **tersamar**. Namun, ada masalah: pasien yang sama sekali tidak menerima perlakuan akan tahu bahwa ia berada di kelompok kontrol. Salah satu solusinya ialah memberi pasien kelompok kontrol perlakuan semu yang disebut **plasebo**. Plasebo yang meyakinkan membantu mempertahankan penyamaran. Contoh klasiknya ialah pil gula yang dibuat menyerupai pil perlakuan yang sebenarnya. Kadang-kadang teramati sedikit perbaikan pada pasien yang menerima plasebo. Fenomena ini sering disebut **efek plasebo**; akan tetapi, pengamatan tersebut tidak dengan sendirinya membuktikan bahwa plasebo menyebabkan perbaikan, sebab perjalanan alami penyakit dan faktor lain juga dapat berperan.

Bukan hanya pasien yang perlu disamarkan: dokter dan peneliti pun dapat tanpa sengaja membiaskan eksperimen. Jika mengetahui bahwa seorang pasien menerima perlakuan sebenarnya, dokter mungkin tanpa sadar memberi pasien itu lebih banyak perhatian atau perawatan daripada pasien yang menerima plasebo. Untuk mencegah bias ini, yang dalam beberapa keadaan terbukti memiliki pengaruh terukur, kebanyakan penelitian modern menggunakan rancangan **tersamar ganda**. Dalam rancangan ini, baik pasien maupun dokter atau peneliti yang berinteraksi dengan mereka tidak mengetahui siapa yang menerima perlakuan.²⁹

LATIHAN TERBIMBING 1.16

G

Tinjau kembali penelitian pada Bagian 1.1, tempat peneliti menguji apakah stent efektif mengurangi stroke pada pasien berisiko. Apakah penelitian tersebut merupakan eksperimen? Apakah eksperimen itu tersamar? Apakah eksperimen itu tersamar ganda?³⁰

LATIHAN TERBIMBING 1.17

G

Untuk penelitian pada Bagian 1.1, dapatkah peneliti menggunakan plasebo? Jika dapat, seperti apa bentuk plasebo tersebut?³¹

Setelah membaca Latihan Terbimbing 1.17, Anda mungkin memiliki banyak pertanyaan tentang etika penggunaan bedah semu sebagai plasebo. Pertanyaan serupa berlaku lebih umum ketika perlakuan yang mungkin membantu tidak diberikan kepada kelompok kontrol. Bedah semu menambatkan risiko dari prosedur itu sendiri. Menahan perlakuan yang manfaatnya belum terbukti dapat mempertahankan risiko dasar, sedangkan menahan terapi standar yang sudah terbukti bermanfaat juga dapat meningkatkan risiko. Karena itu, eksperimen yang etis memerlukan *ekuiipose klinis*: harus ada ketidakpastian yang sungguh-sungguh di kalangan ahli mengenai perlakuan mana yang lebih baik.

Eksperimen dan plasebo selalu dapat dilihat dari beberapa sudut pandang, dan pilihan yang

²⁸Subjek manusia sering disebut **pasien**, **sukarelawan**, atau **peserta penelitian**.

²⁹Sebagian peneliti yang terlibat tetap mengetahui alokasi perlakuan. Namun, mereka tidak berinteraksi dengan pasien dan tidak memberi tahu tenaga kesehatan yang disamarkan tentang perlakuan yang diterima setiap pasien.

³⁰Peneliti mengalokasikan pasien ke kelompok-kelompok eksperimen, jadi penelitian ini merupakan eksperimen. Namun, pasien dapat membedakan perlakuan yang mereka terima sehingga eksperimen tidak tersamar. Karena pasien tidak tersamar, eksperimen tersebut juga tidak mungkin tersamar ganda.

³¹Secara teknis, peneliti dapat menggunakan **bedah semu** agar pasien tidak mengetahui apakah ia menerima komponen terapeutik. Dalam bedah semu, pasien menjalani langkah prosedural yang menyerupai operasi, tetapi tidak menerima perlakuan lengkap. Penyamaran semacam ini memungkinkan peneliti mengukur respons yang berkaitan dengan plasebo, tetapi tetap memaparkan pasien pada risiko prosedural tanpa manfaat terapeutik langsung.

secara etis “benar” jarang tampak jelas. Misalnya, etiskah menggunakan bedah semu jika prosedur tersebut menimbulkan risiko bagi pasien? Di sisi lain, tanpa pembandingan bedah semu, kita mungkin mendorong penggunaan perlakuan mahal yang sebenarnya tidak efektif. Jika itu terjadi, uang dan sumber daya lain dapat teralihkan dari perlakuan yang sudah diketahui bermanfaat. Pada akhirnya, kita menghadapi situasi sulit: perlindungan sempurna tidak dapat sekaligus diberikan kepada pasien yang menjadi sukarelawan sekarang dan kepada pasien yang mungkin memperoleh manfaat, atau tidak memperoleh manfaat, dari perlakuan tersebut di masa mendatang.

Latihan

1.29 Kondisi pencahayaan dan kinerja ujian. Sebuah studi dirancang untuk menguji pengaruh kondisi pencahayaan terhadap kinerja ujian mahasiswa. Peneliti menduga bahwa kondisi pencahayaan dapat memberikan pengaruh yang berbeda pada laki-laki dan perempuan, sehingga keduanya hendak diwakili sama banyak dalam setiap perlakuan. Perlakuannya adalah pencahayaan fluoresen dari atas, pencahayaan kuning dari atas, dan tanpa pencahayaan dari atas (hanya menggunakan lampu meja).

- (a) Apa variabel responsnya?
- (b) Apa variabel penjelasnya? Apa saja levelnya?
- (c) Apa variabel pemblokannya? Apa saja levelnya?

1.30 Suplemen vitamin. Untuk menilai efektivitas konsumsi vitamin C dosis tinggi dalam mengurangi durasi selesma, para peneliti merekrut 400 sukarelawan sehat dari kalangan staf dan mahasiswa di sebuah universitas. Seperempat peserta dialokasikan untuk menerima plasebo, sedangkan peserta lainnya dialokasikan secara merata ke tiga perlakuan: vitamin C dosis 1 g, vitamin C dosis 3 g, atau vitamin C dosis 3 g ditambah zat aditif. Pil tersebut harus mulai diminum ketika selesma muncul dan dilanjutkan selama dua hari berikutnya. Semua tablet memiliki tampilan dan kemasan yang identik. Perawat yang menyerahkan pil yang diresepkan mengetahui perlakuan yang diterima setiap peserta, tetapi peneliti yang menilai peserta ketika mereka sakit tidak mengetahuinya. Tidak ditemukan perbedaan signifikan di antara keempat kelompok pada ukuran durasi maupun tingkat keparahan selesma, dan kelompok plasebo mengalami durasi gejala paling singkat.³²

- (a) Apakah studi ini merupakan eksperimen atau studi observasional? Mengapa?
- (b) Apa variabel penjelas dan variabel respons dalam studi ini?
- (c) Apakah identitas perlakuan disamarkan dari peserta?
- (d) Apakah studi ini tersamar ganda?
- (e) Peserta pada akhirnya dapat memilih apakah akan minum pil yang diresepkan. Kita dapat menduga bahwa tidak semuanya akan mematuhi penugasan dan minum pilnya. Apakah ketidakpatuhan ini dengan sendirinya menciptakan variabel perancu? Jelaskan mengapa alokasi awal tetap acak, serta bagaimana ketidakpatuhan dapat mempersulit estimasi efek perlakuan yang benar-benar diterima dan membiaskan analisis yang mengelompokkan peserta menurut pil yang benar-benar mereka minum.

1.31 Kondisi pencahayaan, kebisingan, dan kinerja ujian. Sebuah studi dirancang untuk menguji pengaruh kondisi pencahayaan dan tingkat kebisingan terhadap kinerja ujian mahasiswa. Peneliti menduga bahwa kedua faktor tersebut dapat memberikan pengaruh yang berbeda pada laki-laki dan perempuan, sehingga keduanya hendak diwakili sama banyak dalam setiap perlakuan. Perlakuan pencahayaan yang dipertimbangkan adalah pencahayaan fluoresen dari atas, pencahayaan kuning dari atas, dan tanpa pencahayaan dari atas (hanya menggunakan lampu meja). Perlakuan kebisingannya adalah tanpa kebisingan, kebisingan konstruksi, dan suara percakapan manusia.

- (a) Apa jenis studi ini?
- (b) Berapa faktor yang dipertimbangkan dalam studi ini? Sebutkan faktor-faktor tersebut dan uraikan levelnya.
- (c) Apa peran variabel jenis kelamin dalam studi ini?

1.32 Musik dan pembelajaran. Anda hendak melakukan eksperimen di kelas untuk mengetahui apakah mahasiswa belajar lebih baik ketika belajar tanpa musik, dengan musik tanpa lirik (instrumental), atau dengan musik berlirik. Uraikan secara ringkas sebuah rancangan untuk studi ini.

1.33 Preferensi minuman bersoda. Anda hendak melakukan eksperimen di kelas untuk mengetahui apakah teman-teman sekelas Anda lebih menyukai rasa Coke biasa atau Diet Coke. Uraikan secara ringkas sebuah rancangan untuk studi ini.

³²C. Audera et al. “Mega-dose vitamin C in treatment of the common cold: a randomised controlled trial”. In: *Medical Journal of Australia* 175.7 (2001), pp. 359–362.


1.34 Olahraga dan kesehatan mental. Seorang peneliti tertarik pada pengaruh olahraga terhadap kesehatan mental dan mengusulkan studi berikut: Gunakan pengambilan sampel acak berstrata untuk memastikan bahwa proporsi kelompok usia 18–30, 31–40, dan 41–55 tahun dalam sampel mewakili populasi. Selanjutnya, alokasikan secara acak separuh subjek dalam setiap kelompok usia untuk berolahraga dua kali seminggu, dan instruksikan subjek lainnya agar tidak berolahraga. Lakukan pemeriksaan kesehatan mental pada awal dan akhir studi, lalu bandingkan hasilnya.

- Apa jenis studi ini?
- Apa kelompok perlakuan dan kelompok kontrol dalam studi ini?
- Apakah studi ini menerapkan pemblokkan? Jika ya, apa variabel pemblokannya?
- Apakah studi ini menerapkan penyamaran?
- Jelaskan apakah hasil studi dapat digunakan untuk menetapkan hubungan sebab-akibat antara olahraga dan kesehatan mental, serta apakah kesimpulannya dapat digeneralisasikan ke populasi secara luas.
- Andaikan Anda ditugaskan untuk menentukan apakah studi yang diusulkan ini layak menerima pendanaan. Apakah Anda memiliki keberatan terhadap usulan studi tersebut?

Latihan bab

1.35 Nama hewan peliharaan. Kota Seattle, Washington, memiliki portal data terbuka yang mencakup hewan peliharaan yang terdaftar di kota tersebut. Untuk setiap hewan peliharaan yang terdaftar, tersedia informasi tentang nama dan spesiesnya. Visualisasi berikut memetakan proporsi anjing dengan nama tertentu terhadap proporsi kucing dengan nama yang sama. Ditampilkan 20 nama kucing dan anjing yang paling umum. Garis diagonal pada grafik adalah garis $x = y$; jika suatu nama terletak pada garis ini, nama tersebut sama populernya di kalangan anjing maupun kucing.

- Apakah data ini dikumpulkan sebagai bagian dari eksperimen atau studi observasional?
- Apa nama anjing yang paling umum? Apa nama kucing yang paling umum?
- Nama apa saja yang lebih umum untuk kucing daripada anjing?
- Apakah hubungan antara kedua variabel positif atau negatif? Apa artinya dalam konteks data ini?



1.36 Stres, Bagian II. Dalam suatu studi yang mengevaluasi hubungan antara stres dan kram otot, separuh subjek ditetapkan secara acak untuk mengalami peningkatan stres dengan ditempatkan di dalam lift yang turun cepat dan berhenti mendadak, sedangkan separuh lainnya dibiarkan tanpa stres atau pada tingkat stres dasar.

- Jenis studi apakah ini?
- Dapatkah studi ini digunakan untuk menyimpulkan hubungan sebab-akibat antara peningkatan stres dan kram otot?

1.37 Biji chia dan penurunan berat badan. Chia Pets—patung kecil terakota yang menumbuhkan “rambut” hijau lebat—membuat tanaman chia dikenal luas. Namun, chia kemudian memperoleh reputasi yang sama sekali baru sebagai suplemen diet. Dalam sebuah studi tahun 2009, tim peneliti merekrut 38 laki-laki dan membagi mereka secara acak ke dalam dua kelompok: perlakuan atau kontrol. Mereka juga merekrut 38 perempuan, lalu menetapkan secara acak separuh peserta ini ke kelompok perlakuan dan separuh lainnya ke kelompok kontrol. Satu kelompok diberi 25 gram biji chia dua kali sehari, sedangkan kelompok lain diberi plasebo. Para subjek menjadi sukarelawan untuk mengikuti studi. Setelah 12 minggu, para ilmuwan tidak menemukan perbedaan signifikan antarkelompok dalam hal nafsu makan maupun penurunan berat badan.³³

- Jenis studi apakah ini?
- Apa perlakuan eksperimen dan perlakuan kontrol dalam studi ini?

³³D.C. Nieman et al. “Chia seed does not promote weight loss or alter disease risk factors in overweight adults”. In: *Nutrition Research* 29.6 (2009), pp. 414–418.

- (c) Apakah pemblokkan digunakan dalam studi ini? Jika ya, apa variabel pemblokannya?
- (d) Apakah pembutaan digunakan dalam studi ini?
- (e) Jelaskan apakah kita dapat membuat pernyataan kausal, dan nyatakan apakah kesimpulannya dapat digeneralisasikan ke populasi yang lebih luas.

1.38 Survei dewan kota. Sebuah dewan kota meminta agar survei rumah tangga dilakukan di wilayah pinggiran kotanya. Wilayah tersebut terbagi menjadi banyak lingkungan yang berbeda-beda: sebagian berisi rumah besar, sebagian hanya apartemen, dan sebagian lainnya memiliki campuran struktur hunian yang beragam. Untuk setiap bagian di bawah ini, tentukan metode pengambilan sampel yang dijelaskan, lalu uraikan kelebihan dan kekurangan statistik metode tersebut dalam konteks kota ini.


- (a) Ambil sampel acak 200 rumah tangga dari kota tersebut.
- (b) Bagi kota menjadi 20 lingkungan, lalu ambil sampel 10 rumah tangga dari setiap lingkungan.
- (c) Bagi kota menjadi 20 lingkungan, ambil sampel acak 3 lingkungan, lalu ambil semua rumah tangga dari ketiga lingkungan tersebut sebagai sampel.
- (d) Bagi kota menjadi 20 lingkungan, ambil sampel acak 8 lingkungan, lalu ambil sampel acak 50 rumah tangga dari lingkungan-lingkungan tersebut.
- (e) Ambil 200 rumah tangga yang paling dekat dengan kantor dewan kota sebagai sampel.

1.39 Penalaran yang cacat. Temukan cacat penalaran dalam skenario-skenario berikut. Jelaskan apa yang seharusnya dilakukan secara berbeda oleh orang-orang dalam studi tersebut jika mereka ingin membuat kesimpulan sekuat itu.

- (a) Para siswa di sebuah sekolah dasar diberi kuesioner yang harus dikembalikan setelah diisi oleh orang tua mereka. Salah satu pertanyaannya berbunyi, “Apakah jadwal kerja Anda menyulitkan Anda meluangkan waktu bersama anak-anak sepulang sekolah?” Dari orang tua yang menjawab, 85% mengatakan “tidak”. Berdasarkan hasil ini, pihak sekolah menyimpulkan bahwa sebagian besar orang tua tidak mengalami kesulitan meluangkan waktu bersama anak-anak mereka sepulang sekolah.
- (b) Survei dilakukan terhadap sampel acak sederhana berisi 1.000 perempuan yang baru saja melahirkan untuk menanyakan apakah mereka merokok selama kehamilan. Tiga tahun kemudian dilakukan survei tindak lanjut yang menanyakan apakah anak-anak mereka mengalami gangguan pernapasan. Namun, hanya 567 perempuan yang dapat dihubungi di alamat yang sama. Peneliti melaporkan bahwa 567 perempuan ini mewakili semua ibu.
- (c) Seorang dokter ortopedi memberikan kuesioner kepada 30 pasiennya yang tidak memiliki masalah sendi dan menemukan bahwa 20 di antaranya rutin berlari. Ia menyimpulkan bahwa berlari menurunkan risiko masalah sendi.

1.40 Pendapatan dan pendidikan di county Amerika Serikat. Diagram pencar di bawah ini menunjukkan hubungan antara pendapatan per kapita (dalam ribuan dolar) dan persentase penduduk yang memiliki gelar sarjana di 3.143 county di Amerika Serikat pada tahun 2010.

- (a) Apa variabel penjelas dan variabel responnya?
- (b) Jelaskan hubungan antara kedua variabel. Pastikan untuk membahas pengamatan yang tidak biasa, jika ada.
- (c) Dapatkah kita menyimpulkan bahwa memiliki gelar sarjana meningkatkan pendapatan seseorang?



1.41 Makan lebih baik, merasa lebih baik? Dalam studi kesehatan masyarakat tentang pengaruh konsumsi buah dan sayur terhadap kesejahteraan psikologis orang dewasa muda, peserta diacak ke tiga kelompok: (1) pola makan biasa; (2) intervensi ekologis sesaat berupa pengingat pesan teks untuk meningkatkan konsumsi buah dan sayur beserta kupon untuk membelinya; atau (3) intervensi buah dan sayur berupa dua porsi tambahan buah dan sayur segar per hari di luar pola makan biasa. Para peserta adalah mahasiswa sukarelawan di University of Otago, Selandia Baru, dan mengisi survei melalui ponsel cerdas setiap malam. Pada akhir studi, hanya kelompok ketiga yang menunjukkan peningkatan kesejahteraan psikologis sepanjang 14 hari dibandingkan dua kelompok lain.³⁴

- (a) Jenis studi apakah ini?

³⁴Tamlin S Conner et al. “Let them eat fruit! The effect of fruit and vegetable consumption on psychological well-being in young adults: A randomized controlled trial”. In: *PloS one* 12.2 (2017), e0171206.

- (b) Tentukan variabel penjelas dan variabel responsnya.
- (c) Dapatkah hasil studi digeneralisasikan ke populasi? Jelaskan.
- (d) Dapatkah hasil studi menetapkan hubungan sebab-akibat? Jelaskan.
- (e) Sebuah artikel surat kabar menyatakan, “Hasil studi ini membuktikan bahwa memberi orang dewasa muda buah dan sayuran segar untuk dimakan dapat memberikan manfaat psikologis, bahkan dalam waktu singkat.” Bagaimana pernyataan itu perlu direvisi agar didukung oleh studi?

1.42 Layar, remaja, dan kesejahteraan psikologis. Studi terhadap tiga kumpulan data berskala besar yang mewakili populasi nasional Irlandia, Amerika Serikat, dan Britania Raya ($n = 17.247$) meminta remaja usia 12–15 tahun mencatat waktu layar dalam buku harian serta menjawab pertanyaan tentang perasaan atau perilaku; jawaban itu digunakan untuk menghitung skor kesejahteraan psikologis. Analisis juga menyertakan jenis kelamin dan usia anak serta, untuk ibu, tingkat pendidikan, etnisitas, tekanan psikologis, dan status pekerjaan. Studi tersebut menyimpulkan bahwa hanya ada sedikit bukti tegas bahwa waktu layar menurunkan kesejahteraan remaja.³⁵

- (a) Jenis studi apakah ini?
- (b) Tentukan variabel penjelasnya.
- (c) Tentukan variabel responsnya.
- (d) Dapatkah hasil studi digeneralisasikan ke populasi? Mengapa?
- (e) Dapatkah hasil studi menetapkan hubungan sebab-akibat? Jelaskan.

1.43 Stanford Open Policing. Proyek Stanford Open Policing menghimpun, menganalisis, dan menerbitkan catatan pemberhentian lalu lintas oleh penegak hukum di seluruh Amerika Serikat untuk membantu peneliti, jurnalis, dan pembuat kebijakan menyelidiki dan memperbaiki interaksi polisi dengan masyarakat.³⁶ Berikut cuplikan tabel ringkasan data proyek tersebut.

County	Neg. bagian	Ras pengemudi	Jumlah per tahun	% dari yang dihentikan mobil digeledah pengemudi ditangkap	
Apache County	Arizona	Hitam	266	0.08	0.02
Apache County	Arizona	Hispanik	1008	0.05	0.02
Apache County	Arizona	Putih	6322	0.02	0.01
Cochise County	Arizona	Hitam	1169	0.05	0.01
Cochise County	Arizona	Hispanik	9453	0.04	0.01
Cochise County	Arizona	Putih	10826	0.02	0.01
...	...	...	...	...	...
Wood County	Wisconsin	Hitam	16	0.24	0.10
Wood County	Wisconsin	Hispanik	27	0.04	0.03
Wood County	Wisconsin	Putih	1157	0.03	0.03

- (a) Variabel apa yang dikumpulkan untuk setiap pemberhentian lalu lintas guna membuat tabel ini?
- (b) Klasifikasikan setiap variabel sebagai numerik (kontinu atau diskret) atau kategoris (ordinal atau nonordinal).
- (c) Anda ingin menilai apakah tingkat penggeledahan kendaraan berbeda menurut ras pengemudi. Mana variabel respons dan variabel penjelasnya?

1.44 Peluncuran antariksa. Tabel berikut merangkum jumlah peluncuran antariksa di Amerika Serikat menurut jenis lembaga peluncur dan hasilnya (berhasil atau gagal).³⁷

	1957 - 1999		2000 - 2018	
	Gagal	Berhasil	Gagal	Berhasil
Swasta	13	295	10	562
Negara	281	3751	33	711
Rintisan	-	-	5	65

- (a) Variabel apa yang dikumpulkan untuk setiap peluncuran guna membuat tabel ini?
- (b) Klasifikasikan setiap variabel sebagai numerik (kontinu atau diskret) atau kategoris (ordinal atau nonordinal).
- (c) Anda ingin mempelajari bagaimana tingkat keberhasilan berbeda menurut lembaga peluncur dan periode waktu. Mana variabel respons dan penjelasnya?

³⁵Amy Orben and AK Baukney-Przybylski. “Screens, Teens and Psychological Well-Being: Evidence from three time-use diary studies”. In: *Psychological Science* (2018).

³⁶Emma Pierson et al. “A large-scale analysis of racial disparities in police stops across the United States”. In: *arXiv preprint arXiv:1706.05678* (2017).

³⁷JSR Launch Vehicle Database, A comprehensive list of suborbital space launches, 2019 Feb 10 Edition.

Bab 2

Merangkum data

2.1 Menelaah data numerik

2.2 Menelaah data kategoris

2.3 Studi kasus: vaksin malaria

Bab ini berfokus pada cara menghitung dan menyusun statistik ringkasan serta grafik. Kami menggunakan perangkat lunak statistik untuk membuat ringkasan dan grafik yang disajikan dalam bab ini maupun di seluruh buku. Namun, karena ini mungkin kali pertama Anda bersentuhan dengan konsep-konsep tersebut, dalam bab ini kami menjelaskan secara bertahap cara membuatnya. Penguasaan materi dalam bab ini sangat penting untuk memahami metode dan teknik yang diperkenalkan di bagian-bagian selanjutnya dalam buku ini.



Untuk video, salindia, dan sumber daya lainnya, kunjungi
www.openintro.org/os


2.1 Menelaah data numerik

Dalam bagian ini kita akan mempelajari teknik untuk merangkum variabel numerik. Sebagai contoh, perhatikan variabel `loan_amount` dari kumpulan data `loan50`, yang menyatakan besar pinjaman untuk seluruh 50 pinjaman dalam kumpulan data tersebut. Variabel ini bersifat numerik karena selisih besar dua pinjaman dapat dibahas secara bermakna sebagai suatu bilangan. Sebaliknya, kode wilayah telepon dan kode pos bukanlah numerik, melainkan variabel kategoris.

Sepanjang bagian ini dan bagian berikutnya, kita akan menerapkan metode-metode tersebut pada kumpulan data `loan50` dan `county`, yang diperkenalkan dalam Bagian 1.2. Jika Anda ingin meninjau variabel dalam kedua kumpulan data itu, lihat Gambar 1.3 dan 1.5.

2.1.1 Diagram pencar untuk data berpasangan

Sebuah **diagram pencar** menyajikan data dua variabel numerik kasus demi kasus. Dalam Gambar 1.8 pada halaman 16, sebuah diagram pencar digunakan untuk menelaah hubungan antara tingkat kepemilikan rumah dan proporsi unit hunian yang merupakan bagian dari properti multiunit (misalnya apartemen) dalam kumpulan data `county`. Diagram pencar lain ditampilkan dalam Gambar 2.1, yang membandingkan total pendapatan seorang peminjam (`total_income`) dengan jumlah yang dipinjamnya (`loan_amount`) dalam kumpulan data `loan50`. Dalam setiap diagram pencar, tiap titik mewakili satu kasus. Karena `loan50` memuat 50 kasus, Gambar 2.1 memuat 50 titik.




Gambar 2.1: Diagram pencar `total_income` terhadap `loan_amount` untuk kumpulan data `loan50`.

Pada Gambar 2.1, terlihat banyak peminjam berpendapatan kurang dari \$100,000 di sisi kiri grafik, sedangkan hanya segelintir peminjam berpendapatan di atas \$250,000.

CONTOH 2.1

Gambar 2.2 menampilkan median pendapatan rumah tangga terhadap tingkat kemiskinan untuk 3,142 county. Apa yang dapat dikatakan tentang hubungan antara kedua variabel ini?

Hubungan tersebut jelas **nonlinear**, sebagaimana ditonjolkan oleh garis putus-putus. Hal ini berbeda dari diagram pencar sebelumnya, yang memperlihatkan hubungan dengan sedikit atau tanpa kelengkungan dalam trennya.



Gambar 2.2: Diagram pencar median pendapatan rumah tangga terhadap tingkat kemiskinan untuk kumpulan data `county`. Sebuah model statistik juga telah dicocokkan dengan data dan ditampilkan sebagai garis putus-putus.

Ⓔ

LATIHAN TERBIMBING 2.2

Apa yang diperlihatkan diagram pencar tentang data, dan apa kegunaannya?¹


Ⓔ

LATIHAN TERBIMBING 2.3

Sebutkan dua variabel yang akan mempunyai hubungan berbentuk tapal kuda dalam diagram pencar ($\cap$ atau $\cup$).²

2.1.2 Diagram titik dan rata-rata


Kadang-kadang dua variabel justru terlalu banyak: mungkin hanya satu variabel yang menarik perhatian. Dalam keadaan ini, diagram titik menyediakan tampilan paling dasar. Sebuah **diagram titik** adalah diagram pencar untuk satu variabel; contoh yang menggunakan suku bunga dari 50 pinjaman ditampilkan dalam Gambar 2.3. Versi bertumpuk dari diagram titik ini ditampilkan dalam Gambar 2.4.



Gambar 2.3: Diagram titik `interest_rate` untuk kumpulan data `loan50`. Rata-rata distribusi ditampilkan sebagai segitiga merah.

¹Jawaban dapat bervariasi. Diagram pencar membantu kita mengenali dengan cepat hubungan antarvariabel, baik yang berbentuk tren sederhana maupun hubungan yang lebih rumit.

²Bayangkan sumbu vertikal menyatakan sesuatu yang “baik”, sedangkan sumbu horizontal menyatakan sesuatu yang hanya baik dalam jumlah sedang. Kesehatan dan konsumsi air memenuhi gambaran ini: kita memerlukan air untuk bertahan hidup, tetapi konsumsi berlebihan membuatnya beracun dan dapat mematikan.



Gambar 2.4: Diagram titik bertumpuk untuk `interest_rate` dalam kumpulan data `loan50`. Pada diagram ini, suku bunga dibulatkan ke persentase terdekat dan rata-rata distribusi ditampilkan sebagai segitiga merah.

Nilai **rata-rata**, yang juga sering disebut **rerata**, merupakan cara yang umum digunakan untuk mengukur pusat suatu **distribusi** data. Untuk menghitung rata-rata suku bunga, kita menjumlahkan semua suku bunga lalu membaginya dengan banyaknya pengamatan:

$$\bar{x} = \frac{10.90\% + 9.92\% + 26.30\% + \cdots + 6.08\%}{50} = 11.57\%$$

Rata-rata sampel sering diberi lambang $\bar{x}$. Huruf x digunakan sebagai penampung umum untuk variabel yang sedang ditelaah, yaitu `interest_rate`; garis di atas x menunjukkan bahwa kita sedang melihat rata-rata suku bunga, yang untuk 50 pinjaman ini bernilai 11.57%. Rata-rata dapat dipandang sebagai titik keseimbangan distribusi; pada Gambar 2.3 dan 2.4, rata-rata ditampilkan sebagai segitiga.

RATA-RATA

Rata-rata sampel dapat dihitung sebagai jumlah semua nilai yang diamati dibagi dengan banyaknya pengamatan:

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

dengan $x_1, x_2, \dots, x_n$ menyatakan n nilai yang diamati.

LATIHAN TERBIMBING 2.4



Perhatikan persamaan untuk rata-rata. Apa yang dinyatakan oleh x_1 ? Bagaimana dengan x_2 ? Dapatkah Anda menyimpulkan makna umum dari x_i ?³

LATIHAN TERBIMBING 2.5



Berapakah n dalam sampel pinjaman ini?⁴

Kumpulan data `loan50` merupakan sampel dari populasi pinjaman yang lebih besar yang diberikan melalui Lending Club. Kita dapat menghitung rata-rata populasi ini dengan cara yang sama seperti rata-rata sampel. Namun, rata-rata populasi mempunyai lambang khusus: μ . Simbol μ adalah huruf Yunani *mu* dan menyatakan rata-rata seluruh pengamatan dalam populasi. Kadang-kadang subskrip seperti x digunakan untuk menunjukkan variabel yang dirujuk oleh rata-

³ x_1 menyatakan suku bunga pinjaman pertama dalam sampel (10.90%), x_2 menyatakan suku bunga pinjaman kedua (9.92%), dan x_i menyatakan suku bunga untuk pinjaman ke- i dalam kumpulan data. Sebagai contoh, jika $i = 4$, kita menelaah x_4 , yang merujuk pada pengamatan keempat dalam kumpulan data.

⁴Ukuran sampelnya adalah $n = 50$.

rata populasi, misalnya μ_x . Mengukur rata-rata populasi secara tepat sering kali terlalu mahal; karena itu, kita biasanya mengestimasi μ menggunakan rata-rata sampel, $\bar{x}$.

CONTOH 2.6

Rata-rata suku bunga seluruh pinjaman dalam populasi dapat diestimasi menggunakan data sampel. Berdasarkan sampel berisi 50 pinjaman, berapakah estimasi yang wajar bagi μ_x , yaitu rata-rata suku bunga seluruh pinjaman dalam kumpulan data lengkap?

E

Rata-rata sampel, 11.57%, memberikan estimasi kasar bagi μ_x . Meskipun tidak sempurna, inilah tebakan tunggal terbaik kita mengenai rata-rata suku bunga seluruh pinjaman dalam populasi yang diteliti.

Dalam Bab 5 dan bab-bab berikutnya, kita akan mengembangkan alat untuk mencirikan ketepatan *estimasi titik*, seperti rata-rata sampel. Seperti yang mungkin Anda duga, estimasi titik yang didasarkan pada sampel lebih besar cenderung lebih akurat daripada estimasi yang didasarkan pada sampel lebih kecil.

CONTOH 2.7

Rata-rata berguna karena memungkinkan kita mengubah skala atau menstandarkan suatu ukuran menjadi bentuk yang lebih mudah ditafsirkan dan dibandingkan. Berikan 2 contoh penggunaan rata-rata untuk membuat perbandingan.

1. Kita ingin mengetahui apakah obat baru lebih efektif untuk menangani serangan asma daripada obat standar. Sebuah uji coba dengan 1500 orang dewasa disusun: 500 orang menerima obat baru, sedangkan 1000 orang dalam kelompok kontrol menerima obat standar:

	Obat baru	Obat standar
Jumlah pasien	500	1000
Total serangan asma	200	300

E

Membandingkan hitungan mentah 200 dengan 300 serangan asma akan membuat obat baru tampak lebih baik, tetapi kesan ini timbul karena ukuran kedua kelompok tidak seimbang. Sebagai gantinya, kita perlu melihat rata-rata jumlah serangan asma per pasien dalam setiap kelompok:

$$\text{Obat baru: } 200/500 = 0.4$$

$$\text{Obat standar: } 300/1000 = 0.3$$

Obat standar menghasilkan rata-rata jumlah serangan asma per pasien yang lebih rendah daripada rata-rata kelompok perlakuan.

2. Tahun lalu Emilio membuka truk makanan untuk menjual burrito, dan usahanya telah stabil selama 3 bulan terakhir. Dalam periode 3 bulan itu, ia memperoleh \$11,000 dengan bekerja selama 625 jam. Rata-rata penghasilan Emilio per jam memberikan statistik yang berguna untuk menilai apakah usahanya layak dijalankan, setidaknya dari sudut pandang keuangan:

$$\frac{\$11000}{625 \text{ jam}} = \$17.60 \text{ per jam}$$

Dengan mengetahui rata-rata upah per jamnya, Emilio telah menyatakan penghasilannya dalam satuan standar yang lebih mudah dibandingkan dengan banyak pekerjaan lain yang mungkin ia pertimbangkan.

CONTOH 2.8

Misalkan kita ingin menghitung rata-rata pendapatan per orang di AS. Mula-mula mungkin terpikir untuk mengambil rata-rata pendapatan per kapita di seluruh 3,142 county dalam kumpulan data `county`. Pendekatan apa yang lebih baik?

E

Kumpulan data `county` istimewa karena setiap county sebenarnya mewakili banyak orang. Jika kita sekadar merata-ratakan variabel `per_capita_income`, county berpenduduk 5,000 dan 5,000,000 akan diberi bobot yang sama dalam perhitungan. Sebagai gantinya, kita perlu menghitung total pendapatan setiap county, menjumlahkan total seluruh county, lalu membaginya dengan jumlah penduduk di seluruh county. Jika langkah-langkah ini diterapkan pada data `county`, kita memperoleh pendapatan per kapita AS sebesar \$30,861. Seandainya kita menghitung rata-rata *sederhana* pendapatan per kapita antar-county, hasilnya hanya \$26,093!


Contoh ini menggunakan apa yang disebut **rata-rata tertimbang**. Untuk mengetahui lebih lanjut tentang topik ini, lihat suplemen daring berikut mengenai rata-rata tertimbang openintro.org/d?file=stat_wtd_mean.

2.1.3 Histogram dan bentuk distribusi

Diagram titik menunjukkan nilai tepat setiap pengamatan. Tampilan ini berguna untuk kumpulan data kecil, tetapi dapat menjadi sulit dibaca pada sampel yang lebih besar. Alih-alih menampilkan nilai setiap pengamatan, kita menganggap setiap nilai sebagai anggota suatu *interval kelas (bin)*. Sebagai contoh, untuk kumpulan data `loan50`, kita membuat tabel hitungan banyaknya pinjaman dengan suku bunga antara 5.0% dan 7.5%, kemudian banyaknya pinjaman dengan suku bunga antara 7.5% dan 10.0%, dan seterusnya. Pengamatan yang tepat berada pada batas interval kelas (misalnya 10.00%) dimasukkan ke kelas yang lebih rendah. Tabulasi ini ditampilkan dalam Gambar 2.5. Hitungan per interval kelas tersebut digambar sebagai batang dalam Gambar 2.6, membentuk apa yang disebut **histogram**. Bentuknya menyerupai diagram titik bertumpuk pada Gambar 2.4, tetapi dengan pengelompokan interval kelas yang lebih lebar.

Suku Bunga	5.0% - 7.5%	7.5% - 10.0%	10.0% - 12.5%	12.5% - 15.0%	...	25.0% - 27.5%
Hitungan	11	15	8	4	...	1

Gambar 2.5: Hitungan data `interest_rate` menurut interval kelas.



Gambar 2.6: Histogram `interest_rate`. Distribusi ini sangat menceng ke kanan.

Histogram menyajikan **kepadatan data**. Batang yang lebih tinggi menunjukkan tempat data relatif lebih sering muncul. Sebagai contoh, kumpulan data ini memuat jauh lebih banyak pinjaman bersuku bunga antara 5% dan 10% daripada pinjaman bersuku bunga antara 20% dan 25%. Batang-

batang tersebut memudahkan kita melihat perubahan kepadatan data terhadap suku bunga.

Histogram sangat berguna untuk memahami bentuk distribusi data. Gambar 2.6 menunjukkan bahwa sebagian besar pinjaman mempunyai suku bunga di bawah 15%, sedangkan hanya segelintir yang bersuku bunga di atas 20%. Jika data makin jarang ke arah kanan seperti ini dan mempunyai ekor kanan yang lebih panjang, bentuknya disebut **menceng kanan**.⁵

Kumpulan data dengan ciri sebaliknya—ekor panjang yang lebih tipis ke arah kiri—disebut **menceng kiri**. Distribusi demikian juga dikatakan mempunyai ekor kiri yang panjang. Kumpulan data yang makin jarang dengan pola kira-kira sama pada kedua arah disebut **simetris**.

MENGENALI KEMENCENGAN DARI EKOR PANJANG

Jika data makin jarang ke satu arah, distribusi mempunyai **ekor panjang**. Distribusi dengan ekor kiri panjang bersifat menceng kiri. Distribusi dengan ekor kanan panjang bersifat menceng kanan.

LATIHAN TERBIMBING 2.9

- Ⓔ Perhatikan diagram titik dalam Gambar 2.3 dan 2.4. Dapatkah Anda melihat kemencengan data? Apakah kemencengan lebih mudah dilihat pada histogram ini atau pada diagram titik?⁶

LATIHAN TERBIMBING 2.10

- Ⓔ Selain rata-rata (karena telah diberi label), apa yang dapat Anda lihat pada diagram titik tetapi tidak pada histogram?⁷

Selain memperhatikan apakah distribusi menceng atau simetris, histogram dapat digunakan untuk mengenali modus. Sebuah **modus** direpresentasikan oleh puncak yang menonjol dalam distribusi. Histogram *interest_rate* hanya mempunyai satu puncak yang menonjol.

Definisi *modus* yang kadang-kadang diajarkan di kelas matematika adalah nilai yang paling sering muncul dalam kumpulan data. Namun, dalam banyak kumpulan data dunia nyata, lazim sekali tidak ada pengamatan yang nilainya sama. Karena itu, definisi ini tidak praktis untuk analisis data.

Gambar 2.7 menampilkan histogram dengan satu, dua, atau tiga puncak yang menonjol. Distribusi seperti ini masing-masing disebut **unimodal**, **bimodal**, dan **multimodal**. Setiap distribusi yang mempunyai lebih dari 2 puncak menonjol disebut multimodal. Perhatikan bahwa distribusi unimodal itu mempunyai satu puncak menonjol dan satu puncak lain yang kurang menonjol. Puncak kedua tidak dihitung karena tingginya hanya berbeda beberapa pengamatan dari interval-interval kelas di sebelahnya.

CONTOH 2.11

Gambar 2.6 hanya menunjukkan satu modus suku bunga yang menonjol. Apakah distribusinya unimodal, bimodal, atau multimodal?

- Ⓔ Unimodal. Ingatlah bahwa *uni* berarti 1 (bayangkan *unicycle*, sepeda roda satu). Demikian pula, *bi* berarti 2 (bayangkan *bicycle*, sepeda roda dua). Kita menanti ditemukannya *multicycle* untuk melengkapi analogi ini.

LATIHAN TERBIMBING 2.12


- Ⓔ Tinggi badan murid-murid kecil dan guru dewasa di sebuah sekolah dasar kelas K-3 diukur. Berapa banyak modus yang Anda perkirakan ada dalam kumpulan data tinggi badan ini?⁸

⁵Ungkapan lain untuk data yang menceng kanan ialah **menceng ke kanan**, **menceng ke arah nilai tinggi**, atau **menceng ke arah nilai positif**.

⁶Kemencengan terlihat pada ketiga diagram, meskipun diagram titik datar adalah yang paling kurang membantu. Diagram titik bertumpuk dan histogram merupakan visualisasi yang berguna untuk mengenali kemencengan.

⁷Suku bunga setiap pinjaman secara individual.

⁸Mungkin tampak dua kelompok tinggi badan dalam kumpulan data: satu kelompok murid dan satu kelompok



Gambar 2.7: Jika hanya puncak yang menonjol yang dihitung, distribusi-distribusi ini (dari kiri ke kanan) bersifat unimodal, bimodal, dan multimodal. Diagram kiri sengaja disebut unimodal karena yang dihitung adalah puncak yang *menonjol*, bukan sembarang puncak.

Mencari modus bukanlah upaya menemukan satu jawaban tegas dan mutlak benar tentang banyaknya modus dalam distribusi. Karena itu, kata *menonjol* tidak didefinisikan secara ketat dalam buku ini. Bagian terpenting dari penelaahan ini adalah memahami data Anda dengan lebih baik.

2.1.4 Varians dan simpangan baku

Rata-rata diperkenalkan sebagai cara untuk menggambarkan pusat kumpulan data. Variabilitas data juga penting. Di sini kita memperkenalkan dua ukuran variabilitas: varians dan simpangan baku. Keduanya sangat berguna dalam analisis data, walaupun rumusnya agak melelahkan jika dihitung dengan tangan. Di antara keduanya, simpangan baku lebih mudah dipahami dan secara kasar menggambarkan seberapa jauh pengamatan tipikal dari rata-rata.

Jarak suatu pengamatan dari rata-ratanya disebut **simpangan**. Berikut adalah simpangan pengamatan ke-1, ke-2, ke-3, dan ke-50 dalam variabel `interest_rate`:

$$\begin{aligned}x_1 - \bar{x} &= 10.90 - 11.57 = -0.67 \\x_2 - \bar{x} &= 9.92 - 11.57 = -1.65 \\x_3 - \bar{x} &= 26.30 - 11.57 = 14.73 \\&\vdots \\x_{50} - \bar{x} &= 6.08 - 11.57 = -5.49\end{aligned}$$

Jika simpangan-simpangan ini dikuadratkan lalu dirata-ratakan, hasilnya sama dengan **varians** sampel, yang dilambangkan dengan s^2 :

$$\begin{aligned}s^2 &= \frac{(-0.67)^2 + (-1.65)^2 + (14.73)^2 + \cdots + (-5.49)^2}{50 - 1} \\&= \frac{0.45 + 2.72 + 216.97 + \cdots + 30.14}{49} \\&= 25.52\end{aligned}$$

Ketika menghitung varians sampel, kita membagi dengan $n - 1$, bukan dengan n . Ada nuansa matematis di balik pilihan ini, tetapi hasil akhirnya adalah statistik yang sedikit lebih andal dan lebih berguna.

Perhatikan bahwa menguadratkan simpangan menghasilkan dua hal. Pertama, nilai yang besar menjadi relatif jauh lebih besar, seperti terlihat dengan membandingkan $(-0.67)^2$, $(-1.65)^2$, $(14.73)^2$, dan $(-5.49)^2$. Kedua, semua tanda negatif hilang.

orang dewasa. Dengan kata lain, datanya mungkin bimodal.

Ukuran **simpangan baku** didefinisikan sebagai akar kuadrat varians:

$$s = \sqrt{25.52} = 5.05$$


Walaupun sering dihilangkan, subskrip x dapat ditambahkan pada varians dan simpangan baku, yakni s_x^2 dan s_x , jika berguna sebagai pengingat bahwa keduanya merupakan varians dan simpangan baku pengamatan yang dinyatakan oleh $x_1, x_2, \dots, x_n$.

VARIANS DAN SIMPANGAN BAKU

Varians adalah rata-rata kuadrat jarak dari rata-rata. Simpangan baku adalah akar kuadrat varians. Simpangan baku berguna untuk menilai seberapa jauh data tersebar dari rata-rata.

Simpangan baku menyatakan simpangan tipikal pengamatan dari rata-rata. Biasanya sekitar 70% data berada dalam satu simpangan baku dari rata-rata dan sekitar 95% berada dalam dua simpangan baku. Namun, sebagaimana terlihat dalam Gambar 2.8 dan 2.9, persentase ini bukan aturan mutlak.

Seperti rata-rata, nilai populasi untuk varians dan simpangan baku mempunyai lambang khusus: σ^2 untuk varians dan σ untuk simpangan baku. Simbol σ adalah huruf Yunani *sigma*.



Gambar 2.8: Untuk variabel `interest_rate`, 34 dari 50 pinjaman (68%) mempunyai suku bunga dalam 1 simpangan baku dari rata-rata, dan 48 dari 50 pinjaman (96%) mempunyai suku bunga dalam 2 simpangan baku. Biasanya sekitar 70% data berada dalam 1 simpangan baku dari rata-rata dan 95% berada dalam 2 simpangan baku, walaupun ini sama sekali bukan aturan mutlak.

LATIHAN TERBIMBING 2.13

G

Pada halaman 47, konsep bentuk distribusi diperkenalkan. Deskripsi bentuk distribusi yang baik harus mencakup modalitas serta apakah distribusi tersebut simetris atau menceng ke satu sisi. Dengan menggunakan Gambar 2.9 sebagai contoh, jelaskan mengapa deskripsi seperti ini penting.⁹

CONTOH 2.14


E

Gambarkan distribusi variabel `interest_rate` menggunakan histogram dalam Gambar 2.6. Deskripsi harus mencakup pusat, variabilitas, dan bentuk distribusi serta ditempatkan dalam konteksnya. Catat pula kasus yang sangat tidak biasa.

Distribusi suku bunga bersifat unimodal dan menceng ke arah nilai tinggi. Banyak suku bunga berada di dekat rata-rata 11.57%, dan sebagian besar berada dalam satu simpangan baku (5.05%) dari rata-rata. Beberapa suku bunga dalam sampel sangat besar, yaitu di atas 20%.

Dalam praktik, varians dan simpangan baku kadang-kadang digunakan sebagai sarana untuk mencapai tujuan, yaitu mengestimasi secara akurat ketidakpastian yang berkaitan dengan suatu

⁹Gambar 2.9 menunjukkan tiga distribusi yang tampak sangat berbeda, tetapi semuanya mempunyai rata-rata, varians, dan simpangan baku yang sama. Berdasarkan modalitas, kita dapat membedakan diagram pertama (bimodal) dari dua diagram terakhir (unimodal). Berdasarkan kemencengan, kita dapat membedakan diagram terakhir (menceng kanan) dari dua diagram pertama. Walaupun gambar seperti histogram menceritakan kisah yang lebih lengkap, modalitas dan bentuk (simetri/kemencengan) dapat digunakan untuk mencirikan informasi dasar mengenai suatu distribusi.




Gambar 2.9: Tiga distribusi populasi yang sangat berbeda dengan rata-rata $\mu = 0$ dan simpangan baku $\sigma = 1$ yang sama.

statistik sampel. Sebagai contoh, dalam Bab 5, simpangan baku digunakan dalam perhitungan yang membantu kita memahami seberapa besar rata-rata sampel berubah dari satu sampel ke sampel berikutnya.

2.1.5 Diagram kotak, kuartil, dan median

Sebuah **diagram kotak** merangkum suatu kumpulan data menggunakan lima statistik sekaligus menggambarkan pengamatan yang tidak biasa. Gambar 2.10 menyajikan diagram titik vertikal di samping diagram kotak untuk variabel `interest_rate` dari kumpulan data `loan50`.



Gambar 2.10: Diagram titik vertikal dengan titik-titik yang ditumpuk secara horizontal, di sebelah diagram kotak berlabel untuk suku bunga dari 50 pinjaman.

Langkah pertama dalam membuat diagram kotak adalah menggambar garis gelap yang menandai

median, yakni nilai yang membagi data menjadi dua bagian. Gambar 2.10 menunjukkan bahwa 50% data berada di bawah median dan 50% lainnya berada di atas median. Kumpulan data memuat 50 pinjaman (bilangan genap), sehingga data terbagi tepat menjadi dua kelompok yang masing-masing berisi 25 pengamatan. Dalam kasus ini, median diambil sebagai rata-rata dua pengamatan yang paling dekat dengan persentil ke-50. Kebetulan, keduanya mempunyai nilai yang sama dalam kumpulan data ini: $(9.93\% + 9.93\%)/2 = 9.93\%$. Jika banyaknya pengamatan ganjil, tepat satu pengamatan membagi data menjadi dua bagian. Dalam keadaan itu, pengamatan tersebut adalah median (tidak perlu dihitung rata-ratanya).

MEDIAN: BILANGAN DI TENGAH

Jika data diurutkan dari yang terkecil hingga terbesar, **median** adalah pengamatan yang tepat berada di tengah. Jika banyaknya pengamatan genap, terdapat dua nilai di tengah dan mediannya diambil sebagai rata-rata kedua nilai tersebut.

Langkah kedua dalam membuat diagram kotak adalah menggambar persegi panjang yang mewakili 50% data bagian tengah. Panjang keseluruhan kotak, yang ditampilkan secara vertikal dalam Gambar 2.10, disebut **rentang antarkuartil** (disingkat IQR). Seperti simpangan baku, IQR merupakan ukuran variabilitas data. Makin bervariasi datanya, makin besar pula kecenderungan nilai simpangan baku dan IQR. Kedua batas kotak disebut **kuartil pertama** (persentil ke-25, yakni 25% data berada di bawah nilai ini) dan **kuartil ketiga** (persentil ke-75). Keduanya sering dilambangkan berturut-turut dengan Q_1 dan Q_3 .

RENTANG ANTARKUARTIL (IQR)

IQR adalah panjang kotak dalam diagram kotak. Nilainya dihitung sebagai

$$IQR = Q_3 - Q_1$$

dengan Q_1 dan Q_3 masing-masing merupakan persentil ke-25 dan ke-75.

LATIHAN TERBIMBING 2.15



Berapa persen data yang berada di antara Q_1 dan median? Berapa persen yang berada di antara median dan Q_3 ?¹⁰

Dari kotak, **garis kumis** (whisker) menjulur untuk mencakup data di luar kotak. Namun, jangkauannya tidak pernah diizinkan melebihi $1.5 \times IQR$. Garis kumis mencakup semua data yang berada dalam jangkauan ini. Dalam Gambar 2.10, garis kumis atas tidak menjangkau dua titik terakhir karena keduanya berada di atas $Q_3 + 1.5 \times IQR$. Karena itu, garis tersebut hanya menjulur hingga titik terakhir di bawah batas ini. Garis kumis bawah berhenti pada nilai terendah, 5.31%, karena tidak ada data lain yang perlu dijangkau. Batas garis kumis bawah tidak ditampilkan dalam gambar karena diagram tidak membentang hingga $Q_1 - 1.5 \times IQR$. Kotak dapat dibayangkan sebagai tubuh diagram kotak, sedangkan garis kumis seperti lengan yang berusaha menjangkau sisa data.

Setiap pengamatan di luar garis kumis ditandai dengan sebuah titik. Tujuan menandai titik-titik ini—alih-alih memanjangkan garis kumis hingga nilai minimum dan maksimum yang diamati—adalah membantu mengenali pengamatan yang tampak sangat jauh dari data lainnya. Pengamatan yang sangat jauh disebut **pencilan**. Dalam kasus ini, suku bunga 24.85% dan 26.30% wajar digolongkan sebagai pencilan karena secara numerik jauh dari sebagian besar data.

¹⁰Karena Q_1 dan Q_3 mencakup 50% data bagian tengah dan median membelah data di tengah, 25% data berada di antara Q_1 dan median, sedangkan 25% lainnya berada di antara median dan Q_3 .

PENCILAN BERSIFAT EKSTREM

Sebuah **pencilan** adalah pengamatan yang tampak ekstrem dibandingkan dengan data lainnya.

Menelaah data untuk mencari pencilan mempunyai banyak kegunaan, antara lain

1. Mengenali kemencengan kuat dalam distribusi.
2. Mengenali kemungkinan kesalahan pengumpulan atau entri data.
3. Memberikan wawasan tentang sifat-sifat data yang menarik.


LATIHAN TERBIMBING 2.16

Dengan menggunakan Gambar 2.10, estimasikan nilai-nilai berikut untuk `interest_rate` dalam kumpulan data `loan50`:

(a) Q_1 , (b) Q_3 , dan (c) IQR.¹¹

2.1.6 Statistik robust

Bagaimana statistik sampel untuk variabel `interest_rate` dipengaruhi oleh pengamatan 26.3%? Apa yang akan terjadi jika suku bunga pinjaman ini hanya 15%? Apa yang akan terjadi pada statistik ringkasan jika pengamatan 26.3% justru lebih besar, misalnya 35%? Skenario-skenario ini digambar bersama data asli dalam Gambar 2.11, dan statistik sampel untuk setiap skenario dihitung dalam Gambar 2.12.



Gambar 2.11: Diagram titik data suku bunga asli dan dua kumpulan data hasil modifikasi.

skenario	robust		tidak robust	
	median	IQR	$\bar{x}$	s
data <code>interest_rate</code> asli	9.93%	5.76%	11.57%	5.05%
pindahkan 26.3% $\rightarrow$ 15%	9.93%	5.76%	11.34%	4.61%
pindahkan 26.3% $\rightarrow$ 35%	9.93%	5.76%	11.74%	5.68%

Gambar 2.12: Perbandingan perubahan median, IQR, rata-rata ($\bar{x}$), dan simpangan baku (s) seandainya satu pengamatan ekstrem dalam variabel `interest_rate` mempunyai nilai yang berbeda.

LATIHAN TERBIMBING 2.17

(a) Manakah yang lebih dipengaruhi pengamatan ekstrem, rata-rata atau median? Gambar 2.12 mungkin membantu. (b) Manakah yang lebih dipengaruhi pengamatan ekstrem, simpangan baku atau IQR?¹²

¹¹Estimasi visual ini akan sedikit berbeda dari satu orang ke orang lain: $Q_1 = 8\%$, $Q_3 = 14\%$, $IQR = Q_3 - Q_1 = 6\%$. (Nilai sebenarnya: $Q_1 = 7.96\%$, $Q_3 = 13.72\%$, $IQR = 5.76\%$.)

Median dan IQR disebut **statistik robust** karena pengamatan ekstrem hanya sedikit memengaruhi nilainya: memindahkan nilai yang paling ekstrem umumnya hanya sedikit memengaruhi kedua statistik ini. Sebaliknya, rata-rata dan simpangan baku lebih banyak dipengaruhi oleh perubahan pengamatan ekstrem, dan hal ini dapat menjadi penting dalam situasi tertentu.

CONTOH 2.18

Median dan IQR tidak berubah dalam ketiga skenario pada Gambar 2.12. Mengapa demikian?


Median dan IQR hanya peka terhadap bilangan di dekat Q_1 , median, dan Q_3 . Karena nilai dalam wilayah-wilayah ini stabil pada ketiga kumpulan data, estimasi median dan IQR juga stabil.

LATIHAN TERBIMBING 2.19

Distribusi jumlah pinjaman dalam kumpulan data `loan50` menceng kanan, dengan beberapa pinjaman besar berada jauh di ekor kanan. Jika Anda ingin memahami besar pinjaman yang tipikal, apakah rata-rata atau median yang lebih relevan?¹³

2.1.7 Mentransformasi data (topik khusus)

Jika data sangat menceng, kita kadang-kadang mentransformasinya agar lebih mudah dimodelkan.



Gambar 2.13: (a) Histogram populasi seluruh county di AS. (b) Histogram populasi county setelah transformasi $\log_{10}$. Dalam diagram ini, nilai x menyatakan pangkat 10; misalnya, “4” pada sumbu x bersesuaian dengan $10^4 = 10,000$.

CONTOH 2.20


Perhatikan histogram populasi county dalam Gambar 2.13(a), yang sangat menceng. Apa yang membuat diagram ini kurang berguna?

Hampir semua data masuk ke interval kelas paling kiri, dan kemencengan yang ekstrem menyamarkan banyak rincian data yang sebenarnya berpotensi menarik.

Beberapa transformasi standar dapat berguna untuk data yang sangat menceng kanan, ketika sebagian besar datanya positif tetapi mengelompok di dekat nol. Sebuah **transformasi** adalah

¹²(a) Rata-rata lebih terpengaruh. (b) Simpangan baku lebih terpengaruh. Penjelasan lengkap diberikan dalam materi setelah Latihan Terbimbing 2.17.

¹³Jawaban dapat bervariasi! Jika kita hanya ingin memahami seperti apa satu pinjaman yang tipikal, median mungkin lebih berguna. Namun, jika tujuannya memahami besaran yang dapat diskalakan, seperti total uang yang perlu tersedia jika kita menawarkan 1,000 pinjaman, rata-rata akan lebih berguna.



Gambar 2.14: (a) Diagram pencar perubahan populasi terhadap populasi sebelum perubahan. (b) Diagram pencar data yang sama setelah ukuran populasi ditransformasi dengan logaritma.

perubahan skala data menggunakan suatu fungsi. Sebagai contoh, menggambar logaritma (basis 10) dari populasi county menghasilkan histogram baru dalam Gambar 2.13(b). Data ini simetris, dan setiap pencilan potensial tampak jauh kurang ekstrem daripada dalam kumpulan data asli. Dengan meredam pencilan dan kemencengan ekstrem, transformasi seperti ini sering memudahkan penyusunan model statistik untuk data.

Transformasi juga dapat diterapkan pada salah satu atau kedua variabel dalam diagram pencar. Diagram pencar perubahan populasi dari 2010 hingga 2017 terhadap populasi pada 2010 ditampilkan dalam Gambar 2.14(a). Pada diagram pencar pertama ini, pola yang menarik sulit dikenali karena variabel populasi sangat menceng. Namun, jika transformasi $\log_{10}$ diterapkan pada variabel populasi seperti dalam Gambar 2.14(b), terlihat asosiasi positif antara kedua variabel. Bahkan, ketika mempelajari metode pencocokan garis regresi dalam Bab belum dimuat, kita mungkin tertarik mencocokkan sebuah garis tren pada data ini.

Transformasi selain logaritma juga dapat berguna. Sebagai contoh, akar kuadrat ($\sqrt{\text{pengamatan asli}}$) dan kebalikan ($\frac{1}{\text{pengamatan asli}}$) lazim digunakan oleh ilmuwan data. Tujuan umum transformasi data adalah melihat struktur data dari sudut berbeda, mengurangi kemencengan, membantu pemodelan, atau meluruskan hubungan nonlinear dalam diagram pencar.

2.1.8 Memetakan data (topik khusus)

Kumpulan data `county` menyediakan banyak variabel numerik yang dapat kita gambar dengan diagram titik, diagram pencar, atau diagram kotak, tetapi ketiganya tidak menangkap sifat geografis data. Ketika berhadapan dengan data geografis, kita sebaiknya membuat **peta intensitas**, yang menggunakan warna untuk menunjukkan nilai variabel yang lebih tinggi dan lebih rendah. Gambar 2.15 dan 2.16 menampilkan peta intensitas untuk persentase tingkat kemiskinan (`poverty`), tingkat pengangguran (`unemployment_rate`), persentase tingkat kepemilikan rumah (`homeownership`), dan median pendapatan rumah tangga (`median_hh_income`). Kunci warna menunjukkan warna yang bersesuaian dengan setiap nilai. Peta intensitas umumnya tidak terlalu membantu untuk memperoleh nilai tepat di suatu county, tetapi sangat membantu untuk melihat tren geografis dan merumuskan pertanyaan penelitian atau hipotesis yang menarik.

CONTOH 2.21

Ciri menarik apa yang tampak pada peta intensitas `poverty` dan `unemployment_rate`?


Tingkat kemiskinan jelas lebih tinggi di beberapa lokasi. Khususnya, wilayah Selatan Jauh menunjukkan tingkat kemiskinan yang lebih tinggi, demikian pula sebagian besar Arizona dan New Mexico. Tingkat kemiskinan tinggi tampak di dataran banjir Mississippi yang sedikit ke utara dari New Orleans serta di sebagian besar Kentucky.

Tingkat pengangguran mengikuti tren serupa, dan kita dapat melihat kesesuaian antara kedua variabel. Memang masuk akal apabila tingkat pengangguran yang lebih tinggi berkaitan erat dengan tingkat kemiskinan. Satu pengamatan menonjol saat kedua peta dibandingkan: tingkat kemiskinan jauh lebih tinggi daripada tingkat pengangguran. Artinya, walaupun banyak orang mungkin bekerja, penghasilan mereka tidak cukup untuk keluar dari kemiskinan.


LATIHAN TERBIMBING 2.22

Ciri menarik apa yang tampak pada peta intensitas `median_hh_income` dalam Gambar 2.16(b)?¹⁴

¹⁴Catatan: jawaban dapat bervariasi. Ada kesesuaian tertentu antara pendapatan tinggi dan kawasan metropolitan, yang tampak sebagai daerah lebih gelap (median pendapatan rumah tangga lebih tinggi), walaupun ada beberapa pengecualian. Anda dapat mencari kota-kota besar yang Anda kenal dan mencoba menemukannya sebagai daerah gelap pada peta.



Gambar 2.15: (a) Peta intensitas tingkat kemiskinan (persen). (b) Peta tingkat pengangguran (persen).




Gambar 2.16: (a) Peta intensitas tingkat kepemilikan rumah (persen). (b) Peta intensitas median pendapatan rumah tangga (\$1000-an).


Latihan

2.1 Rentang hidup mamalia. Data rentang hidup (dalam tahun) dan masa kehamilan (dalam hari) dikumpulkan untuk 62 mamalia. Diagram pencar rentang hidup terhadap masa kehamilan ditampilkan di bawah ini.¹⁵

- Jenis asosiasi apa yang tampak antara rentang hidup dan masa kehamilan?
- Jenis asosiasi apa yang Anda perkirakan akan terlihat jika sumbu-sumbu diagram dibalik, yaitu jika masa kehamilan diplot terhadap rentang hidup?
- Apakah rentang hidup dan masa kehamilan saling bebas? Jelaskan alasan Anda.



2.2 Asosiasi. Tentukan diagram mana yang menunjukkan (a) asosiasi positif, (b) asosiasi negatif, atau (c) tidak ada asosiasi. Tentukan juga apakah asosiasi positif dan negatif tersebut linear atau nonlinear. Setiap bagian dapat merujuk pada lebih dari satu diagram.



2.3 Bakteri berkembang biak. Andaikan ruang dan nutrisi dalam sebuah cawan petri hanya cukup untuk menampung satu juta sel bakteri. Anda menempatkan beberapa sel bakteri di dalam cawan petri tersebut, membiarkannya berkembang biak tanpa hambatan, dan mencatat jumlah sel bakteri di dalam cawan dari waktu ke waktu. Buatlah sketsa diagram yang menggambarkan hubungan antara jumlah sel bakteri dan waktu.

2.4 Produktivitas kantor. Produktivitas kantor relatif rendah ketika karyawan sama sekali tidak merasa

¹⁵T. Allison and D.V. Cicchetti. "Sleep in mammals: ecological and constitutional correlates". In: *Arch. Hydrobiol.* 75 (1975), p. 442.

tertekan oleh pekerjaan atau keamanan kerja mereka. Namun, tingkat stres yang tinggi juga dapat menurunkan produktivitas karyawan. Buatlah sketsa diagram yang menggambarkan hubungan antara stres dan produktivitas.

2.5 Parameter dan statistik. Tentukan nilai mana yang merupakan rata-rata sampel dan nilai mana yang merupakan rata-rata populasi yang diklaim.

- (a) Pada tahun 2007, rumah tangga di Amerika Serikat membelanjakan rata-rata sekitar \$52 untuk keperluan Halloween seperti kostum, dekorasi, dan permen. Untuk mengetahui apakah angka ini telah berubah, peneliti melakukan survei baru pada tahun 2008 sebelum angka dari industri dilaporkan. Survei tersebut mencakup 1,500 rumah tangga dan menemukan bahwa pengeluaran Halloween rata-rata adalah \$58 per rumah tangga.
- (b) Rata-rata indeks prestasi kumulatif (GPA) mahasiswa pada tahun 2001 di sebuah universitas swasta adalah 3.37. Satu dekade kemudian, survei terhadap sampel yang terdiri atas 203 mahasiswa dari universitas tersebut menghasilkan GPA rata-rata sebesar 3.59.

2.6 Tidur semasa kuliah. Sebuah artikel terbaru di surat kabar kampus menyatakan bahwa mahasiswa tidur rata-rata 5.5 jam setiap malam. Seorang mahasiswa yang meragukan nilai ini memutuskan untuk melakukan survei dengan mengambil sampel acak sebanyak 25 mahasiswa. Mahasiswa dalam sampel tersebut tidur rata-rata 6.25 jam per malam. Tentukan nilai mana yang merupakan rata-rata sampel dan nilai mana yang merupakan rata-rata populasi yang diklaim.

2.7 Hari libur di lokasi pertambangan. Para pekerja di sebuah lokasi pertambangan menerima rata-rata 35 hari cuti berbayar, lebih rendah daripada rata-rata nasional. Manajer lokasi tersebut mendapat tekanan dari serikat pekerja setempat untuk menambah jumlah hari cuti berbayar. Namun, ia tidak ingin memberi pekerja lebih banyak hari libur karena hal itu akan mahal. Sebagai gantinya, ia memutuskan untuk memecat 10 karyawan sedemikian rupa sehingga rata-rata jumlah hari libur yang dilaporkan oleh para karyawannya meningkat. Untuk mencapai tujuan ini, apakah ia harus memecat karyawan yang memiliki hari libur terbanyak, yang memiliki hari libur paling sedikit, atau yang memiliki jumlah hari libur sekitar rata-rata?


2.8 Median dan IQR. Untuk setiap bagian, bandingkan distribusi (1) dan (2) berdasarkan median dan IQR-nya. Anda tidak perlu menghitung statistik tersebut; cukup nyatakan bagaimana median dan IQR kedua distribusi dibandingkan. Pastikan untuk menjelaskan alasan Anda.

- | | |
|-----------------------|----------------------------|
| (a) (1) 3, 5, 6, 7, 9 | (c) (1) 1, 2, 3, 4, 5 |
| (2) 3, 5, 6, 7, 20 | (2) 6, 7, 8, 9, 10 |
| (b) (1) 3, 5, 6, 7, 9 | (d) (1) 0, 10, 50, 60, 100 |
| (2) 3, 5, 7, 8, 9 | (2) 0, 100, 500, 600, 1000 |

2.9 Rata-rata dan simpangan baku. Untuk setiap bagian, bandingkan distribusi (1) dan (2) berdasarkan rata-rata dan simpangan bakunya. Anda tidak perlu menghitung statistik tersebut; cukup nyatakan bagaimana rata-rata dan simpangan baku kedua distribusi dibandingkan. Pastikan untuk menjelaskan alasan Anda.
Petunjuk: Membuat sketsa diagram titik kedua distribusi mungkin berguna.


- | | |
|---------------------------------------|---------------------------------|
| (a) (1) 3, 5, 5, 5, 8, 11, 11, 11, 13 | (c) (1) 0, 2, 4, 6, 8, 10 |
| (2) 3, 5, 5, 5, 8, 11, 11, 11, 20 | (2) 20, 22, 24, 26, 28, 30 |
| (b) (1) -20, 0, 0, 0, 15, 25, 30, 30 | (d) (1) 100, 200, 300, 400, 500 |
| (2) -40, 0, 0, 0, 15, 25, 30, 30 | (2) 0, 50, 300, 550, 600 |

2.10 Cocokkan. Deskripsikan distribusi pada histogram di bawah ini dan cocokkan setiap histogram dengan diagram kotaknya.




2.11 Kualitas udara. Kualitas udara harian diukur dengan indeks kualitas udara (AQI) yang dilaporkan oleh Badan Perlindungan Lingkungan Amerika Serikat. Indeks ini melaporkan tingkat pencemaran dan dampak kesehatan terkait yang mungkin perlu diperhatikan. Indeks tersebut dihitung untuk lima pencemar udara utama yang diatur oleh Undang-Undang Udara Bersih dan memiliki nilai dari 0 hingga 300; nilai yang lebih tinggi menunjukkan kualitas udara yang lebih rendah. AQI dilaporkan untuk sampel sebanyak 91 hari pada tahun 2011 di Durham, Carolina Utara. Histogram frekuensi relatif di bawah ini menunjukkan distribusi nilai AQI pada hari-hari tersebut.¹⁶


- Perkirakan nilai median AQI sampel ini.
- Apakah Anda memperkirakan nilai rata-rata AQI sampel ini lebih tinggi atau lebih rendah daripada mediannya? Jelaskan alasan Anda.
- Perkirakan Q1, Q3, dan IQR distribusi tersebut.
- Apakah ada hari dalam sampel ini yang dapat dianggap memiliki AQI yang sangat rendah atau sangat tinggi? Jelaskan alasan Anda.



2.12 Median versus rata-rata. Perkirakan median untuk 400 pengamatan yang ditampilkan dalam histogram, lalu nyatakan apakah Anda memperkirakan rata-ratanya lebih tinggi atau lebih rendah daripada median.



2.13 Histogram versus diagram kotak. Bandingkan kedua diagram di bawah ini. Karakteristik distribusi apa yang tampak dalam histogram tetapi tidak dalam diagram kotak? Karakteristik apa yang tampak dalam diagram kotak tetapi tidak dalam histogram?



2.14 Teman Facebook. Data Facebook menunjukkan bahwa 50% pengguna Facebook memiliki 100 teman atau lebih dan bahwa jumlah teman rata-rata pengguna adalah 190. Apa yang disiratkan oleh temuan ini

¹⁶US Environmental Protection Agency, AirData, 2011.

tentang bentuk distribusi jumlah teman pengguna Facebook?¹⁷

2.15 Distribusi dan statistik yang sesuai, Bagian I. Untuk setiap hal berikut, nyatakan apakah Anda memperkirakan distribusinya simetris, menceng kanan, atau menceng kiri. Tentukan juga apakah rata-rata atau median paling tepat mewakili pengamatan tipikal dalam data, serta apakah variabilitas pengamatan paling tepat diwakili oleh simpangan baku atau IQR. Jelaskan alasan Anda.


- (a) Jumlah hewan peliharaan per rumah tangga.
- (b) Jarak ke tempat kerja, yaitu jarak dalam mil antara tempat kerja dan rumah.
- (c) Tinggi badan laki-laki dewasa.

¹⁷Lars Backstrom. "Anatomy of Facebook". In: *Facebook Data Team's Notes* (2011).


2.16 Distribusi dan statistik yang sesuai, Bagian II. Untuk setiap hal berikut, nyatakan apakah Anda memperkirakan distribusinya simetris, menceng kanan, atau menceng kiri. Tentukan juga apakah rata-rata atau median paling tepat mewakili pengamatan tipikal dalam data, serta apakah variabilitas pengamatan paling tepat diwakili oleh simpangan baku atau IQR. Jelaskan alasan Anda.

- Harga rumah di sebuah negara tempat 25% rumah berharga di bawah \$350,000, 50% rumah berharga di bawah \$450,000, 75% rumah berharga di bawah \$1,000,000, dan cukup banyak rumah berharga lebih dari \$6,000,000.
- Harga rumah di sebuah negara tempat 25% rumah berharga di bawah \$300,000, 50% rumah berharga di bawah \$600,000, 75% rumah berharga di bawah \$900,000, dan sangat sedikit rumah berharga lebih dari \$1,200,000.
- Jumlah minuman beralkohol yang dikonsumsi mahasiswa dalam satu minggu. Andaikan sebagian besar mahasiswa tersebut tidak minum karena berusia di bawah 21 tahun dan hanya sedikit yang minum secara berlebihan.
- Gaji tahunan karyawan di sebuah perusahaan Fortune 500, tempat hanya beberapa eksekutif tingkat tinggi yang memperoleh gaji jauh lebih besar daripada semua karyawan lain.

2.17 Pendapatan di kedai kopi. Histogram pertama di bawah ini menunjukkan distribusi pendapatan tahunan 40 pelanggan di sebuah kedai kopi kampus. Andaikan dua orang baru memasuki kedai kopi tersebut: seorang berpenghasilan \$225,000 dan seorang lagi berpenghasilan \$250,000. Histogram kedua menunjukkan distribusi pendapatan yang baru. Statistik ringkasan juga disediakan.



(1)




(2)

	(1)	(2)
n	40	42
Min.	60,680	60,680
Ku. 1	63,620	63,710
Median	65,240	65,350
Rata-rata	65,090	73,300
Ku. 3	66,160	66,540
Maks.	69,890	250,000
Simp. baku	2,122	37,321

- Apakah rata-rata atau median paling tepat mewakili pendapatan yang dapat kita anggap tipikal bagi 42 pelanggan kedai kopi ini? Apa yang ditunjukkan hal tersebut tentang sifat robust kedua ukuran ini?
- Apakah simpangan baku atau IQR paling tepat mewakili besarnya variabilitas pendapatan 42 pelanggan kedai kopi ini? Apa yang ditunjukkan hal tersebut tentang sifat robust kedua ukuran ini?


2.18 Nilai tengah rentang. *Nilai tengah rentang* suatu distribusi didefinisikan sebagai rata-rata dari nilai maksimum dan minimum distribusi tersebut. Apakah statistik ini robust terhadap pencilan dan kemencengan ekstrem? Jelaskan alasan Anda.

2.19 Waktu perjalanan ke tempat kerja. Sensus Amerika Serikat mengumpulkan data tentang waktu yang dibutuhkan penduduk Amerika untuk bepergian ke tempat kerja, selain banyak variabel lain. Histogram di bawah ini menunjukkan distribusi waktu perjalanan rata-rata di 3,142 county di Amerika Serikat pada tahun 2010. Peta intensitas spasial dari data yang sama juga ditampilkan di bawah ini.



- Deskripsikan distribusi numeriknya dan berikan pendapat apakah transformasi logaritma layak diterapkan pada data ini.
- Deskripsikan distribusi spasial waktu perjalanan ke tempat kerja dengan menggunakan peta di atas.

2.20 Populasi Hispanik. Sensus Amerika Serikat mengumpulkan data tentang ras dan etnis penduduk Amerika, selain banyak variabel lain. Histogram di bawah ini menunjukkan distribusi persentase penduduk Hispanik di 3,142 county di Amerika Serikat pada tahun 2010. Histogram logaritma nilai-nilai tersebut juga ditampilkan.



- Deskripsikan distribusi numeriknya dan jelaskan mengapa kita mungkin ingin menggunakan nilai yang telah ditransformasi dengan logaritma ketika menganalisis atau memodelkan data ini.
- Karakteristik distribusi populasi Hispanik di county-county Amerika Serikat apa yang tampak pada peta tetapi tidak pada histogram? Karakteristik apa yang tampak pada histogram tetapi tidak pada peta?
- Apakah salah satu visualisasi lebih tepat atau lebih membantu daripada yang lain? Jelaskan alasan Anda.

2.2 Menelaah data kategoris

Pada bagian ini, kita akan memperkenalkan tabel dan perangkat dasar lain untuk data kategoris yang digunakan di seluruh buku ini. Himpunan data `loan50` merupakan sampel dari himpunan data pinjaman yang lebih besar, yaitu `loans`. Himpunan data yang lebih besar ini memuat informasi tentang 10,000 pinjaman yang diberikan melalui Lending Club. Kita akan menelaah hubungan antara `homeownership`, yang dalam data `loans` dapat bernilai `rent`, `mortgage` (memiliki rumah, tetapi masih menanggung hipotek), atau `own`, dan `app_type`, yang menunjukkan apakah pengajuan pinjaman dilakukan bersama pemohon lain atau diajukan secara perorangan.

2.2.1 Tabel kontingensi dan diagram batang

Gambar 2.17 merangkum dua variabel: `app_type` dan `homeownership`. Tabel yang merangkum data untuk dua variabel kategoris dengan cara ini disebut **tabel kontingensi**. Setiap nilai dalam tabel menyatakan berapa kali kombinasi hasil variabel tertentu muncul. Sebagai contoh, nilai 3496 menyatakan banyaknya pinjaman dalam himpunan data ketika peminjam menyewa rumahnya dan jenis pengajuannya adalah perorangan. Total baris dan kolom juga disertakan. **Total baris** memberikan jumlah keseluruhan pada setiap baris (misalnya $3496 + 3839 + 1170 = 8505$), sedangkan **total kolom** merupakan jumlah keseluruhan pada setiap kolom. Kita juga dapat membuat tabel yang hanya menampilkan persentase atau proporsi keseluruhan untuk setiap kombinasi kategori, atau membuat tabel untuk satu variabel saja, seperti yang ditampilkan pada Gambar 2.18 untuk variabel `homeownership`.


		homeownership			Total
		sewa	hipotek	milik	
app-type	perorangan	3496	3839	1170	8505
	bersama	362	950	183	1495
	Total	3858	4789	1353	10000

Gambar 2.17: Tabel kontingensi untuk `app_type` dan `homeownership`.

homeownership	Frekuensi
sewa	3858
hipotek	4789
milik	1353
Total	10000

Gambar 2.18: Tabel yang merangkum frekuensi setiap nilai variabel `homeownership`.

Diagram batang merupakan cara yang lazim untuk menampilkan satu variabel kategoris. Panel kiri Gambar 2.19 menampilkan **diagram batang** untuk variabel `homeownership`. Pada panel kanan, frekuensi diubah menjadi proporsi, yang menunjukkan proporsi pengamatan pada setiap kategori (misalnya $3858/10000 = 0.3858$ untuk `rent`).



Gambar 2.19: Dua diagram batang untuk **homeownership**. Panel kiri menunjukkan frekuensi, sedangkan panel kanan menunjukkan proporsi setiap kelompok.

2.2.2 Proporsi baris dan kolom

Kadang-kadang kita perlu memahami pembagian proporsional satu variabel di dalam variabel lain, dan tabel kontingensi dapat diubah untuk memberikan tampilan tersebut. Gambar 2.20 menampilkan **proporsi baris** untuk Gambar 2.17, yang dihitung dengan membagi frekuensi setiap sel dengan total barisnya. Nilai 3496 pada perpotongan **individual** dan **rent** diganti dengan $3496/8505 = 0.411$, yaitu 3496 dibagi dengan total barisnya, 8505. Jadi, apa arti 0.411? Nilai itu adalah proporsi pemohon perorangan yang menyewa rumah.

	sewa	hipotek	milik	Total
perorangan	0.411	0.451	0.138	1.000
bersama	0.242	0.635	0.122	1.000
Total	0.386	0.479	0.135	1.000

Gambar 2.20: Tabel kontingensi dengan proporsi baris untuk variabel **app_type** dan **homeownership**. Total baris **joint** berselisih 0.001 akibat pembulatan.

Tabel kontingensi berisi proporsi kolom dihitung dengan cara serupa; setiap **proporsi kolom** dihitung dengan membagi frekuensi sel dengan total kolom yang bersesuaian. Gambar 2.21 menampilkan tabel semacam itu, dan nilai 0.906 menunjukkan bahwa 90.6% penyewa mengajukan pinjaman secara perorangan. Angka ini lebih tinggi daripada pinjaman dari orang yang memiliki rumah dengan hipotek (80.2%) atau memiliki rumah (86.5%). Karena angka-angka tersebut berbeda di antara ketiga kategori **homeownership** (**rent**, **mortgage**, **own**), hal ini menjadi bukti adanya hubungan antara variabel **app_type** dan **homeownership**.

	sewa	hipotek	milik	Total
perorangan	0.906	0.802	0.865	0.851
bersama	0.094	0.198	0.135	0.150
Total	1.000	1.000	1.000	1.000

Gambar 2.21: Tabel kontingensi dengan proporsi kolom untuk variabel **app_type** dan **homeownership**. Total pada kolom terakhir berselisih 0.001 akibat pembulatan.

Kita juga dapat memeriksa hubungan antara **app_type** dan **homeownership** pada Gambar 2.20 dengan menggunakan proporsi baris. Ketika membandingkan proporsi baris tersebut, kita melihat ke bawah pada setiap kolom untuk mengetahui apakah proporsi pinjaman bagi peminjam yang menyewa, memiliki hipotek, atau memiliki rumah berbeda antara jenis pengajuan **individual** dan **joint**.

LATIHAN TERBIMBING 2.23

G

- (a) Apa arti 0.451 pada Gambar 2.20?
 (b) Apa arti 0.802 pada Gambar 2.21?¹⁸

LATIHAN TERBIMBING 2.24

G

- (a) Apa arti 0.122 pada perpotongan **joint** dan **own** dalam Gambar 2.20?
 (b) Apa arti 0.135 pada Gambar 2.21?¹⁹

CONTOH 2.25

Ilmuwan data menggunakan statistika untuk menyaring spam dari pesan surel masuk. Dengan memperhatikan karakteristik tertentu pada sebuah surel, ilmuwan data dapat menggolongkan sebagian surel sebagai spam atau bukan spam dengan ketepatan tinggi. Salah satu karakteristik tersebut ialah apakah surel tidak memuat angka, memuat angka kecil, atau memuat angka besar. Karakteristik lainnya ialah format surel, yang menunjukkan apakah sebuah surel memuat konten HTML, misalnya teks tebal. Kita akan memusatkan perhatian pada format surel dan status spam dalam himpunan data **email**; kedua variabel tersebut dirangkum dalam tabel kontingensi pada Gambar 2.22. Untuk orang yang ingin menggolongkan surel sebagai spam atau surel biasa, manakah yang lebih membantu: proporsi baris atau proporsi kolom?

E

Ilmuwan data akan tertarik pada perubahan proporsi spam di dalam setiap format surel. Hal ini bersesuaian dengan proporsi kolom: proporsi spam dalam surel teks biasa dan proporsi spam dalam surel HTML.

Jika kita menghitung proporsi kolom, terlihat bahwa proporsi surel teks biasa yang merupakan spam ($209/1195 = 17.5\%$) lebih tinggi daripada proporsi surel HTML yang merupakan spam ($158/2726 = 5.8\%$). Informasi ini saja belum cukup untuk menggolongkan sebuah surel sebagai spam atau bukan spam, sebab lebih dari 80% surel teks biasa bukanlah spam. Namun, bila informasi ini dipadukan secara cermat dengan banyak karakteristik lain, cukup masuk akal bahwa kita dapat menggolongkan sebagian surel sebagai spam atau bukan spam dengan yakin.

	teks	HTML	Total
spam	209	158	367
bukan spam	986	2568	3554
Total	1195	2726	3921

Gambar 2.22: Tabel kontingensi untuk **spam** dan **format**.

Contoh 2.25 menunjukkan bahwa proporsi baris dan proporsi kolom tidaklah setara. Sebelum memilih satu bentuk tabel, keduanya perlu dipertimbangkan agar tabel yang paling berguna dapat dibuat. Namun, kadang-kadang memang tidak jelas mana yang lebih berguna, atau apakah salah satunya berguna.

¹⁸(a) 0.451 menyatakan proporsi pemohon perorangan yang memiliki hipotek. (b) 0.802 menyatakan proporsi pemohon dengan hipotek yang mengajukan pinjaman secara perorangan.

¹⁹(a) 0.122 menyatakan proporsi peminjam bersama yang memiliki rumah. (b) 0.135 menyatakan proporsi peminjam pemilik rumah yang mengajukan pinjaman bersama.

CONTOH 2.26

Perhatikan kembali Tabel 2.20 dan 2.21. Adakah situasi yang jelas ketika salah satunya lebih berguna daripada yang lain?

E

Tidak ada yang menurut kami jelas! Perbedaan antara **app_type** dan **homeownership** dengan contoh surel ialah bahwa kedua variabel tersebut tidak memiliki hubungan variabel penjelas-respons yang jelas untuk dihipotesiskan (lihat Bagian 1.2.4 untuk istilah ini). Biasanya, paling berguna bila kita "mengondisikan" pada variabel penjelas. Misalnya, dalam contoh surel, format surel dipandang sebagai kemungkinan variabel penjelas bagi status spam suatu pesan. Karena itu, lebih menarik untuk menghitung frekuensi relatif (proporsi) pada setiap format surel.

2.2.3 Menggunakan diagram batang untuk dua variabel

Tabel kontingensi yang menggunakan proporsi baris atau kolom sangat berguna untuk menelaah hubungan antara dua variabel kategoris. Diagram batang bertumpuk menyediakan cara untuk memvisualisasikan informasi dalam tabel tersebut.

Diagram batang bertumpuk merupakan tampilan grafis dari informasi tabel kontingensi. Sebagai contoh, diagram batang bertumpuk yang mewakili Gambar 2.21 ditampilkan pada Gambar 2.23(a), setelah kita terlebih dahulu membuat diagram batang menggunakan variabel **homeownership**, lalu membagi setiap kelompok menurut kategori **app_type**.

Visualisasi yang berkaitan dengan diagram batang bertumpuk ialah **diagram batang berdampingan**, seperti yang ditampilkan pada Gambar 2.23(b).

Untuk jenis diagram batang terakhir yang diperkenalkan, proporsi kolom pada tabel kontingensi **app_type** dan **homeownership** diubah menjadi diagram batang bertumpuk terstandarisasi pada Gambar 2.23(c). Visualisasi ini membantu kita memahami proporsi pengajuan pinjaman perorangan atau bersama bagi peminjam pada setiap kategori **homeownership**. Selain itu, karena proporsi **joint** dan **individual** berbeda antarkelompok, kita dapat menyimpulkan bahwa kedua variabel tersebut saling berhubungan.

CONTOH 2.27


Perhatikan ketiga diagram batang pada Gambar 2.23. Kapan diagram batang bertumpuk, berdampingan, atau bertumpuk terstandarisasi paling berguna?

E

Diagram batang bertumpuk paling berguna ketika masuk akal untuk menetapkan satu variabel sebagai variabel penjelas dan variabel lainnya sebagai variabel respons, sebab pada dasarnya kita terlebih dahulu mengelompokkan menurut satu variabel lalu membaginya lagi menurut variabel yang lain.

Tampilan diagram batang berdampingan lebih netral terhadap variabel mana, jika ada, yang berperan sebagai variabel penjelas dan mana yang berperan sebagai variabel respons. Banyaknya kasus dalam keenam kombinasi kelompok juga mudah dilihat. Namun, salah satu kelemahannya adalah kebutuhan ruang horizontal yang lebih besar; lebar Gambar 2.23(b) yang terbatas membuat diagram terasa agak sesak. Selain itu, ketika ukuran dua kelompok sangat berbeda, seperti kelompok **own** dibandingkan dengan kedua kelompok lainnya, sulit untuk melihat apakah kedua variabel saling berhubungan.

Diagram batang bertumpuk terstandarisasi membantu ketika variabel utama dalam diagram batang bertumpuk memiliki ukuran kategori yang sangat tidak seimbang. Sebagai contoh, kategori **own** hanya memiliki sepertiga jumlah pengamatan pada kategori **mortgage**, sehingga diagram batang bertumpuk biasa kurang berguna untuk memeriksa hubungan. Kelemahan utama versi terstandarisasi ialah hilangnya informasi tentang banyaknya kasus yang diwakili setiap batang.




Gambar 2.23: (a) Diagram batang bertumpuk untuk **homeownership**, dengan frekuensi yang selanjutnya dibagi menurut **app_type**. (b) Diagram batang berdampingan untuk **homeownership** dan **app_type**. (c) Versi terstandarisasi dari diagram batang bertumpuk.

2.2.4 Diagram mosaik

Diagram mosaik merupakan teknik visualisasi yang cocok untuk tabel kontingensi. Bentuknya menyerupai diagram batang bertumpuk terstandarisasi, tetapi tetap memperlihatkan ukuran relatif kelompok pada variabel utama.


Untuk mulai membuat diagram mosaik pertama, kita membagi sebuah persegi menjadi kolom-kolom bagi setiap kategori variabel **homeownership**, seperti pada Gambar 2.24(a). Setiap kolom mewakili satu kategori **homeownership**, dan lebarnya sebanding dengan proporsi pinjaman dalam kategori tersebut. Sebagai contoh, jumlah pinjaman bagi peminjam yang memiliki rumah lebih sedikit daripada jumlah pinjaman bagi peminjam yang memiliki hipotek. Secara umum, diagram mosaik menggunakan *luas* kotak untuk menyatakan banyaknya kasus dalam setiap kategori.

Untuk menghasilkan diagram mosaik lengkap, diagram mosaik satu variabel pada Gambar 2.24(b) dibagi lagi menjadi beberapa bagian menggunakan variabel **app_type**. Setiap kolom dibagi sebanding dengan banyaknya pinjaman dari peminjam perorangan dan peminjam bersama. Sebagai contoh, kolom kedua mewakili pinjaman bagi peminjam yang memiliki hipotek dan dibagi menjadi pinjaman perorangan (bagian atas) serta pinjaman bersama (bagian bawah). Sebagai contoh lain, bagian bawah kolom ketiga mewakili peminjam yang memiliki rumah dan mengajukan pinjaman bersama, sedangkan bagian atas kolom tersebut mewakili pemilik rumah yang mengajukan pinjaman secara perorangan. Diagram ini sekali lagi menunjukkan adanya hubungan antara variabel **homeownership** dan **app_type**, sebab garis pembagi horizontal berada pada ketinggian yang berbeda di setiap kolom. Teknik yang sama digunakan untuk memeriksa hubungan pada diagram batang bertumpuk terstandarisasi.



Gambar 2.24: (a) Diagram mosaik satu variabel untuk **homeownership**. (b) Diagram mosaik dua variabel untuk **homeownership** dan **app_type**.


Pada Gambar 2.24, kita memilih status kepemilikan rumah peminjam sebagai pembagian pertama. Namun, kita juga dapat terlebih dahulu membagi menurut jenis pengajuan, seperti pada Gambar 2.25. Seperti pada diagram batang, variabel penjelas lazim digunakan untuk pembagian pertama dalam diagram mosaik, lalu setiap kategori variabel penjelas dibagi menurut variabel respons, apabila sebutan tersebut memang masuk akal bagi variabel yang sedang dipertimbangkan.



Gambar 2.25: Diagram mosaik yang mengelompokkan pinjaman menurut variabel **homeownership** setelah terlebih dahulu membaginya ke dalam jenis pengajuan **individual** dan **joint**.

2.2.5 Satu-satunya diagram lingkaran dalam buku ini

Sebuah **diagram lingkaran** ditampilkan pada Gambar 2.26, berdampingan dengan diagram batang yang mewakili informasi yang sama. Diagram lingkaran dapat berguna untuk memberikan gambaran umum tentang pembagian sekumpulan kasus. Namun, rincian dalam diagram lingkaran juga sulit dibaca. Sebagai contoh, saat melihat diagram lingkaran, kita memerlukan beberapa detik lebih lama untuk menyadari bahwa jumlah pinjaman bagi peminjam yang memiliki hipotek lebih banyak daripada bagi penyewa, sedangkan rincian ini sangat jelas pada diagram batang. Walaupun diagram lingkaran dapat berguna, kami lebih menyukai diagram batang karena kelompok-kelompoknya lebih mudah dibandingkan.



Gambar 2.26: Diagram lingkaran dan diagram batang untuk homeownership.

2.2.6 Membandingkan data numerik antarkelompok

Sejumlah penyelidikan yang lebih menarik dapat dilakukan dengan menelaah data numerik antarkelompok. Metode yang diperlukan di sini sebenarnya tidak baru: kita cukup membuat diagram numerik untuk setiap kelompok dalam grafik yang sama. Di sini diperkenalkan dua cara yang praktis: diagram kotak berdampingan dan histogram berongga.


Kita akan kembali menggunakan himpunan data `county` dan membandingkan pendapatan rumah tangga median di county yang mengalami pertumbuhan penduduk antara 2010 dan 2017 dengan county yang tidak mengalami pertumbuhan. Meskipun kita mungkin tergoda untuk menarik kesimpulan kausal, ingatlah bahwa data ini bersifat observasional sehingga penafsiran semacam itu, paling banter, belum matang.

Terdapat 1,454 county yang penduduknya bertambah antara 2010 dan 2017, dan terdapat 1,672 county tanpa pertumbuhan (semuanya berkurang, kecuali satu). Sampel acak 100 county dari kelompok pertama dan 50 county dari kelompok kedua ditampilkan pada Gambar 2.27 agar sebagian data mentah pendapatan median lebih mudah diamati.

Pendapatan Median untuk 150 County, dalam satuan \$1000

Penduduk Bertambah						Penduduk Tidak Bertambah		
38.2	43.6	42.2	61.5	51.1	45.7	48.3	60.3	50.7
44.6	51.8	40.7	48.1	56.4	41.9	39.3	40.4	40.3
40.6	63.3	52.1	60.3	49.8	51.7	57	47.2	45.9
51.1	34.1	45.5	52.8	49.1	51	42.3	41.5	46.1
80.8	46.3	82.2	43.6	39.7	49.4	44.9	51.7	46.4
75.2	40.6	46.3	62.4	44.1	51.3	29.1	51.8	50.5
51.9	34.7	54	42.9	52.2	45.1	27	30.9	34.9
61	51.4	56.5	62	46	46.4	40.7	51.8	61.1
53.8	57.6	69.2	48.4	40.5	48.6	43.4	34.7	45.7
53.1	54.6	55	46.4	39.9	56.7	33.1	21	37
63	49.1	57.2	44.1	50	38.9	52	31.9	45.7
46.6	46.5	38.9	50.9	56	34.6	56.3	38.7	45.7
74.2	63	49.6	53.7	77.5	60	56.2	43	21.7
63.2	47.6	55.9	39.1	57.8	42.6	44.5	34.5	48.9
50.4	49	45.6	39	38.8	37.1	50.9	42.1	43.2
57.2	44.7	71.7	35.3	100.2		35.4	41.3	33.6
42.6	55.5	38.6	52.7	63		43.4	56.5	

Gambar 2.27: Di sebelah kiri ditampilkan pendapatan rumah tangga median (dalam satuan \$1000) dari sampel acak 100 county yang mengalami pertambahan penduduk. Di sebelah kanan ditampilkan pendapatan median dari sampel acak 50 county yang tidak mengalami pertambahan penduduk.



Gambar 2.28: Diagram kotak berdampingan (panel kiri) dan histogram berongga (panel kanan) untuk `med_hh_income`, dengan county dibagi menurut apakah penduduknya bertambah atau tidak bertambah.

Diagram kotak berdampingan merupakan perangkat tradisional untuk membandingkan kelompok. Contohnya ditampilkan pada panel kiri Gambar 2.28, yang memuat dua diagram kotak, masing-masing untuk satu kelompok, dalam bidang gambar yang sama dan digambar dengan skala yang sama.

Metode grafis lain yang berguna menggunakan **histogram berongga** untuk membandingkan data numerik antarkelompok. Histogram ini hanya berupa garis luar histogram setiap kelompok yang ditempatkan pada grafik yang sama, seperti pada panel kanan Gambar 2.28.

LATIHAN TERBIMBING 2.28

G

Gunakan grafik pada Gambar 2.28 untuk membandingkan pendapatan county dalam kedua kelompok. Apa yang Anda amati tentang perkiraan pusat setiap kelompok? Apa yang Anda amati tentang variabilitas antarkelompok? Apakah bentuk distribusinya relatif serupa pada kedua kelompok? Berapa banyak modus yang *menonjol* pada setiap kelompok?²⁰


LATIHAN TERBIMBING 2.29

G

Komponen mana dari masing-masing grafik pada Gambar 2.28 yang menurut Anda paling berguna?²¹

Latihan

2.21 Penggunaan antibiotik pada anak. Diagram batang dan diagram lingkaran di bawah menunjukkan distribusi kondisi medis yang sudah ada sebelumnya pada anak-anak yang terlibat dalam penelitian tentang durasi optimal penggunaan antibiotik untuk mengobati trakeitis, yaitu infeksi saluran pernapasan atas.



- Ciri apa yang tampak pada diagram batang, tetapi tidak pada diagram lingkaran?
- Ciri apa yang tampak pada diagram lingkaran, tetapi tidak pada diagram batang?
- Grafik mana yang lebih Anda pilih untuk menampilkan data kategoris ini?

2.22 Pandangan tentang imigrasi. Sebanyak 910 pemilih terdaftar yang dipilih secara acak di Tampa, Florida, ditanya tentang pendapat mereka mengenai pekerja yang masuk ke Amerika Serikat tanpa izin. Pilihannya ialah: (i) diizinkan mempertahankan pekerjaan dan mengajukan kewarganegaraan AS, (ii) diizinkan mempertahankan pekerjaan sebagai pekerja tamu sementara, tetapi tidak diizinkan mengajukan kewarganegaraan AS, atau (iii) kehilangan pekerjaan dan harus meninggalkan negara tersebut. Hasil survei menurut ideologi politik ditampilkan di bawah ini.²²

	Ideologi politik			Total
	Konservatif	Moderat	Liberal	
<i>Tanggapan</i> (i) Ajukan kewarganegaraan	57	120	101	278
(ii) Pekerja tamu	121	113	28	262
(iii) Tinggalkan negara	179	126	45	350
(iv) Tidak yakin	15	4	1	20
Total	372	363	175	910

- Berapa persen pemilih Tampa, Florida, ini yang mengidentifikasi diri sebagai konservatif?
- Berapa persen pemilih Tampa, Florida, ini yang mendukung pilihan kewarganegaraan?
- Berapa persen pemilih Tampa, Florida, ini yang mengidentifikasi diri sebagai konservatif dan mendukung pilihan kewarganegaraan?


²⁰Jawaban dapat sedikit berbeda. County yang mengalami pertumbuhan penduduk cenderung memiliki pendapatan lebih tinggi (median sekitar \$53,000) daripada county tanpa pertumbuhan (median sekitar \$45,000). Variabilitas kelompok dengan pertumbuhan penduduk juga sedikit lebih besar. Hal ini tampak pada IQR-nya, yang sekitar 50% lebih besar dalam kelompok *Bertambah*. Kedua distribusi sedikit sampai sedang menceng kanan dan unimodal. Diagram kotak menunjukkan banyak pengamatan yang jauh di atas median pada kedua kelompok. Namun, ketika menelaah himpunan data yang memuat lebih dari beberapa ratus titik data, kita memang dapat memperkirakan bahwa banyak pengamatan akan berada di luar garis kumis.

²¹Jawaban dapat bervariasi. Diagram kotak berdampingan sangat berguna untuk membandingkan pusat dan sebaran, sedangkan histogram berongga lebih berguna untuk melihat bentuk distribusi, kemencengan, dan kemungkinan anomali.


²²SurveyUSA, News Poll #18927, data collected Jan 27-29, 2012.

- (d) Di antara pemilih yang mengidentifikasi diri sebagai konservatif, berapa persen yang juga mendukung pilihan kewarganegaraan? Berapa persen pemilih moderat yang berpandangan sama? Berapa persen pemilih liberal yang berpandangan sama?
- (e) Apakah ideologi politik dan pandangan tentang imigrasi tampak saling independen? Jelaskan alasan Anda.

2.23 Pandangan tentang DREAM Act. Sampel acak pemilih terdaftar di Tampa, Florida, ditanya apakah mereka mendukung DREAM Act, sebuah rancangan undang-undang yang akan menyediakan jalur menuju kewarganegaraan bagi orang-orang yang dibawa masuk ke Amerika Serikat tanpa izin ketika masih anak-anak. Survei tersebut juga mengumpulkan informasi tentang ideologi politik responden. Berdasarkan diagram mosaik di bawah, apakah pandangan tentang DREAM Act dan ideologi politik tampak saling independen? Jelaskan alasan Anda.²³



2.24 Menaikkan pajak. Sampel acak pemilih terdaftar secara nasional ditanya apakah menurut mereka lebih baik menaikkan pajak orang kaya atau menaikkan pajak orang miskin. Survei tersebut juga mengumpulkan informasi tentang afiliasi partai politik responden. Berdasarkan diagram mosaik di bawah, apakah pandangan tentang kenaikan pajak dan afiliasi politik tampak saling independen? Jelaskan alasan Anda.²⁴



²³SurveyUSA, News Poll #18927, data collected Jan 27-29, 2012.

²⁴Public Policy Polling, Americans on College Degrees, Classic Literature, the Seasons, and More, data collected Feb 20-22, 2015.

2.3 Studi kasus: vaksin malaria

CONTOH 2.30

Misalkan dosen Anda membagi mahasiswa di kelas menjadi dua kelompok: mahasiswa di sisi kiri dan mahasiswa di sisi kanan. Jika $\hat{p}_L$ dan $\hat{p}_R$ masing-masing menyatakan proporsi mahasiswa yang memiliki produk Apple di sisi kiri dan kanan, apakah Anda akan terkejut jika $\hat{p}_L$ tidak persis sama dengan $\hat{p}_R$?

Walaupun kedua proporsi itu kemungkinan besar berdekatan, tidak lazim jika keduanya persis sama. Kita mungkin akan mengamati sedikit perbedaan karena faktor kebetulan.

LATIHAN TERBIMBING 2.31

Jika kita beranggapan bahwa sisi ruangan tempat seseorang duduk di kelas tidak berkaitan dengan apakah orang tersebut memiliki produk Apple, asumsi apa yang kita buat tentang hubungan antara kedua variabel ini?²⁵

2.3.1 Variabilitas dalam data

Kita meninjau sebuah penelitian mengenai vaksin malaria baru bernama PfSPZ. Dalam penelitian ini, pasien relawan dialokasikan secara acak ke salah satu dari dua kelompok eksperimen: 14 pasien menerima vaksin eksperimental dan 6 pasien menerima vaksin plasebo. Sembilan belas minggu kemudian, seluruh 20 pasien dipaparkan pada galur parasit malaria yang sensitif terhadap obat; galur yang sensitif terhadap obat digunakan di sini atas pertimbangan etis, agar setiap infeksi dapat diobati secara efektif. Hasilnya dirangkum dalam Gambar 2.29: 9 dari 14 pasien kelompok perlakuan tetap bebas dari tanda-tanda infeksi, sedangkan seluruh 6 pasien dalam kelompok kontrol menunjukkan sejumlah tanda awal infeksi.

		outcome		Total
		terinfeksi	tidak terinfeksi	
treatment	vaksin	5	9	14
	plasebo	6	0	6
	Total	11	9	20

Gambar 2.29: Ringkasan hasil eksperimen vaksin malaria.

LATIHAN TERBIMBING 2.32

Apakah penelitian ini merupakan studi observasional atau eksperimen? Apa dampak jenis penelitian ini terhadap kesimpulan yang dapat ditarik dari hasilnya?²⁶

Dalam penelitian ini, proporsi pasien yang menunjukkan tanda-tanda infeksi lebih kecil pada kelompok yang menerima vaksin (35.7% dibandingkan dengan 100%). Namun, sampelnya sangat kecil, dan belum jelas apakah perbedaan tersebut memberikan *bukti meyakinkan* bahwa vaksin itu efektif.

²⁵Kita mengasumsikan bahwa kedua variabel ini saling independen.

²⁶Penelitian ini merupakan eksperimen karena pasien dialokasikan secara acak ke kelompok eksperimen. Karena penelitian ini merupakan eksperimen, hasilnya dapat digunakan untuk menilai hubungan kausal antara vaksin malaria dan apakah pasien menunjukkan tanda-tanda infeksi.

CONTOH 2.33

Ilmuwan data terkadang diminta menilai kekuatan bukti. Ketika melihat tingkat infeksi pasien pada kedua kelompok dalam penelitian ini, apa yang terlintas dalam pikiran saat kita mencoba menentukan apakah data tersebut menunjukkan bukti meyakinkan adanya perbedaan nyata?

E

Tingkat infeksi yang diamati (35.7% pada kelompok perlakuan dibandingkan dengan 100% pada kelompok kontrol) mengisyaratkan bahwa vaksin mungkin efektif. Namun, kita tidak dapat memastikan apakah perbedaan yang diamati mencerminkan efikasi vaksin atau sekadar timbul karena faktor kebetulan. Data sampel umumnya mengalami sedikit fluktuasi, dan kita tidak mengharapkan proporsi sampel *persis* sama, meskipun sebenarnya tingkat infeksi tidak bergantung pada pemberian vaksin. Selain itu, dengan sampel sekecil ini, mungkin perbedaan sebesar itu memang lazim muncul ketika kita membagi sebuah kelompok secara acak semata-mata karena kebetulan!

Contoh 2.33 mengingatkan kita bahwa hasil yang diamati dalam sampel data mungkin tidak mencerminkan secara sempurna hubungan sebenarnya antara variabel karena terdapat **derau acak**. Walaupun perbedaan tingkat infeksi yang diamati besar, ukuran sampel penelitian ini kecil, sehingga belum jelas apakah perbedaan yang diamati tersebut mencerminkan efikasi vaksin atau sekadar timbul karena kebetulan. Kita menamai dua pernyataan yang bersaing ini, H_0 dan H_A , yang dibaca “H-nol” dan “H-A”:

H_0 : **Model independensi.** Variabel **treatment** dan **outcome** saling independen. Keduanya tidak memiliki hubungan, dan perbedaan yang diamati antara proporsi pasien yang mengalami infeksi pada kedua kelompok, yaitu 64.3%, terjadi karena kebetulan.

H_A : **Model alternatif.** Kedua variabel *tidak* saling independen. Perbedaan tingkat infeksi sebesar 64.3% tidak terjadi karena kebetulan, dan vaksin memengaruhi tingkat infeksi.

Apa artinya jika model independensi, yang menyatakan bahwa vaksin tidak memengaruhi tingkat infeksi, benar? Artinya, 11 pasien akan mengalami infeksi *terlepas dari kelompok mana mereka dialokasikan secara acak*, dan 9 pasien tidak akan mengalami infeksi *terlepas dari kelompok mana mereka dialokasikan secara acak*. Dengan kata lain, jika vaksin tidak memengaruhi tingkat infeksi, perbedaan tingkat infeksi itu semata-mata terjadi secara kebetulan akibat cara pasien dialokasikan secara acak.

Sekarang tinjau model alternatif: tingkat infeksi dipengaruhi oleh apakah seorang pasien menerima vaksin atau tidak. Jika hal ini benar, terlebih jika pengaruhnya cukup besar, kita akan mengharapkan adanya perbedaan tingkat infeksi antara pasien dalam kedua kelompok.

Kita memilih di antara kedua pernyataan yang bersaing ini dengan menilai apakah data sedemikian bertentangan dengan H_0 sehingga model independensi tidak lagi dapat dianggap masuk akal. Jika demikian, dan data mendukung H_A , kita akan menolak gagasan independensi dan menyimpulkan bahwa vaksin tersebut efektif.

2.3.2 Menyimulasikan penelitian

Kita akan menjalankan **simulasi**, dengan berpura-pura mengetahui bahwa vaksin malaria yang sedang diuji *tidak* bekerja. Pada akhirnya, kita ingin memahami apakah perbedaan besar yang kita amati lazim muncul dalam simulasi-simulasi ini. Jika lazim, mungkin perbedaan yang kita amati murni terjadi karena kebetulan. Jika sangat tidak lazim, kemungkinan bahwa vaksin tersebut bermanfaat menjadi lebih masuk akal.

Gambar 2.29 menunjukkan bahwa 11 pasien mengalami infeksi dan 9 tidak. Untuk simulasi ini, kita akan menganggap bahwa infeksi tidak bergantung pada vaksin dan bahwa kita dapat *memutar balik* waktu ke saat peneliti mengalokasikan pasien dalam penelitian secara acak. Seandainya pasien dialokasikan secara acak dengan cara yang berbeda, kita mungkin memperoleh hasil berbeda dalam dunia hipotetis yang menganggap vaksin tidak memengaruhi infeksi ini. Mari kita lakukan **pengacakan** lain dengan sebuah simulasi.

Dalam **simulasi** ini, kita menggunakan 20 kartu indeks untuk mewakili 20 pasien, lalu menuliskan “terinfeksi” pada 11 kartu dan “tidak terinfeksi” pada 9 kartu. Dalam dunia hipotetis ini, kita menganggap setiap pasien yang mengalami infeksi memang akan mengalaminya terlepas dari kelompoknya. Karena itu, mari kita lihat apa yang terjadi jika kita kembali mengalokasikan pasien secara acak ke kelompok perlakuan dan kontrol. Kita mengocok kartu-kartu indeks tersebut secara menyeluruh, lalu membagikan 14 kartu ke tumpukan **vaccine** dan 6 kartu ke tumpukan **placebo**. Terakhir, kita menyusun hasilnya dalam tabel, seperti ditampilkan pada Gambar 2.30.

		outcome		Total
		terinfeksi	tidak terinfeksi	
perlakuan (simulasi)	vaksin	7	7	14
	plasebo	4	2	6
	Total	11	9	20

Gambar 2.30: Hasil simulasi; setiap perbedaan tingkat infeksi di sini semata-mata terjadi karena kebetulan.

LATIHAN TERBIMBING 2.34

Ⓔ Berapa selisih tingkat infeksi antara kedua kelompok hasil simulasi pada Gambar 2.30? Bagaimana selisih ini dibandingkan dengan selisih 64.3% yang diamati pada data sebenarnya?²⁷

2.3.3 Memeriksa independensi

Kita menghitung satu perbedaan yang mungkin terjadi di bawah model independensi dalam Latihan Terpandu 2.34; perbedaan tersebut mewakili satu perbedaan akibat kebetulan. Dalam simulasi pertama ini, kita membagikan kartu indeks secara fisik untuk mewakili pasien, tetapi simulasi ini lebih efisien dilakukan dengan komputer. Ketika simulasi diulangi dengan komputer, kita memperoleh perbedaan lain akibat kebetulan:

$$\frac{2}{6} - \frac{9}{14} = -0.310$$


Lalu perbedaan lainnya:

$$\frac{3}{6} - \frac{8}{14} = -0.071$$

Demikian seterusnya, hingga simulasi telah cukup sering diulangi sehingga kita memahami dengan baik seperti apa *distribusi perbedaan yang semata-mata timbul karena kebetulan*. Gambar 2.31 menampilkan diagram titik bertumpuk untuk perbedaan yang diperoleh dari 100 simulasi; setiap titik mewakili selisih tingkat infeksi hasil simulasi (tingkat kelompok kontrol dikurangi tingkat kelompok perlakuan).

Perhatikan bahwa distribusi perbedaan hasil simulasi ini berpusat di sekitar 0. Kita menyimulasikan perbedaan-perbedaan tersebut dengan menganggap model independensi benar. Dalam kondisi ini, kita memperkirakan selisihnya mendekati nol dengan sedikit fluktuasi acak. Istilah *mendekati* digunakan cukup longgar dalam kasus ini karena ukuran sampel penelitian begitu kecil.

²⁷ $4/6 - 7/14 = 0.167$, atau sekitar 16.7% yang berpihak pada vaksin. Perbedaan akibat kebetulan ini jauh lebih kecil daripada perbedaan yang diamati pada kelompok sebenarnya.



Gambar 2.31: Diagram titik bertumpuk untuk perbedaan dari 100 simulasi yang dihasilkan di bawah model independensi, H_0 , dengan infeksi yang tidak dipengaruhi oleh vaksin dalam simulasi-simulasi ini. Dua dari 100 simulasi menghasilkan perbedaan setidaknya sebesar 64.3%, yaitu perbedaan yang diamati dalam penelitian.

CONTOH 2.35

Seberapa sering Anda akan mengamati perbedaan setidaknya sebesar 64.3% (0.643) menurut Gambar 2.31? Sering, kadang-kadang, jarang, atau tidak pernah?

E

Perbedaan setidaknya sebesar 64.3% yang semata-mata terjadi karena kebetulan tampaknya hanya muncul sekitar 2% dari seluruh simulasi menurut Gambar 2.31. Peluang serendah itu menunjukkan peristiwa yang jarang.

Karena perbedaan sebesar 64.3% merupakan peristiwa langka, hasil penelitian ini dapat ditafsirkan dengan dua cara:

H_0 **Model independensi.** Vaksin tidak memengaruhi tingkat infeksi, dan kebetulan saja kita mengamati perbedaan yang hanya akan terjadi sesekali.

H_A **Model alternatif.** Vaksin memengaruhi tingkat infeksi, dan perbedaan yang kita amati memang terjadi karena vaksin efektif melawan malaria; hal ini menjelaskan perbedaan besar sebesar 64.3%.

Berdasarkan simulasi tersebut, kita memiliki dua pilihan. (1) Kita menyimpulkan bahwa hasil penelitian tidak memberikan bukti kuat untuk menentang model independensi. Dengan kata lain, kita tidak memiliki bukti yang cukup kuat untuk menyimpulkan bahwa vaksin berpengaruh dalam konteks klinis ini. (2) Kita menyimpulkan bahwa bukti tersebut cukup kuat untuk menolak H_0 dan menyatakan bahwa vaksin bermanfaat. Ketika melakukan penelitian formal, biasanya kita menolak gagasan bahwa kita kebetulan mengamati suatu peristiwa langka.²⁸ Jadi, dalam kasus ini kita menolak model independensi dan memilih model alternatif. Dengan kata lain, kita menyimpulkan

²⁸Penalaran ini pada umumnya tidak dapat diperluas ke pengamatan anekdot. Setiap orang mengamati berbagai peristiwa yang sangat langka setiap hari, yaitu peristiwa yang mustahil dapat kita ramalkan. Namun, dalam konteks bukti anekdot yang tidak ketat, hampir segala sesuatu dapat tampak sebagai peristiwa langka. Karena itu, mencari peristiwa langka dalam kegiatan sehari-hari dapat sangat menyesatkan. Sebagai contoh, perhatikan lotere: hanya terdapat peluang 1 banding 292 juta bahwa nomor Powerball untuk hadiah terbesar sepanjang sejarah (13 Januari 2016) akan berupa (04, 08, 19, 27, 34) dengan nomor Powerball (10), tetapi nomor-nomor itu tetap muncul! Namun, nomor apa pun yang muncul akan memiliki peluang luar biasa kecil yang sama. Artinya, *setiap himpunan nomor yang mungkin kita amati pada akhirnya akan sama-sama sangat langka*. Situasi seperti ini lazim dalam kehidupan sehari-hari: setiap peristiwa yang mungkin terjadi tampak sangat langka jika ditinjau sendiri, tetapi jika semua alternatif dipertimbangkan, hasil-hasil lain tersebut juga sangat langka. Kita harus berhati-hati agar tidak salah menafsirkan bukti anekdot semacam ini.

bahwa data memberikan bukti kuat bahwa vaksin memberi perlindungan tertentu terhadap malaria dalam konteks klinis ini.

Salah satu cabang statistika, yaitu statistika inferensial, dibangun di atas penilaian apakah perbedaan semacam ini terjadi karena kebetulan. Dalam statistika inferensial, ilmuwan data menilai model mana yang paling masuk akal berdasarkan data. Kesalahan tetap dapat terjadi, seperti halnya peristiwa langka, dan kita mungkin memilih model yang salah. Walaupun pilihan kita tidak selalu tepat, statistika inferensial memberi kita perangkat untuk mengendalikan dan menilai seberapa sering kesalahan itu terjadi. Dalam Bab 5, kita memberikan pengantar formal mengenai masalah pemilihan model. Dua bab berikutnya digunakan untuk membangun landasan probabilitas dan teori yang diperlukan agar pembahasan tersebut menjadi ketat.

Latihan


2.25 Efek samping Avandia. Rosiglitazon adalah bahan aktif dalam obat diabetes tipe 2 Avandia yang kontroversial dan telah dikaitkan dengan peningkatan risiko masalah kardiovaskular serius, seperti stroke, gagal jantung, dan kematian. Salah satu pengobatan alternatif yang umum adalah pioglitazon, yaitu bahan aktif dalam obat diabetes bernama Actos. Dalam sebuah studi observasional retrospektif berskala nasional terhadap 227,571 penerima manfaat Medicare berusia 65 tahun atau lebih, ditemukan bahwa 2,593 dari 67,593 pasien yang menggunakan rosiglitazon dan 5,386 dari 159,978 pasien yang menggunakan pioglitazon mengalami masalah kardiovaskular serius. Data ini dirangkum dalam tabel kontingensi berikut.²⁹

	Masalah kardiovaskular		Total
	Ya	Tidak	
Perlakuan Rosiglitazon	2,593	65,000	67,593
Pioglitazon	5,386	154,592	159,978
Total	7,979	219,592	227,571


- Tentukan apakah setiap pernyataan berikut benar atau salah. Jika salah, jelaskan alasannya. *Berhati-hatilah:* Penalarannya mungkin salah walaupun kesimpulan pernyataannya benar. Dalam kasus seperti itu, pernyataan harus dianggap salah.
 - Karena lebih banyak pasien pengguna pioglitazon mengalami masalah kardiovaskular (5,386 dibandingkan dengan 2,593), kita dapat menyimpulkan bahwa tingkat masalah kardiovaskular pada orang yang menerima perlakuan pioglitazon lebih tinggi.
 - Data mengisyaratkan bahwa pasien diabetes yang menggunakan rosiglitazon lebih mungkin mengalami masalah kardiovaskular karena tingkat kejadiannya adalah $(2,593 / 67,593 = 0.038)$ 3.8% pada pasien yang menerima perlakuan ini, sedangkan pada pasien pengguna pioglitazon hanya $(5,386 / 159,978 = 0.034)$ 3.4%.
 - Fakta bahwa tingkat kejadian lebih tinggi pada kelompok rosiglitazon membuktikan bahwa rosiglitazon menyebabkan masalah kardiovaskular serius.
 - Berdasarkan informasi yang diberikan sejauh ini, kita tidak dapat menentukan apakah perbedaan tingkat kejadian disebabkan oleh hubungan antara kedua variabel atau oleh faktor kebetulan.
- Berapa proporsi seluruh pasien yang mengalami masalah kardiovaskular?
- Jika jenis perlakuan dan kejadian masalah kardiovaskular saling independen, kira-kira berapa banyak pasien dalam kelompok rosiglitazon yang diperkirakan mengalami masalah kardiovaskular?
- Kita dapat menyelidiki hubungan antara hasil dan perlakuan dalam penelitian ini dengan teknik pengacakan. Dalam praktiknya, simulasi yang diperlukan untuk pengacakan akan dijalankan menggunakan perangkat lunak statistika, tetapi misalkan kita benar-benar menyimulasikannya dengan kartu indeks. Untuk menyimulasikan model independensi, yang menyatakan bahwa hasil tidak bergantung pada perlakuan, pada setiap kartu kita tuliskan apakah seorang pasien mengalami masalah kardiovaskular atau tidak. Semua kartu kemudian dikocok dan dibagikan ke dalam dua kelompok berukuran 67,593 dan 159,978. Kita mengulangi simulasi ini 1,000 kali dan setiap kali mencatat jumlah orang dalam kelompok rosiglitazon yang mengalami masalah kardiovaskular. Gunakan histogram frekuensi relatif dari jumlah tersebut untuk menjawab (i)–(iii).

²⁹D.J. Graham et al. "Risk of acute myocardial infarction, stroke, heart failure, and death in elderly Medicare patients treated with rosiglitazone or pioglitazone". In: *JAMA* 304.4 (2010), p. 411. ISSN: 0098-7484.

- i. Pernyataan apa saja yang sedang diuji?
- ii. Dibandingkan dengan jumlah yang dihitung pada bagian (c), manakah yang akan lebih mendukung hipotesis alternatif: *lebih banyak* atau *lebih sedikit* pasien dengan masalah kardiovaskular dalam kelompok rosiglitazon?
- iii. Apa yang ditunjukkan oleh hasil simulasi mengenai hubungan antara penggunaan rosiglitazon dan kejadian masalah kardiovaskular pada pasien diabetes?



2.26 Transplantasi jantung. Studi Transplantasi Jantung Universitas Stanford dilakukan untuk menentukan apakah program transplantasi jantung eksperimental memperpanjang masa hidup. Setiap pasien yang mengikuti program ditetapkan sebagai calon resmi penerima transplantasi jantung. Artinya, pasien tersebut sakit parah dan kemungkinan besar akan memperoleh manfaat dari jantung baru. Sebagian pasien menerima transplantasi dan sebagian lainnya tidak. Variabel **transplant** menunjukkan kelompok pasien; pasien dalam kelompok perlakuan menerima transplantasi, sedangkan pasien dalam kelompok kontrol tidak. Dari 34 pasien dalam kelompok kontrol, 30 meninggal. Dari 69 orang dalam kelompok perlakuan, 45 meninggal. Variabel lain bernama **survived** digunakan untuk menunjukkan apakah pasien masih hidup pada akhir penelitian.³⁰



- (a) Berdasarkan diagram mosaik, apakah kelangsungan hidup independen dari status penerimaan transplantasi? Jelaskan penalaran Anda.
- (b) Apa yang ditunjukkan oleh diagram kotak di atas mengenai efikasi (keefektifan) perlakuan transplantasi jantung?
- (c) Berapa proporsi pasien yang meninggal dalam kelompok perlakuan, dan berapa proporsinya dalam kelompok kontrol?
- (d) Salah satu pendekatan untuk menyelidiki apakah perlakuan tersebut efektif adalah dengan menggunakan teknik pengacakan.


- i. Pernyataan apa saja yang sedang diuji?
- ii. Paragraf berikut menjelaskan penyiapan pendekatan tersebut jika kita melakukannya tanpa perangkat lunak statistika. Isi bagian kosong dengan angka atau frasa yang sesuai.

Kita menuliskan *hidup* pada _____ kartu yang mewakili pasien yang masih hidup pada akhir penelitian, dan *meninggal* pada _____ kartu yang mewakili pasien yang sudah meninggal. Kemudian, kartu-kartu ini dikocok dan dibagi menjadi dua kelompok: satu kelompok berukuran _____ yang mewakili perlakuan, dan kelompok lain berukuran _____ yang mewakili kontrol. Kita menghitung selisih antara proporsi kartu *meninggal* dalam kelompok perlakuan dan kelompok kontrol (perlakuan - kontrol), lalu mencatat nilainya. Prosedur ini diulangi 100 kali untuk membangun distribusi yang berpusat di _____. Terakhir, kita menghitung proporsi simulasi dengan selisih

³⁰B. Turnbull et al. "Survivorship of Heart Transplant Data". In: *Journal of the American Statistical Association* 69 (1974), pp. 74–80.

proporsi hasil simulasi yang _____. Jika proporsi ini kecil, kita menyimpulkan bahwa hasil seperti itu kecil kemungkinannya untuk teramati secara kebetulan; hipotesis nol harus ditolak dan hipotesis alternatif dipilih.

iii. Apa yang ditunjukkan oleh hasil simulasi berikut mengenai keefektifan program transplantasi?




Latihan bab

2.27 Ujian susulan. Dalam sebuah kelas yang terdiri atas 25 mahasiswa, 24 mahasiswa mengikuti ujian di kelas dan 1 mahasiswa mengikuti ujian susulan pada hari berikutnya. Dosen menilai 24 ujian pertama dan memperoleh rerata nilai 74 poin dengan simpangan baku 8.9 poin. Mahasiswa yang mengikuti ujian susulan pada hari berikutnya memperoleh nilai 64 poin.

- Apakah nilai mahasiswa yang mengikuti ujian susulan tersebut menaikkan atau menurunkan rerata nilai?
- Berapakah rerata nilai yang baru?
- Apakah nilai mahasiswa yang mengikuti ujian susulan tersebut menaikkan atau menurunkan simpangan baku nilai-nilai itu?

2.28 Kematian bayi. Angka kematian bayi didefinisikan sebagai banyaknya kematian bayi per 1,000 kelahiran hidup. Angka ini sering digunakan sebagai indikator tingkat kesehatan suatu negara. Histogram frekuensi relatif di bawah ini menunjukkan distribusi perkiraan angka kematian bayi untuk 224 negara yang datanya tersedia pada 2014.³¹

- Perkirakan Q1, median, dan Q3 dari histogram tersebut.
- Apakah Anda memperkirakan rata-rata kumpulan data ini lebih kecil atau lebih besar daripada mediannya? Jelaskan penalaran Anda.



2.29 Penonton televisi. Para siswa dalam sebuah kelas AP Statistics ditanya berapa jam mereka menonton televisi setiap minggu (termasuk melalui layanan streaming daring). Sampel ini menghasilkan rerata 4.71 jam dengan simpangan baku 4.18 jam. Apakah distribusi banyaknya jam menonton televisi per minggu tersebut simetris? Jika tidak, bentuk seperti apa yang Anda perkirakan untuk distribusi ini? Jelaskan penalaran Anda.


2.30 Statistik baru. Statistik $\frac{\bar{x}}{\text{median}}$ dapat digunakan sebagai ukuran kemencengan. Misalkan kita memiliki distribusi yang seluruh pengamatannya lebih besar daripada 0, $x_i > 0$. Bagaimanakah bentuk distribusi yang diperkirakan dalam setiap kondisi berikut? Jelaskan penalaran Anda.

- $\frac{\bar{x}}{\text{median}} = 1$
- $\frac{\bar{x}}{\text{median}} < 1$
- $\frac{\bar{x}}{\text{median}} > 1$

2.31 Pemenang Oscar. Penghargaan Oscar untuk kategori Aktor Terbaik dan Aktris Terbaik pertama kali diberikan pada 1929. Histogram di bawah ini menunjukkan distribusi usia seluruh pemenang kategori

³¹CIA Factbook, Country Comparisons, 2014.

Aktor Terbaik dan Aktris Terbaik dari 1929 hingga 2018. Statistik ringkasan untuk kedua distribusi ini juga disediakan. Bandingkan distribusi usia pemenang kategori Aktor Terbaik dan Aktris Terbaik.³²



2.32 Nilai ujian. Rerata nilai sebuah ujian sejarah (dengan nilai maksimum 100 poin) adalah 85, dengan simpangan baku 15. Apakah distribusi nilai ujian ini simetris? Jika tidak, bentuk seperti apa yang Anda perkirakan untuk distribusi tersebut? Jelaskan penalaran Anda.


2.33 Nilai statistika. Berikut adalah nilai ujian akhir dua puluh mahasiswa yang mengikuti mata kuliah statistika pengantar.

57, 66, 69, 71, 72, 73, 74, 77, 78, 78, 79, 79, 81, 81, 82, 83, 83, 88, 89, 94

Buatlah diagram kotak untuk distribusi nilai tersebut. Ringkasan lima angka di bawah ini mungkin berguna.

Min	Q1	Q2 (Median)	Q3	Maks
57	72.5	78.5	82.5	94


2.34 Pemenang maraton. Histogram dan diagram kotak di bawah ini menunjukkan distribusi waktu finis dalam jam bagi pemenang pria dan wanita Maraton New York antara 1970 dan 1999.




- Ciri-ciri distribusi apa yang tampak pada histogram tetapi tidak pada diagram kotak? Ciri-ciri apa yang tampak pada diagram kotak tetapi tidak pada histogram?
- Apa yang mungkin menyebabkan distribusi bimodal tersebut? Jelaskan.

³²Pemenang Oscar dari 1929–2012; data hingga 2009 berasal dari arsip data Journal of Statistics Education, dan data yang lebih mutakhir berasal dari wikipedia.org.

- (c) Bandingkan distribusi waktu maraton pria dan wanita berdasarkan diagram kotak di bawah ini.



- (d) Grafik deret waktu di bawah ini merupakan cara lain untuk menelaah data tersebut. Uraikan apa yang tampak pada grafik ini tetapi tidak pada grafik lain.



Bab 3

Probabilitas

3.1 Mendefinisikan probabilitas

3.2 Peluang bersyarat

3.3 Pengambilan sampel dari populasi kecil

3.4 Variabel acak

3.5 Distribusi kontinu

Probabilitas merupakan landasan statistika, dan Anda mungkin sudah mengenal banyak gagasan yang disajikan dalam bab ini. Namun, formalisasi konsep probabilitas kemungkinan besar masih baru bagi sebagian besar pembaca.

Walaupun bab ini memberikan landasan teoretis bagi gagasan-gagasan pada bab-bab selanjutnya dan membuka jalan menuju pemahaman yang lebih mendalam, penguasaan konsep-konsep yang diperkenalkan di bab ini tidak diperlukan untuk menerapkan metode yang diperkenalkan di bagian lain buku ini.



Untuk video, salindia, dan sumber daya lainnya, kunjungi
www.openintro.org/os

3.1 Mendefinisikan probabilitas

Statistika didasarkan pada probabilitas, dan walaupun probabilitas tidak diperlukan untuk teknik-teknik terapan dalam buku ini, pemahaman probabilitas dapat membantu Anda memahami metode secara lebih mendalam dan membangun landasan yang lebih baik untuk mata kuliah selanjutnya.

3.1.1 Contoh pengantar

Sebelum membahas gagasan teknis, mari kita lihat beberapa contoh dasar yang mungkin terasa lebih akrab.

CONTOH 3.1

“Dadu”, bentuk tunggal dari dice, adalah kubus dengan enam sisi bernomor 1, 2, 3, 4, 5, dan 6. Berapa peluang memperoleh 1 saat melempar dadu?

Jika dadunya adil, peluang memperoleh 1 sama dengan peluang memperoleh bilangan lain. Karena ada enam hasil, peluangnya adalah 1 banding 6 atau, secara ekuivalen, $1/6$.

CONTOH 3.2

Berapa peluang memperoleh 1 atau 2 pada lemparan berikutnya?

1 dan 2 merupakan dua dari enam hasil yang mungkin dan sama-sama berpeluang, sehingga peluang memperoleh salah satu dari kedua hasil ini adalah $2/6 = 1/3$.

CONTOH 3.3

Berapa peluang memperoleh 1, 2, 3, 4, 5, atau 6 pada lemparan berikutnya?

100%. Hasilnya pasti salah satu dari bilangan tersebut.

CONTOH 3.4

Berapa peluang tidak memperoleh 2?

Karena peluang memperoleh 2 adalah $1/6$ atau $16.\bar{6}\%$, peluang tidak memperoleh 2 adalah $100\% - 16.\bar{6}\% = 83.\bar{3}\%$ atau $5/6$.

Sebagai alternatif, kita dapat menyadari bahwa tidak memperoleh 2 sama dengan memperoleh 1, 3, 4, 5, atau 6. Kelima hasil itu mencakup lima dari enam hasil yang sama-sama berpeluang, sehingga probabilitasnya $5/6$.

CONTOH 3.5

Misalkan kita melempar dua dadu. Jika pada $1/6$ bagian dari seluruh lemparan dadu pertama menunjukkan 1, dan pada $1/6$ bagian dari waktu tersebut dadu kedua juga menunjukkan 1, berapa peluang memperoleh dua 1?

Jika dadu pertama menunjukkan 1 pada $16.\bar{6}\%$ lemparan dan pada $1/6$ bagian dari lemparan tersebut dadu kedua juga menunjukkan 1, maka peluang kedua dadu menunjukkan 1 adalah $(1/6) \times (1/6)$ atau $1/36$.

3.1.2 Probabilitas

Kita menggunakan probabilitas untuk membangun alat guna menggambarkan dan memahami keacakan yang tampak. Kita sering merumuskan probabilitas melalui **proses acak** yang menghasilkan suatu **hasil**.

Lempar dadu $\rightarrow$ 1, 2, 3, 4, 5, atau 6
 Lempar koin $\rightarrow$ H atau T


Melempar dadu atau koin merupakan proses yang tampak acak, dan masing-masing menghasilkan suatu hasil.

PROBABILITAS

Probabilitas suatu hasil adalah proporsi kemunculan hasil tersebut jika kita mengamati proses acak itu sebanyak tak berhingga kali.

Probabilitas didefinisikan sebagai proporsi dan selalu bernilai antara 0 dan 1, termasuk kedua batasnya. Probabilitas juga dapat ditampilkan sebagai persentase antara 0% dan 100%.

Probabilitas dapat diilustrasikan dengan melempar dadu berkali-kali. Misalkan $\hat{p}_n$ adalah proporsi hasil yang berupa 1 setelah n lemparan pertama. Ketika jumlah lemparan bertambah, $\hat{p}_n$ akan konvergen ke probabilitas memperoleh 1, yaitu $p = 1/6$. Gambar 3.1 menunjukkan konvergensi ini untuk 100.000 lemparan dadu. Kecenderungan $\hat{p}_n$ untuk stabil di sekitar p dijelaskan oleh **Hukum Bilangan Besar**.



Gambar 3.1: Fraksi lemparan dadu yang menghasilkan 1 pada setiap tahap simulasi. Seiring bertambahnya jumlah lemparan, proporsinya cenderung mendekati probabilitas $1/6 \approx 0.167$.

HUKUM BILANGAN BESAR

Semakin banyak pengamatan dikumpulkan, proporsi $\hat{p}_n$ kemunculan suatu hasil tertentu akan konvergen ke probabilitas p hasil tersebut.

Sesekali proporsi akan menyimpang dari probabilitas dan tampak menentang Hukum Bilangan Besar, seperti yang sering terjadi pada $\hat{p}_n$ di Gambar 3.1. Namun, penyimpangan itu mengecil ketika jumlah lemparan bertambah.

Di atas kita menulis p sebagai probabilitas memperoleh 1. Probabilitas ini juga dapat ditulis sebagai

$$P(\text{memperoleh } 1)$$

Seiring terbiasanya kita dengan notasi ini, kita dapat meningkatkannya lebih lanjut. Misalnya, jika prosesnya jelas berupa “melempar dadu”, kita dapat meningkatkan $P(\text{memperoleh } 1)$ menjadi $P(1)$.

LATIHAN TERBIMBING 3.6



Contoh proses acak adalah melempar dadu dan melempar koin. (a) Pikirkan proses acak lain. (b) Uraikan semua hasil yang mungkin dari proses itu. Sebagai contoh, melempar dadu adalah proses acak dengan hasil yang mungkin 1, 2, ..., 6.¹

Hal-hal yang kita anggap sebagai proses acak belum tentu benar-benar acak; mungkin saja proses itu terlalu sulit dipahami secara tepat. Contoh keempat dalam jawaban catatan kaki Latihan Terbimbing 3.6 mengisyaratkan bahwa perilaku teman sekamar adalah proses acak. Namun, meskipun perilaku teman sekamar tidak benar-benar acak, memodelkannya sebagai proses acak tetap dapat berguna.

3.1.3 Hasil saling lepas atau saling eksklusif

Dua hasil disebut **saling lepas** atau **saling eksklusif** jika keduanya tidak mungkin terjadi bersamaan. Misalnya, jika kita melempar dadu, hasil 1 dan 2 saling lepas karena keduanya tidak mungkin muncul sekaligus. Sebaliknya, hasil 1 dan “memperoleh bilangan ganjil” tidak saling lepas karena keduanya terjadi jika hasil lemparan adalah 1. Istilah *saling lepas* dan *saling eksklusif* ekuivalen dan dapat dipertukarkan.

Menghitung probabilitas hasil yang saling lepas cukup mudah. Saat melempar dadu, hasil 1 dan 2 saling lepas, sehingga probabilitas salah satu hasil itu terjadi dihitung dengan menjumlahkan probabilitas masing-masing:

$$P(1 \text{ atau } 2) = P(1) + P(2) = 1/6 + 1/6 = 1/3$$

Bagaimana dengan probabilitas memperoleh 1, 2, 3, 4, 5, atau 6? Sekali lagi, semua hasil tersebut saling lepas, sehingga probabilitasnya dijumlahkan:

$$\begin{aligned} P(1 \text{ atau } 2 \text{ atau } 3 \text{ atau } 4 \text{ atau } 5 \text{ atau } 6) \\ &= P(1) + P(2) + P(3) + P(4) + P(5) + P(6) \\ &= 1/6 + 1/6 + 1/6 + 1/6 + 1/6 + 1/6 = 1 \end{aligned}$$

Aturan Penjumlahan menjamin ketepatan pendekatan ini ketika hasil-hasilnya saling lepas.

ATURAN PENJUMLAHAN UNTUK HASIL YANG SALING LEPAS

Jika A_1 dan A_2 menyatakan dua hasil yang saling lepas, probabilitas salah satunya terjadi diberikan oleh

$$P(A_1 \text{ atau } A_2) = P(A_1) + P(A_2)$$

Jika terdapat banyak hasil yang saling lepas, $A_1, \dots, A_k$, probabilitas salah satu hasil tersebut terjadi adalah

$$P(A_1) + P(A_2) + \dots + P(A_k)$$

¹Berikut empat contoh. (i) Apakah seseorang akan sakit bulan depan atau tidak merupakan proses yang tampak acak, dengan hasil **sakit** dan **tidak**. (ii) Kita dapat *membangkitkan* proses acak dengan memilih seseorang secara acak lalu mengukur tinggi badannya. Hasil proses ini berupa bilangan positif. (iii) Apakah pasar saham naik atau turun minggu depan merupakan proses yang tampak acak, dengan hasil yang mungkin **naik**, **turun**, dan **tidak berubah**. Sebagai alternatif, perubahan persentase pasar saham dapat digunakan sebagai hasil numerik. (iv) Apakah teman sekamar Anda mencuci piring malam ini juga mungkin tampak seperti proses acak, dengan hasil **mencuci piring** dan **meninggalkan piring**.

LATIHAN TERBIMBING 3.7

G

Kita tertarik pada probabilitas memperoleh 1, 4, atau 5. (a) Jelaskan mengapa hasil 1, 4, dan 5 saling lepas. (b) Terapkan Aturan Penjumlahan untuk hasil yang saling lepas guna menentukan $P(1 \text{ atau } 4 \text{ atau } 5)$.²


LATIHAN TERBIMBING 3.8

Dalam himpunan data **loans** pada Bab 2, variabel **homeownership** menjelaskan apakah peminjam menyewa, memiliki hipotek, atau memiliki rumah sendiri. Dari 10.000 peminjam, 3858 menyewa, 4789 memiliki hipotek, dan 1353 memiliki rumah sendiri.³

G

- Apakah hasil **rent**, **mortgage**, dan **own** saling lepas?
- Tentukan proporsi pinjaman dengan nilai **mortgage** dan **own** secara terpisah.
- Gunakan Aturan Penjumlahan untuk hasil yang saling lepas guna menghitung probabilitas bahwa pinjaman yang dipilih secara acak dari himpunan data tersebut adalah milik seseorang yang memiliki hipotek atau rumah sendiri.

Ilmuwan data jarang bekerja dengan hasil individual; mereka lebih sering mempertimbangkan *himpunan* atau *kumpulan* hasil. Misalkan A menyatakan peristiwa ketika lemparan dadu menghasilkan 1 atau 2, dan B menyatakan peristiwa ketika lemparan menghasilkan 4 atau 6. Kita menulis A sebagai himpunan hasil $\{1, 2\}$ dan $B = \{4, 6\}$. Himpunan-himpunan ini lazim disebut **peristiwa**. Karena A dan B tidak memiliki elemen yang sama, keduanya adalah peristiwa yang saling lepas. A dan B ditunjukkan pada Gambar 3.2.



Gambar 3.2: Tiga peristiwa, A , B , dan D , terdiri atas hasil dari lemparan dadu. A dan B saling lepas karena tidak memiliki hasil yang sama.

Aturan Penjumlahan berlaku untuk hasil maupun peristiwa yang saling lepas. Probabilitas salah satu peristiwa saling lepas A atau B terjadi adalah jumlah probabilitas masing-masing:

$$P(A \text{ atau } B) = P(A) + P(B) = 1/3 + 1/3 = 2/3$$

LATIHAN TERBIMBING 3.9

G

- Verifikasi bahwa probabilitas peristiwa A , $P(A)$, adalah $1/3$ menggunakan Aturan Penjumlahan.
- Lakukan hal yang sama untuk peristiwa B .⁴

LATIHAN TERBIMBING 3.10

G

- Dengan menggunakan Gambar 3.2 sebagai acuan, hasil apa yang direpresentasikan oleh peristiwa D ? (b) Apakah peristiwa B dan D saling lepas? (c) Apakah peristiwa A dan D saling lepas?⁵

²(a) Proses acaknya adalah lemparan dadu, dan paling banyak satu dari hasil tersebut yang dapat muncul. Jadi, hasil-hasil itu saling lepas. (b) $P(1 \text{ atau } 4 \text{ atau } 5) = P(1) + P(4) + P(5) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{3}{6} = \frac{1}{2}$.

³(a) Ya. Setiap pinjaman dikategorikan ke tepat satu level **homeownership**. (b) Hipotek: $\frac{4789}{10000} = 0.479$. Milik sendiri: $\frac{1353}{10000} = 0.135$. (c) $P(\text{mortgage atau own}) = P(\text{mortgage}) + P(\text{own}) = 0.479 + 0.135 = 0.614$.

⁴(a) $P(A) = P(1 \text{ atau } 2) = P(1) + P(2) = \frac{1}{6} + \frac{1}{6} = \frac{2}{6} = \frac{1}{3}$. (b) Dengan cara serupa, $P(B) = 1/3$.

⁵(a) Hasil 2 dan 3. (b) Ya, peristiwa B dan D saling lepas karena tidak memiliki hasil yang sama. (c) Peristiwa A dan D memiliki hasil yang sama, yaitu 2, sehingga tidak saling lepas.

LATIHAN TERBIMBING 3.11

Dalam Latihan Terbimbing 3.10, Anda mengonfirmasi bahwa B dan D pada Gambar 3.2 saling lepas. Hitung probabilitas peristiwa B atau D terjadi.⁶

⁶Karena B dan D adalah peristiwa yang saling lepas, gunakan Aturan Penjumlahan: $P(B \text{ atau } D) = P(B) + P(D) = \frac{1}{3} + \frac{1}{3} = \frac{2}{3}$.

3.1.4 Probabilitas ketika peristiwa tidak saling lepas

Mari kita pertimbangkan perhitungan untuk dua peristiwa yang tidak saling lepas dalam konteks dek standar 52 kartu, yang ditampilkan pada Gambar 3.3. Jika Anda belum mengenal kartu dalam dek standar, lihat catatan kaki.⁷


2♣	3♣	4♣	5♣	6♣	7♣	8♣	9♣	10♣	J♣	Q♣	K♣	A♣
2♦	3♦	4♦	5♦	6♦	7♦	8♦	9♦	10♦	J♦	Q♦	K♦	A♦
2♥	3♥	4♥	5♥	6♥	7♥	8♥	9♥	10♥	J♥	Q♥	K♥	A♥
2♠	3♠	4♠	5♠	6♠	7♠	8♠	9♠	10♠	J♠	Q♠	K♠	A♠

Gambar 3.3: Representasi 52 kartu unik dalam sebuah dek.

LATIHAN TERBIMBING 3.12

(a) Berapa probabilitas kartu yang dipilih secara acak merupakan wajik? (b) Berapa probabilitas kartu yang dipilih secara acak merupakan kartu bergambar?⁸

Diagram Venn berguna ketika hasil dapat dikategorikan sebagai “masuk” atau “tidak masuk” untuk dua atau tiga variabel, atribut, atau proses acak. Diagram Venn pada Gambar 3.4 menggunakan satu lingkaran untuk mewakili wajik dan lingkaran lain untuk mewakili kartu bergambar. Jika sebuah kartu merupakan wajik sekaligus kartu bergambar, kartu itu berada di irisan kedua lingkaran. Jika kartu itu wajik tetapi bukan kartu bergambar, kartu itu berada di bagian lingkaran kiri yang tidak termasuk lingkaran kanan (dan seterusnya). Jumlah kartu wajik diberikan oleh seluruh kartu di dalam lingkaran wajik: $10 + 3 = 13$. Probabilitasnya juga ditampilkan (misalnya, $10/52 = 0.1923$).



Gambar 3.4: Diagram Venn untuk wajik dan kartu bergambar.

Misalkan A menyatakan peristiwa bahwa kartu yang dipilih secara acak adalah wajik dan B menyatakan peristiwa bahwa kartu tersebut merupakan kartu bergambar. Bagaimana menghitung $P(A$ atau $B)$? Peristiwa A dan B tidak saling lepas—kartu $J♦$, $Q♦$, dan $K♦$ termasuk dalam kedua kategori—sehingga kita tidak dapat menggunakan Aturan Penjumlahan untuk peristiwa yang saling lepas. Sebagai gantinya, kita menggunakan diagram Venn. Kita mulai dengan menjumlahkan probabilitas kedua peristiwa:

$$P(A) + P(B) = P(♦) + P(\text{kartu bergambar}) = 13/52 + 12/52$$

⁷Ke-52 kartu dibagi menjadi empat **jenis**: ♣ (keriting), ♦ (wajik), ♥ (hati), dan ♠ (sekop). Setiap jenis memiliki 13 kartu berlabel: 2, 3, ..., 10, J (jack), Q (queen), K (king), dan A (as). Jadi, setiap kartu merupakan kombinasi unik antara jenis dan label, misalnya $4♥$ dan $J♣$. Ke-12 kartu berupa jack, queen, dan king disebut **kartu bergambar**. Kartu berjenis ♦ atau ♥ biasanya berwarna **merah**, sedangkan dua jenis lainnya biasanya berwarna hitam.

⁸(a) Ada 52 kartu dan 13 kartu wajik. Jika kartu dikocok dengan baik, setiap kartu memiliki peluang yang sama untuk terambil, sehingga probabilitas kartu yang dipilih secara acak merupakan wajik adalah $P(♦) = \frac{13}{52} = 0.250$. (b) Demikian pula, ada 12 kartu bergambar, sehingga $P(\text{kartu bergambar}) = \frac{12}{52} = \frac{3}{13} = 0.231$.

Namun, tiga kartu yang termasuk dalam kedua peristiwa telah dihitung dua kali, sekali pada setiap probabilitas. Kita harus memperbaiki penghitungan ganda ini:

$$\begin{aligned} P(A \text{ atau } B) &= P(\diamond \text{ atau kartu bergambar}) \\ &= P(\diamond) + P(\text{kartu bergambar}) - P(\diamond \text{ dan kartu bergambar}) \\ &= 13/52 + 12/52 - 3/52 \\ &= 22/52 = 11/26 \end{aligned}$$

Persamaan ini merupakan contoh **Aturan Penjumlahan Umum**.

ATURAN PENJUMLAHAN UMUM

Jika A dan B adalah sembarang dua peristiwa, baik saling lepas maupun tidak, probabilitas bahwa setidaknya salah satunya terjadi adalah

$$P(A \text{ atau } B) = P(A) + P(B) - P(A \text{ dan } B)$$

dengan $P(A \text{ dan } B)$ adalah probabilitas kedua peristiwa terjadi.

KIAT: “atau” bersifat inklusif

Ketika kita menulis “atau” dalam statistika, yang dimaksud adalah “dan/atau” kecuali dinyatakan secara eksplisit. Jadi, A atau B terjadi berarti A , B , atau keduanya, A dan B , terjadi.

LATIHAN TERBIMBING 3.13

G

(a) Jika A dan B saling lepas, jelaskan mengapa hal ini berarti $P(A \text{ dan } B) = 0$. (b) Dengan menggunakan bagian (a), verifikasi bahwa Aturan Penjumlahan Umum menyederhana menjadi Aturan Penjumlahan untuk peristiwa saling lepas jika A dan B saling lepas.⁹

LATIHAN TERBIMBING 3.14

G

Dalam himpunan data **loans** yang memuat 10.000 pinjaman, 1495 pinjaman berasal dari permohonan bersama (misalnya, pasangan mengajukan bersama), 4789 pemohon memiliki hipotek, dan 950 memiliki kedua karakteristik tersebut. Buat diagram Venn untuk situasi ini.¹⁰

LATIHAN TERBIMBING 3.15


G

(a) Gunakan diagram Venn dari Latihan Terbimbing 3.14 untuk menentukan probabilitas bahwa pinjaman yang dipilih secara acak dari himpunan data **loans** berasal dari permohonan bersama dengan pasangan yang memiliki hipotek. (b) Berapa probabilitas pinjaman memiliki salah satu atribut tersebut?¹¹

⁹(a) Jika A dan B saling lepas, A dan B tidak mungkin terjadi secara bersamaan. (b) Jika A dan B saling lepas, suku terakhir $P(A \text{ dan } B)$ dalam rumus Aturan Penjumlahan Umum bernilai 0 (lihat bagian (a)), sehingga tersisa Aturan Penjumlahan untuk peristiwa saling lepas.

¹⁰Baik jumlah maupun **probabilitas** yang bersesuaian (misalnya, $3839/10000 = 0.384$) ditampilkan. Perhatikan bahwa jumlah pinjaman pada lingkaran kiri adalah $3839 + 950 = 4789$, sedangkan jumlah pada lingkaran kanan adalah $950 + 545 = 1495$.

¹¹(a) Jawabannya direpresentasikan oleh irisan kedua lingkaran: 0.095. (b) Ini adalah jumlah tiga probabilitas yang saling lepas yang ditunjukkan di dalam lingkaran: $0.384 + 0.095 + 0.055 = 0.534$ (berbeda 0.001 karena pembulatan).



3.1.5 Distribusi probabilitas

Distribusi probabilitas adalah tabel semua hasil yang saling lepas beserta probabilitasnya. Gambar 3.5 menunjukkan distribusi probabilitas jumlah dua dadu.

Jumlah dadu	2	3	4	5	6	7	8	9	10	11	12
Probabilitas	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$

Gambar 3.5: Distribusi probabilitas jumlah dua dadu.

ATURAN DISTRIBUSI PROBABILITAS

Distribusi probabilitas adalah daftar hasil yang mungkin beserta probabilitasnya, yang memenuhi tiga aturan berikut:

1. Hasil yang tercantum harus saling lepas.
2. Setiap probabilitas harus berada antara 0 dan 1.
3. Jumlah seluruh probabilitas harus 1.


LATIHAN TERBIMBING 3.16

Gambar 3.6 menyajikan tiga distribusi pendapatan rumah tangga di Amerika Serikat. Hanya satu yang benar. Yang mana? Apa kesalahan pada dua lainnya?¹²

Rentang pendapatan	\$0-25k	\$25k-50k	\$50k-100k	\$100k+
(a)	0.18	0.39	0.33	0.16
(b)	0.38	-0.27	0.52	0.37
(c)	0.28	0.27	0.29	0.16


Gambar 3.6: Distribusi pendapatan rumah tangga AS yang diusulkan (Latihan Terbimbing 3.16).

Bab 1 menekankan pentingnya membuat plot data untuk memperoleh ringkasan cepat. Distribusi probabilitas juga dapat diringkas dengan diagram batang. Misalnya, distribusi pendapatan rumah tangga AS ditampilkan sebagai diagram batang pada Gambar 3.7. Distribusi probabilitas jumlah dua dadu ditampilkan pada Gambar 3.5 dan diplot pada Gambar 3.8.



Gambar 3.7: Distribusi probabilitas pendapatan rumah tangga AS.

¹²Probabilitas pada (a) tidak berjumlah 1. Probabilitas kedua pada (b) bernilai negatif. Dengan demikian tersisa (c), yang memang memenuhi syarat sebuah distribusi. Salah satu dari ketiganya disebut sebagai distribusi pendapatan rumah tangga AS yang sebenarnya, sehingga jawabannya pasti (c).




Gambar 3.8: Distribusi probabilitas jumlah dua dadu.

Pada diagram batang ini, tinggi batang merepresentasikan probabilitas hasil. Jika hasilnya numerik dan diskret, biasanya (secara visual) nyaman membuat diagram batang yang menyerupai histogram, seperti pada jumlah dua dadu. Contoh lain penempatan batang pada lokasi masing-masing ditunjukkan pada Gambar 3.18 di halaman 120.

3.1.6 Komplemen suatu peristiwa

Melempar dadu menghasilkan nilai dalam himpunan $\{1, 2, 3, 4, 5, 6\}$. Himpunan semua hasil yang mungkin ini disebut **ruang sampel** (S) untuk lemparan dadu. Kita sering menggunakan ruang sampel untuk memeriksa situasi ketika suatu peristiwa tidak terjadi.

Misalkan $D = \{2, 3\}$ menyatakan peristiwa bahwa hasil lemparan dadu adalah 2 atau 3. Kemudian **komplemen** D menyatakan semua hasil dalam ruang sampel yang bukan anggota D , dilambangkan dengan $D^c = \{1, 4, 5, 6\}$. Dengan kata lain, D^c adalah himpunan semua hasil yang mungkin yang belum termasuk dalam D . Gambar 3.9 menunjukkan hubungan antara D , D^c , dan ruang sampel S .

Gambar 3.9: Peristiwa $D = \{2, 3\}$ dan komplemennya, $D^c = \{1, 4, 5, 6\}$. S menyatakan ruang sampel, yaitu himpunan semua hasil yang mungkin.

LATIHAN TERBIMBING 3.17

(a) Hitung $P(D^c) = P(\text{memperoleh } 1, 4, 5, \text{ atau } 6)$. (b) Berapakah $P(D) + P(D^c)$?¹³

LATIHAN TERBIMBING 3.18

Peristiwa $A = \{1, 2\}$ dan $B = \{4, 6\}$ ditunjukkan pada Gambar 3.2 di halaman 86. (a) Tuliskan apa yang direpresentasikan oleh A^c dan B^c . (b) Hitung $P(A^c)$ dan $P(B^c)$. (c) Hitung $P(A) + P(A^c)$ dan $P(B) + P(B^c)$.¹⁴

¹³(a) Hasil-hasilnya saling lepas dan masing-masing memiliki probabilitas $1/6$, sehingga probabilitas totalnya $4/6 = 2/3$. (b) Kita juga dapat melihat bahwa $P(D) = \frac{1}{6} + \frac{1}{6} = 1/3$. Karena D dan D^c saling lepas, $P(D) + P(D^c) = 1$.

¹⁴Jawaban singkat: (a) $A^c = \{3, 4, 5, 6\}$ dan $B^c = \{1, 2, 3, 5\}$. (b) Karena setiap hasil saling lepas, jumlahkan probabilitas hasil individual untuk memperoleh $P(A^c) = 2/3$ dan $P(B^c) = 2/3$. (c) A dan A^c saling lepas, demikian

Komplemen suatu peristiwa A dibentuk agar memiliki dua sifat penting: (i) setiap hasil yang mungkin dan bukan anggota A merupakan anggota A^c , dan (ii) A dan A^c saling lepas. Sifat (i) menyiratkan

$$P(A \text{ atau } A^c) = 1$$

Artinya, jika hasil bukan anggota A , hasil itu harus direpresentasikan dalam A^c . Kita menggunakan Aturan Penjumlahan untuk peristiwa saling lepas guna menerapkan Sifat (ii):

$$P(A \text{ atau } A^c) = P(A) + P(A^c)$$

Menggabungkan dua persamaan terakhir menghasilkan hubungan yang sangat berguna antara probabilitas suatu peristiwa dan komplemennya.

KOMPLEMEN

Komplemen peristiwa A dilambangkan A^c , dan A^c menyatakan semua hasil yang bukan anggota A . A dan A^c berhubungan secara matematis:

$$P(A) + P(A^c) = 1, \quad \text{i.e.} \quad P(A) = 1 - P(A^c)$$

Dalam contoh sederhana, menghitung A atau A^c dapat dilakukan dalam beberapa langkah. Namun, menggunakan komplemen dapat menghemat banyak waktu ketika masalah menjadi lebih kompleks.

LATIHAN TERBIMBING 3.19

G

Misalkan A menyatakan peristiwa ketika kita melempar dua dadu dan jumlahnya kurang dari 12. (a) Apa yang direpresentasikan oleh peristiwa A^c ? (b) Tentukan $P(A^c)$ dari Gambar 3.5 pada halaman 90. (c) Tentukan $P(A)$.¹⁵

LATIHAN TERBIMBING 3.20

Tentukan probabilitas berikut untuk lemparan dua dadu:¹⁶

G

- (a) Jumlah dadu *bukan* 6.
- (b) Jumlahnya paling sedikit 4. Artinya, tentukan probabilitas peristiwa $B = \{4, 5, \dots, 12\}$.
- (c) Jumlahnya paling banyak 10. Artinya, tentukan probabilitas peristiwa $D = \{2, 3, \dots, 10\}$.

3.1.7 Kemandirian

Sebagaimana variabel dan pengamatan dapat saling independen, proses acak juga dapat saling independen. Dua proses **independen** jika mengetahui hasil salah satunya tidak memberikan informasi berguna tentang hasil yang lain. Misalnya, melempar koin dan melempar dadu adalah dua proses independen—mengetahui koin menunjukkan kepala tidak membantu menentukan hasil lemparan dadu. Sebaliknya, harga saham biasanya bergerak naik atau turun bersama-sama, sehingga tidak independen.

Contoh 3.5 memberikan contoh dasar dua proses independen: melempar dua dadu. Kita ingin

pula B dan B^c . Oleh karena itu, $P(A) + P(A^c) = 1$ dan $P(B) + P(B^c) = 1$.


¹⁵(a) Komplemen A : jumlahnya sama dengan 12. (b) $P(A^c) = 1/36$. (c) Gunakan probabilitas komplemen dari bagian (b), $P(A^c) = 1/36$, dan persamaan komplemen: $P(\text{kurang dari } 12) = 1 - P(12) = 1 - 1/36 = 35/36$.

¹⁶(a) Pertama, cari $P(6) = 5/36$, lalu gunakan komplemen: $P(\text{bukan } 6) = 1 - P(6) = 31/36$.

(b) Pertama, cari komplemennya, yang membutuhkan jauh lebih sedikit usaha: $P(2 \text{ atau } 3) = 1/36 + 2/36 = 1/12$. Kemudian hitung $P(B) = 1 - P(B^c) = 1 - 1/12 = 11/12$.

(c) Seperti sebelumnya, mencari komplemen adalah cara cerdas untuk menentukan $P(D)$. Pertama, cari $P(D^c) = P(11 \text{ atau } 12) = 2/36 + 1/36 = 1/12$. Kemudian hitung $P(D) = 1 - P(D^c) = 11/12$.

menentukan probabilitas keduanya menunjukkan 1. Misalkan salah satu dadu berwarna merah dan yang lain putih. Jika hasil dadu merah adalah 1, hal itu tidak memberikan informasi tentang hasil dadu putih. Kita telah menjumpai pertanyaan yang sama pada Contoh 3.5 (halaman 83), ketika probabilitas dihitung dengan penalaran berikut: dadu merah menunjukkan 1 pada $1/6$ bagian waktu, dan pada $1/6$ bagian dari *waktu tersebut* dadu putih juga menunjukkan 1. Hal ini diilustrasikan pada Gambar 3.10. Karena lemparan-lemparan itu independen, probabilitas hasil yang bersesuaian dapat dikalikan untuk memperoleh jawaban akhir: $(1/6) \times (1/6) = 1/36$. Penalaran ini dapat digeneralisasi ke banyak proses independen.



Gambar 3.10: Pada $1/6$ bagian waktu, lemparan pertama bernilai 1. Kemudian pada $1/6$ bagian dari *waktu tersebut*, lemparan kedua juga bernilai 1.

CONTOH 3.21

Bagaimana jika ada dadu biru yang juga independen dari dua dadu lainnya? Berapa probabilitas melempar ketiga dadu dan semuanya menunjukkan 1?

E

Logika yang sama seperti pada Contoh 3.5 berlaku. Jika dadu putih dan merah sama-sama 1 pada $1/36$ bagian waktu, maka pada $1/6$ bagian dari *waktu tersebut* dadu biru juga akan 1, sehingga kita mengalikan:

$$\begin{aligned} P(\text{putih} = 1 \text{ dan } \text{merah} = 1 \text{ dan } \text{biru} = 1) &= P(\text{putih} = 1) \times P(\text{merah} = 1) \times P(\text{biru} = 1) \\ &= (1/6) \times (1/6) \times (1/6) = 1/216 \end{aligned}$$

Contoh 3.21 mengilustrasikan apa yang disebut Aturan Perkalian untuk proses independen.

ATURAN PERKALIAN UNTUK PROSES INDEPENDEN

Jika A dan B menyatakan peristiwa dari dua proses yang berbeda dan independen, probabilitas bahwa A dan B terjadi dapat dihitung sebagai hasil kali probabilitas masing-masing:

$$P(A \text{ dan } B) = P(A) \times P(B)$$

Demikian pula, jika terdapat k peristiwa $A_1, \dots, A_k$ dari k proses independen, probabilitas semuanya terjadi adalah

$$P(A_1) \times P(A_2) \times \dots \times P(A_k)$$

LATIHAN TERBIMBING 3.22

G

Sekitar 9% orang kidal. Misalkan 2 orang dipilih secara acak dari populasi AS. Karena ukuran sampel 2 sangat kecil dibandingkan populasi, wajar untuk menganggap kedua orang ini independen. (a) Berapa probabilitas keduanya kidal? (b) Berapa probabilitas keduanya tidak kidal?¹⁷

LATIHAN TERBIMBING 3.23

Misalkan 5 orang dipilih secara acak.¹⁸

- (a) Berapa probabilitas semuanya tidak kidal?
 (b) Berapa probabilitas semuanya kidal?
 (c) Berapa probabilitas tidak semua orang tidak kidal?

Misalkan variabel **dominansi tangan** dan **jenis kelamin** independen, artinya mengetahui **jenis kelamin** seseorang tidak memberikan informasi berguna tentang **dominansi tangan**-nya, dan sebaliknya. Kita dapat menghitung probabilitas orang yang dipilih secara acak tidak kidal dan perempuan¹⁹ dengan Aturan Perkalian:

$$\begin{aligned} P(\text{tidak kidal dan perempuan}) &= P(\text{tidak kidal}) \times P(\text{perempuan}) \\ &= 0.91 \times 0.50 = 0.455 \end{aligned}$$

LATIHAN TERBIMBING 3.24

Tiga orang dipilih secara acak.²⁰

- (a) Berapa probabilitas orang pertama laki-laki dan tidak kidal?
 (b) Berapa probabilitas dua orang pertama laki-laki dan tidak kidal?
 (c) Berapa probabilitas orang ketiga perempuan dan kidal?
 (d) Berapa probabilitas dua orang pertama laki-laki dan tidak kidal, sedangkan orang ketiga perempuan dan kidal?

Kadang-kadang kita ingin tahu apakah suatu hasil memberikan informasi berguna tentang hasil lain. Pertanyaannya: apakah kemunculan kedua peristiwa itu independen? Dua peristiwa A dan B disebut independen jika memenuhi $P(A \text{ dan } B) = P(A) \times P(B)$.

¹⁷(a) Probabilitas orang pertama kidal adalah 0.09, sama dengan orang kedua. Kita menerapkan Aturan Perkalian untuk proses independen untuk menentukan probabilitas keduanya kidal: $0.09 \times 0.09 = 0.0081$.

(b) Wajar untuk menganggap proporsi orang ambidekster (dapat menggunakan tangan kanan dan kiri) mendekati 0, sehingga $P(\text{tidak kidal}) = 1 - 0.09 = 0.91$. Dengan penalaran yang sama seperti bagian (a), probabilitas keduanya tidak kidal adalah $0.91 \times 0.91 = 0.8281$.

¹⁸(a) Singkatan RH dan LH digunakan masing-masing untuk tidak kidal dan kidal. Karena semuanya independen, kita menerapkan Aturan Perkalian untuk proses independen:

$$\begin{aligned} P(\text{kelima orang adalah RH}) &= P(\text{pertama} = \text{RH}, \text{kedua} = \text{RH}, \dots, \text{kelima} = \text{RH}) \\ &= P(\text{pertama} = \text{RH}) \times P(\text{kedua} = \text{RH}) \times \dots \times P(\text{kelima} = \text{RH}) \\ &= 0.91 \times 0.91 \times 0.91 \times 0.91 \times 0.91 = 0.624 \end{aligned}$$

(b) Dengan penalaran yang sama seperti pada (a), $0.09 \times 0.09 \times 0.09 \times 0.09 \times 0.09 = 0.0000059$

(c) Gunakan komplemen, $P(\text{kelima orang RH})$, untuk menjawab pertanyaan ini:

$$P(\text{tidak semua RH}) = 1 - P(\text{semua RH}) = 1 - 0.624 = 0.376$$

¹⁹Proporsi aktual populasi AS yang perempuan sekitar 50%, sehingga kita menggunakan 0,5 sebagai probabilitas memilih perempuan. Namun, probabilitas ini berbeda di negara lain.

²⁰Jawaban singkat diberikan. (a) Dalam notasi probabilitas, ini dapat ditulis $P(\text{orang yang dipilih secara acak adalah laki-laki dan tidak kidal}) = 0.455$. (b) 0.207. (c) 0.045. (d) 0.0093.

CONTOH 3.25

Jika kita mengocok dek kartu lalu mengambil satu kartu, apakah peristiwa kartu itu hati independen dari peristiwa kartu itu as?

E

Probabilitas kartu itu hati adalah $1/4$ dan probabilitas kartu itu as adalah $1/13$. Probabilitas kartu itu as hati adalah $1/52$. Kita memeriksa apakah $P(A \text{ dan } B) = P(A) \times P(B)$ terpenuhi:

$$P(\heartsuit) \times P(\text{as}) = \frac{1}{4} \times \frac{1}{13} = \frac{1}{52} = P(\heartsuit \text{ dan as})$$

Karena persamaan tersebut berlaku, peristiwa kartu itu hati dan peristiwa kartu itu as merupakan peristiwa independen.

Latihan

3.1 Benar atau salah. Tentukan apakah pernyataan berikut benar atau salah, dan jelaskan penalaran Anda.

- (a) Jika koin adil dilempar berkali-kali dan delapan lemparan terakhir semuanya kepala, peluang lemparan berikutnya menghasilkan kepala sedikit kurang dari 50%.
- (b) Mengambil kartu bergambar (jack, queen, atau king) dan mengambil kartu merah dari dek kartu penuh merupakan peristiwa yang saling eksklusif.
- (c) Mengambil kartu bergambar dan mengambil kartu as dari dek kartu penuh merupakan peristiwa yang saling eksklusif.

3.2 Roda roulette. Permainan roulette menggunakan roda dengan 38 slot: 18 merah, 18 hitam, dan 2 hijau. Sebuah bola diputar di atas roda dan akhirnya berhenti di salah satu slot; setiap slot memiliki peluang yang sama untuk menangkap bola.

- (a) Anda mengamati roda roulette berputar 3 kali berturut-turut dan bola berhenti di slot merah setiap kali. Berapa probabilitas bola berhenti di slot merah pada putaran berikutnya?
- (b) Anda mengamati roda roulette berputar 300 kali berturut-turut dan bola berhenti di slot merah setiap kali. Berapa probabilitas bola berhenti di slot merah pada putaran berikutnya?
- (c) Apakah Anda sama yakinnya terhadap jawaban bagian (a) dan (b)? Mengapa?



Photo by Håkan Dahlström
(<http://flic.kr/p/93fEzp>)
lisensi CC BY 2.0

3.3 Empat permainan, satu pemenang. Berikut empat versi permainan yang sama. Musuh bebuyutan Anda memilih versinya, lalu Anda memilih berapa kali melempar koin: 10 atau 100 kali. Tentukan jumlah lemparan koin yang sebaiknya dipilih untuk setiap versi. Biaya bermain setiap permainan adalah \$1. Jelaskan penalaran Anda.

- (a) Jika proporsi kepala lebih besar dari 0.60, Anda menang \$1.
- (b) Jika proporsi kepala lebih besar dari 0.40, Anda menang \$1.
- (c) Jika proporsi kepala berada antara 0.40 dan 0.60, Anda menang \$1.
- (d) Jika proporsi kepala lebih kecil dari 0.30, Anda menang \$1.

3.4 Backgammon. Backgammon adalah permainan papan untuk dua pemain, dengan bidak yang dipindahkan sesuai hasil lemparan dua dadu. Pemain menang dengan mengeluarkan semua bidaknya dari papan, sehingga biasanya baik untuk memperoleh angka tinggi. Anda bermain backgammon dengan seorang teman dan mendapatkan dua angka 6 pada lemparan pertama serta dua angka 6 pada lemparan kedua. Teman Anda mendapatkan dua angka 3 pada lemparan pertama dan lagi pada lemparan kedua. Teman Anda menuduh Anda curang karena memperoleh dua angka 6 dua kali berturut-turut tampak sangat tidak mungkin. Dengan probabilitas, tunjukkan bahwa lemparan Anda sama mungkin dengan lemparannya.

3.5 Lemparan koin. Jika Anda melempar koin adil 10 kali, berapa probabilitas

- (a) semuanya ekor?
- (b) semuanya kepala?
- (c) setidaknya satu ekor?

3.6 Lemparan dadu. Jika Anda melempar sepasang dadu adil, berapa probabilitas

- (a) memperoleh jumlah 1?
- (b) memperoleh jumlah 5?
- (c) memperoleh jumlah 12?

3.7 Pemilih mengambang. Survei Pew Research menanyakan kepada 2.373 pemilih terdaftar yang dipilih secara acak tentang afiliasi politik mereka (Republik, Demokrat, atau Independen) dan apakah mereka mengidentifikasi diri sebagai pemilih mengambang. Sebanyak 35% responden mengidentifikasi diri sebagai Independen, 23% sebagai pemilih mengambang, dan 11% sebagai keduanya.²¹

- (a) Apakah menjadi Independen dan menjadi pemilih mengambang saling lepas, yaitu saling eksklusif?
- (b) Buat diagram Venn yang merangkum variabel dan probabilitas terkait.
- (c) Berapa persen pemilih yang Independen tetapi bukan pemilih mengambang?
- (d) Berapa persen pemilih yang Independen atau pemilih mengambang?
- (e) Berapa persen pemilih yang bukan Independen maupun pemilih mengambang?
- (f) Apakah peristiwa seseorang menjadi pemilih mengambang independen dari peristiwa seseorang menjadi Independen secara politik?

3.8 Kemiskinan dan bahasa. American Community Survey adalah survei berkelanjutan yang menyediakan data setiap tahun agar komunitas memperoleh informasi terkini yang dibutuhkan untuk merencanakan investasi dan layanan. American Community Survey tahun 2010 memperkirakan 14.6% orang Amerika hidup di bawah garis kemiskinan, 20.7% berbicara bahasa selain bahasa Inggris (bahasa asing) di rumah, dan 4.2% termasuk dalam kedua kategori tersebut.²²

- (a) Apakah hidup di bawah garis kemiskinan dan berbicara bahasa asing di rumah saling lepas?
- (b) Buat diagram Venn yang merangkum variabel dan probabilitas terkait.
- (c) Berapa persen orang Amerika yang hidup di bawah garis kemiskinan dan hanya berbicara bahasa Inggris di rumah?
- (d) Berapa persen orang Amerika yang hidup di bawah garis kemiskinan atau berbicara bahasa asing di rumah?
- (e) Berapa persen orang Amerika yang hidup di atas garis kemiskinan dan hanya berbicara bahasa Inggris di rumah?
- (f) Apakah peristiwa seseorang hidup di bawah garis kemiskinan independen dari peristiwa orang tersebut berbicara bahasa asing di rumah?

3.9 Saling lepas versus independen. Pada bagian (a) dan (b), tentukan apakah peristiwa saling lepas, independen, atau tidak keduanya (peristiwa tidak dapat sekaligus saling lepas dan independen).

- (a) Anda dan seorang mahasiswa dari kelas Anda yang dipilih secara acak sama-sama mendapat nilai A dalam mata kuliah ini.
- (b) Anda dan rekan belajar sekelas sama-sama mendapat nilai A dalam mata kuliah ini.
- (c) Jika dua peristiwa dapat terjadi bersamaan, apakah keduanya pasti dependen?

3.10 Menebak dalam ujian. Dalam ujian pilihan ganda, terdapat 5 pertanyaan dan 4 pilihan untuk setiap pertanyaan (a, b, c, d). Nancy sama sekali belum belajar untuk ujian dan memutuskan menebak jawaban secara acak. Berapa probabilitas bahwa:

- (a) pertanyaan pertama yang dijawab benar adalah pertanyaan ke-5?
- (b) ia menjawab semua pertanyaan dengan benar?
- (c) ia menjawab setidaknya satu pertanyaan dengan benar?

²¹Pew Research Center, With Voters Focused on Economy, Obama Lead Narrows, data collected between April 4-15, 2012.

²²U.S. Census Bureau, 2010 American Community Survey 1-Year Estimates, Characteristics of People by Language Spoken at Home.

3.11 Pencapaian pendidikan pasangan. Tabel berikut menunjukkan distribusi tingkat pendidikan yang dicapai penduduk AS menurut gender berdasarkan data American Community Survey 2010.²³

		<i>Jenis kelamin</i>	
		Laki-laki	Perempuan
<i>Pendidikan tertinggi yang dicapai</i>	Kurang dari kelas 9	0.07	0.13
	Kelas 9 sampai 12, tanpa ijazah	0.10	0.09
	Lulusan SMA (atau sederajat)	0.30	0.20
	Pernah kuliah, tanpa gelar	0.22	0.24
	Gelar associate	0.06	0.08
	Gelar sarjana	0.16	0.17
	Gelar pascasarjana atau profesional	0.09	0.09
	Total	1.00	1.00

- Berapa probabilitas laki-laki yang dipilih secara acak memiliki setidaknya gelar sarjana?
- Berapa probabilitas perempuan yang dipilih secara acak memiliki setidaknya gelar sarjana?
- Berapa probabilitas laki-laki dan perempuan yang menikah sama-sama memiliki setidaknya gelar sarjana? Catat asumsi yang harus dibuat untuk menjawab pertanyaan ini.
- Jika Anda membuat asumsi pada bagian (c), apakah asumsi itu wajar? Jika tidak membuat asumsi, periksa kembali jawaban sebelumnya lalu kembali ke bagian ini.

3.12 Ketidakhadiran di sekolah. Data yang dikumpulkan di sekolah dasar di DeKalb County, GA menunjukkan bahwa setiap tahun sekitar 25% siswa tidak masuk tepat satu hari, 15% tidak masuk 2 hari, dan 28% tidak masuk 3 hari atau lebih karena sakit.²⁴

- Berapa probabilitas siswa yang dipilih secara acak tidak absen sama sekali karena sakit tahun ini?
- Berapa probabilitas siswa yang dipilih secara acak absen tidak lebih dari satu hari?
- Berapa probabilitas siswa yang dipilih secara acak absen setidaknya satu hari?
- Jika orang tua memiliki dua anak di sekolah dasar DeKalb County, berapa probabilitas tidak satu pun anak absen? Catat asumsi yang harus dibuat untuk menjawab pertanyaan ini.
- Jika orang tua memiliki dua anak di sekolah dasar DeKalb County, berapa probabilitas kedua anak absen, yaitu setidaknya satu hari? Catat asumsi yang dibuat.
- Jika Anda membuat asumsi pada bagian (d) atau (e), apakah asumsi itu wajar? Jika tidak membuat asumsi, periksa kembali jawaban sebelumnya.

²³U.S. Census Bureau, 2010 American Community Survey 1-Year Estimates, Educational Attainment.

²⁴S.S. Mizan et al. "Absence, Extended Absence, and Repeat Tardiness Related to Asthma Status among Elementary School Children". In: *Journal of Asthma* 48.3 (2011), pp. 228–234.

3.2 Peluang bersyarat


Hubungan antara dua variabel atau lebih dapat sangat kaya dan penting untuk dipahami. Sebagai contoh, perusahaan asuransi mobil akan mempertimbangkan informasi tentang riwayat mengemudi seseorang untuk menilai risiko bahwa orang tersebut akan menyebabkan kecelakaan. Hubungan semacam ini merupakan ranah peluang bersyarat.

3.2.1 Mengeksplorasi peluang dengan tabel kontingensi

Himpunan data `photo_classify` memuat hasil kerja sebuah pengklasifikasi pada sampel 1822 foto dari situs berbagi foto. Para ilmuwan data berupaya meningkatkan kemampuan pengklasifikasi untuk menentukan apakah sebuah foto berkaitan dengan mode, dan 1.822 foto ini digunakan untuk menguji pengklasifikasi tersebut. Setiap foto memperoleh dua klasifikasi: yang pertama disebut `mach_learn` dan berisi klasifikasi dari sistem pembelajaran mesin (ML), yakni `pred_fashion` atau `pred_not`. Masing-masing dari 1822 foto ini juga telah diklasifikasikan dengan cermat oleh sebuah tim manusia, yang kita jadikan acuan kebenaran; variabel ini disebut `truth` dan bernilai `fashion` atau `not`. Gambar 3.11 merangkum hasilnya.

		truth		Total
		fashion	not	
mach_learn	pred_fashion	197	22	219
	pred_not	112	1491	1603
	Total	309	1513	1822

Gambar 3.11: Tabel kontingensi yang merangkum himpunan data `photo_classify`.



Gambar 3.12: Diagram Venn yang menggunakan kotak untuk himpunan data `photo_classify`.

CONTOH 3.26

Jika sebuah foto memang berkaitan dengan mode, berapa peluang pengklasifikasi ML mengidentifikasi dengan benar bahwa foto tersebut berkaitan dengan mode?

E

Kita dapat memperkirakan peluang ini menggunakan data. Dari 309 foto mode, algoritma ML mengklasifikasikan 197 foto dengan benar:

$$P(\text{mach_learn adalah pred_fashion jika truth adalah fashion}) = \frac{197}{309} = 0.638$$

CONTOH 3.27

Kita mengambil sampel sebuah foto dari himpunan data dan mengetahui bahwa algoritma ML memprediksi foto ini tidak berkaitan dengan mode. Berapa peluang prediksi tersebut keliru dan foto itu sebenarnya berkaitan dengan mode?

E

Jika pengklasifikasi ML menyatakan bahwa sebuah foto tidak berkaitan dengan mode, foto itu berasal dari baris kedua pada himpunan data. Dari 1603 foto tersebut, 112 sebenarnya berkaitan dengan mode:

$$P(\text{truth adalah fashion jika mach_learn adalah pred_not}) = \frac{112}{1603} = 0.070$$

3.2.2 Peluang marginal dan bersama

Gambar 3.11 memuat total baris dan kolom untuk setiap variabel secara terpisah dalam himpunan data `photo_classify`. Total-total ini menyatakan **peluang marginal** untuk sampel tersebut, yaitu peluang yang didasarkan pada satu variabel tanpa memperhatikan variabel lain. Sebagai contoh, peluang yang hanya didasarkan pada variabel `mach_learn` merupakan peluang marginal:

$$P(\text{mach_learn adalah pred_fashion}) = \frac{219}{1822} = 0.12$$

Peluang hasil untuk dua variabel atau proses atau lebih disebut **peluang bersama**:

$$P(\text{mach_learn adalah pred_fashion dan truth adalah fashion}) = \frac{197}{1822} = 0.11$$

Dalam peluang bersama, kata “dan” lazim diganti dengan koma, meskipun penggunaan kata “dan” maupun koma sama-sama dapat diterima:

$$P(\text{mach_learn adalah pred_fashion, truth adalah fashion})$$

berarti sama dengan

$$P(\text{mach_learn adalah pred_fashion dan truth adalah fashion})$$

PELUANG MARGINAL DAN BERSAMA

Jika suatu peluang didasarkan pada satu variabel, peluang tersebut merupakan *peluang marginal*. Peluang hasil untuk dua variabel atau proses atau lebih disebut *peluang bersama*.

Kita menggunakan **proporsi tabel** untuk merangkum peluang bersama pada sampel `photo_classify`. Proporsi ini dihitung dengan membagi setiap frekuensi dalam Gambar 3.11 dengan total tabel, 1822, sehingga diperoleh proporsi pada Gambar 3.13. Distribusi peluang bersama variabel `mach_learn` dan `truth` ditampilkan pada Gambar 3.14.

	truth: fashion	truth: not	Total
mach_learn: pred_fashion	0.1081	0.0121	0.1202
mach_learn: pred_not	0.0615	0.8183	0.8798
Total	0.1696	0.8304	1.00

Gambar 3.13: Tabel peluang yang merangkum himpunan data `photo_classify`.

Hasil bersama	Peluang
<code>mach_learn</code> adalah <code>pred_fashion</code> dan <code>truth</code> adalah <code>fashion</code>	0.1081
<code>mach_learn</code> adalah <code>pred_fashion</code> dan <code>truth</code> adalah <code>not</code>	0.0121
<code>mach_learn</code> adalah <code>pred_not</code> dan <code>truth</code> adalah <code>fashion</code>	0.0615
<code>mach_learn</code> adalah <code>pred_not</code> dan <code>truth</code> adalah <code>not</code>	0.8183
Total	1.0000

Gambar 3.14: Distribusi peluang bersama untuk himpunan data `photo_classify`.**LATIHAN TERBIMBING 3.28**

Verifikasikan bahwa Gambar 3.14 menyatakan suatu distribusi probabilitas: peristiwa-peristiwanya saling lepas, semua peluangnya tak negatif, dan jumlah seluruh peluangnya adalah 1.²⁵

Peluang marginal dapat dihitung dari peluang bersama. Misalnya, peluang foto bertema mode adalah jumlah peluang bagi hasil-hasil dengan `truth` bernilai `fashion`:

$$\begin{aligned}
 P(\text{truth adalah fashion}) &= P(\text{mach_learn adalah pred_fashion dan truth adalah fashion}) \\
 &\quad + P(\text{mach_learn adalah pred_not dan truth adalah fashion}) \\
 &= 0.1081 + 0.0615 \\
 &= 0.1696
 \end{aligned}$$

3.2.3 Mendefinisikan peluang bersyarat

Pengklasifikasi ML memprediksi apakah sebuah foto berkaitan dengan mode, meskipun hasilnya tidak sempurna. Kita ingin memahami dengan lebih baik cara menggunakan informasi dari variabel seperti `mach_learn` untuk memperbaiki perkiraan peluang bagi variabel kedua, yang dalam contoh ini adalah `truth`.

Peluang bahwa sebuah foto acak dari himpunan data berkaitan dengan mode adalah sekitar 0,17. Jika kita mengetahui bahwa pengklasifikasi pembelajaran mesin memprediksi foto tersebut berkaitan dengan mode, dapatkah kita memperoleh perkiraan yang lebih baik atas peluang bahwa foto itu memang berkaitan dengan mode? Tentu saja. Untuk melakukannya, kita membatasi perhatian hanya pada 219 kasus ketika pengklasifikasi ML memprediksi bahwa foto tersebut berkaitan dengan mode, lalu melihat fraksi foto yang memang berkaitan dengan mode:

$$P(\text{truth adalah fashion jika mach_learn adalah pred_fashion}) = \frac{197}{219} = 0.900$$

Kita menyebutnya **peluang bersyarat** karena kita menghitung peluang di bawah suatu syarat: pengklasifikasi ML memprediksi bahwa foto tersebut berkaitan dengan mode.

Peluang bersyarat terdiri atas dua bagian, yaitu **hasil yang menjadi perhatian** dan **syarat**. Syarat dapat dipandang sebagai informasi yang kita ketahui benar, dan informasi ini biasanya dapat dinyatakan sebagai hasil atau peristiwa yang diketahui. Dalam notasi peluang, kita umumnya memisahkan hasil yang menjadi perhatian dan syaratnya dengan garis vertikal:

$$\begin{aligned}
 &P(\text{truth adalah fashion jika mach_learn adalah pred_fashion}) \\
 &= P(\text{truth adalah fashion} \mid \text{mach_learn adalah pred_fashion}) = \frac{197}{219} = 0.900
 \end{aligned}$$

Garis vertikal “|” dibaca *dengan syarat*.

²⁵Keempat kombinasi hasil tersebut saling lepas, semua peluangnya memang tak negatif, dan jumlah peluangnya adalah $0.1081 + 0.0121 + 0.0615 + 0.8183 = 1.00$.

Pada persamaan terakhir, kita menghitung peluang sebuah foto berkaitan dengan mode dengan syarat algoritma ML memprediksi foto itu berkaitan dengan mode, sebagai fraksi:

$$\begin{aligned} &P(\text{truth adalah fashion} \mid \text{mach_learn adalah pred_fashion}) \\ &= \frac{\# \text{ kasus ketika truth adalah fashion dan mach_learn adalah pred_fashion}}{\# \text{ kasus ketika mach_learn adalah pred_fashion}} \\ &= \frac{197}{219} = 0.900 \end{aligned}$$

Kita hanya mempertimbangkan kasus yang memenuhi syarat, **mach_learn** bernilai **pred_fashion**, lalu menghitung rasio kasus yang memenuhi hasil yang menjadi perhatian, yaitu foto tersebut memang berkaitan dengan mode.

Sering kali peluang marginal dan bersama diberikan sebagai pengganti data frekuensi. Sebagai contoh, tingkat penyakit lazim disajikan dalam persentase, bukan dalam bentuk frekuensi. Kita ingin dapat menghitung peluang bersyarat meskipun tidak tersedia frekuensi, dan kita menggunakan persamaan terakhir sebagai pola untuk memahami teknik ini.

Kita hanya mempertimbangkan kasus yang memenuhi syarat, yaitu algoritma ML memprediksi mode. Di antara kasus-kasus ini, peluang bersyarat adalah fraksi yang menyatakan hasil yang menjadi perhatian, yakni foto tersebut berkaitan dengan mode. Misalkan kita hanya diberi informasi dalam Gambar 3.13, yaitu hanya data peluang. Jika kita kemudian mengambil sampel 1.000 foto, kita memperkirakan sekitar 12,0% atau $0.120 \times 1000 = 120$ foto akan diprediksi berkaitan dengan mode (**mach_learn** adalah **pred_fashion**). Demikian pula, kita memperkirakan sekitar 10,8% atau $0.108 \times 1000 = 108$ foto memenuhi kriteria informasi tersebut sekaligus mewakili hasil yang menjadi perhatian. Peluang bersyarat lalu dapat dihitung sebagai

$$\begin{aligned} &P(\text{truth adalah fashion} \mid \text{mach_learn adalah pred_fashion}) \\ &= \frac{\# (\text{truth adalah fashion dan mach_learn adalah pred_fashion})}{\# (\text{mach_learn adalah pred_fashion})} \\ &= \frac{108}{120} = \frac{0.108}{0.120} = 0.90 \end{aligned}$$

Di sini kita menelaah tepatnya fraksi dari dua peluang, 0,108 dan 0,120, yang dapat kita tulis sebagai

$$\begin{aligned} &P(\text{truth adalah fashion dan mach_learn adalah pred_fashion}) \\ &\text{dan} \quad P(\text{mach_learn adalah pred_fashion}). \end{aligned}$$

Fraksi kedua peluang ini merupakan contoh rumus umum peluang bersyarat.

PELUANG BERSYARAT

Peluang bersyarat hasil A dengan syarat B dihitung sebagai berikut:

$$P(A|B) = \frac{P(A \text{ dan } B)}{P(B)}$$

LATIHAN TERBIMBING 3.29

(a) Tuliskan pernyataan berikut dalam notasi peluang bersyarat: “Peluang bahwa prediksi ML benar, jika foto tersebut berkaitan dengan mode”. Di sini, syaratnya didasarkan pada status **truth** foto, bukan pada algoritma ML.

(b) Tentukan peluang pada bagian (a). Tabel 3.13 di halaman 100 mungkin membantu.²⁶

²⁶(a) Jika foto tersebut berkaitan dengan mode dan prediksi algoritma ML benar, maka variabel keluaran algoritma ML harus bernilai **pred_fashion**:

$$P(\text{mach_learn adalah pred_fashion} \mid \text{truth adalah fashion})$$

(b) Persamaan peluang bersyarat menunjukkan bahwa kita harus terlebih dahulu mencari $P(\text{mach_learn adalah pred_fashion dan truth adalah fashion}) = 0.1081$ dan $P(\text{truth adalah fashion}) = 0.1696$. Rasionya kemudian menyatakan peluang bersyarat: $0.1081/0.1696 = 0.6374$.

LATIHAN TERBIMBING 3.30

- (a) Tentukan peluang bahwa algoritma tersebut keliru jika diketahui foto itu berkaitan dengan mode.
 (b) Dengan menggunakan jawaban bagian (a) dan Latihan Terbimbing 3.29(b), hitung

$$P(\text{mach_learn adalah pred_fashion} \mid \text{truth adalah fashion}) \\ + P(\text{mach_learn adalah pred_not} \mid \text{truth adalah fashion})$$

- (c) Berikan alasan intuitif yang menjelaskan mengapa jumlah pada (b) bernilai 1.²⁷

3.2.4 Cacar di Boston, 1721

Himpunan data `smallpox` memuat sampel 6.224 orang dari tahun 1721 yang terpapar cacar di Boston. Para dokter pada masa itu meyakini bahwa inokulasi, yakni memaparkan seseorang pada penyakit secara terkendali, dapat mengurangi peluang kematian.

Setiap kasus mewakili satu orang dengan dua variabel: `inoculated` dan `result`. Variabel `inoculated` memiliki dua tingkat, yaitu `yes` atau `no`, yang menunjukkan apakah orang tersebut diinokulasi. Variabel `result` memiliki hasil `lived` atau `died`. Data ini dirangkum dalam Tabel 3.15 dan 3.16.

		diinokulasi		Total
		yes	no	
result	lived	238	5136	5374
	died	6	844	850
Total		244	5980	6224

Gambar 3.15: Tabel kontingensi untuk himpunan data `smallpox`.

		diinokulasi		Total
		yes	no	
result	lived	0.0382	0.8252	0.8634
	died	0.0010	0.1356	0.1366
Total		0.0392	0.9608	1.0000

Gambar 3.16: Proporsi tabel untuk data `smallpox`, yang dihitung dengan membagi setiap frekuensi dengan total tabel, 6.224.

LATIHAN TERBIMBING 3.31

- Tuliskan, dalam notasi formal, peluang bahwa seseorang yang dipilih secara acak dan tidak diinokulasi meninggal akibat cacar, lalu hitung peluang tersebut.²⁸

LATIHAN TERBIMBING 3.32

- Tentukan peluang bahwa seseorang yang diinokulasi meninggal akibat cacar. Bagaimana hasil ini dibandingkan dengan hasil Latihan Terbimbing 3.31?²⁹

²⁷(a) Peluang ini adalah $\frac{P(\text{mach_learn adalah pred_not, truth adalah fashion})}{P(\text{truth adalah fashion})} = \frac{0.0615}{0.1696} = 0.3626$. (b) Jumlahnya sama dengan 1. (c) Dengan syarat foto tersebut berkaitan dengan mode, algoritma ML pasti memprediksinya berkaitan dengan mode atau tidak berkaitan dengan mode. Aturan komplemen tetap berlaku untuk peluang bersyarat, selama peluang-peluang tersebut dikondisikan pada informasi yang sama.

²⁸ $P(\text{result} = \text{died} \mid \text{inoculated} = \text{no}) = \frac{P(\text{result} = \text{died dan inoculated} = \text{no})}{P(\text{inoculated} = \text{no})} = \frac{0.1356}{0.9608} = 0.1411$.

²⁹ $P(\text{result} = \text{died} \mid \text{inoculated} = \text{yes}) = \frac{P(\text{result} = \text{died dan inoculated} = \text{yes})}{P(\text{inoculated} = \text{yes})} = \frac{0.0010}{0.0392} = 0.0255$ (jika kesalahan pembulatan dihindari, diperoleh $6/244 = 0.0246$). Tingkat kematian orang yang diinokulasi hanya sekitar 1 dari 40,

LATIHAN TERBIMBING 3.33

G

Penduduk Boston memilih sendiri apakah mereka akan diinokulasi. (a) Apakah penelitian ini bersifat observasional atau merupakan eksperimen? (b) Dapatkah kita menyimpulkan hubungan sebab-akibat dari data ini? (c) Apa saja variabel perancu potensial yang mungkin memengaruhi apakah seseorang *lived* atau *died*, sekaligus memengaruhi apakah orang tersebut diinokulasi?³⁰

3.2.5 Aturan perkalian umum

Bagian 3.1.7 memperkenalkan Aturan Perkalian untuk proses yang saling independen. Di sini kita menyajikan **Aturan Perkalian Umum** untuk peristiwa yang mungkin tidak saling independen.

ATURAN PERKALIAN UMUM

Jika A dan B menyatakan dua hasil atau peristiwa, maka

$$P(A \text{ dan } B) = P(A|B) \times P(B)$$

A dapat dipandang sebagai hasil yang menjadi perhatian dan B sebagai syaratnya.

Aturan Perkalian Umum ini hanyalah bentuk susunan ulang dari persamaan peluang bersyarat.

CONTOH 3.34

Perhatikan himpunan data *smallpox*. Misalkan kita hanya diberi dua informasi: 96,08% penduduk tidak diinokulasi, dan 85,88% penduduk yang tidak diinokulasi bertahan hidup. Bagaimana kita dapat menghitung peluang bahwa seorang penduduk tidak diinokulasi dan tetap hidup?

Kita akan menghitung jawabannya menggunakan Aturan Perkalian Umum, lalu memverifikasinya dengan Gambar 3.16. Kita ingin menentukan

$$P(\text{result} = \text{lived dan inoculated} = \text{no})$$

E

dan diketahui bahwa

$$P(\text{result} = \text{lived} \mid \text{inoculated} = \text{no}) = 0.8588 \quad P(\text{inoculated} = \text{no}) = 0.9608$$

Di antara 96,08% orang yang tidak diinokulasi, 85,88% bertahan hidup:

$$P(\text{result} = \text{lived dan inoculated} = \text{no}) = 0.8588 \times 0.9608 = 0.8251$$

Perhitungan ini setara dengan Aturan Perkalian Umum. Kita dapat mengonfirmasi peluang ini pada Gambar 3.16, di perpotongan *no* dan *lived* (dengan sedikit kesalahan pembulatan).

LATIHAN TERBIMBING 3.35

G

Gunakan $P(\text{inoculated} = \text{yes}) = 0.0392$ dan $P(\text{result} = \text{lived} \mid \text{inoculated} = \text{yes}) = 0.9754$ untuk menentukan peluang bahwa seseorang diinokulasi dan tetap hidup.³¹

LATIHAN TERBIMBING 3.36

G

Jika 97,54% orang yang diinokulasi tetap hidup, berapa proporsi orang yang diinokulasi yang meninggal?³²

sedangkan pada orang yang tidak diinokulasi sekitar 1 dari 7.

³⁰Jawaban singkat: (a) Observasional. (b) Tidak, kita tidak dapat menyimpulkan sebab-akibat dari penelitian observasional ini. (c) Akses terhadap perawatan medis terbaru dan terbaik. Ada jawaban lain yang juga sah untuk bagian (c).

³¹Jawabannya adalah 0,0382, yang dapat diverifikasi menggunakan Gambar 3.16.

JUMLAH PELUANG BERSYARAT

Misalkan $A_1, \dots, A_k$ menyatakan semua hasil yang saling lepas bagi suatu variabel atau proses. Jika B adalah sebuah peristiwa, yang mungkin berasal dari variabel atau proses lain, maka:

$$P(A_1|B) + \dots + P(A_k|B) = 1$$

Aturan komplemen juga berlaku apabila sebuah peristiwa dan komplemennya dikondisikan pada informasi yang sama:

$$P(A|B) = 1 - P(A^c|B)$$

LATIHAN TERBIMBING 3.37

Berdasarkan peluang yang dihitung di atas, apakah inokulasi tampaknya efektif mengurangi risiko kematian akibat cacar?³³

3.2.6 Pertimbangan independensi dalam peluang bersyarat

Jika dua peristiwa saling independen, mengetahui hasil salah satunya tidak memberikan informasi tentang peristiwa lainnya. Dengan peluang bersyarat, kita dapat menunjukkan bahwa pernyataan ini benar secara matematis.

LATIHAN TERBIMBING 3.38

Misalkan X dan Y menyatakan hasil pelemparan dua dadu.³⁴

- Berapa peluang bahwa dadu pertama, X , menghasilkan 1?
- Berapa peluang bahwa X dan Y sama-sama menghasilkan 1?
- Gunakan rumus peluang bersyarat untuk menghitung $P(Y = 1 | X = 1)$.
- Berapa nilai $P(Y = 1)$? Apakah hasil ini berbeda dari jawaban bagian (c)? Jelaskan.

Pada Latihan Terbimbing 3.38(c), kita dapat menunjukkan bahwa informasi yang menjadi syarat tidak berpengaruh dengan menggunakan Aturan Perkalian untuk proses yang saling independen:

$$\begin{aligned} P(Y = 1 | X = 1) &= \frac{P(Y = 1 \text{ dan } X = 1)}{P(X = 1)} \\ &= \frac{P(Y = 1) \times P(X = 1)}{P(X = 1)} \\ &= P(Y = 1) \end{aligned}$$

LATIHAN TERBIMBING 3.39

Ron sedang mengamati meja rolet di kasino dan melihat bahwa lima hasil terakhir adalah **black**. Ia beranggapan bahwa peluang memperoleh **black** enam kali berturut-turut sangat kecil (sekitar $1/64$), lalu mempertaruhkan seluruh gajinya pada merah. Apa yang keliru dalam penalarannya?³⁵

³²Hanya ada dua hasil yang mungkin: **lived** atau **died**. Artinya, $100\% - 97,54\% = 2,46\%$ orang yang diinokulasi meninggal.


³³Ukuran sampelnya besar jika dibandingkan dengan perbedaan tingkat kematian antara kelompok “diinokulasi” dan “tidak diinokulasi”, sehingga tampaknya terdapat hubungan antara **inoculated** dan **result**. Namun, sebagaimana dicatat dalam jawaban Latihan Terbimbing 3.33, penelitian ini bersifat observasional sehingga kita tidak dapat memastikan adanya hubungan sebab-akibat. (Penelitian lebih lanjut menunjukkan bahwa inokulasi efektif menurunkan tingkat kematian.)

³⁴Jawaban singkat: (a) $1/6$. (b) $1/36$. (c) $\frac{P(Y=1 \text{ dan } X=1)}{P(X=1)} = \frac{1/36}{1/6} = 1/6$. (d) Peluangnya sama seperti pada bagian (c): $P(Y = 1) = 1/6$. Peluang bahwa $Y = 1$ tidak berubah setelah kita mengetahui X , sesuai dengan fakta bahwa X dan Y saling independen.

3.2.7 Diagram pohon

Diagram pohon merupakan alat untuk menata hasil dan peluang berdasarkan struktur data. Diagram ini paling berguna ketika dua proses atau lebih terjadi secara berurutan dan setiap proses dikondisikan pada proses-proses sebelumnya.

Data **smallpox** sesuai dengan gambaran ini. Populasi terbagi menurut **inoculation**: **yes** dan **no**. Setelah pembagian ini, tingkat kelangsungan hidup diamati pada setiap kelompok. Struktur tersebut tercermin dalam **diagram pohon** pada Gambar 3.17. Cabang pertama untuk **inoculation** disebut **cabang utama**, sedangkan cabang-cabang lainnya disebut **cabang sekunder**.



Gambar 3.17: Diagram pohon untuk himpunan data **smallpox**.

Diagram pohon diberi keterangan peluang marginal dan peluang bersyarat, seperti pada Gambar 3.17. Diagram ini membagi data cacar menurut **inoculation** menjadi kelompok **yes** dan **no**, dengan peluang marginal masing-masing 0,0392 dan 0,9608. Cabang-cabang sekunder dikondisikan pada cabang pertama, sehingga kita memberikan peluang bersyarat pada cabang-cabang ini. Sebagai contoh, cabang teratas pada Gambar 3.17 adalah peluang bahwa **result** = **lived** dengan syarat **inoculated** = **yes**. Kita dapat (dan biasanya memang) menghitung peluang bersama di ujung setiap cabang dengan mengalikan bilangan-bilangan yang ditemui saat bergerak dari kiri ke kanan. Peluang bersama ini dihitung menggunakan Aturan Perkalian Umum:

$$\begin{aligned}
 &P(\text{inoculated} = \text{yes dan result} = \text{lived}) \\
 &= P(\text{inoculated} = \text{yes}) \times P(\text{result} = \text{lived} | \text{inoculated} = \text{yes}) \\
 &= 0.0392 \times 0.9754 = 0.0382
 \end{aligned}$$

³⁵Ia lupa bahwa putaran rolet berikutnya independen dari putaran-putaran sebelumnya. Kasino memang menggunakan praktik ini: mereka menampilkan beberapa hasil terakhir dari berbagai permainan taruhan untuk mengecoh penjudi yang tidak waspada agar percaya bahwa peluang berpihak kepada mereka. Kekeliruan ini disebut **sesat pikir penjudi**.


CONTOH 3.40

Perhatikan ujian tengah semester dan ujian akhir pada sebuah kelas statistika. Misalkan 13% mahasiswa memperoleh A pada ujian tengah semester. Di antara mahasiswa yang memperoleh A pada ujian tengah semester, 47% memperoleh A pada ujian akhir; sementara itu, 11% mahasiswa yang memperoleh nilai di bawah A pada ujian tengah semester memperoleh A pada ujian akhir. Anda mengambil secara acak satu lembar ujian akhir dan melihat bahwa mahasiswa tersebut memperoleh A. Berapa peluang mahasiswa itu juga memperoleh A pada ujian tengah semester?

Tujuan akhirnya adalah mencari $P(\text{midterm} = A | \text{final} = A)$. Untuk menghitung peluang bersyarat ini, kita memerlukan peluang berikut:

$$P(\text{midterm} = A \text{ dan } \text{final} = A) \quad \text{dan} \quad P(\text{final} = A)$$

Namun, informasi ini tidak diberikan, dan cara menghitung peluang tersebut tidak langsung terlihat. Karena langkah berikutnya belum jelas, informasi ini sebaiknya kita tata dalam sebuah diagram pohon:



Ketika menyusun diagram pohon, variabel yang dilengkapi peluang marginal sering digunakan untuk membentuk cabang utama; dalam kasus ini, peluang marginal diberikan untuk nilai ujian tengah semester. Nilai ujian akhir, yang bersesuaian dengan peluang bersyarat yang diberikan, ditampilkan pada cabang sekunder.

Setelah diagram pohon tersusun, kita dapat menghitung peluang yang diperlukan:

$$\begin{aligned}
 P(\text{midterm} = A \text{ dan } \text{final} = A) &= 0.0611 \\
 P(\text{final} = A) \\
 &= P(\text{midterm} = \text{other dan } \text{final} = A) + P(\text{midterm} = A \text{ dan } \text{final} = A) \\
 &= 0.0957 + 0.0611 = 0.1568
 \end{aligned}$$

Peluang marginal $P(\text{final} = A)$ dihitung dengan menjumlahkan semua peluang bersama di sisi kanan pohon yang bersesuaian dengan $\text{final} = A$. Sekarang kita dapat mengambil rasio kedua peluang tersebut:

$$\begin{aligned}
 P(\text{midterm} = A | \text{final} = A) &= \frac{P(\text{midterm} = A \text{ dan } \text{final} = A)}{P(\text{final} = A)} \\
 &= \frac{0.0611}{0.1568} = 0.3897
 \end{aligned}$$

Peluang bahwa mahasiswa tersebut juga memperoleh A pada ujian tengah semester adalah sekitar 0,39.

LATIHAN TERBIMBING 3.41

Setelah mengikuti mata kuliah statistika pengantar, 78% mahasiswa dapat menyusun diagram pohon dengan benar. Di antara mahasiswa yang dapat menyusun diagram pohon, 97% lulus, sedangkan hanya 57% mahasiswa yang tidak dapat menyusun diagram pohon yang lulus. (a) Susun informasi ini dalam sebuah diagram pohon. (b) Berapa peluang bahwa mahasiswa yang dipilih secara acak lulus? (c) Hitung peluang bahwa seorang mahasiswa mampu menyusun diagram pohon jika diketahui mahasiswa tersebut lulus.³⁶

3.2.8 Teorema Bayes

Dalam banyak kasus, kita diberi peluang bersyarat berbentuk

$$P(\text{pernyataan tentang variabel 1} \mid \text{pernyataan tentang variabel 2})$$


padahal yang ingin kita ketahui adalah peluang bersyarat dengan arah terbalik:

$$P(\text{pernyataan tentang variabel 2} \mid \text{pernyataan tentang variabel 1})$$

Diagram pohon dapat digunakan untuk mencari peluang bersyarat kedua jika peluang yang pertama diketahui. Namun, kadang-kadang skenarionya tidak dapat digambarkan dengan diagram pohon. Dalam kasus seperti ini, kita dapat menerapkan rumus umum yang sangat berguna: Teorema Bayes.

Pertama, kita telaah dengan cermat sebuah contoh pembalikan peluang bersyarat yang masih dapat diselesaikan menggunakan diagram pohon.

³⁶(a) Diagram pohon ditampilkan di sebelah kanan.
 (b) Tentukan dua peluang bersama yang mewakili mahasiswa yang lulus, lalu jumlahkan: $P(\text{lulus}) = 0.7566 + 0.1254 = 0.8820$.
 (c) $P(\text{mampu menyusun diagram pohon} \mid \text{lulus}) = \frac{0.7566}{0.8820} = 0.8578$.




CONTOH 3.42

Di Kanada, sekitar 0,35% perempuan berusia di atas 40 tahun mengidap kanker payudara pada suatu tahun. Mamogram lazim digunakan untuk penapisan, tetapi tidak sempurna. Pada 11% pasien yang mengidap kanker, hasilnya **negatif palsu**: pemeriksaan menyatakan tidak ada kanker padahal kanker ada. Pada 7% pasien tanpa kanker, hasilnya **positif palsu**: pemeriksaan menyatakan ada kanker padahal tidak. Jika seorang perempuan di atas 40 tahun dipilih secara acak dan hasil mamogramnya positif, berapa peluang ia benar-benar mengidap kanker payudara?

Informasi ini langsung memberi peluang hasil pemeriksaan positif jika pasien mengidap kanker ($1.00 - 0.11 = 0.89$). Namun, kita mencari peluang dengan arah terbalik: peluang mengidap kanker dengan syarat hasil pemeriksaan positif. (Dalam istilah penapisan yang kurang intuitif, hasil mamogram *positif* menunjukkan kemungkinan adanya kanker.) Peluang terbalik ini dapat diuraikan menjadi dua bagian:

$$P(\text{mengidap KP} \mid \text{mamogram}^+) = \frac{P(\text{mengidap KP dan mamogram}^+)}{P(\text{mamogram}^+)}$$

dengan “mengidap KP” sebagai singkatan bahwa pasien mengidap kanker payudara dan “mamogram⁺” berarti hasil penapisan mamogram positif. Kita dapat menyusun diagram pohon untuk peluang-peluang ini:



Peluang bahwa pasien mengidap kanker payudara dan hasil mamogramnya positif adalah

$$\begin{aligned} P(\text{mengidap KP dan mamogram}^+) &= P(\text{mamogram}^+ \mid \text{mengidap KP})P(\text{mengidap KP}) \\ &= 0.89 \times 0.0035 = 0.00312 \end{aligned}$$

Peluang hasil pemeriksaan positif adalah jumlah peluang dua skenario yang bersesuaian:

$$\begin{aligned} P(\text{mamogram}^+) &= P(\text{mamogram}^+ \text{ dan mengidap KP}) \\ &\quad + P(\text{mamogram}^+ \text{ dan tidak mengidap KP}) \\ &= P(\text{mengidap KP})P(\text{mamogram}^+ \mid \text{mengidap KP}) \\ &\quad + P(\text{tidak mengidap KP})P(\text{mamogram}^+ \mid \text{tidak mengidap KP}) \\ &= 0.0035 \times 0.89 + 0.9965 \times 0.07 = 0.07288 \end{aligned}$$

Jadi, jika hasil penapisan mamogram seorang pasien positif, peluang bahwa pasien tersebut mengidap kanker payudara adalah

$$\begin{aligned} P(\text{mengidap KP} \mid \text{mamogram}^+) &= \frac{P(\text{mengidap KP dan mamogram}^+)}{P(\text{mamogram}^+)} \\ &= \frac{0.00312}{0.07288} \approx 0.0428 \end{aligned}$$

Dengan kata lain, meskipun hasil penapisan mamogram seorang pasien positif, peluang bahwa pasien tersebut mengidap kanker payudara tetap hanya sekitar 4%.

Contoh 3.42 menunjukkan mengapa dokter sering melakukan pemeriksaan lanjutan setelah hasil pemeriksaan pertama positif. Jika suatu kondisi medis jarang terjadi, satu hasil positif umumnya belum bersifat meyakinkan.

Perhatikan kembali persamaan terakhir pada Contoh 3.42. Dari diagram pohon, kita melihat bahwa pembilang (bagian atas pecahan) sama dengan hasil kali berikut:

$$P(\text{mengidap KP dan mamogram}^+) = P(\text{mamogram}^+ \mid \text{mengidap KP})P(\text{mengidap KP})$$

Penyebutnya – peluang bahwa hasil penapisan positif – sama dengan jumlah peluang setiap skenario penapisan positif:

$$P(\text{mamogram}^+) = P(\text{mamogram}^+ \text{ dan tidak mengidap KP}) + P(\text{mamogram}^+ \text{ dan mengidap KP})$$

Dalam contoh tersebut, diagram pohon digunakan untuk menguraikan setiap peluang di ruas kanan menjadi hasil kali peluang bersyarat dan peluang marginal.

$$\begin{aligned} P(\text{mamogram}^+) &= P(\text{mamogram}^+ \text{ dan tidak mengidap KP}) + P(\text{mamogram}^+ \text{ dan mengidap KP}) \\ &= P(\text{mamogram}^+ \mid \text{tidak mengidap KP})P(\text{tidak mengidap KP}) \\ &\quad + P(\text{mamogram}^+ \mid \text{mengidap KP})P(\text{mengidap KP}) \end{aligned}$$

Penerapan Teorema Bayes terlihat ketika bentuk-bentuk peluang yang dihasilkan disubstitusikan ke pembilang dan penyebut peluang bersyarat semula.

$$\begin{aligned} P(\text{mengidap KP} \mid \text{mamogram}^+) &= \frac{P(\text{mamogram}^+ \mid \text{mengidap KP})P(\text{mengidap KP})}{P(\text{mamogram}^+ \mid \text{tidak mengidap KP})P(\text{tidak mengidap KP}) \\ &\quad + P(\text{mamogram}^+ \mid \text{mengidap KP})P(\text{mengidap KP})} \end{aligned}$$

TEOREMA BAYES: MEMBALIK PELUANG

Perhatikan peluang bersyarat berikut untuk variabel 1 dan variabel 2:

$$P(\text{hasil } A_1 \text{ dari variabel 1} \mid \text{hasil } B \text{ dari variabel 2})$$

Teorema Bayes menyatakan bahwa peluang bersyarat ini dapat ditentukan dengan pecahan berikut:

$$\frac{P(B|A_1)P(A_1)}{P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + \cdots + P(B|A_k)P(A_k)}$$

dengan $A_2, A_3, \dots$, dan A_k menyatakan semua hasil lain yang mungkin dari variabel pertama.

Teorema Bayes merupakan generalisasi dari langkah yang telah kita lakukan dengan diagram pohon. Pembilangnya menunjukkan peluang memperoleh A_1 dan B sekaligus. Penyebutnya adalah peluang marginal memperoleh B . Bagian bawah pecahan ini tampak panjang dan rumit karena kita harus menjumlahkan peluang dari semua cara berbeda untuk memperoleh B . Kita selalu melakukan langkah ini saat menggunakan diagram pohon. Namun, biasanya langkah tersebut dikerjakan secara terpisah sehingga tidak tampak serumit ini.

Untuk menerapkan Teorema Bayes dengan benar, ada dua langkah persiapan:

- (1) Pertama, tentukan peluang marginal setiap hasil yang mungkin dari variabel pertama: $P(A_1), P(A_2), \dots, P(A_k)$.
- (2) Kemudian, tentukan peluang hasil B dengan syarat setiap skenario yang mungkin bagi variabel pertama: $P(B|A_1), P(B|A_2), \dots, P(B|A_k)$.

Setelah semua peluang ini ditentukan, nilainya dapat langsung dimasukkan ke dalam rumus. Teorema Bayes biasanya merupakan pilihan yang baik ketika terdapat begitu banyak skenario sehingga diagram pohon akan rumit.

LATIHAN TERBIMBING 3.43

Jose mengunjungi kampus setiap Kamis malam. Namun, pada beberapa malam gedung parkir penuh, sering kali karena ada acara kampus. Acara akademik berlangsung pada 35% malam, acara olahraga pada 20% malam, dan tidak ada acara pada 45% malam. Saat ada acara akademik, gedung parkir penuh sekitar 25% dari waktu tersebut; saat ada acara olahraga, gedung parkir penuh pada 70% malam. Pada malam tanpa acara, gedung parkir hanya penuh sekitar 5% dari waktu tersebut. Jika Jose datang ke kampus dan mendapati gedung parkir penuh, berapa peluang bahwa sedang berlangsung acara olahraga? Gunakan diagram pohon untuk menyelesaikan masalah ini.³⁷

CONTOH 3.44

Di sini kita menyelesaikan masalah yang sama seperti pada Latihan Terbimbing 3.43, tetapi kali ini menggunakan Teorema Bayes.

Hasil yang menjadi perhatian adalah ada atau tidaknya acara olahraga (kita sebut A_1), sedangkan syaratnya adalah gedung parkir penuh (B). Misalkan A_2 menyatakan acara akademik dan A_3 menyatakan tidak adanya acara di kampus. Peluang yang diberikan dapat ditulis sebagai


$$\begin{array}{lll} P(A_1) = 0.2 & P(A_2) = 0.35 & P(A_3) = 0.45 \\ P(B|A_1) = 0.7 & P(B|A_2) = 0.25 & P(B|A_3) = 0.05 \end{array}$$

Teorema Bayes dapat digunakan untuk menghitung peluang adanya acara olahraga (A_1) dengan syarat gedung parkir penuh (B):

$$\begin{aligned} P(A_1|B) &= \frac{P(B|A_1)P(A_1)}{P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + P(B|A_3)P(A_3)} \\ &= \frac{(0.7)(0.2)}{(0.7)(0.2) + (0.25)(0.35) + (0.05)(0.45)} \\ &= 0.56 \end{aligned}$$

Berdasarkan informasi bahwa gedung parkir penuh, peluang bahwa acara olahraga sedang berlangsung di kampus pada malam itu adalah 56%.

³⁷Diagram pohon dengan tiga cabang utama ditampilkan di sebelah kanan. Selanjutnya, kita menentukan dua peluang dari diagram tersebut. (1) Peluang bahwa ada acara olahraga dan gedung parkir penuh: 0,14. (2) Peluang gedung parkir penuh: $0.0875 + 0.14 + 0.0225 = 0.25$. Jawabannya adalah rasio kedua peluang tersebut: $\frac{0.14}{0.25} = 0.56$. Jika gedung parkir penuh, peluang bahwa ada acara olahraga adalah 56%.



LATIHAN TERBIMBING 3.45

Gunakan informasi pada latihan dan contoh sebelumnya untuk memverifikasi bahwa peluang adanya acara akademik dengan syarat gedung parkir penuh adalah 0,35.³⁸

LATIHAN TERBIMBING 3.46

Dalam Latihan Terbimbing 3.43 dan 3.45, Anda menemukan bahwa jika gedung parkir penuh, peluang adanya acara olahraga adalah 0,56 dan peluang adanya acara akademik adalah 0,35. Dengan informasi ini, hitung $P(\text{tidak ada acara} \mid \text{gedung parkir penuh})$.³⁹

Beberapa latihan terakhir memberikan cara untuk memperbarui keyakinan kita mengenai apakah sedang ada acara olahraga, acara akademik, atau tidak ada acara di kampus berdasarkan informasi bahwa gedung parkir penuh. Strategi *memperbarui keyakinan* dengan Teorema Bayes ini merupakan landasan sebuah cabang statistika yang disebut **statistika Bayes**. Walaupun statistika Bayes sangat penting dan berguna, buku ini tidak akan membahasnya lebih jauh.

³⁸Jawaban singkat:

$$\begin{aligned} P(A_2|B) &= \frac{P(B|A_2)P(A_2)}{P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + P(B|A_3)P(A_3)} \\ &= \frac{(0.25)(0.35)}{(0.7)(0.2) + (0.25)(0.35) + (0.05)(0.45)} \\ &= 0.35 \end{aligned}$$

³⁹Setiap peluang dikondisikan pada informasi yang sama, yaitu gedung parkir penuh, sehingga aturan komplemen dapat digunakan: $1.00 - 0.56 - 0.35 = 0.09$.

Latihan

3.13 Peluang bersama dan peluang bersyarat. $P(A) = 0.3$, $P(B) = 0.7$

- Dapatkah Anda menghitung $P(A \text{ dan } B)$ jika hanya mengetahui $P(A)$ dan $P(B)$?
- Dengan asumsi bahwa peristiwa A dan B muncul dari proses acak yang saling independen,
 - berapakah $P(A \text{ dan } B)$?
 - berapakah $P(A \text{ atau } B)$?
 - berapakah $P(A|B)$?
- Jika diketahui bahwa $P(A \text{ dan } B) = 0.1$, apakah variabel acak yang menghasilkan peristiwa A dan B saling independen?
- Jika diketahui bahwa $P(A \text{ dan } B) = 0.1$, berapakah $P(A|B)$?

3.14 Selai kacang & jeli. Misalkan 80% orang menyukai selai kacang, 89% menyukai jeli, dan 78% menyukai keduanya. Jika diketahui bahwa seseorang yang dipilih secara acak menyukai selai kacang, berapakah peluang orang tersebut juga menyukai jeli?

3.15 Pemanasan global. Sebuah jajak pendapat Pew Research menanyakan kepada 1.306 orang Amerika, “Berdasarkan apa yang telah Anda baca dan dengar, apakah ada bukti kuat bahwa suhu rata-rata bumi meningkat selama beberapa dekade terakhir, atau tidak?” Tabel berikut menunjukkan distribusi tanggapan menurut partai dan ideologi; jumlah responden telah diganti dengan frekuensi relatif.⁴⁰

		Tanggapan			Total
		Bumi memanas	Tidak memanas	Tidak tahu Menolak	
Partai dan ideologi	Republikan konservatif	0.11	0.20	0.02	0.33
	Republikan moderat/liberal	0.06	0.06	0.01	0.13
	Demokrat moderat/konservatif	0.25	0.07	0.02	0.34
	Demokrat liberal	0.18	0.01	0.01	0.20
	Total	0.60	0.34	0.06	1.00

- Apakah meyakini bahwa bumi sedang memanas dan menjadi seorang Demokrat liberal merupakan peristiwa yang saling eksklusif?
- Berapakah peluang responden yang dipilih secara acak meyakini bahwa bumi sedang memanas atau merupakan seorang Demokrat liberal?
- Berapakah peluang responden yang dipilih secara acak meyakini bahwa bumi sedang memanas jika diketahui bahwa responden tersebut merupakan seorang Demokrat liberal?
- Berapakah peluang responden yang dipilih secara acak meyakini bahwa bumi sedang memanas jika diketahui bahwa responden tersebut merupakan seorang Republikan konservatif?
- Apakah keyakinan responden tentang bumi sedang memanas tampak saling independen dengan partai dan ideologinya? Jelaskan penalaran Anda.
- Berapakah peluang responden yang dipilih secara acak merupakan seorang Republikan moderat/liberal jika diketahui bahwa responden tersebut tidak meyakini bahwa bumi sedang memanas?

⁴⁰Pew Research Center, Majority of Republicans No Longer See Evidence of Global Warming, data collected on October 27, 2010.

3.16 Jaminan kesehatan, frekuensi relatif. Behavioral Risk Factor Surveillance System (BRFSS) adalah survei telepon tahunan yang dirancang untuk mengidentifikasi faktor risiko pada populasi orang dewasa dan melaporkan tren kesehatan yang sedang berkembang. Tabel berikut menampilkan distribusi status kesehatan responden survei ini (prima, sangat baik, baik, cukup, buruk) dan apakah mereka memiliki jaminan kesehatan.

		<i>Status kesehatan</i>					Total
		Prima	Sangat baik	Baik	Cukup	Buruk	
<i>Jaminan kesehatan</i>	Tidak	0.0230	0.0364	0.0427	0.0192	0.0050	0.1262
	Ya	0.2099	0.3123	0.2410	0.0817	0.0289	0.8738
	Total	0.2329	0.3486	0.2838	0.1009	0.0338	1.0000

- Apakah berstatus kesehatan prima dan memiliki jaminan kesehatan merupakan peristiwa yang saling eksklusif?
- Berapakah peluang individu yang dipilih secara acak berstatus kesehatan prima?
- Berapakah peluang individu yang dipilih secara acak berstatus kesehatan prima jika diketahui bahwa individu tersebut memiliki jaminan kesehatan?
- Berapakah peluang individu yang dipilih secara acak berstatus kesehatan prima jika diketahui bahwa individu tersebut tidak memiliki jaminan kesehatan?
- Apakah berstatus kesehatan prima dan memiliki jaminan kesehatan tampak saling independen?

3.17 Preferensi burger. Sebuah jajak pendapat SurveyUSA tahun 2010 menanyakan kepada 500 penduduk Los Angeles, “Manakah tempat hamburger terbaik di California Selatan? Five Guys Burgers? In-N-Out Burger? Fat Burger? Tommy’s Hamburgers? Umami Burger? Atau tempat lain?” Distribusi tanggapan menurut jenis kelamin ditunjukkan berikut ini.⁴¹

		<i>Jenis kelamin</i>		Total
		Laki-laki	Perempuan	
<i>Tempat hamburger terbaik</i>	Five Guys Burgers	5	6	11
	In-N-Out Burger	162	181	343
	Fat Burger	10	12	22
	Tommy’s Hamburgers	27	27	54
	Umami Burger	5	1	6
	Lainnya	26	20	46
	Tidak yakin	13	5	18
Total		248	252	500

- Apakah menjadi perempuan dan paling menyukai Five Guys Burgers merupakan peristiwa yang saling eksklusif?
- Berapakah peluang laki-laki yang dipilih secara acak paling menyukai In-N-Out?
- Berapakah peluang perempuan yang dipilih secara acak paling menyukai In-N-Out?
- Berapakah peluang seorang laki-laki dan seorang perempuan yang berpacaran keduanya paling menyukai In-N-Out? Nyatakan setiap asumsi yang Anda buat dan nilai apakah menurut Anda asumsi tersebut wajar.
- Berapakah peluang seseorang yang dipilih secara acak paling menyukai Umami atau orang tersebut perempuan?

⁴¹SurveyUSA, Results of SurveyUSA News Poll #17718, data collected on December 2, 2010.

3.18 Perkawinan asortatif. Perkawinan asortatif adalah pola perkawinan nonacak ketika individu dengan genotipe dan/atau fenotipe serupa berpasangan lebih sering daripada yang diharapkan dalam pola perkawinan acak. Peneliti yang mengkaji topik ini mengumpulkan data warna mata 204 laki-laki Skandinavia dan pasangan perempuan mereka. Tabel berikut merangkum hasilnya.⁴²

	<i>Pasangan (perempuan)</i>			Total
	Biru	Cokelat	Hijau	
<i>Diri (laki-laki)</i>	Biru	78	13	114
	Cokelat	19	12	54
	Hijau	11	16	36
	Total	108	41	204

- Berapakah peluang responden laki-laki yang dipilih secara acak atau pasangannya memiliki mata biru?
- Berapakah peluang responden laki-laki bermata biru yang dipilih secara acak memiliki pasangan bermata biru?
- Berapakah peluang responden laki-laki bermata cokelat yang dipilih secara acak memiliki pasangan bermata biru? Bagaimana dengan peluang responden laki-laki bermata hijau yang dipilih secara acak memiliki pasangan bermata biru?
- Apakah warna mata responden laki-laki dan pasangannya tampak saling independen? Jelaskan penalaran Anda.

3.19 Membuat diagram kotak. Setelah mengikuti mata kuliah pengantar statistika, 80% mahasiswa dapat membuat diagram kotak dengan benar. Di antara mahasiswa yang dapat membuat diagram kotak, 86% lulus, sedangkan hanya 65% mahasiswa yang tidak dapat membuat diagram kotak yang lulus.

- Buat diagram pohon untuk skenario ini.
- Hitung peluang seorang mahasiswa dapat membuat diagram kotak jika diketahui bahwa mahasiswa tersebut lulus.

3.20 Predisposisi trombosis. Sebuah tes genetik digunakan untuk menentukan apakah seseorang memiliki predisposisi terhadap *trombosis*, yaitu pembentukan bekuan darah di dalam pembuluh darah yang menghambat aliran darah melalui sistem peredaran darah. Diperkirakan bahwa 3% orang benar-benar memiliki predisposisi ini. Tes genetik tersebut akurat 99% jika seseorang benar-benar memiliki predisposisi, yang berarti peluang hasil tes positif ketika seseorang benar-benar memiliki predisposisi adalah 0.99. Tes tersebut akurat 98% jika seseorang tidak memiliki predisposisi. Berapakah peluang seseorang yang dipilih secara acak dan mendapat hasil tes positif untuk predisposisi tersebut benar-benar memiliki predisposisi?

3.21 Penyebabnya tak pernah lupus. Lupus adalah fenomena medis ketika antibodi yang seharusnya menyerang sel asing untuk mencegah infeksi justru menganggap protein plasma sebagai benda asing, sehingga menimbulkan risiko tinggi terjadinya pembekuan darah. Diperkirakan bahwa 2% populasi menderita penyakit ini. Tes tersebut akurat 98% jika seseorang benar-benar menderita penyakit ini. Tes tersebut akurat 74% jika seseorang tidak menderita penyakit ini. Ada sebuah kalimat dari acara televisi *Fox House* yang sering diucapkan setelah seorang pasien mendapat hasil tes positif untuk lupus: “Penyebabnya tak pernah lupus.” Menurut Anda, adakah kebenaran dalam pernyataan ini? Gunakan peluang yang sesuai untuk mendukung jawaban Anda.

3.22 Jajak pendapat seusai pemungutan suara. Edison Research mengumpulkan hasil jajak pendapat seusai pemungutan suara dari beberapa sumber untuk pemilihan pencabutan mandat Scott Walker di Wisconsin. Mereka menemukan bahwa 53% responden memilih Scott Walker. Selain itu, mereka memperkirakan bahwa di antara responden yang memilih Scott Walker, 37% memiliki gelar dari perguruan tinggi, sedangkan 44% responden yang tidak memilih Scott Walker memiliki gelar dari perguruan tinggi. Misalkan kita memilih secara acak seseorang yang mengikuti jajak pendapat tersebut dan mengetahui bahwa orang itu memiliki gelar dari perguruan tinggi. Berapakah peluang bahwa orang tersebut memilih Scott Walker?⁴³

⁴²B. Laeng et al. “Why do blue-eyed men prefer women with the same eye color?” In: *Behavioral Ecology and Sociobiology* 61.3 (2007), pp. 371–384.

⁴³New York Times, Wisconsin recall exit polls.

3.3 Pengambilan sampel dari populasi kecil

Ketika kita mengambil pengamatan dari suatu populasi sebagai sampel, biasanya kita hanya mengambil sebagian kecil dari individu atau kasus yang mungkin. Namun, terkadang ukuran sampel kita cukup besar atau populasinya cukup kecil sehingga kita mengambil lebih dari 10% populasi⁴⁴ *tanpa pengembalian* (artinya kita tidak mungkin mengambil kasus yang sama dua kali). Pengambilan bagian populasi yang cukup besar seperti ini dapat memengaruhi cara kita menganalisis sampel tersebut.

CONTOH 3.47

Dosen terkadang memilih seorang mahasiswa secara acak untuk menjawab pertanyaan. Jika setiap mahasiswa memiliki peluang yang sama untuk dipilih dan ada 15 orang di kelas Anda, berapakah peluang dosen memilih Anda untuk pertanyaan berikutnya?

Jika ada 15 orang yang dapat ditanya dan semuanya hadir di kelas, peluangnya adalah $1/15$, atau sekitar 0.067.

CONTOH 3.48

Jika dosen mengajukan 3 pertanyaan, berapakah peluang Anda tidak terpilih? Anggap dosen tidak memilih orang yang sama dua kali dalam satu perkuliahan.

Untuk pertanyaan pertama, dosen memilih orang lain dengan peluang $14/15$. Ketika mengajukan pertanyaan kedua, hanya ada 14 orang yang belum ditanya. Jadi, jika Anda tidak terpilih untuk pertanyaan pertama, peluang Anda kembali tidak terpilih adalah $13/14$. Demikian pula, peluang Anda kembali tidak terpilih untuk pertanyaan ketiga adalah $12/13$, dan peluang tidak terpilih untuk ketiga pertanyaan tersebut adalah

$$\begin{aligned} P(\text{tidak terpilih dalam 3 pertanyaan}) \\ &= P(Q1 = \text{tidak_terpilih}, Q2 = \text{tidak_terpilih}, Q3 = \text{tidak_terpilih}) \\ &= \frac{14}{15} \times \frac{13}{14} \times \frac{12}{13} = \frac{12}{15} = 0.80 \end{aligned}$$

LATIHAN TERBIMBING 3.49

Aturan apa yang memungkinkan kita mengalikan peluang-peluang dalam Contoh 3.48?⁴⁵

⁴⁴Pedoman 10% merupakan batas berdasarkan kaidah praktis untuk menentukan kapan pertimbangan ini menjadi lebih penting.

⁴⁵Ketiga peluang yang kita hitung sebenarnya terdiri atas satu peluang marginal, $P(Q1=\text{tidak_terpilih})$, dan dua peluang bersyarat:

$$\begin{aligned} P(Q2 = \text{tidak_terpilih} \mid Q1 = \text{tidak_terpilih}) \\ P(Q3 = \text{tidak_terpilih} \mid Q1 = \text{tidak_terpilih}, Q2 = \text{tidak_terpilih}) \end{aligned}$$

Dengan Aturan Perkalian Umum, hasil kali ketiga peluang ini adalah peluang tidak terpilih dalam 3 pertanyaan.

CONTOH 3.50

Misalkan dosen memilih secara acak tanpa memperhatikan siapa yang sudah dipilih, yaitu mahasiswa dapat dipilih lebih dari sekali. Berapakah peluang Anda tidak terpilih untuk ketiga pertanyaan tersebut?

Pemilihan-pemilihan tersebut saling independen, dan peluang tidak terpilih untuk satu pertanyaan adalah $14/15$. Jadi, kita dapat menggunakan Aturan Perkalian untuk proses yang saling independen.

$$\begin{aligned} P(\text{tidak terpilih dalam 3 pertanyaan}) \\ &= P(Q1 = \text{tidak terpilih}, Q2 = \text{tidak terpilih}, Q3 = \text{tidak terpilih}) \\ &= \frac{14}{15} \times \frac{14}{15} \times \frac{14}{15} = 0.813 \end{aligned}$$

Peluang Anda untuk tidak terpilih sedikit lebih besar dibandingkan ketika dosen memilih orang yang berbeda untuk setiap pertanyaan. Namun, sekarang Anda mungkin dipilih lebih dari sekali.

LATIHAN TERBIMBING 3.51

Berdasarkan skenario pada Contoh 3.50, berapakah peluang Anda terpilih untuk menjawab ketiga pertanyaan?⁴⁶

Jika kita mengambil sampel dari populasi kecil **tanpa pengembalian**, pengamatan-pengamatan kita tidak lagi saling independen. Dalam Contoh 3.48, peluang tidak terpilih untuk pertanyaan kedua dikondisikan pada peristiwa bahwa Anda tidak terpilih untuk pertanyaan pertama. Dalam Contoh 3.50, dosen mengambil sampel mahasiswa **dengan pengembalian**: dosen tersebut berulang kali mengambil sampel dari seluruh kelas tanpa memedulikan siapa yang sudah dipilih.

LATIHAN TERBIMBING 3.52

Departemen Anda mengadakan undian berhadiah. Mereka menjual 30 tiket dan menyediakan tujuh hadiah. (a) Tiket-tiket tersebut dimasukkan ke dalam topi dan satu tiket diundi untuk setiap hadiah. Tiket diambil tanpa pengembalian, yaitu tiket yang terpilih tidak dimasukkan kembali ke dalam topi. Berapakah peluang memenangkan hadiah jika Anda membeli satu tiket? (b) Bagaimana jika tiket diambil dengan pengembalian?⁴⁷

LATIHAN TERBIMBING 3.53

Bandingkan jawaban Anda dalam Latihan Terbimbing 3.52. Seberapa besar pengaruh metode pengambilan sampel terhadap peluang Anda memenangkan hadiah?⁴⁸

Seandainya kita mengulangi Latihan Terbimbing 3.52 dengan 300 tiket, bukan 30 tiket, kita akan menemukan hal yang menarik: hasilnya akan hampir identik. Peluangnya adalah 0.0233 tanpa pengembalian dan 0.0231 dengan pengembalian. Ketika ukuran sampel hanya merupakan sebagian kecil dari populasi (di bawah 10%), pengamatan hampir saling independen meskipun pengambilan sampel dilakukan tanpa pengembalian.

⁴⁶ $P(\text{terpilih untuk menjawab ketiga pertanyaan}) = \left(\frac{1}{15}\right)^3 = 0.00030$.

⁴⁷ (a) Pertama, tentukan peluang tidak menang. Tiket diambil tanpa pengembalian, yang berarti peluang Anda tidak menang pada pengundian pertama adalah $29/30$, $28/29$ pada pengundian kedua, ..., dan $23/24$ pada pengundian ketujuh. Peluang Anda tidak memenangkan hadiah adalah hasil kali peluang-peluang tersebut: $23/30$. Artinya, peluang memenangkan hadiah adalah $1 - 23/30 = 7/30 = 0.233$. (b) Ketika tiket diambil dengan pengembalian, terdapat tujuh pengundian yang saling independen. Sekali lagi, pertama-tama kita mencari peluang tidak memenangkan hadiah: $(29/30)^7 = 0.789$. Jadi, peluang memenangkan (setidaknya) satu hadiah ketika pengambilan dilakukan dengan pengembalian adalah 0.211.

⁴⁸ Peluang memenangkan hadiah sekitar 10% lebih besar jika pengambilan sampel dilakukan tanpa pengembalian. Namun, dengan prosedur pengambilan sampel ini, paling banyak hanya satu hadiah yang dapat dimenangkan.

Latihan

3.23 Kelereng di dalam guci. Bayangkan Anda memiliki sebuah guci yang berisi 5 kelereng merah, 3 biru, dan 2 oranye.

- Berapakah peluang bahwa kelereng pertama yang Anda ambil berwarna biru?
- Misalkan Anda mengambil kelereng biru pada pengambilan pertama. Jika pengambilan dilakukan dengan pengembalian, berapakah peluang mengambil kelereng biru pada pengambilan kedua?
- Misalkan Anda justru mengambil kelereng oranye pada pengambilan pertama. Jika pengambilan dilakukan dengan pengembalian, berapakah peluang mengambil kelereng biru pada pengambilan kedua?
- Jika pengambilan dilakukan dengan pengembalian, berapakah peluang mengambil dua kelereng biru berturut-turut?
- Ketika pengambilan dilakukan dengan pengembalian, apakah setiap pengambilan saling independen? Jelaskan.

3.24 Kaus kaki di dalam laci. Di dalam laci kaus kaki, Anda memiliki 4 kaus kaki biru, 5 abu-abu, dan 3 hitam. Dalam keadaan setengah mengantuk pada suatu pagi, Anda mengambil 2 kaus kaki secara acak lalu memakainya. Tentukan peluang bahwa Anda akhirnya mengenakan

- 2 kaus kaki biru
- tidak ada kaus kaki abu-abu
- setidaknya 1 kaus kaki hitam
- sebuah kaus kaki hijau
- sepasang kaus kaki dengan warna yang sama

3.25 Keping di dalam kantong. Bayangkan Anda memiliki sebuah kantong yang berisi 5 keping merah, 3 biru, dan 2 oranye.

- Misalkan Anda mengambil satu keping dan keping itu berwarna biru. Jika pengambilan dilakukan tanpa pengembalian, berapakah peluang bahwa keping berikutnya juga berwarna biru?
- Misalkan Anda mengambil satu keping dan keping itu berwarna oranye, lalu Anda mengambil keping kedua tanpa pengembalian. Berapakah peluang bahwa keping kedua ini berwarna biru?
- Jika pengambilan dilakukan tanpa pengembalian, berapakah peluang mengambil dua keping biru berturut-turut?
- Ketika pengambilan dilakukan tanpa pengembalian, apakah setiap pengambilan saling independen? Jelaskan.

3.26 Buku di rak buku. Tabel di bawah ini menunjukkan distribusi buku di sebuah rak berdasarkan jenis fiksi atau nonfiksi serta format sampul keras atau sampul lunak.

		Format		Total
		Sampul keras	Sampul lunak	
Jenis	Fiksi	13	59	72
	Nonfiksi	15	8	23
	Total	28	67	95

- Tentukan peluang mengambil sebuah buku sampul keras terlebih dahulu, lalu sebuah buku fiksi bersampul lunak sebagai buku kedua, ketika pengambilan dilakukan tanpa pengembalian.
- Tentukan peluang mengambil sebuah buku fiksi terlebih dahulu, lalu sebuah buku sampul keras sebagai buku kedua, ketika pengambilan dilakukan tanpa pengembalian.
- Hitung peluang untuk skenario pada bagian (b), tetapi kali ini lakukan perhitungan untuk skenario ketika buku pertama dikembalikan ke rak sebelum buku kedua diambil secara acak.
- Jawaban akhir untuk bagian (b) dan (c) sangat mirip. Jelaskan mengapa hal ini terjadi.

3.27 Pakaian mahasiswa. Di sebuah kelas yang terdiri atas 24 mahasiswa, 7 mahasiswa mengenakan jins, 4 mengenakan celana pendek, 8 mengenakan rok, dan sisanya mengenakan legging. Jika kita memilih 3 mahasiswa secara acak tanpa pengembalian, berapakah peluang bahwa satu mahasiswa yang terpilih mengenakan legging dan dua lainnya mengenakan jins? Perhatikan bahwa jenis-jenis pakaian ini saling lepas.

3.28 Masalah ulang tahun. Misalkan kita memilih tiga orang secara acak. Untuk setiap pertanyaan berikut, abaikan kasus khusus ketika seseorang mungkin lahir pada 29 Februari, dan anggap kelahiran tersebar merata sepanjang tahun.

- Berapakah peluang bahwa dua orang pertama berulang tahun pada tanggal yang sama?
- Berapakah peluang bahwa setidaknya dua orang berulang tahun pada tanggal yang sama?

3.4 Variabel acak

Sering kali, suatu proses berguna untuk dimodelkan dengan menggunakan apa yang disebut **variabel acak**. Model semacam ini memungkinkan kita menerapkan kerangka matematis dan prinsip-prinsip statistika untuk memahami dan memprediksi hasil dengan lebih baik di dunia nyata.

CONTOH 3.54

Dua buku diwajibkan untuk sebuah kelas statistika: buku teks dan panduan belajar yang menyertainya. Toko buku universitas menemukan bahwa 20% mahasiswa yang terdaftar tidak membeli satu pun dari kedua buku tersebut, 55% hanya membeli buku teks, dan 25% membeli keduanya; persentase ini relatif konstan dari satu semester ke semester berikutnya. Jika ada 100 mahasiswa yang terdaftar, berapa banyak buku yang diperkirakan akan dijual toko buku tersebut kepada kelas ini?

Sekitar 20 mahasiswa tidak akan membeli satu pun buku (total 0 buku), sekitar 55 mahasiswa akan membeli satu buku (total 55 buku), dan sekitar 25 mahasiswa akan membeli dua buku (total 50 buku untuk 25 mahasiswa ini). Toko buku tersebut diperkirakan akan menjual sekitar 105 buku kepada kelas ini.

LATIHAN TERBIMBING 3.55

Apakah Anda akan terkejut jika toko buku tersebut menjual sedikit lebih banyak atau lebih sedikit daripada 105 buku?⁴⁹

CONTOH 3.56

Harga buku teks adalah \$137 dan harga panduan belajar adalah \$33. Berapa besar pendapatan yang diperkirakan akan diperoleh toko buku dari kelas yang terdiri atas 100 mahasiswa ini?

Sekitar 55 mahasiswa hanya akan membeli buku teks, sehingga menghasilkan pendapatan sebesar


$$\$137 \times 55 = \$7,535$$

Sekitar 25 mahasiswa yang membeli buku teks dan panduan belajar akan membayar total sebesar

$$(\$137 + \$33) \times 25 = \$170 \times 25 = \$4,250$$

Jadi, toko buku tersebut diperkirakan memperoleh sekitar $\$7,535 + \$4,250 = \$11,785$ dari 100 mahasiswa dalam satu kelas ini. Namun, mungkin terdapat *variabilitas pengambilan sampel*, sehingga jumlah sebenarnya dapat sedikit berbeda.

⁴⁹ Jika toko buku menjual sedikit lebih banyak atau sedikit lebih sedikit, hal ini seharusnya tidak mengejutkan. Semoga Bab 1 telah memperjelas bahwa data yang diamati memiliki variabilitas alami. Sebagai contoh, jika kita melempar koin 100 kali, sisi kepala biasanya tidak akan muncul tepat separuh dari seluruh lemparan, tetapi jumlahnya mungkin akan mendekati separuh.



Gambar 3.18: Distribusi peluang pendapatan toko buku dari satu mahasiswa. Segitiga menunjukkan pendapatan rata-rata per mahasiswa.

CONTOH 3.57

Berapakah pendapatan rata-rata per mahasiswa untuk mata kuliah ini?

E

Total pendapatan yang diharapkan adalah \$11,785 dan terdapat 100 mahasiswa. Oleh karena itu, pendapatan yang diharapkan per mahasiswa adalah $\$11,785/100 = \117.85 .

3.4.1 Nilai harapan

Variabel atau proses dengan hasil numerik disebut **variabel acak**, dan variabel acak ini biasanya dilambangkan dengan huruf kapital seperti X , Y , atau Z . Jumlah uang yang dibelanjakan seorang mahasiswa untuk buku-buku statistiknya merupakan variabel acak, dan kita melambangkannya dengan X .

VARIABEL ACAK

Proses acak atau variabel yang memiliki hasil numerik.


Hasil-hasil yang mungkin dari X diberi label dengan huruf kecil x dan subskrip yang bersesuaian. Sebagai contoh, kita menulis $x_1 = \$0$, $x_2 = \$137$, dan $x_3 = \$170$, yang masing-masing terjadi dengan peluang 0.20, 0.55, dan 0.25. Distribusi X diringkas pada Gambar 3.18 dan Gambar 3.19.

i	1	2	3	Total
x_i	\$0	\$137	\$170	–
$P(X = x_i)$	0.20	0.55	0.25	1.00


Gambar 3.19: Distribusi peluang variabel acak X , yang menyatakan pendapatan toko buku dari satu mahasiswa.

Kita menghitung hasil rata-rata X sebesar \$117.85 dalam Contoh 3.57. Rata-rata ini disebut **nilai harapan** X , yang dilambangkan dengan $E(X)$. Nilai harapan suatu variabel acak dihitung dengan menjumlahkan setiap hasil yang dibobotkan menurut peluangnya:

$$\begin{aligned} E(X) &= 0 \times P(X = 0) + 137 \times P(X = 137) + 170 \times P(X = 170) \\ &= 0 \times 0.20 + 137 \times 0.55 + 170 \times 0.25 = 117.85 \end{aligned}$$



Gambar 3.20: Sistem beban yang merepresentasikan distribusi peluang X . Tali menahan distribusi pada rata-ratanya agar sistem tetap seimbang.



Gambar 3.21: Distribusi kontinu juga dapat diseimbangkan pada rata-ratanya.

NILAI HARAPAN VARIABEL ACAK DISKRET

Jika X memiliki hasil $x_1, \dots, x_k$ dengan peluang $P(X = x_1), \dots, P(X = x_k)$, nilai harapan X adalah jumlah setiap hasil yang dikalikan dengan peluang yang bersesuaian:

$$\begin{aligned} E(X) &= x_1 \times P(X = x_1) + \dots + x_k \times P(X = x_k) \\ &= \sum_{i=1}^k x_i P(X = x_i) \end{aligned}$$

Huruf Yunani μ dapat digunakan sebagai pengganti notasi $E(X)$.

Nilai harapan suatu variabel acak menyatakan hasil rata-rata. Sebagai contoh, $E(X) = 117.85$ menyatakan jumlah rata-rata yang diperkirakan akan diperoleh toko buku dari satu mahasiswa, yang juga dapat kita tulis sebagai $\mu = 117.85$.

Nilai harapan variabel acak kontinu juga dapat dihitung (lihat Bagian 3.5). Namun, perhitungannya memerlukan sedikit kalkulus dan kita menundanya untuk mata kuliah lanjutan.⁵⁰

Dalam fisika, nilai harapan memiliki makna yang sama dengan pusat gravitasi. Distribusi dapat direpresentasikan oleh serangkaian beban pada setiap hasil, dan rata-rata menyatakan titik keseimbangan. Hal ini ditampilkan pada Gambar 3.18 dan 3.20. Gagasan pusat gravitasi juga berlaku untuk distribusi peluang kontinu. Gambar 3.21 menunjukkan distribusi peluang kontinu yang seimbang di atas penyangga yang ditempatkan pada rata-rata.

⁵⁰ $\mu = \int xf(x)dx$ dengan $f(x)$ menyatakan fungsi bagi kurva kepadatan.

3.4.2 Variabilitas dalam variabel acak

Misalkan Anda mengelola toko buku universitas. Selain besarnya pendapatan yang diperkirakan akan diperoleh, Anda mungkin juga ingin mengetahui volatilitas (variabilitas) pendapatan tersebut.

Varians dan simpangan baku dapat digunakan untuk mendeskripsikan variabilitas suatu variabel acak. Bagian 2.1.4 memperkenalkan metode untuk menentukan varians dan simpangan baku suatu kumpulan data. Pertama, kita menghitung simpangan dari rata-rata $(x_i - \mu)$, mengkuadratkan simpangan tersebut, lalu mengambil rata-ratanya untuk memperoleh varians. Untuk variabel acak, kita kembali menghitung kuadrat simpangan. Namun, kita menjumlahkannya dengan pembobotan berdasarkan peluang yang bersesuaian, seperti yang kita lakukan untuk nilai harapan. Jumlah kuadrat simpangan berbobot ini sama dengan varians, dan kita menghitung simpangan baku dengan mengambil akar kuadrat varians, seperti yang dilakukan pada Bagian 2.1.4.

RUMUS UMUM VARIANS

Jika X memiliki hasil $x_1, \dots, x_k$ dengan peluang $P(X = x_1), \dots, P(X = x_k)$ dan nilai harapan $\mu = E(X)$, varians X , yang dilambangkan dengan $Var(X)$ atau simbol σ^2 , adalah

$$\begin{aligned}\sigma^2 &= (x_1 - \mu)^2 \times P(X = x_1) + \dots \\ &\quad \dots + (x_k - \mu)^2 \times P(X = x_k) \\ &= \sum_{j=1}^k (x_j - \mu)^2 P(X = x_j)\end{aligned}$$

Simpangan baku X , yang dilambangkan dengan σ , adalah akar kuadrat dari varians.

CONTOH 3.58

Hitung nilai harapan, varians, dan simpangan baku X , yaitu pendapatan toko buku dari satu mahasiswa statistika.

Kita dapat menyusun tabel yang memuat perhitungan setiap hasil secara terpisah, lalu menjumlahkan hasil-hasilnya.

i	1	2	3	Total
x_i	\$0	\$137	\$170	
$P(X = x_i)$	0.20	0.55	0.25	
$x_i \times P(X = x_i)$	0	75.35	42.50	117.85

E

Jadi, nilai harapannya adalah $\mu = 117.85$, seperti yang telah kita hitung. Varians dapat disusun dengan memperluas tabel ini:

i	1	2	3	Total
x_i	\$0	\$137	\$170	
$P(X = x_i)$	0.20	0.55	0.25	
$x_i \times P(X = x_i)$	0	75.35	42.50	117.85
$x_i - \mu$	-117.85	19.15	52.15	
$(x_i - \mu)^2$	13888.62	366.72	2719.62	
$(x_i - \mu)^2 \times P(X = x_i)$	2777.7	201.7	679.9	3659.3

Varians X adalah $\sigma^2 = 3659.3$, yang berarti simpangan bakunya adalah $\sigma = \sqrt{3659.3} = \60.49 .

LATIHAN TERBIMBING 3.59

Toko buku tersebut juga menawarkan buku teks kimia seharga \$159 dan buku pendamping seharga \$41. Berdasarkan pengalaman sebelumnya, mereka mengetahui bahwa sekitar 25% mahasiswa kimia hanya membeli buku teks, sedangkan 60% membeli buku teks beserta buku pendamping.⁵¹

- (a) Berapa proporsi mahasiswa yang tidak membeli satu pun dari kedua buku tersebut? Anggap tidak ada mahasiswa yang membeli buku pendamping tanpa buku teks.
- (b) Misalkan Y menyatakan pendapatan dari satu mahasiswa. Tuliskan distribusi peluang Y , yaitu tabel yang memuat setiap hasil beserta peluangnya.
- (c) Hitung pendapatan yang diharapkan dari satu mahasiswa kimia.
- (d) Tentukan simpangan baku untuk mendeskripsikan variabilitas pendapatan dari satu mahasiswa.

3.4.3 Kombinasi linear variabel acak

Sejauh ini, kita menganggap setiap variabel sebagai gambaran yang lengkap dengan sendirinya. Terkadang, kombinasi beberapa variabel lebih tepat digunakan. Sebagai contoh, waktu yang dihabiskan seseorang untuk bepergian ke tempat kerja setiap minggu dapat diuraikan menjadi beberapa perjalanan harian. Demikian pula, total keuntungan atau kerugian dalam suatu portofolio saham merupakan jumlah keuntungan dan kerugian dari komponen-komponennya.

CONTOH 3.60

John pergi ke tempat kerja lima hari dalam seminggu. Kita akan menggunakan X_1 untuk menyatakan waktu perjalanannya pada hari Senin, X_2 untuk menyatakan waktu perjalanannya pada hari Selasa, dan seterusnya. Tuliskan persamaan menggunakan $X_1, \dots, X_5$ yang menyatakan waktu perjalanannya selama seminggu, yang dilambangkan dengan W .

Total waktu perjalanan mingguannya adalah jumlah kelima nilai harian:

$$W = X_1 + X_2 + X_3 + X_4 + X_5$$

Menguraikan waktu perjalanan mingguan W menjadi beberapa bagian menyediakan kerangka untuk memahami setiap sumber keacakan dan berguna dalam memodelkan W .

⁵¹(a) $100\% - 25\% - 60\% = 15\%$ mahasiswa tidak membeli buku apa pun untuk kelas tersebut. Bagian (b) direpresentasikan oleh dua baris pertama pada tabel di bawah ini. Nilai harapan untuk bagian (c) diberikan sebagai total pada baris $y_i \times P(Y = y_i)$. Hasil bagian (d) adalah akar kuadrat varians yang tercantum sebagai total pada baris terakhir: $\sigma = \sqrt{\text{Var}(Y)} = \69.28 .

i (skenario)	1 (tanpa buku)	2 (buku teks)	3 (keduanya)	Total
y_i	0.00	159.00	200.00	
$P(Y = y_i)$	0.15	0.25	0.60	
$y_i \times P(Y = y_i)$	0.00	39.75	120.00	$E(Y) = 159.75$
$y_i - E(Y)$	-159.75	-0.75	40.25	
$(y_i - E(Y))^2$	25520.06	0.56	1620.06	
$(y_i - E(Y))^2 \times P(Y)$	3828.0	0.1	972.0	$\text{Var}(Y) \approx 4800$

CONTOH 3.61

Waktu rata-rata yang dibutuhkan John untuk pergi ke tempat kerja setiap hari adalah 18 menit. Berapa waktu perjalanan rata-rata yang Anda harapkan selama seminggu?

Kita diberi tahu bahwa rata-rata (yaitu nilai harapan) waktu perjalanan adalah 18 menit per hari: $E(X_i) = 18$. Untuk memperoleh waktu yang diharapkan bagi jumlah lima hari tersebut, kita dapat menjumlahkan waktu yang diharapkan untuk setiap hari:

$$\begin{aligned} E(W) &= E(X_1 + X_2 + X_3 + X_4 + X_5) \\ &= E(X_1) + E(X_2) + E(X_3) + E(X_4) + E(X_5) \\ &= 18 + 18 + 18 + 18 + 18 = 90 \text{ menit} \end{aligned}$$

Nilai harapan waktu total sama dengan jumlah nilai harapan waktu masing-masing. Secara lebih umum, nilai harapan jumlah beberapa variabel acak selalu sama dengan jumlah nilai harapan setiap variabel acak.

LATIHAN TERBIMBING 3.62

Elena menjual sebuah TV dalam lelang tunai dan juga bermaksud membeli oven pemanggang dalam lelang tersebut. Jika X menyatakan keuntungan dari penjualan TV dan Y menyatakan biaya oven pemanggang, tuliskan persamaan yang menyatakan perubahan bersih uang tunai Elena.⁵²

LATIHAN TERBIMBING 3.63

Berdasarkan lelang sebelumnya, Elena memperkirakan akan memperoleh sekitar \$175 dari TV dan membayar sekitar \$23 untuk oven pemanggang. Secara keseluruhan, berapa banyak uang yang diperkirakan akan ia peroleh atau belanjakan?⁵³

LATIHAN TERBIMBING 3.64

Apakah Anda akan terkejut jika waktu perjalanan mingguan John tidak tepat 90 menit atau jika Elena tidak memperoleh tepat \$152? Jelaskan.⁵⁴

Dua konsep penting mengenai kombinasi variabel acak telah diperkenalkan. Pertama, suatu nilai akhir terkadang dapat dinyatakan dalam persamaan sebagai jumlah bagian-bagiannya. Kedua, secara intuitif, memasukkan nilai rata-rata setiap bagian ke dalam persamaan ini akan memberikan nilai total rata-rata yang kita harapkan. Poin kedua ini perlu diperjelas – hal tersebut dijamin benar untuk apa yang disebut *kombinasi linear variabel acak*.

Kombinasi linear dua variabel acak X dan Y adalah istilah untuk menyatakan kombinasi

$$aX + bY$$

dengan a dan b sebagai bilangan tetap yang diketahui. Untuk waktu perjalanan John, terdapat lima variabel acak – satu untuk setiap hari kerja – dan setiap variabel acak dapat ditulis dengan koefisien tetap sebesar 1:

$$1X_1 + 1X_2 + 1X_3 + 1X_4 + 1X_5$$

Untuk keuntungan atau kerugian bersih Elena, variabel acak X memiliki koefisien +1 dan variabel acak Y memiliki koefisien -1.

⁵²Elena akan memperoleh X dolar dari TV, tetapi membelanjakan Y dolar untuk oven pemanggang: $X - Y$.

⁵³ $E(X - Y) = E(X) - E(Y) = 175 - 23 = \152 . Elena diperkirakan akan memperoleh sekitar \$152.

⁵⁴Tidak, karena kemungkinan terdapat variabilitas. Sebagai contoh, kondisi lalu lintas berubah dari satu hari ke hari berikutnya, dan harga lelang akan bervariasi bergantung pada kualitas barang serta minat para peserta.

Ketika mempertimbangkan rata-rata kombinasi linear variabel acak, kita dapat memasukkan rata-rata setiap variabel acak lalu menghitung hasil akhirnya. Beberapa contoh kombinasi nonlinear variabel acak – yaitu kasus ketika kita tidak dapat sekadar memasukkan rata-rata – diberikan dalam catatan kaki.⁵⁵

KOMBINASI LINEAR VARIABEL ACAK DAN HASIL RATA-RATA

Jika X dan Y merupakan variabel acak, kombinasi linear kedua variabel acak tersebut diberikan oleh

$$aX + bY$$

dengan a dan b sebagai bilangan tetap. Untuk menghitung nilai rata-rata kombinasi linear variabel acak, masukkan rata-rata setiap variabel acak lalu hitung hasilnya:

$$a \times E(X) + b \times E(Y)$$

Ingat bahwa nilai harapan sama dengan rata-rata, misalnya $E(X) = \mu_X$.

CONTOH 3.65

Leonard telah menginvestasikan \$6000 di Caterpillar Inc (kode saham: CAT) dan \$2000 di Exxon Mobil Corp (XOM). Jika X menyatakan perubahan saham Caterpillar pada bulan depan dan Y menyatakan perubahan saham Exxon Mobil pada bulan depan, tuliskan persamaan yang mendeskripsikan berapa banyak uang yang akan diperoleh atau hilang dari saham Leonard selama bulan tersebut.

E

Untuk menyederhanakan, kita menganggap X dan Y tidak dinyatakan dalam persen, melainkan dalam bentuk desimal (misalnya, jika saham Caterpillar naik 1%, maka $X = 0.01$; atau jika turun 1%, maka $X = -0.01$). Dengan demikian, kita dapat menuliskan persamaan keuntungan Leonard sebagai

$$\$6000 \times X + \$2000 \times Y$$

Jika kita memasukkan perubahan nilai saham untuk X dan Y , persamaan ini memberikan perubahan nilai portofolio saham Leonard selama bulan tersebut. Nilai positif menyatakan keuntungan, sedangkan nilai negatif menyatakan kerugian.

LATIHAN TERBIMBING 3.66

G

Saham Caterpillar akhir-akhir ini naik sebesar 2.0% dan saham Exxon Mobil sebesar 0.2% per bulan. Hitung perubahan yang diharapkan pada portofolio saham Leonard untuk bulan depan.⁵⁶

LATIHAN TERBIMBING 3.67

G

Anda seharusnya menemukan bahwa Leonard mengharapkan keuntungan positif dalam Latihan Terbimbing 3.66. Namun, apakah Anda akan terkejut jika ia sebenarnya mengalami kerugian pada bulan ini?⁵⁷


⁵⁵ Jika X dan Y merupakan variabel acak, pertimbangkan kombinasi berikut: X^{1+Y} , $X \times Y$, X/Y . Dalam kasus seperti ini, memasukkan nilai rata-rata setiap variabel acak dan menghitung hasilnya umumnya tidak akan menghasilkan nilai rata-rata yang akurat bagi hasil akhir.

⁵⁶ $E(\$6000 \times X + \$2000 \times Y) = \$6000 \times 0.020 + \$2000 \times 0.002 = \$124$.

⁵⁷ Tidak. Walaupun saham cenderung naik dari waktu ke waktu, nilainya sering bergejolak dalam jangka pendek.

3.4.4 Variabilitas dalam kombinasi linear variabel acak

Mengukur hasil rata-rata dari kombinasi linear variabel acak memang berguna, tetapi kita juga perlu memahami ketidakpastian yang berkaitan dengan hasil total kombinasi variabel acak tersebut. Keuntungan atau kerugian bersih yang diharapkan dari portofolio saham Leonard telah dipertimbangkan dalam Latihan Terbimbing 3.66. Namun, volatilitas portofolio ini belum dibahas secara kuantitatif. Sebagai contoh, meskipun keuntungan bulanan rata-rata menurut data mungkin sekitar \$124, keuntungan tersebut tidak terjamin. Gambar 3.22 menunjukkan perubahan bulanan pada portofolio seperti milik Leonard selama periode tiga tahun. Keuntungan dan kerugiannya sangat bervariasi, dan mengukur fluktuasi ini penting ketika berinvestasi dalam saham.



Gambar 3.22: Perubahan portofolio seperti milik Leonard selama 36 bulan, dengan \$6000 diinvestasikan dalam saham Caterpillar dan \$2000 dalam saham Exxon Mobil.

Seperti dalam banyak kasus sebelumnya, kita menggunakan varians dan simpangan baku untuk mendeskripsikan ketidakpastian yang berkaitan dengan imbal hasil bulanan Leonard. Untuk itu, varians imbal hasil bulanan setiap saham akan berguna, dan nilainya ditampilkan pada Gambar 3.23. Imbal hasil kedua saham tersebut hampir saling independen.

Di sini kita menggunakan persamaan dari teori probabilitas untuk mendeskripsikan ketidakpastian imbal hasil bulanan Leonard; pembuktian metode ini diserahkan kepada mata kuliah khusus probabilitas. Varians kombinasi linear variabel acak dapat dihitung dengan memasukkan varians setiap variabel acak dan mengkuadratkan koefisien variabel-variabel acak tersebut:

$$\text{Var}(aX + bY) = a^2 \times \text{Var}(X) + b^2 \times \text{Var}(Y)$$

Perlu diperhatikan bahwa kesamaan ini mengasumsikan variabel-variabel acak tersebut saling independen; jika independensi tidak terpenuhi, persamaan ini perlu dimodifikasi. Topik tersebut akan dibahas dalam mata kuliah selanjutnya. Persamaan ini dapat digunakan untuk menghitung varians imbal hasil bulanan Leonard:

$$\begin{aligned} \text{Var}(6000 \times X + 2000 \times Y) &= 6000^2 \times \text{Var}(X) + 2000^2 \times \text{Var}(Y) \\ &= 36,000,000 \times 0.0057 + 4,000,000 \times 0.0021 \\ &\approx 213,600 \end{aligned}$$

Simpangan baku dihitung sebagai akar kuadrat varians: $\sqrt{213,600} = \$463$. Meskipun imbal hasil bulanan rata-rata sebesar \$124 dari investasi \$8000 bukanlah jumlah yang kecil, imbal hasil bulanan tersebut begitu bergejolak sehingga Leonard sebaiknya tidak mengharapkan pendapatan ini sangat stabil.

	Rata-rata ($\bar{x}$)	Simpangan baku (s)	Varians (s^2)
CAT	0.0204	0.0757	0.0057
XOM	0.0025	0.0455	0.0021

Gambar 3.23: Rata-rata, simpangan baku, dan varians saham CAT dan XOM. Statistik ini diestimasi dari data saham historis, sehingga digunakan notasi untuk statistik sampel.

VARIABILITAS KOMBINASI LINEAR VARIABEL ACAK

Varians kombinasi linear variabel acak dapat dihitung dengan menguadratkan konstanta, mengganti variabel acak dengan variansnya, lalu menghitung hasilnya:

$$Var(aX + bY) = a^2 \times Var(X) + b^2 \times Var(Y)$$

Persamaan ini berlaku selama variabel-variabel acak tersebut saling independen. Simpangan baku kombinasi linear dapat diperoleh dengan mengambil akar kuadrat varians.

CONTOH 3.68

Misalkan waktu perjalanan harian John memiliki simpangan baku 4 menit. Berapakah ketidakpastian total waktu perjalanannya selama seminggu?

Ekspresi untuk waktu perjalanan John adalah

$$X_1 + X_2 + X_3 + X_4 + X_5$$

Setiap koefisien bernilai 1, dan varians waktu perjalanan setiap hari adalah $4^2 = 16$. Jadi, varians total waktu perjalanan mingguan adalah

$$\text{variens} = 1^2 \times 16 + 1^2 \times 16 + 1^2 \times 16 + 1^2 \times 16 + 1^2 \times 16 = 5 \times 16 = 80$$

$$\text{simpangan baku} = \sqrt{\text{variens}} = \sqrt{80} = 8.94$$

Simpangan baku waktu perjalanan mingguan John ke tempat kerja adalah sekitar 9 menit.

LATIHAN TERBIMBING 3.69

Perhitungan dalam Contoh 3.68 bergantung pada asumsi penting: waktu perjalanan setiap hari saling independen dari waktu perjalanan pada hari-hari lain dalam minggu tersebut. Menurut Anda, apakah asumsi ini valid? Jelaskan.⁵⁸

LATIHAN TERBIMBING 3.70

Pertimbangkan kembali dua lelang Elena dari Latihan Terbimbing 3.62 pada halaman 124. Misalkan kedua lelang ini kira-kira saling independen dan variabilitas harga lelang TV serta oven pemanggang dapat dideskripsikan menggunakan simpangan baku \$25 dan \$8. Hitung simpangan baku keuntungan bersih Elena.⁵⁹

Pertimbangkan kembali Latihan Terbimbing 3.70. Koefisien negatif untuk Y dalam kombinasi linear hilang ketika kita menguadratkan koefisien. Hal ini berlaku secara umum: tanda negatif dalam kombinasi linear tidak memengaruhi variabilitas yang dihitung untuk kombinasi linear, tetapi memengaruhi perhitungan nilai harapan.

⁵⁸Salah satu hal yang perlu dipertimbangkan adalah apakah pola lalu lintas cenderung memiliki siklus mingguan (misalnya, hari Jumat mungkin lebih buruk daripada hari lainnya). Jika demikian dan John berkendara, asumsi tersebut mungkin tidak masuk akal. Namun, jika John berjalan kaki ke tempat kerja, waktu perjalanannya mungkin tidak dipengaruhi oleh siklus lalu lintas mingguan.

⁵⁹Persamaan untuk Elena dapat ditulis sebagai

$$(1) \times X + (-1) \times Y$$

Varians X dan Y adalah 625 dan 64. Kita menguadratkan koefisien dan memasukkan nilai varians:

$$(1)^2 \times Var(X) + (-1)^2 \times Var(Y) = 1 \times 625 + 1 \times 64 = 689$$

Varians kombinasi linear tersebut adalah 689, dan simpangan bakunya adalah akar kuadrat 689: sekitar \$26.25.

Latihan

3.29 Mahasiswa perokok. Di sebuah universitas, 13% mahasiswanya merokok.

- Hitung jumlah perokok yang diharapkan dalam sampel acak 100 mahasiswa dari universitas ini.
- Pusat kebugaran universitas buka pada pukul 9 pagi setiap hari Sabtu. Pada suatu Sabtu pagi, pukul 8:55 terdapat 27 mahasiswa di luar pusat kebugaran yang menunggu tempat itu dibuka. Apakah Anda sebaiknya menggunakan pendekatan yang sama seperti pada bagian (a) untuk menghitung jumlah perokok yang diharapkan di antara 27 mahasiswa ini?

3.30 As keriting menang. Pertimbangkan permainan kartu berikut dengan setumpuk kartu yang telah dikocok dengan baik. Jika Anda mengambil kartu merah, Anda tidak memperoleh apa pun. Jika Anda memperoleh kartu sekop, Anda memenangkan \$5. Untuk kartu keriting apa pun, Anda memenangkan \$10 ditambah \$20 tambahan jika memperoleh as keriting.

- Buat model probabilitas untuk jumlah yang Anda menangkan dalam permainan ini. Tentukan pula nilai harapan uang kemenangan untuk satu permainan dan simpangan baku uang kemenangan tersebut.
- Berapa jumlah maksimum yang bersedia Anda bayarkan untuk memainkan permainan ini? Jelaskan alasan Anda.

3.31 Kartu hati menang. Dalam permainan kartu baru, Anda memulai dengan setumpuk kartu lengkap yang telah dikocok dengan baik dan mengambil 3 kartu tanpa pengembalian. Jika Anda mengambil 3 kartu hati, Anda memenangkan \$50. Jika Anda mengambil 3 kartu hitam, Anda memenangkan \$25. Untuk hasil pengambilan lainnya, Anda tidak memperoleh apa pun.

- Buat model probabilitas untuk jumlah yang Anda menangkan dalam permainan ini, lalu tentukan nilai harapan uang kemenangan. Hitung pula simpangan baku distribusi ini.
- Jika biaya memainkan permainan adalah \$5, berapakah nilai harapan dan simpangan baku laba (atau rugi) bersih? (*Petunjuk: laba = uang kemenangan - biaya; $X - 5$*)
- Jika biaya memainkan permainan adalah \$5, apakah Anda sebaiknya memainkannya? Jelaskan.

3.32 Apakah sepadan? Andy selalu mencari cara untuk mendapatkan uang dengan cepat. Belakangan ini, ia mencoba mendapatkan uang melalui perjudian. Berikut permainan yang sedang dipertimbangkannya: biaya bermain adalah \$2. Ia mengambil satu kartu dari setumpuk kartu. Jika memperoleh kartu angka (2-10), ia tidak memenangkan apa pun. Untuk setiap kartu bergambar (jack, queen, atau king), ia memenangkan \$3. Untuk setiap as, ia memenangkan \$5, dan memperoleh *tambahan* \$20 jika mengambil as keriting.

- Buat model probabilitas dan tentukan laba yang diharapkan Andy per permainan.
- Apakah Anda akan merekomendasikan permainan ini kepada Andy sebagai cara yang baik untuk mendapatkan uang? Jelaskan.

3.33 Imbal hasil portofolio. Nilai suatu portofolio meningkat sebesar 18% selama ledakan ekonomi dan sebesar 9% dalam kondisi normal. Nilainya turun 12% selama resesi. Berapakah imbal hasil yang diharapkan dari portofolio ini jika setiap skenario memiliki peluang yang sama?

3.34 Biaya bagasi. Sebuah maskapai mengenakan biaya bagasi berikut: \$25 untuk tas pertama dan \$35 untuk tas kedua. Misalkan 54% penumpang tidak memiliki bagasi tercatat, 34% memiliki satu bagasi tercatat, dan 12% memiliki dua bagasi. Kita menganggap proporsi penumpang yang mendaftarkan lebih dari dua tas dapat diabaikan.

- (a) Susun model probabilitas, hitung pendapatan rata-rata per penumpang, dan hitung simpangan baku yang bersesuaian.
- (b) Sekitar berapa besar pendapatan yang dapat diharapkan maskapai untuk penerbangan dengan 120 penumpang? Dengan simpangan baku berapa? Nyatakan setiap asumsi yang Anda buat dan apakah menurut Anda asumsi tersebut dapat dibenarkan.

3.35 Roulette Amerika. Permainan roulette Amerika menggunakan roda dengan 38 slot: 18 merah, 18 hitam, dan 2 hijau. Sebuah bola diputar pada roda dan akhirnya akan jatuh ke salah satu slot; setiap slot memiliki peluang yang sama untuk menangkap bola. Pemain dapat bertaruh pada warna merah atau hitam. Jika bola jatuh pada warna pilihan mereka, uang mereka menjadi dua kali lipat. Jika jatuh pada warna lain, mereka kehilangan uang taruhan. Misalkan Anda mempertaruhkan \$1 pada warna merah. Berapakah nilai harapan dan simpangan baku hasil bersih taruhan Anda?

3.36 Roulette Eropa. Permainan roulette Eropa menggunakan roda dengan 37 slot: 18 merah, 18 hitam, dan 1 hijau. Sebuah bola diputar pada roda dan akhirnya akan jatuh ke salah satu slot; setiap slot memiliki peluang yang sama untuk menangkap bola. Pemain dapat bertaruh pada warna merah atau hitam. Jika bola jatuh pada warna pilihan mereka, uang mereka menjadi dua kali lipat. Jika jatuh pada warna lain, mereka kehilangan uang taruhan.

- (a) Misalkan Anda bermain roulette dan mempertaruhkan \$3 dalam satu putaran. Berapakah nilai harapan dan simpangan baku total hasil bersih taruhan Anda?
- (b) Misalkan Anda mempertaruhkan \$1 dalam tiga putaran berbeda. Berapakah nilai harapan dan simpangan baku total hasil bersih taruhan Anda?
- (c) Bagaimana perbandingan jawaban Anda untuk bagian (a) dan (b)? Apa yang ditunjukkan hal ini mengenai tingkat risiko kedua permainan tersebut?

3.5 Distribusi kontinu


Sejauh ini dalam bab ini kita telah membahas kasus ketika hasil suatu variabel bersifat diskret. Dalam bagian ini, kita mempertimbangkan konteks ketika hasilnya merupakan variabel numerik kontinu.

CONTOH 3.71

Gambar 3.24 menampilkan beberapa histogram berongga yang berbeda untuk tinggi badan orang dewasa di AS. Bagaimana perubahan jumlah bin memungkinkan Anda membuat penafsiran yang berbeda terhadap data tersebut?

(E)

Penambahan jumlah bin memberikan perincian yang lebih besar. Sampel ini sangat besar, sehingga bin yang jauh lebih sempit masih dapat digunakan dengan baik. Biasanya kita tidak menggunakan bin sebanyak ini pada sampel yang lebih kecil karena sedikitnya hitungan per bin membuat tinggi bin sangat tidak stabil.



Gambar 3.24: Empat histogram berongga tinggi badan orang dewasa di AS dengan lebar bin yang berbeda-beda.

CONTOH 3.72


Berapa proporsi sampel yang memiliki tinggi antara 180 cm dan 185 cm (sekitar 5 kaki 11 inci sampai 6 kaki 1 inci)?

(E)

Kita dapat menjumlahkan tinggi bin-bin dalam rentang 180 cm sampai 185 cm lalu membaginya dengan ukuran sampel. Sebagai contoh, hal ini dapat dilakukan menggunakan dua bin berarsir pada Gambar 3.25. Kedua bin dalam rentang ini memiliki hitungan 195,307 dan 156,239 orang, sehingga menghasilkan estimasi peluang berikut:

$$\frac{195307 + 156239}{3,000,000} = 0.1172$$

Pecahan ini sama dengan proporsi luas histogram yang berada dalam rentang 180 sampai 185 cm.




Gambar 3.25: Histogram dengan lebar bin 2.5 cm. Daerah berarsir merepresentasikan individu dengan tinggi antara 180 dan 185 cm.

3.5.1 Dari histogram ke distribusi kontinu

Perhatikan peralihan dari histogram berongga yang menyerupai kotak-kotak di bagian kiri atas Gambar 3.24 ke grafik yang jauh lebih mulus di bagian kanan bawah. Pada grafik terakhir ini, bin-bin begitu sempit sehingga histogram berongganya mulai menyerupai kurva mulus. Hal ini menunjukkan bahwa tinggi badan populasi sebagai variabel numerik *kontinu* mungkin paling baik dijelaskan dengan kurva yang merepresentasikan garis luar bin-bin yang sangat sempit.

Kurva mulus ini merepresentasikan **fungsi kepadatan peluang** (juga disebut **kepadatan** atau **distribusi**), dan kurva semacam itu ditampilkan pada Gambar 3.26 serta ditumpangkan pada histogram sampel. Suatu kepadatan memiliki sifat khusus: luas total di bawah kurva kepadatan adalah 1.



Gambar 3.26: Distribusi peluang kontinu tinggi badan orang dewasa di AS.

3.5.2 Peluang dari distribusi kontinu


Dalam Contoh 3.72, kita menghitung proporsi individu dengan tinggi 180 sampai 185 cm sebagai pecahan:

$$\frac{\text{jumlah orang dengan tinggi antara 180 dan 185}}{\text{ukuran sampel total}}$$

Kita menemukan jumlah orang dengan tinggi antara 180 dan 185 cm dengan menentukan proporsi luas histogram dalam rentang tersebut. Serupa dengan itu, kita dapat menggunakan luas daerah berarsir di bawah kurva untuk menemukan peluang (dengan bantuan komputer):

$$P(\text{tinggi antara 180 dan 185}) = \text{luas antara 180 dan 185} = 0.1157$$

Peluang bahwa orang yang dipilih secara acak memiliki tinggi antara 180 dan 185 cm adalah 0.1157. Nilai ini sangat dekat dengan estimasi dari Contoh 3.72: 0.1172.



Gambar 3.27: Kepadatan tinggi badan populasi orang dewasa di AS dengan luas antara 180 dan 185 cm diberi arsiran. Bandingkan grafik ini dengan Gambar 3.25.

LATIHAN TERBIMBING 3.73

Tiga orang dewasa di AS dipilih secara acak. Peluang bahwa satu orang dewasa memiliki tinggi antara 180 dan 185 cm adalah 0.1157.⁶⁰

- Berapa peluang bahwa ketiganya memiliki tinggi antara 180 dan 185 cm?
- Berapa peluang bahwa tidak satu pun memiliki tinggi antara 180 dan 185 cm?

CONTOH 3.74

Berapa peluang bahwa orang yang dipilih secara acak memiliki tinggi **tepat** 180 cm? Anggap Anda dapat mengukur dengan sempurna.

Peluang ini adalah nol. Seseorang mungkin memiliki tinggi yang mendekati 180 cm, tetapi tidak tepat 180 cm. Hal ini juga masuk akal berdasarkan definisi peluang sebagai luas; tidak ada luas yang tercakup antara 180 cm dan 180 cm.

LATIHAN TERBIMBING 3.75

Misalkan tinggi seseorang dibulatkan ke sentimeter terdekat. Apakah ada peluang bahwa tinggi **terukur** seseorang yang dipilih secara acak adalah 180 cm?⁶¹


⁶⁰Jawaban singkat: (a) $0.1157 \times 0.1157 \times 0.1157 = 0.0015$. (b) $(1 - 0.1157)^3 = 0.692$

⁶¹Peluang ini bernilai positif. Siapa pun yang tingginya antara 179.5 cm dan 180.5 cm akan memiliki tinggi *terukur* sebesar 180 cm. Ini mungkin merupakan skenario yang lebih realistis dijumpai dalam praktik daripada Contoh 3.74.

Latihan

3.37 Berat kucing. Histogram di bawah ini merepresentasikan berat (dalam kg) 47 kucing betina dan 97 kucing jantan.⁶²

- Berapa proporsi kucing-kucing ini yang beratnya kurang dari 2.5 kg?
- Berapa proporsi kucing-kucing ini yang beratnya antara 2.5 dan 2.75 kg?
- Berapa proporsi kucing-kucing ini yang beratnya antara 2.75 dan 3.5 kg?



3.38 Pendapatan dan gender. Tabel frekuensi relatif di bawah ini menampilkan distribusi pendapatan pribadi total tahunan (dalam dolar yang disesuaikan dengan inflasi tahun 2009) untuk sampel representatif yang terdiri atas 96,420,486 penduduk Amerika Serikat. Data ini berasal dari American Community Survey tahun 2005–2009. Sampel ini terdiri atas 59% laki-laki dan 41% perempuan.⁶³

- Deskripsikan distribusi pendapatan pribadi total.
- Berapa peluang bahwa penduduk AS yang dipilih secara acak berpenghasilan kurang dari \$50,000 per tahun?
- Berapa peluang bahwa penduduk AS yang dipilih secara acak berpenghasilan kurang dari \$50,000 per tahun dan berjenis kelamin perempuan? Nyatakan setiap asumsi yang Anda buat.
- Sumber data yang sama menunjukkan bahwa 71.8% perempuan berpenghasilan kurang dari \$50,000 per tahun. Gunakan nilai ini untuk menentukan apakah asumsi yang Anda buat pada bagian (c) valid.

Pendapatan	Total
\$1 sampai \$9,999 atau rugi	2.2%
\$10,000 sampai \$14,999	4.7%
\$15,000 sampai \$24,999	15.8%
\$25,000 sampai \$34,999	18.3%
\$35,000 sampai \$49,999	21.2%
\$50,000 sampai \$64,999	13.9%
\$65,000 sampai \$74,999	5.8%
\$75,000 sampai \$99,999	8.4%
\$100,000 atau lebih	9.7%

⁶²W. N. Venables and B. D. Ripley. *Modern Applied Statistics with S*. Fourth Edition. www.stats.ox.ac.uk/pub/MASS4. New York: Springer, 2002.

⁶³U.S. Census Bureau, 2005–2009 American Community Survey.

Bab 4

Distribusi variabel acak

4.1 Distribusi normal

4.2 Distribusi geometrik

4.3 Distribusi binomial

4.4 Distribusi binomial negatif

4.5 Distribusi Poisson


Dalam bab ini, kita membahas berbagai distribusi yang sering dijumpai dalam analisis data atau inferensi statistika. Kita mulai dengan distribusi normal pada bagian pertama, yang kerap digunakan dalam bab-bab selanjutnya. Bagian-bagian lainnya sesekali akan dirujuk, tetapi dapat dianggap sebagai materi opsional dalam buku ini.



Untuk video, salindia, dan sumber daya lainnya, kunjungi
www.openintro.org/os

4.1 Distribusi normal

Di antara semua distribusi yang kita jumpai dalam praktik, ada satu yang jauh lebih umum daripada yang lain. Kurva lonceng yang simetris dan unimodal muncul di mana-mana dalam statistika. Bahkan, kurva ini begitu umum sehingga orang sering menyebutnya **kurva normal** atau **distribusi normal**,¹ seperti yang ditampilkan pada Gambar 4.1. Variabel seperti skor SAT dan tinggi badan laki-laki dewasa di AS mendekati distribusi normal.




Gambar 4.1: Sebuah kurva normal.

FAKTA TENTANG DISTRIBUSI NORMAL

Banyak variabel hampir mengikuti distribusi normal, tetapi tidak ada yang tepat mengikuti distribusi normal. Jadi, meskipun tidak sempurna untuk satu pun masalah tertentu, distribusi normal sangat berguna untuk beragam masalah. Kita akan menggunakannya dalam eksplorasi data dan untuk menyelesaikan berbagai masalah penting dalam statistika.

4.1.1 Model distribusi normal

Distribusi normal selalu menggambarkan kurva berbentuk lonceng yang simetris dan unimodal. Namun, tampilan kurva-kurva tersebut dapat berbeda bergantung pada rincian modelnya. Secara khusus, model distribusi normal dapat disesuaikan dengan dua parameter: rata-rata dan simpangan baku. Seperti yang mungkin Anda duga, perubahan rata-rata menggeser kurva lonceng ke kiri atau ke kanan, sedangkan perubahan simpangan baku meregangkan atau menyempitkan kurva. Panel kiri Gambar 4.2 menampilkan distribusi normal dengan rata-rata 0 dan simpangan baku 1, sedangkan panel kanan menampilkan distribusi normal dengan rata-rata 19 dan simpangan baku 4. Gambar 4.3 menampilkan kedua distribusi ini pada sumbu yang sama.




Gambar 4.2: Kedua kurva merepresentasikan distribusi normal. Namun, pusat dan sebarannya berbeda.

Jika suatu distribusi normal memiliki rata-rata μ dan simpangan baku σ , kita dapat menuliskan distribusinya sebagai $N(\mu, \sigma)$. Kedua distribusi pada Gambar 4.3 dapat dituliskan sebagai

$$N(\mu = 0, \sigma = 1) \quad \text{dan} \quad N(\mu = 19, \sigma = 4)$$

¹Distribusi ini juga diperkenalkan sebagai distribusi Gaussian, dari nama Carl Friedrich Gauss, orang pertama yang memformalkan bentuk matematisnya.



Gambar 4.3: Distribusi normal pada Gambar 4.2, tetapi digambar bersama-sama dengan skala yang sama.

Karena rata-rata dan simpangan baku menggambarkan suatu distribusi normal secara tepat, keduanya disebut **parameter** distribusi tersebut. Distribusi normal dengan rata-rata $\mu = 0$ dan simpangan baku $\sigma = 1$ disebut **distribusi normal baku**.

LATIHAN TERBIMBING 4.1

Tuliskan notasi ringkas untuk distribusi normal dengan²

- (a) rata-rata 5 dan simpangan baku 3,
- (b) rata-rata -100 dan simpangan baku 10, serta
- (c) rata-rata 2 dan simpangan baku 9.

4.1.2 Standardisasi dengan skor-Z

Kita sering ingin menempatkan data pada skala baku agar perbandingan menjadi lebih masuk akal.

CONTOH 4.2

Tabel 4.4 menampilkan rata-rata dan simpangan baku skor total pada SAT dan ACT. Distribusi skor SAT dan ACT sama-sama hampir normal. Misalkan Ann memperoleh skor 1300 pada SAT dan Tom memperoleh skor 24 pada ACT. Siapa yang memperoleh hasil relatif lebih baik?


Kita menggunakan simpangan baku sebagai panduan. Skor SAT Ann berada 1 simpangan baku di atas rata-rata: $1100 + 200 = 1300$. Skor ACT Tom berada 0.5 simpangan baku di atas rata-rata: $21 + 0.5 \times 6 = 24$. Pada Gambar 4.5, kita dapat melihat bahwa, dibandingkan dengan peserta lain, Ann cenderung berprestasi lebih baik daripada Tom; jadi skor relatif Ann lebih baik.

	SAT	ACT
Rata-rata	1100	21
Simpangan baku	200	6

Gambar 4.4: Rata-rata dan simpangan baku untuk SAT dan ACT.

Contoh 4.2 menggunakan teknik standardisasi yang disebut skor-Z. Metode ini paling sering digunakan untuk pengamatan yang hampir normal, tetapi dapat digunakan pada distribusi apa pun. **Skor-Z** suatu pengamatan menyatakan berapa simpangan baku letak pengamatan tersebut di atas atau di bawah rata-rata. Jika pengamatan berada satu simpangan baku di atas rata-rata, skor-Z-nya adalah 1. Jika pengamatan berada 1.5 simpangan baku *di bawah* rata-rata, skor-Z-nya adalah -1.5. Jika x merupakan pengamatan dari distribusi $N(\mu, \sigma)$, secara matematis kita mendefinisikan skor-Z sebagai

²(a) $N(\mu = 5, \sigma = 3)$. (b) $N(\mu = -100, \sigma = 10)$. (c) $N(\mu = 2, \sigma = 9)$.



Gambar 4.5: Skor Ann dan Tom pada distribusi SAT dan ACT.

$$Z = \frac{x - \mu}{\sigma}$$

Dengan $\mu_{SAT} = 1100$, $\sigma_{SAT} = 200$, dan $x_{Ann} = 1300$, kita memperoleh skor-Z Ann:

$$Z_{Ann} = \frac{x_{Ann} - \mu_{SAT}}{\sigma_{SAT}} = \frac{1300 - 1100}{200} = 1$$

SKOR-Z

Skor-Z suatu pengamatan menyatakan berapa simpangan baku letak pengamatan tersebut di atas atau di bawah rata-rata. Kita menghitung skor-Z untuk pengamatan x yang mengikuti distribusi dengan rata-rata μ dan simpangan baku σ menggunakan

$$Z = \frac{x - \mu}{\sigma}$$

LATIHAN TERBIMBING 4.3

Ⓔ

Gunakan skor ACT Tom, 24, bersama rata-rata dan simpangan baku ACT untuk mencari skor-Z-nya.³

Pengamatan di atas rata-rata selalu memiliki skor-Z positif, sedangkan pengamatan di bawah rata-rata selalu memiliki skor-Z negatif. Jika suatu pengamatan sama dengan rata-rata, misalnya skor SAT sebesar 1100, skor-Z-nya adalah 0.

LATIHAN TERBIMBING 4.4

Ⓔ

Misalkan X merepresentasikan variabel acak dari $N(\mu = 3, \sigma = 2)$ dan kita mengamati $x = 5.19$.

(a) Carilah skor-Z untuk x .

(b) Gunakan skor-Z untuk menentukan berapa simpangan baku posisi x di atas atau di bawah rata-rata.⁴

LATIHAN TERBIMBING 4.5

Ⓔ

Panjang kepala posum ekor sikat mengikuti distribusi normal dengan rata-rata 92.6 mm dan simpangan baku 3.6 mm. Hitung skor-Z untuk posum dengan panjang kepala 95.4 mm dan 85.8 mm.⁵

³ $Z_{Tom} = \frac{x_{Tom} - \mu_{ACT}}{\sigma_{ACT}} = \frac{24 - 21}{6} = 0.5$

⁴ (a) Skor-Z-nya diberikan oleh $Z = \frac{x - \mu}{\sigma} = \frac{5.19 - 3}{2} = 2.19/2 = 1.095$. (b) Pengamatan x berada 1.095 simpangan baku di atas rata-rata. Kita tahu pengamatan itu berada di atas rata-rata karena Z positif.

Kita dapat menggunakan skor-Z untuk mengenali secara kasar pengamatan mana yang lebih tak lazim daripada yang lain. Pengamatan x_1 disebut lebih tak lazim daripada pengamatan lain x_2 jika nilai mutlak skor-Z-nya lebih besar daripada nilai mutlak skor-Z pengamatan lainnya: $|Z_1| > |Z_2|$. Teknik ini sangat informatif ketika distribusinya simetris.




LATIHAN TERBIMBING 4.6

Manakah di antara pengamatan pada Latihan Terpandu 4.5 yang lebih tak lazim?⁶

4.1.3 Mencari luas ekor

Dalam statistika, kemampuan menentukan luas ekor suatu distribusi sangatlah berguna. Sebagai contoh, berapa proporsi peserta yang memperoleh skor SAT di bawah skor Ann sebesar 1300? Nilai ini sama dengan **persentil** Ann, yaitu persentase peserta yang skornya lebih rendah daripada skor Ann. Kita dapat memvisualisasikan luas ekor tersebut dengan kurva dan arsiran seperti pada Gambar 4.6.



Gambar 4.6: Luas di sebelah kiri Z merepresentasikan proporsi peserta yang memperoleh skor lebih rendah daripada Ann.

Ada banyak teknik untuk melakukan perhitungan ini; kita akan membahas tiga pilihan.

1. Pendekatan yang paling umum dalam praktik adalah menggunakan perangkat lunak statistika. Sebagai contoh, dalam program **R**, kita dapat mencari luas pada Gambar 4.6 dengan perintah berikut. Perintah ini menerima skor-Z dan mengembalikan luas ekor bawah:

```
> pnorm(1)
[1] 0.8413447
```

Menurut perhitungan ini, daerah berarsir di bawah 1300 merepresentasikan proporsi 0.841 (84.1%) peserta SAT yang memiliki skor-Z di bawah $Z = 1$. Secara lebih umum, kita juga dapat menetapkan nilai batas secara eksplisit jika rata-rata dan simpangan bakunya turut diberikan:

```
> pnorm(1300, mean = 1100, sd = 200)
[1] 0.8413447
```

Ada banyak pilihan perangkat lunak lain, seperti Python atau SAS; bahkan program lembar kerja seperti Excel dan Google Sheets mendukung perhitungan ini.

2. Strategi yang umum digunakan di kelas adalah memakai kalkulator grafik, misalnya kalkulator TI atau Casio. Kalkulator-kalkulator ini memerlukan serangkaian penekanan tombol yang tidak mudah dijelaskan secara ringkas. Petunjuk penggunaan kalkulator tersebut untuk mencari luas ekor distribusi normal tersedia di pustaka video OpenIntro:

www.openintro.org/videos

3. Pilihan terakhir untuk mencari luas ekor adalah menggunakan **tabel peluang**; tabel semacam ini kadang digunakan di kelas, tetapi jarang digunakan dalam praktik. Lampiran belum dimuat memuat tabel tersebut beserta panduan penggunaannya.

⁵Untuk $x_1 = 95.4$ mm: $Z_1 = \frac{x_1 - \mu}{\sigma} = \frac{95.4 - 92.6}{3.6} = 0.78$. Untuk $x_2 = 85.8$ mm: $Z_2 = \frac{85.8 - 92.6}{3.6} = -1.89$.

⁶Karena *nilai mutlak* skor-Z pengamatan kedua lebih besar daripada pengamatan pertama, pengamatan kedua memiliki panjang kepala yang lebih tak lazim.

Dalam bagian ini, kita akan menyelesaikan soal distribusi normal dengan selalu mencari skor-Z terlebih dahulu. Alasannya, mulai Bab 5 kita akan menjumpai konsep yang sangat serupa, yaitu statistik uji; dalam banyak keadaan, statistik uji setara dengan skor-Z.


4.1.4 Contoh peluang normal

Skor total SAT dapat dihipotesiskan dengan baik oleh model normal $N(\mu = 1100, \sigma = 200)$.

CONTOH 4.7

Shannon dipilih secara acak dari para peserta SAT, dan tidak ada informasi tentang kemampuannya dalam SAT. Berapa peluang Shannon memperoleh skor sekurang-kurangnya 1190 pada SAT?

Pertama, selalu gambar dan beri keterangan pada kurva normal. (Gambar tidak harus tepat agar tetap berguna.) Kita tertarik pada peluang bahwa skornya melebihi 1190, sehingga kita mengarsir ekor atas berikut:



E

Gambar tersebut menampilkan rata-rata dan nilai-nilai yang terletak 2 simpangan baku di atas dan di bawah rata-rata. Cara termudah untuk mencari luas berarsir di bawah kurva menggunakan skor-Z dari nilai batas. Dengan $\mu = 1100$, $\sigma = 200$, dan nilai batas $x = 1190$, skor-Z dihitung sebagai

$$Z = \frac{x - \mu}{\sigma} = \frac{1190 - 1100}{200} = \frac{90}{200} = 0.45$$

Dengan perangkat lunak statistika (atau metode lain yang dipilih), kita memperoleh luas di sebelah kiri $Z = 0.45$ sebesar 0.6736. Untuk mencari luas *di atas* $Z = 0.45$, kita menghitung satu dikurangi luas ekor bawah:

$$1.0000 - 0.6736 = 0.3264$$

Peluang Shannon memperoleh skor SAT sekurang-kurangnya 1190 adalah 0.3264.

SELALU GAMBAR TERLEBIH DAHULU, LALU CARI SKOR-Z

Dalam setiap situasi peluang normal, *selalu, selalu, selalu* gambar dan beri keterangan pada kurva normal, kemudian arsir daerah yang ditanyakan. Gambar tersebut akan memberikan perkiraan peluang. Setelah menggambar situasinya, tentukan skor-Z untuk nilai yang ditanyakan.

LATIHAN TERBIMBING 4.8


G

Jika peluang Shannon memperoleh skor sekurang-kurangnya 1190 adalah 0.3264, berapa peluang ia memperoleh skor kurang dari 1190? Gambarlah kurva normal untuk latihan ini dan arsir daerah bawah, bukan daerah atas.⁷

CONTOH 4.9

Edward memperoleh skor SAT sebesar 1030. Berapa persentilnya?

Pertama, kita perlu menggambar situasinya. Persentil Edward adalah proporsi peserta yang tidak mencapai skor setinggi 1030. Skor-skor ini berada di sebelah kiri 1030.



Dengan menentukan rata-rata $\mu = 1100$, simpangan baku $\sigma = 200$, dan nilai batas untuk luas ekor $x = 1030$, kita dapat menghitung skor-Z dengan mudah:

$$Z = \frac{x - \mu}{\sigma} = \frac{1030 - 1100}{200} = -0.35$$

Dengan perangkat lunak statistika, kita memperoleh luas ekor 0.3632. Edward berada pada persentil ke-36.

LATIHAN TERBIMBING 4.10

Gunakan hasil Contoh 4.9 untuk menghitung proporsi peserta SAT yang memperoleh skor lebih tinggi daripada Edward. Gambarlah pula situasi yang baru.⁸

MENCARI LUAS DI SEBELAH KANAN

Ketika diberi skor-Z, banyak program perangkat lunak mengembalikan luas di sebelah kiri. Jika Anda memerlukan luas di sebelah kanan, cari dahulu luas di sebelah kiri lalu kurangi nilai tersebut dari satu.

LATIHAN TERBIMBING 4.11

Stuart memperoleh skor SAT sebesar 1500. Gambarlah situasi untuk setiap bagian.

- Berapa persentilnya?
- Berapa persen peserta SAT yang memperoleh skor lebih tinggi daripada Stuart?⁹


Berdasarkan sampel 100 laki-laki, tinggi badan laki-laki dewasa di AS hampir berdistribusi normal dengan rata-rata 70.0" dan simpangan baku 3.3".

LATIHAN TERBIMBING 4.12


Mike memiliki tinggi 5'7" dan Jose 6'4", dan keduanya tinggal di AS.

- Berapa persentil tinggi badan Mike?
 - Berapa persentil tinggi badan Jose?
- Gambarlah pula satu situasi untuk setiap bagian.¹⁰

⁷Kita telah memperoleh peluang ini pada Contoh 4.7: 0.6736.



⁸Jika Edward memperoleh skor lebih tinggi daripada 36% peserta SAT, sekitar 64% peserta tentu memperoleh skor lebih tinggi daripada Edward.




⁹Gambarnya kami serahkan kepada Anda. (a) $Z = \frac{1500 - 1100}{200} = 2 \rightarrow 0.9772$. (b) $1 - 0.9772 = 0.0228$.

Beberapa soal terakhir berfokus pada pencarian persentil (ekor bawah) atau ekor atas untuk suatu pengamatan tertentu. Bagaimana jika Anda ingin mengetahui pengamatan yang bersesuaian dengan persentil tertentu?

CONTOH 4.13

Tinggi Erik berada pada persentil ke-40. Berapakah tinggi Erik?

Seperti biasa, gambar dahulu situasinya.



E

Dalam kasus ini, peluang ekor bawah diketahui (0.40) dan dapat diarsir pada diagram. Kita ingin mencari pengamatan yang bersesuaian dengan nilai tersebut. Sebagai langkah awal, kita menentukan skor-Z yang bersesuaian dengan persentil ke-40. Dengan perangkat lunak, kita memperoleh skor-Z yang bersesuaian, yaitu sekitar -0.25.

Setelah mengetahui $Z_{\text{Erik}} = -0.25$ serta parameter populasi $\mu = 70$ dan $\sigma = 3.3$ inci, kita dapat menyusun rumus skor-Z untuk menentukan tinggi Erik yang belum diketahui, yang diberi label x_{Erik} :


$$-0.25 = Z_{\text{Erik}} = \frac{x_{\text{Erik}} - \mu}{\sigma} = \frac{x_{\text{Erik}} - 70}{3.3}$$

Dengan menyelesaikan persamaan untuk x_{Erik} , diperoleh tinggi 69.18 inci. Jadi, tinggi Erik sekitar 5'9".

CONTOH 4.14

Berapa tinggi laki-laki dewasa pada persentil ke-82?

Sekali lagi, kita menggambar situasinya terlebih dahulu.



E

Berikutnya, kita ingin mencari skor-Z pada persentil ke-82. Nilainya positif dan dapat diperoleh dengan perangkat lunak sebagai $Z = 0.92$. Terakhir, tinggi x dicari menggunakan rumus skor-Z dengan rata-rata μ , simpangan baku σ , dan skor-Z $Z = 0.92$ yang diketahui:

$$0.92 = Z = \frac{x - \mu}{\sigma} = \frac{x - 70}{3.3}$$


Hasilnya adalah 73.04 inci, atau sekitar 6'1", sebagai tinggi pada persentil ke-82.

LATIHAN TERBIMBING 4.15

Skor SAT mengikuti $N(1100, 200)$.¹¹

- (a) Berapakah skor SAT pada persentil ke-95?
(b) Berapakah skor SAT pada persentil ke-97.5?

¹¹Ubah dahulu tinggi badan menjadi inci: 67 dan 76 inci. Gambar-gambarnya ditampilkan di bawah.
(a) $Z_{\text{Mike}} = \frac{67-70}{3.3} = -0.91 \rightarrow 0.1814$. (b) $Z_{\text{Jose}} = \frac{76-70}{3.3} = 1.82 \rightarrow 0.9656$.



LATIHAN TERBIMBING 4.16


Tinggi badan laki-laki dewasa mengikuti $N(70.0'', 3.3'')$.¹²

- (a) Berapa peluang bahwa laki-laki dewasa yang dipilih secara acak memiliki tinggi sekurang-kurangnya 6'2'' (74 inci)?
 (b) Berapa peluang bahwa seorang laki-laki dewasa memiliki tinggi kurang dari 5'9'' (69 inci)?

CONTOH 4.17

Berapa peluang bahwa laki-laki dewasa yang dipilih secara acak memiliki tinggi antara 5'9'' dan 6'2''?

Tinggi tersebut bersesuaian dengan 69 inci dan 74 inci. Pertama, gambar situasinya. Daerah yang ditanyakan bukan lagi ekor atas atau ekor bawah.



Luas total di bawah kurva adalah 1. Jika kita mencari luas kedua ekor yang tidak diarsir (dari Latihan Terpandu 4.16, luasnya masing-masing 0.3821 dan 0.1131), kita dapat mencari luas bagian tengah:

$$1.0000 - 0.3821 - 0.1131 = 0.5048$$

Jadi, peluang tinggi badan berada antara 5'9'' dan 6'2'' adalah 0.5048.

LATIHAN TERBIMBING 4.18

Skor SAT mengikuti $N(1100, 200)$. Berapa persen peserta SAT yang memperoleh skor antara 1100 dan 1400?¹³

LATIHAN TERBIMBING 4.19

Tinggi badan laki-laki dewasa mengikuti $N(70.0'', 3.3'')$. Berapa persen laki-laki dewasa yang tingginya antara 5'5'' dan 5'7''?¹⁴

¹¹Jawaban singkat: (a) $Z_{95} = 1.6449 \rightarrow 1429$ skor SAT. (b) $Z_{97.5} = 1.96 \rightarrow 1492$ skor SAT.


¹²Jawaban singkat: (a) $Z = 1.21 \rightarrow 0.8869$, kemudian kurangi nilai ini dari 1 untuk memperoleh 0.1131. (b) $Z = -0.30 \rightarrow 0.3821$.

¹³Berikut solusi ringkasnya. (Pastikan Anda menggambar situasinya!) Pertama, cari persentase peserta yang memperoleh skor di bawah 1100 dan persentase yang memperoleh skor di atas 1400: $Z_{1100} = 0.00 \rightarrow 0.5000$ (luas di bawah), $Z_{1400} = 1.5 \rightarrow 0.0668$ (luas di atas). Jawaban akhir: $1.0000 - 0.5000 - 0.0668 = 0.4332$.

¹⁴5'5'' adalah 65 inci ($Z = -1.52$). 5'7'' adalah 67 inci ($Z = -0.91$). Solusi numerik: $1.000 - 0.0643 - 0.8186 = 0.1171$, yaitu 11.71%.

4.1.5 Kaidah 68-95-99.7

Di sini kita memperkenalkan kaidah praktis untuk peluang bahwa suatu nilai berada dalam jarak 1, 2, dan 3 simpangan baku dari rata-rata pada distribusi normal. Kaidah ini berguna dalam beragam situasi praktis, terutama ketika kita ingin membuat perkiraan cepat tanpa kalkulator atau tabel-Z.



Gambar 4.7: Peluang berada dalam jarak 1, 2, dan 3 simpangan baku dari rata-rata pada distribusi normal.

LATIHAN TERBIMBING 4.20

Gunakan perangkat lunak, kalkulator, atau tabel peluang untuk mengonfirmasi bahwa sekitar 68%, 95%, dan 99.7% pengamatan masing-masing berada dalam jarak 1, 2, dan 3 simpangan baku dari rata-rata pada distribusi normal. Sebagai contoh, carilah dahulu luas antara $Z = -1$ dan $Z = 1$, yang seharusnya sekitar 0.68. Demikian pula, luas antara $Z = -2$ dan $Z = 2$ seharusnya sekitar 0.95.¹⁵

Variabel acak normal mungkin saja berada 4, 5, atau bahkan lebih banyak simpangan baku dari rata-rata. Namun, kejadian semacam ini sangat jarang jika datanya hampir normal. Peluang berada lebih dari 4 simpangan baku dari rata-rata adalah sekitar 1 dari 15,000. Untuk 5 dan 6 simpangan baku, peluangnya masing-masing sekitar 1 dari 2 juta dan 1 dari 500 juta.

LATIHAN TERBIMBING 4.21

Distribusi skor SAT dapat dihipotesis dengan baik oleh model normal dengan rata-rata $\mu = 1100$ dan simpangan baku $\sigma = 200$.¹⁶

- Kira-kira berapa persen peserta ujian yang memperoleh skor antara 700 dan 1500?
- Berapa persen yang memperoleh skor antara 1100 dan 1500?

¹⁵Gambarlah situasinya terlebih dahulu. Dengan perangkat lunak, kita memperoleh 0.6827 dalam 1 simpangan baku, 0.9545 dalam 2 simpangan baku, dan 0.9973 dalam 3 simpangan baku.

¹⁶(a) 700 dan 1500 berada dua simpangan baku di bawah dan di atas rata-rata, sehingga sekitar 95% peserta ujian memperoleh skor antara 700 dan 1500. (b) Kita telah menemukan bahwa rentang 700 sampai 1500 mencakup sekitar 95% peserta ujian. Para peserta ini terbagi sama banyak oleh pusat distribusi, yaitu 1100, sehingga $\frac{95\%}{2} = 47.5\%$ dari seluruh peserta ujian memperoleh skor antara 1100 dan 1500.

Latihan

4.1 Luas di bawah kurva, Bagian I. Berapa persen dari distribusi normal baku $N(\mu = 0, \sigma = 1)$ yang terdapat pada setiap daerah berikut? Pastikan Anda menggambar grafik.

- (a) $Z < -1.35$ (b) $Z > 1.48$ (c) $-0.4 < Z < 1.5$ (d) $|Z| > 2$

4.2 Luas di bawah kurva, Bagian II. Berapa persen dari distribusi normal baku $N(\mu = 0, \sigma = 1)$ yang terdapat pada setiap daerah berikut? Pastikan Anda menggambar grafik.

- (a) $Z > -1.13$ (b) $Z < 0.18$ (c) $Z > 8$ (d) $|Z| < 0.5$

4.3 Skor GRE, Bagian I. Sophia mengikuti Graduate Record Examination (GRE) dan memperoleh skor 160 pada bagian Penalaran Verbal (Verbal Reasoning, VR) serta 157 pada bagian Penalaran Kuantitatif (Quantitative Reasoning, QR). Rata-rata skor bagian Penalaran Verbal untuk seluruh peserta ujian adalah 151 dengan simpangan baku 7, sedangkan rata-rata skor Penalaran Kuantitatif adalah 153 dengan simpangan baku 7.67. Anggap kedua distribusi hampir normal.

- Tuliskan notasi ringkas untuk kedua distribusi normal ini.
- Berapa skor-Z Sophia pada bagian Penalaran Verbal? Pada bagian Penalaran Kuantitatif? Gambarlah kurva distribusi normal baku dan tandai kedua skor-Z tersebut.
- Apa yang ditunjukkan oleh kedua skor-Z ini?
- Dibandingkan dengan peserta lain, pada bagian mana ia berprestasi lebih baik?
- Carilah persentil skornya untuk kedua bagian ujian.
- Berapa persen peserta ujian yang memperoleh skor lebih tinggi daripada Sophia pada bagian Penalaran Verbal? Pada bagian Penalaran Kuantitatif?
- Jelaskan mengapa hanya membandingkan skor mentah dari kedua bagian dapat menghasilkan kesimpulan yang keliru tentang bagian mana yang dikerjakan seorang peserta dengan lebih baik.
- Jika distribusi skor pada kedua bagian ujian tidak hampir normal, apakah jawaban Anda untuk bagian (b)–(f) akan berubah? Jelaskan alasan Anda.

4.4 Waktu triathlon, Bagian I. Dalam triathlon, peserta biasanya ditempatkan dalam kelompok usia dan gender. Leo dan Mary, yang berteman, sama-sama menyelesaikan Hermosa Beach Triathlon. Leo bertanding dalam kelompok *Laki-laki, Usia 30–34*, sedangkan Mary bertanding dalam kelompok *Perempuan, Usia 25–29*. Leo menyelesaikan perlombaan dalam 1:22:28 (4948 detik), sedangkan Mary menyelesaikannya dalam 1:31:53 (5513 detik). Leo jelas finis lebih cepat, tetapi mereka ingin tahu bagaimana hasil mereka jika dibandingkan dengan kelompok masing-masing. Dapatkah Anda membantu mereka? Berikut beberapa informasi tentang kinerja kedua kelompok:

- Waktu finis kelompok *Laki-laki, Usia 30–34* memiliki rata-rata 4313 detik dengan simpangan baku 583 detik.
- Waktu finis kelompok *Perempuan, Usia 25–29* memiliki rata-rata 5261 detik dengan simpangan baku 807 detik.
- Distribusi waktu finis kedua kelompok mendekati distribusi normal.

Ingat: kinerja yang lebih baik bersesuaian dengan waktu finis yang lebih cepat.

- Tuliskan notasi ringkas untuk kedua distribusi normal ini.
- Berapa skor-Z waktu finis Leo dan Mary? Apa yang ditunjukkan oleh skor-Z tersebut?
- Siapa yang memiliki peringkat lebih baik dalam kelompoknya, Leo atau Mary? Jelaskan alasan Anda.
- Berapa persen peserta triathlon dalam kelompok Leo yang finis lebih lambat daripada Leo?
- Berapa persen peserta triathlon dalam kelompok Mary yang finis lebih lambat daripada Mary?
- Jika distribusi waktu finis tidak hampir normal, apakah jawaban Anda untuk bagian (b)–(e) akan berubah? Jelaskan alasan Anda.

4.5 Skor GRE, Bagian II. Pada Latihan 4.3, kita melihat dua distribusi skor GRE: $N(\mu = 151, \sigma = 7)$ untuk bagian verbal dan $N(\mu = 153, \sigma = 7.67)$ untuk bagian kuantitatif. Gunakan informasi ini untuk menghitung setiap nilai berikut:

- Skor seorang peserta yang berada pada persentil ke-80 di bagian Penalaran Kuantitatif.
- Skor seorang peserta yang memperoleh hasil lebih buruk daripada 70% peserta ujian di bagian Penalaran Verbal.

4.6 Waktu triatlon, Bagian II. Pada Latihan 4.4, kita melihat dua distribusi waktu triatlon: $N(\mu = 4313, \sigma = 583)$ untuk *Laki-laki, Usia 30–34* dan $N(\mu = 5261, \sigma = 807)$ untuk kelompok *Perempuan, Usia 25–29*. Waktu dinyatakan dalam detik. Gunakan informasi ini untuk menghitung setiap nilai berikut:

- (a) Batas waktu bagi 5% atlet tercepat dalam kelompok laki-laki, yakni atlet dengan 5% waktu penyelesaian tersingkat.
- (b) Batas waktu bagi 10% atlet paling lambat dalam kelompok perempuan.

4.7 Cuaca LA, Bagian I. Rata-rata suhu maksimum harian pada bulan Juni di LA adalah 77°F dengan simpangan baku 5°F . Anggap suhu pada bulan Juni mendekati distribusi normal.

- (a) Berapa peluang mengamati suhu 83°F atau lebih tinggi di LA pada suatu hari yang dipilih secara acak pada bulan Juni?
- (b) Seberapa rendah suhu pada 10% hari terdingin (hari dengan suhu maksimum terendah) selama bulan Juni di LA?

4.8 CAPM. Capital Asset Pricing Model (CAPM) adalah model keuangan yang mengasumsikan imbal hasil suatu portofolio berdistribusi normal. Misalkan suatu portofolio memiliki imbal hasil tahunan rata-rata 14.7% (yakni keuntungan rata-rata 14.7%) dengan simpangan baku 33%. Imbal hasil 0% berarti nilai portofolio tidak berubah, imbal hasil negatif berarti portofolio merugi, dan imbal hasil positif berarti portofolio memperoleh keuntungan.

- (a) Dalam berapa persen tahun portofolio ini merugi, yakni memiliki imbal hasil kurang dari 0%?
- (b) Berapa batas untuk 15% imbal hasil tahunan tertinggi pada portofolio ini?

4.9 Cuaca LA, Bagian II. Latihan 4.7 menyatakan bahwa rata-rata suhu maksimum harian pada bulan Juni di LA adalah 77°F dengan simpangan baku 5°F , dan suhu tersebut dapat diasumsikan mengikuti distribusi normal. Kita menggunakan persamaan berikut untuk mengubah $^\circ\text{F}$ (Fahrenheit) menjadi $^\circ\text{C}$ (Celsius):

$$C = (F - 32) \times \frac{5}{9}.$$

- (a) Tuliskan model peluang untuk distribusi suhu dalam $^\circ\text{C}$ pada bulan Juni di LA.
- (b) Berapa peluang mengamati suhu 28°C (yang kira-kira bersesuaian dengan 83°F) atau lebih tinggi pada bulan Juni di LA? Hitung menggunakan model $^\circ\text{C}$ dari bagian (a).
- (c) Apakah Anda memperoleh jawaban yang sama atau berbeda pada bagian (b) soal ini dan bagian (a) Latihan 4.7? Apakah Anda terkejut? Jelaskan.
- (d) Perkirakan IQR suhu (dalam $^\circ\text{C}$) pada bulan Juni di LA.

4.10 Cari simpangan baku. Kadar kolesterol perempuan berusia 20 sampai 34 tahun mengikuti distribusi yang mendekati normal dengan rata-rata 185 miligram per desiliter (mg/dl). Perempuan dengan kadar kolesterol di atas 220 mg/dl dianggap memiliki kolesterol tinggi, dan sekitar 18.5% perempuan termasuk dalam kategori ini. Berapa simpangan baku distribusi kadar kolesterol perempuan berusia 20 sampai 34 tahun?

4.2 Distribusi geometrik

Berapa kali, menurut perkiraan kita, sebuah koin perlu dilempar sampai muncul sisi **kepala**? Atau berapa kali sebuah dadu perlu dilempar sampai kita memperoleh 1? Pertanyaan-pertanyaan ini dapat dijawab dengan distribusi geometrik. Pertama-tama, kita memformalkan setiap percobaan—seperti satu lemparan koin atau dadu—dengan distribusi Bernoulli. Kemudian, kita menggabungkannya dengan perangkat peluang dari Bab 3 untuk membangun distribusi geometrik.

4.2.1 Distribusi Bernoulli

Banyak program asuransi kesehatan di Amerika Serikat menerapkan risiko sendiri (*deductible*). Dalam skema ini, tertanggung menanggung biaya hingga batas risiko sendiri; biaya di atas batas itu kemudian dibagi antara tertanggung dan perusahaan asuransi selama sisa tahun berjalan.

Misalkan sebuah perusahaan asuransi kesehatan mendapati bahwa 70% orang yang diasuransikannya tetap berada di bawah batas risiko sendiri pada suatu tahun. Setiap orang tersebut dapat dipandang sebagai satu **percobaan**. Kita memberi label **sukses** kepada seseorang jika biaya layanan kesehatannya tidak melampaui batas risiko sendiri. Kita memberi label **gagal** jika biaya orang tersebut melampaui batas risiko sendiri pada tahun itu. Karena 70% orang tidak mencapai batas risiko sendiri, kita menyatakan **peluang sukses** sebagai $p = 0.7$. Peluang gagal kadang-kadang dinyatakan dengan $q = 1 - p$, yang bernilai 0.3 pada contoh asuransi ini.

Jika sebuah percobaan hanya memiliki dua hasil yang mungkin, yang sering diberi label **sukses** atau **gagal**, percobaan itu disebut **variabel acak Bernoulli**. Kita memilih untuk memberi label “sukses” kepada orang yang tidak mencapai batas risiko sendiri dan “gagal” kepada semua orang lainnya. Namun, kedua label tersebut dapat saja kita pertukarkan. Kerangka matematis yang akan kita bangun tidak bergantung pada hasil mana yang diberi label sukses dan mana yang diberi label gagal, asalkan kita konsisten.

Variabel acak Bernoulli sering dinyatakan dengan 1 untuk sukses dan 0 untuk gagal. Selain memudahkan pemasukan data, pelabelan ini juga praktis secara matematis. Misalkan kita mengamati sepuluh percobaan:

1 1 1 0 1 0 0 1 1 0

Maka **proporsi sampel**, $\hat{p}$, adalah rata-rata sampel pengamatan-pengamatan tersebut:

$$\hat{p} = \frac{\# \text{ sukses}}{\# \text{ percobaan}} = \frac{1 + 1 + 1 + 0 + 1 + 0 + 0 + 1 + 1 + 0}{10} = 0.6$$

Kajian matematis terhadap variabel acak Bernoulli ini masih dapat diperluas. Karena 0 dan 1 merupakan hasil numerik, kita dapat mendefinisikan rata-rata dan simpangan baku variabel acak Bernoulli. (Lihat Latihan 4.15 dan 4.16.)

VARIABEL ACAK BERNOULLI

Jika X adalah variabel acak yang bernilai 1 dengan peluang sukses p dan bernilai 0 dengan peluang $1 - p$, maka X adalah variabel acak Bernoulli dengan rata-rata dan simpangan baku

$$\mu = p \qquad \sigma = \sqrt{p(1 - p)}$$

Secara umum, variabel acak Bernoulli berguna jika dipandang sebagai proses acak yang hanya memiliki dua hasil: sukses atau gagal. Selanjutnya, kita membangun kerangka matematis menggunakan label numerik 1 dan 0, masing-masing untuk sukses dan gagal.

4.2.2 Distribusi geometrik

Distribusi geometrik digunakan untuk menggambarkan berapa banyak percobaan yang diperlukan sampai suatu sukses diamati. Mari kita awali dengan sebuah contoh.

CONTOH 4.22

Misalkan kita bekerja di perusahaan asuransi dan memerlukan satu kasus orang yang tidak melampaui batas risiko sendiri sebagai studi kasus. Jika peluang seseorang tidak melampaui batas risiko sendiri adalah 0.7 dan kita memilih orang secara acak, berapa peluang bahwa orang pertama tidak melampaui batas risiko sendiri, yakni menjadi sukses? Bagaimana dengan orang kedua? Orang ketiga? Bagaimana jika kita memilih $n - 1$ kasus sebelum menemukan sukses pertama, yakni sukses pertama ditemukan pada orang ke- n ? (Jika sukses pertama ditemukan pada orang kelima, kita menyatakan $n = 5$.)

E

Peluang bahwa kita berhenti setelah orang pertama sama dengan peluang orang pertama tidak mencapai batas risiko sendiri: 0.7. Peluang bahwa orang kedua merupakan orang pertama yang tidak mencapai batas risiko sendiri adalah


$$\begin{aligned} P(\text{orang kedua menjadi sukses pertama}) \\ = P(\text{orang pertama gagal, orang kedua sukses}) = (0.3)(0.7) = 0.21 \end{aligned}$$

Demikian pula, peluang bahwa sukses pertama ditemukan pada kasus ketiga adalah $(0.3)(0.3)(0.7) = 0.063$.

Jika sukses pertama ditemukan pada orang ke- n , terdapat $n - 1$ kegagalan yang diikuti 1 sukses. Urutan ini bersesuaian dengan peluang $(0.3)^{n-1}(0.7)$. Nilai ini sama dengan $(1 - 0.7)^{n-1}(0.7)$.

Contoh 4.22 mengilustrasikan **distribusi geometrik**, yang menggambarkan waktu tunggu hingga sukses untuk variabel acak Bernoulli yang **saling independen dan berdistribusi identik (iid)**. Dalam kasus ini, aspek *independensi* hanya berarti bahwa setiap orang dalam contoh tidak saling memengaruhi, sedangkan *identik* berarti bahwa masing-masing memiliki peluang sukses yang sama.

Distribusi geometrik dari Contoh 4.22 ditampilkan pada Gambar 4.8. Secara umum, peluang-peluang pada distribusi geometrik menurun dengan cepat **secara eksponensial**.



Gambar 4.8: Distribusi geometrik ketika peluang sukses adalah $p = 0.7$.

Teks ini tidak menurunkan rumus rata-rata (nilai harapan) banyaknya percobaan yang diperlukan untuk menemukan sukses pertama, ataupun rumus simpangan baku dan varians distribusi ini. Namun, kita menyajikan rumus umum untuk ketiganya.

DISTRIBUSI GEOMETRIK

Jika peluang sukses dalam satu percobaan adalah p dan peluang gagal adalah $1 - p$, peluang bahwa sukses pertama ditemukan pada percobaan ke- n diberikan oleh

$$(1 - p)^{n-1}p$$

Rata-rata (yakni nilai harapan), varians, dan simpangan baku waktu tunggu ini diberikan oleh

$$\mu = \frac{1}{p} \qquad \sigma^2 = \frac{1-p}{p^2} \qquad \sigma = \sqrt{\frac{1-p}{p^2}}$$

Bukan kebetulan bahwa kita menggunakan simbol μ untuk rata-rata sekaligus nilai harapan. Rata-rata dan nilai harapan adalah hal yang sama.

Dalam distribusi geometrik, rata-rata banyaknya percobaan yang diperlukan untuk memperoleh sukses adalah $1/p$. Hasil matematis ini sesuai dengan intuisi. Jika peluang sukses tinggi (misalnya 0.8), biasanya kita tidak menunggu lama untuk memperoleh sukses: rata-rata $1/0.8 = 1.25$ percobaan. Jika peluang sukses rendah (misalnya 0.1), kita memperkirakan perlu mengamati banyak percobaan sebelum melihat sukses: $1/0.1 = 10$ percobaan.

LATIHAN TERBIMBING 4.23

G

Peluang bahwa suatu kasus tidak melampaui batas risiko sendiri adalah 0.7. Jika kita memeriksa kasus satu demi satu sampai menemukan seseorang yang tidak mencapai batas risiko sendiri, berapa banyak kasus yang diperkirakan perlu kita periksa?¹⁷

CONTOH 4.24

Berapa peluang bahwa kita menemukan sukses pertama di antara tiga kasus pertama?

Sukses pertama dapat ditemukan pada kasus pertama ($n = 1$), kedua ($n = 2$), atau ketiga ($n = 3$). Ketiganya merupakan hasil yang saling lepas. Karena orang-orang dalam sampel dipilih secara acak dari populasi besar, pemilihan mereka saling independen. Kita menghitung peluang setiap kasus lalu menjumlahkan hasil-hasil yang terpisah tersebut:

E

$$\begin{aligned} P(n = 1, 2, \text{ atau } 3) &= P(n = 1) + P(n = 2) + P(n = 3) \\ &= (0.3)^{1-1}(0.7) + (0.3)^{2-1}(0.7) + (0.3)^{3-1}(0.7) \\ &= 0.973 \end{aligned}$$

Peluang bahwa kita menemukan kasus yang sukses dalam tiga kasus pertama adalah 0.973.

LATIHAN TERBIMBING 4.25

G

Tentukan cara yang lebih cerdas untuk menyelesaikan Contoh 4.24. Tunjukkan bahwa Anda memperoleh hasil yang sama.¹⁸

¹⁷Kita memperkirakan perlu memeriksa sekitar $1/0.7 \approx 1.43$ orang untuk menemukan sukses pertama.

¹⁸Pertama, cari peluang komplementnya: $P(\text{tidak ada sukses dalam 3 percobaan pertama}) = 0.3^3 = 0.027$. Selanjutnya, hitung satu dikurangi peluang tersebut: $1 - P(\text{tidak ada sukses dalam 3 percobaan}) = 1 - 0.027 = 0.973$.

CONTOH 4.26

Misalkan sebuah perusahaan asuransi mobil telah menentukan bahwa 88% pengemudinya tidak melampaui batas risiko sendiri pada suatu tahun. Jika seorang pegawai perusahaan memilih berkas pengemudi secara acak sampai menemukan satu pengemudi yang tidak melampaui batas risiko sendiri, berapa banyak berkas pengemudi yang diperkirakan perlu diperiksa pegawai tersebut? Berapa simpangan baku banyaknya berkas pengemudi yang harus dipilih?

E

Dalam contoh ini, sukses kembali didefinisikan sebagai keadaan ketika seseorang tidak melampaui batas risiko sendiri pada polisnya, yang memiliki peluang $p = 0.88$. Banyaknya orang yang diperkirakan perlu diperiksa adalah $1/p = 1/0.88 = 1.14$, dan simpangan bakunya adalah $\sqrt{(1-p)/p^2} = 0.39$.

LATIHAN TERBIMBING 4.27

G

Berdasarkan hasil dari Contoh 4.26, yaitu $\mu = 1.14$ dan $\sigma = 0.39$, apakah model normal tepat digunakan untuk mencari proporsi eksperimen yang berakhir dalam 3 percobaan atau kurang?¹⁹

Asumsi independensi sangat penting agar distribusi geometrik dapat menggambarkan suatu skenario secara akurat. Secara matematis, ketika membangun peluang sukses pada percobaan ke- n , kita harus menggunakan Aturan Perkalian untuk proses yang saling independen. Tidak mudah menggeneralisasi model geometrik untuk percobaan-percobaan yang saling dependen.

¹⁹Tidak. Distribusi geometrik selalu menceng kanan dan tidak pernah dapat didekati dengan baik oleh model normal.

Latihan

4.11 Apakah ini Bernoulli? Tentukan apakah setiap percobaan dapat dianggap sebagai percobaan Bernoulli yang saling independen dalam situasi-situasi berikut.

- (a) Kartu-kartu yang dibagikan dalam satu tangan permainan poker.
- (b) Hasil setiap lemparan dadu.

4.12 Dengan dan tanpa pengembalian. Dalam situasi-situasi berikut, asumsikan bahwa separuh populasi yang disebutkan adalah laki-laki dan separuh lainnya perempuan.

- (a) Misalkan Anda mengambil sampel dari sebuah ruangan yang berisi 10 orang. Berapa peluang terpilihnya dua perempuan berturut-turut jika pengambilan dilakukan dengan pengembalian? Berapa peluangnya jika pengambilan dilakukan tanpa pengembalian?
- (b) Sekarang, misalkan Anda mengambil sampel dari sebuah stadion yang berisi 10.000 orang. Berapa peluang terpilihnya dua perempuan berturut-turut jika pengambilan dilakukan dengan pengembalian? Berapa peluangnya jika pengambilan dilakukan tanpa pengembalian?
- (c) Kita sering memperlakukan orang-orang yang diambil sebagai sampel dari populasi besar sebagai saling independen. Berdasarkan temuan Anda pada bagian (a) dan (b), jelaskan apakah asumsi ini masuk akal.

4.13 Warna mata, Bagian I. Sepasang suami istri sama-sama bermata cokelat, tetapi membawa gen yang memungkinkan anak mereka bermata cokelat (peluang 0.75), biru (0.125), atau hijau (0.125).

- (a) Berapa peluang bahwa anak pertama mereka yang bermata biru adalah anak ketiga? Asumsikan bahwa warna mata setiap anak saling independen.
- (b) Secara rata-rata, berapa banyak anak yang akan dimiliki pasangan tersebut hingga memperoleh anak bermata biru pertama? Berapa simpangan baku banyaknya anak yang diperkirakan akan mereka miliki hingga anak bermata biru pertama lahir?

4.14 Tingkat cacat. Sebuah mesin yang memproduksi transistor jenis khusus (salah satu komponen komputer) memiliki tingkat cacat 2%. Produksi dianggap sebagai proses acak dan setiap transistor saling independen.

- (a) Berapa peluang bahwa transistor ke-10 yang diproduksi adalah transistor cacat pertama?
- (b) Berapa peluang bahwa mesin tersebut tidak menghasilkan transistor cacat dalam satu kelompok produksi yang terdiri atas 100 transistor?
- (c) Secara rata-rata, berapa banyak transistor yang diperkirakan akan diproduksi hingga muncul transistor cacat pertama? Berapa simpangan bakunya?
- (d) Mesin lain yang juga memproduksi transistor memiliki tingkat cacat 5%, dan setiap transistor diproduksi secara independen dari yang lain. Secara rata-rata, berapa banyak transistor yang diperkirakan akan diproduksi mesin ini hingga muncul transistor cacat pertama? Berapa simpangan bakunya?
- (e) Berdasarkan jawaban Anda pada bagian (c) dan (d), bagaimana peningkatan peluang suatu peristiwa memengaruhi rata-rata dan simpangan baku waktu tunggu hingga sukses?

4.15 Bernoulli, rata-rata. Gunakan aturan peluang dari Bagian 3.4 untuk menurunkan rata-rata variabel acak Bernoulli, yaitu variabel acak X yang bernilai 1 dengan peluang p dan bernilai 0 dengan peluang $1 - p$. Dengan kata lain, hitung nilai harapan variabel acak Bernoulli umum.

4.16 Bernoulli, simpangan baku. Gunakan aturan peluang dari Bagian 3.4 untuk menurunkan simpangan baku variabel acak Bernoulli, yaitu variabel acak X yang bernilai 1 dengan peluang p dan bernilai 0 dengan peluang $1 - p$. Dengan kata lain, hitung akar kuadrat varians variabel acak Bernoulli umum.

4.3 Distribusi binomial

Distribusi binomial digunakan untuk menggambarkan banyaknya sukses ketika jumlah percobaannya tetap. Distribusi ini berbeda dari distribusi geometrik, yang menggambarkan banyaknya percobaan yang harus kita tunggu sebelum mengamati suatu sukses.

4.3.1 Distribusi binomial

Mari kita bayangkan lagi bahwa kita berada di perusahaan asuransi, tempat 70% tertanggung tidak melampaui batas risiko sendiri.

CONTOH 4.28

Misalkan perusahaan asuransi mempertimbangkan sampel acak berisi empat orang yang diasuransikannya. Berapa peluang bahwa tepat satu orang melampaui batas risiko sendiri, sedangkan tiga orang lainnya tidak? Agar mudah, kita namai keempat orang tersebut Ariana (A), Brittany (B), Carlton (C), dan Damian (D).

Mari kita tinjau satu skenario ketika satu orang melampaui batas risiko sendiri:

$$\begin{aligned}
 &P(A = \text{melampaui}, B = \text{tidak}, C = \text{tidak}, D = \text{tidak}) \\
 &= P(A = \text{melampaui}) P(B = \text{tidak}) P(C = \text{tidak}) P(D = \text{tidak}) \\
 &= (0.3)(0.7)(0.7)(0.7) \\
 &= (0.7)^3(0.3)^1 \\
 &= 0.103
 \end{aligned}$$

Namun, terdapat tiga skenario lain: Brittany, Carlton, atau Damian dapat menjadi satu-satunya orang yang melampaui batas risiko sendiri. Pada masing-masing kasus tersebut, peluangnya kembali sebesar $(0.7)^3(0.3)^1$. Keempat skenario ini mencakup semua kemungkinan cara tepat satu dari keempat orang tersebut melampaui batas risiko sendiri. Karena itu, peluang totalnya adalah $4 \times (0.7)^3(0.3)^1 = 0.412$.

LATIHAN TERBIMBING 4.29

Verifikasikan bahwa skenario ketika Brittany menjadi satu-satunya orang yang melampaui batas risiko sendiri memiliki peluang $(0.7)^3(0.3)^1$.²⁰

Skenario yang diuraikan pada Contoh 4.28 merupakan contoh eksperimen binomial. **Distribusi binomial** menggambarkan peluang untuk memperoleh tepat k sukses dalam n percobaan Bernoulli yang saling independen dengan peluang sukses p (pada Contoh 4.28, $n = 4$, $k = 3$, dan $p = 0.7$). Kita hendak menentukan peluang-peluang yang berkaitan dengan distribusi binomial secara lebih umum. Dengan kata lain, kita menginginkan rumus yang menggunakan n , k , dan p untuk memperoleh peluang tersebut. Untuk itu, kita menelaah kembali setiap bagian dari Contoh 4.28.

Terdapat empat orang yang masing-masing dapat menjadi satu-satunya orang yang melampaui batas risiko sendiri, dan keempat skenario tersebut memiliki peluang yang sama. Dengan demikian, peluang akhirnya dapat kita nyatakan sebagai

$$[\# \text{ skenario}] \times P(\text{satu skenario})$$

Komponen pertama persamaan ini adalah banyaknya cara untuk menempatkan $k = 3$ sukses di antara $n = 4$ percobaan. Komponen kedua adalah peluang salah satu dari keempat skenario yang berpeluang sama tersebut.

²⁰ $P(A = \text{tidak}, B = \text{melampaui}, C = \text{tidak}, D = \text{tidak}) = (0.7)(0.3)(0.7)(0.7) = (0.7)^3(0.3)^1$.

Tinjau P (satu skenario) dalam kasus umum ketika terdapat k sukses dan $n-k$ kegagalan dalam n percobaan. Pada setiap skenario seperti itu, kita menerapkan Aturan Perkalian untuk peristiwa yang saling independen:

$$p^k(1-p)^{n-k}$$

Inilah rumus umum kita untuk P (satu skenario).

Selanjutnya, kita memperkenalkan rumus umum untuk banyaknya cara memilih k sukses dalam n percobaan, yaitu menempatkan k sukses dan $n-k$ kegagalan:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Besaran $\binom{n}{k}$ dibaca **n pilih k**.²¹ Notasi tanda seru ($k!$) menyatakan ekspresi **faktorial**.

$$0! = 1$$

$$1! = 1$$

$$2! = 2 \times 1 = 2$$

$$3! = 3 \times 2 \times 1 = 6$$

$$4! = 4 \times 3 \times 2 \times 1 = 24$$

$$\vdots$$

$$n! = n \times (n-1) \times \dots \times 3 \times 2 \times 1$$

Dengan rumus tersebut, kita dapat menghitung banyaknya cara memilih $k = 3$ sukses dalam $n = 4$ percobaan:

$$\binom{4}{3} = \frac{4!}{3!(4-3)!} = \frac{4!}{3!1!} = \frac{4 \times 3 \times 2 \times 1}{(3 \times 2 \times 1)(1)} = 4$$

Hasil ini tepat sama dengan yang kita peroleh ketika mempertimbangkan setiap skenario yang mungkin secara saksama pada Contoh 4.28.

Mengganti banyaknya skenario dengan n pilih k dan peluang satu skenario dengan $p^k(1-p)^{n-k}$ menghasilkan rumus umum binomial.

DISTRIBUSI BINOMIAL

Misalkan peluang bahwa satu percobaan menghasilkan sukses adalah p . Maka peluang untuk mengamati tepat k sukses dalam n percobaan yang saling independen diberikan oleh

$$\binom{n}{k} p^k (1-p)^{n-k} = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$$

Rata-rata, varians, dan simpangan baku banyaknya sukses yang diamati adalah

$$\mu = np \qquad \sigma^2 = np(1-p) \qquad \sigma = \sqrt{np(1-p)}$$

APAKAH MODELNYA BINOMIAL? EMPAT SYARAT YANG PERLU DIPERIKSA.

- (1) Percobaan-percobaannya saling independen.
- (2) Jumlah percobaan, n , tetap.
- (3) Hasil setiap percobaan dapat diklasifikasikan sebagai *sukses* atau *gagal*.
- (4) Peluang sukses, p , sama untuk setiap percobaan.

²¹Notasi lain untuk n pilih k mencakup ${}_nC_k$, C_n^k , dan $C(n, k)$.

CONTOH 4.30

Berapa peluang bahwa 3 dari 8 orang yang dipilih secara acak akan melampaui batas risiko sendiri, atau dengan kata lain bahwa 5 dari 8 orang tidak akan melampauinya? Ingat bahwa 70% orang tidak melampaui batas risiko sendiri.

Kita hendak menerapkan model binomial, sehingga kita memeriksa syarat-syaratnya. Jumlah percobaan tetap ($n = 8$) (syarat 2), dan setiap hasil percobaan dapat diklasifikasikan sebagai sukses atau gagal (syarat 3). Karena sampelnya acak, percobaan-percobaan tersebut saling independen (syarat 1), dan peluang sukses sama untuk setiap percobaan (syarat 4).

Pada hasil yang menjadi perhatian, terdapat $k = 5$ sukses dalam $n = 8$ percobaan (ingat bahwa sukses adalah seseorang yang *tidak* melampaui batas risiko sendiri), dan peluang suksesnya adalah $p = 0.7$. Jadi, peluang bahwa 5 dari 8 orang tidak melampaui batas risiko sendiri dan 3 orang melampauinya diberikan oleh

$$\begin{aligned}\binom{8}{5}(0.7)^5(1-0.7)^{8-5} &= \frac{8!}{5!(8-5)!}(0.7)^5(1-0.7)^{8-5} \\ &= \frac{8!}{5!3!}(0.7)^5(0.3)^3\end{aligned}$$

Untuk menangani bagian faktorial:

$$\frac{8!}{5!3!} = \frac{8 \times 7 \times 6 \times 5 \times 4 \times 3 \times 2 \times 1}{(5 \times 4 \times 3 \times 2 \times 1)(3 \times 2 \times 1)} = \frac{8 \times 7 \times 6}{3 \times 2 \times 1} = 56$$

Dengan menggunakan $(0.7)^5(0.3)^3 \approx 0.00454$, peluang akhirnya sekitar $56 \times 0.00454 \approx 0.254$.

MENGHITUNG PELUANG BINOMIAL

Langkah pertama ketika menggunakan model binomial adalah memeriksa bahwa model tersebut tepat. Langkah kedua adalah mengidentifikasi n , p , dan k . Pada tahap terakhir, gunakan perangkat lunak atau rumus untuk menentukan peluang, lalu tafsirkan hasilnya.

Jika Anda harus melakukan perhitungan dengan tangan, sering kali berguna untuk mencoret sebanyak mungkin faktor yang sama pada pembilang dan penyebut koefisien binomial.

LATIHAN TERBIMBING 4.31

Jika kita mengambil sampel acak berisi 40 berkas kasus dari perusahaan asuransi yang dibahas sebelumnya, berapa banyak kasus yang diperkirakan tidak melampaui batas risiko sendiri dalam suatu tahun? Berapa simpangan baku banyaknya kasus yang tidak melampaui batas risiko sendiri?²²

LATIHAN TERBIMBING 4.32

Peluang bahwa seorang perokok yang dipilih secara acak akan mengalami gangguan paru-paru berat sepanjang hidupnya adalah sekitar 0.3. Jika Anda memiliki 4 teman yang merokok, apakah syarat-syarat model binomial terpenuhi?²³

²²Kita diminta menentukan banyaknya kasus yang diharapkan (rata-rata) dan simpangan bakunya. Keduanya dapat dihitung langsung dari rumus: $\mu = np = 40 \times 0.7 = 28$ dan $\sigma = \sqrt{np(1-p)} = \sqrt{40 \times 0.7 \times 0.3} = 2.9$. Karena secara sangat kasar 95% pengamatan berada dalam jarak 2 simpangan baku dari rata-rata (lihat Bagian 2.1.4), dalam sampel ini mungkin akan kita amati setidaknya 22 tetapi kurang dari 34 orang yang tidak melampaui batas risiko sendiri.

²³Salah satu jawaban yang mungkin: jika teman-teman tersebut saling mengenal, asumsi independensi mungkin tidak terpenuhi. Sebagai contoh, orang-orang yang saling mengenal mungkin memiliki kebiasaan merokok yang serupa, atau mereka mungkin bersepakat untuk berhenti merokok bersama-sama.

LATIHAN TERBIMBING 4.33

Misalkan keempat teman tersebut tidak saling mengenal dan dapat kita perlakukan seolah-olah mereka merupakan sampel acak dari populasi. Apakah model binomial tepat? Berapa peluang bahwa²⁴

- (a) Tidak seorang pun mengalami gangguan paru-paru berat?
- (b) Satu orang mengalami gangguan paru-paru berat?
- (c) Tidak lebih dari satu orang mengalami gangguan paru-paru berat?

LATIHAN TERBIMBING 4.34

Berapa peluang bahwa sekurang-kurangnya 2 dari 4 teman Anda yang merokok akan mengalami gangguan paru-paru berat sepanjang hidup mereka?²⁵

LATIHAN TERBIMBING 4.35

Misalkan Anda memiliki 7 teman yang merokok dan mereka dapat diperlakukan sebagai sampel acak perokok.²⁶

- (a) Berapa banyak di antara mereka yang diperkirakan akan mengalami gangguan paru-paru berat, yaitu berapa rata-ratanya?
- (b) Berapa peluang bahwa paling banyak 2 dari 7 teman Anda akan mengalami gangguan paru-paru berat?

Selanjutnya, kita meninjau suku pertama dalam peluang binomial, yaitu n pilih k , untuk beberapa skenario khusus.

LATIHAN TERBIMBING 4.36

Mengapa $\binom{n}{0} = 1$ dan $\binom{n}{n} = 1$ berlaku untuk sebarang bilangan n ?²⁷

LATIHAN TERBIMBING 4.37

Ada berapa cara untuk menempatkan satu sukses dan $n - 1$ kegagalan dalam n percobaan? Ada berapa cara untuk menempatkan $n - 1$ sukses dan satu kegagalan dalam n percobaan?²⁸

²⁴Untuk memeriksa apakah model binomial tepat, kita harus memverifikasi syarat-syaratnya. (i) Karena kita mengandaikan bahwa teman-teman tersebut dapat diperlakukan sebagai sampel acak, mereka saling independen. (ii) Kita memiliki jumlah percobaan yang tetap ($n = 4$). (iii) Setiap hasil adalah sukses atau gagal. (iv) Peluang sukses sama pada setiap percobaan karena orang-orang tersebut dapat diperlakukan sebagai sampel acak ($p = 0.3$ jika kita menyebut seseorang yang mengalami gangguan paru-paru sebagai “sukses”, sebuah pilihan istilah yang suram). Hitung bagian (a) dan (b) dengan rumus binomial: $P(0) = \binom{4}{0}(0.3)^0(0.7)^4 = 1 \times 1 \times 0.7^4 = 0.2401$, $P(1) = \binom{4}{1}(0.3)^1(0.7)^3 = 0.4116$. Catatan: $0! = 1$. Bagian (c) dapat dihitung sebagai jumlah bagian (a) dan (b): $P(0) + P(1) = 0.2401 + 0.4116 = 0.6517$. Artinya, terdapat peluang sekitar 65% bahwa tidak lebih dari satu di antara keempat teman Anda yang merokok akan mengalami gangguan paru-paru berat.

²⁵Peluang komplementnya (tidak lebih dari satu orang akan mengalami gangguan paru-paru berat) telah dihitung sebagai 0.6517 pada Latihan Terbimbing 4.33. Jadi, kita menghitung satu dikurangi nilai tersebut: 0.3483.

²⁶(a) $\mu = 0.3 \times 7 = 2.1$. (b) $P(0, 1, \text{ atau } 2 \text{ orang mengalami gangguan paru-paru berat}) = P(k = 0) + P(k = 1) + P(k = 2) = 0.6471$.

²⁷Nyatakan ekspresi-ekspresi ini dengan kata-kata. Ada berapa cara berbeda untuk menempatkan 0 sukses dan n kegagalan dalam n percobaan? (1 cara.) Ada berapa cara berbeda untuk menempatkan n sukses dan 0 kegagalan dalam n percobaan? (1 cara.)

²⁸Untuk satu sukses dan $n - 1$ kegagalan, terdapat tepat n posisi berbeda tempat kita dapat menaruh sukses. Jadi, terdapat n cara untuk menempatkan satu sukses dan $n - 1$ kegagalan. Argumen serupa digunakan untuk pertanyaan kedua. Secara matematis, kita menunjukkan hasil-hasil ini dengan memverifikasi kedua persamaan berikut:

$$\binom{n}{1} = n, \quad \binom{n}{n-1} = n$$

4.3.2 Pendekatan normal terhadap distribusi binomial

Rumus binomial merepotkan ketika ukuran sampel (n) besar, terutama ketika kita meninjau suatu rentang pengamatan. Dalam beberapa kasus, kita dapat menggunakan distribusi normal sebagai cara yang lebih mudah dan cepat untuk menaksir peluang binomial.

CONTOH 4.38

Sekitar 15% penduduk Amerika Serikat merokok. Pemerintah daerah meyakini bahwa proporsi perokok di komunitasnya lebih rendah, lalu meminta pelaksanaan survei terhadap 400 orang yang dipilih secara acak. Survei tersebut menemukan bahwa hanya 42 dari 400 peserta yang merokok. Jika proporsi perokok yang sebenarnya di komunitas itu memang 15%, berapa peluang untuk mengamati 42 perokok atau kurang dalam sampel berisi 400 orang?

Verifikasi seperti biasa bahwa keempat syarat model binomial berlaku kita serahkan sebagai latihan.

E

Pertanyaan yang diajukan setara dengan menanyakan peluang untuk mengamati $k = 0, 1, 2, \dots$, atau 42 perokok dalam sampel berisi $n = 400$ orang ketika $p = 0.15$. Kita dapat menghitung 43 peluang yang berbeda ini dan menjumlahkannya untuk memperoleh jawaban:

$$\begin{aligned} P(k = 0 \text{ atau } k = 1 \text{ atau } \dots \text{ atau } k = 42) \\ &= P(k = 0) + P(k = 1) + \dots + P(k = 42) \\ &= 0.0054 \end{aligned}$$

Jika proporsi perokok yang sebenarnya di komunitas adalah $p = 0.15$, peluang untuk mengamati 42 perokok atau kurang dalam sampel berukuran $n = 400$ adalah 0.0054.

Perhitungan dalam Contoh 4.38 membosankan dan panjang. Secara umum, kita sebaiknya menghindari pekerjaan semacam itu jika tersedia metode alternatif yang lebih cepat, lebih mudah, dan tetap akurat. Ingat bahwa menghitung peluang suatu rentang nilai jauh lebih mudah dengan model normal. Kita mungkin bertanya-tanya apakah model normal layak digunakan sebagai pengganti distribusi binomial. Ternyata jawabannya ya, asalkan syarat-syarat tertentu terpenuhi.

LATIHAN TERBIMBING 4.39

G

Di sini kita meninjau model binomial ketika peluang sukses adalah $p = 0.10$. Gambar 4.9 menampilkan empat histogram berongga untuk sampel simulasi dari distribusi binomial dengan empat ukuran sampel berbeda: $n = 10, 30, 100, 300$. Apa yang terjadi pada bentuk distribusi ketika ukuran sampel meningkat? Distribusi apakah yang menyerupai histogram berongga terakhir?²⁹


PENDEKATAN NORMAL TERHADAP DISTRIBUSI BINOMIAL

Distribusi binomial dengan peluang sukses p mendekati distribusi normal apabila ukuran sampel n cukup besar sehingga np dan $n(1 - p)$ masing-masing sekurang-kurangnya 10. Distribusi normal yang digunakan sebagai pendekatan memiliki parameter yang bersesuaian dengan rata-rata dan simpangan baku distribusi binomial:

$$\mu = np \qquad \sigma = \sqrt{np(1 - p)}$$

Pendekatan normal dapat digunakan ketika menghitung peluang bagi rentang yang mencakup banyak kemungkinan banyaknya sukses. Sebagai contoh, kita dapat menerapkan distribusi normal pada latar Contoh 4.38.

²⁹Distribusinya berubah dari distribusi berbentuk balok dan menceng menjadi distribusi yang cukup menyerupai distribusi normal pada histogram berongga terakhir.



Gambar 4.9: Histogram berongga sampel dari model binomial ketika $p = 0.10$. Ukuran sampel keempat grafik tersebut berturut-turut adalah $n = 10, 30, 100$, dan 300.

CONTOH 4.40

Bagaimana kita dapat menggunakan pendekatan normal untuk menaksir peluang mengamati 42 perokok atau kurang dalam sampel berukuran 400, jika proporsi perokok yang sebenarnya adalah $p = 0.15$?

Menunjukkan bahwa model binomial layak digunakan merupakan latihan yang disarankan dalam Contoh 4.38. Kita juga memverifikasi bahwa np dan $n(1 - p)$ masing-masing sekurang-kurangnya 10:

$$np = 400 \times 0.15 = 60$$

$$n(1 - p) = 400 \times 0.85 = 340$$

Setelah syarat-syarat ini diperiksa, kita dapat menggunakan pendekatan normal sebagai pengganti distribusi binomial dengan rata-rata dan simpangan baku dari model binomial:

$$\mu = np = 60$$

$$\sigma = \sqrt{np(1 - p)} = 7.14$$

Kita ingin mencari peluang mengamati 42 perokok atau kurang dengan model ini.

LATIHAN TERBIMBING 4.41

Gunakan model normal $N(\mu = 60, \sigma = 7.14)$ untuk menaksir peluang mengamati 42 perokok atau kurang. Jawaban Anda seharusnya kira-kira sama dengan penyelesaian Contoh 4.38: 0.0054.³⁰

³⁰Hitung skor-Z terlebih dahulu: $Z = \frac{42-60}{7.14} = -2.52$. Luas ekor kiri yang bersesuaian adalah 0.0059.

4.3.3 Pendekatan normal tidak akurat pada interval kecil


Pendekatan normal terhadap distribusi binomial cenderung memberikan taksiran yang buruk ketika menaksir peluang bagi rentang kecil banyaknya sukses, bahkan apabila syarat-syaratnya terpenuhi.

Misalkan kita ingin menghitung peluang mengamati 49, 50, atau 51 perokok di antara 400 orang ketika $p = 0.15$. Dengan sampel sebesar itu, kita mungkin tergoda untuk menerapkan pendekatan normal dan menggunakan rentang 49 hingga 51. Namun, kita akan menemukan bahwa penyelesaian binomial dan pendekatan normal berbeda secara nyata:

Binomial: 0.0649

Normal: 0.0421

Kita dapat mengidentifikasi penyebab perbedaan ini dengan menggunakan Gambar 4.10, yang menampilkan daerah yang mewakili peluang binomial (dibatasi garis) dan pendekatan normal (diarsir). Perhatikan bahwa daerah di bawah distribusi normal lebih sempit sebesar 0.5 satuan pada kedua sisi interval.



Gambar 4.10: Kurva normal dengan daerah antara 49 dan 51 diarsir. Daerah yang dibatasi garis mewakili peluang binomial eksak.

MEMPERBAIKI PENDEKATAN NORMAL TERHADAP DISTRIBUSI BINOMIAL

Pendekatan normal terhadap distribusi binomial pada interval nilai biasanya menjadi lebih baik jika nilai batasnya sedikit diubah. Nilai batas pada ujung bawah daerah yang diarsir perlu dikurangi 0.5, sedangkan nilai batas pada ujung atas perlu ditambah 0.5.

Anjuran untuk menambahkan luas tambahan ketika menerapkan pendekatan normal paling sering berguna saat menelaah suatu rentang pengamatan. Dalam contoh di atas, taksiran distribusi normal yang telah diperbaiki adalah 0.0633, jauh lebih dekat dengan nilai eksak 0.0649. Meskipun koreksi ini juga dapat diterapkan ketika menghitung luas ekor, manfaat koreksi tersebut biasanya hilang karena keseluruhan intervalnya umumnya cukup lebar.

Latihan

4.17 Konsumsi alkohol di bawah umur, Bagian I. Data yang dikumpulkan oleh Substance Abuse and Mental Health Services Administration (SAMHSA) menunjukkan bahwa 69.7% kaum muda berusia 18–20 tahun mengonsumsi minuman beralkohol dalam suatu tahun.³¹

- Misalkan diambil sampel acak berisi sepuluh orang berusia 18–20 tahun. Apakah distribusi binomial tepat digunakan untuk menghitung peluang bahwa tepat enam orang mengonsumsi minuman beralkohol? Jelaskan.
- Hitung peluang bahwa tepat 6 dari 10 orang berusia 18–20 tahun yang dipilih secara acak mengonsumsi minuman beralkohol.
- Berapakah peluang bahwa tepat empat dari sepuluh orang berusia 18–20 tahun *tidak* mengonsumsi minuman beralkohol?
- Berapakah peluang bahwa paling banyak 2 dari 5 orang berusia 18–20 tahun yang dipilih secara acak mengonsumsi minuman beralkohol?
- Berapakah peluang bahwa setidaknya 1 dari 5 orang berusia 18–20 tahun yang dipilih secara acak mengonsumsi minuman beralkohol?

4.18 Cacar air, Bagian I. Boston Children's Hospital memperkirakan bahwa 90% orang Amerika pernah terkena cacar air sebelum mencapai usia dewasa.³²

- Misalkan kita mengambil sampel acak berisi 100 orang dewasa Amerika. Apakah distribusi binomial tepat digunakan untuk menghitung peluang bahwa tepat 97 dari 100 orang dewasa Amerika yang dipilih secara acak pernah terkena cacar air pada masa kanak-kanak? Jelaskan.
- Hitung peluang bahwa tepat 97 dari 100 orang dewasa Amerika yang dipilih secara acak pernah terkena cacar air pada masa kanak-kanak.
- Berapakah peluang bahwa tepat 3 orang dari sampel baru yang berisi 100 orang dewasa Amerika *tidak* pernah terkena cacar air pada masa kanak-kanak?
- Berapakah peluang bahwa setidaknya 1 dari 10 orang dewasa Amerika yang dipilih secara acak pernah terkena cacar air?
- Berapakah peluang bahwa paling banyak 3 dari 10 orang dewasa Amerika yang dipilih secara acak *tidak* pernah terkena cacar air?

4.19 Konsumsi alkohol di bawah umur, Bagian II. Pada Latihan 4.17, kita mengetahui bahwa sekitar 70% orang berusia 18–20 tahun mengonsumsi minuman beralkohol dalam suatu tahun. Sekarang kita mempertimbangkan sampel acak berisi lima puluh orang berusia 18–20 tahun.

- Berapa banyak orang yang diperkirakan telah mengonsumsi minuman beralkohol? Berapakah simpangan bakunya?
- Apakah Anda akan terkejut jika terdapat 45 orang atau lebih yang telah mengonsumsi minuman beralkohol?
- Berapakah peluang bahwa 45 orang atau lebih dalam sampel ini telah mengonsumsi minuman beralkohol? Bagaimana peluang ini berkaitan dengan jawaban Anda pada bagian (b)?

4.20 Cacar air, Bagian II. Pada Latihan 4.18, kita mengetahui bahwa sekitar 90% orang dewasa Amerika pernah terkena cacar air sebelum dewasa. Sekarang kita mempertimbangkan sampel acak berisi 120 orang dewasa Amerika.

- Berapa banyak orang dalam sampel ini yang diperkirakan pernah terkena cacar air pada masa kanak-kanak? Berapakah simpangan bakunya?
- Apakah Anda akan terkejut jika terdapat 105 orang yang pernah terkena cacar air pada masa kanak-kanak?
- Berapakah peluang bahwa 105 orang atau kurang dalam sampel ini pernah terkena cacar air pada masa kanak-kanak? Bagaimana peluang ini berkaitan dengan jawaban Anda pada bagian (b)?

4.21 Permainan dreidel. Dreidel adalah gasing bersisi empat yang masing-masing sisinya memuat salah satu huruf Ibrani *nun*, *gimel*, *hei*, dan *shin*. Pada sekali putaran dreidel, setiap sisi memiliki peluang yang sama untuk muncul. Misalkan Anda memutar dreidel tiga kali. Hitung peluang memperoleh

³¹SAMHSA, Office of Applied Studies, National Survey on Drug Use and Health, 2007 and 2008.

³²Boston Children's Hospital, Chickenpox summary page, referenced April 29, 2021.

- (a) setidaknya satu *nun*?
- (b) tepat 2 *nun*?
- (c) tepat 1 *hei*?
- (d) paling banyak 2 *gimel*?



Foto oleh Staccabees, dipangkas
 (<http://flic.kr/p/7gLZTf>)
 lisensi CC BY 2.0

4.22 Araknofobia. Sebuah jajak pendapat Gallup menemukan bahwa 7% remaja (berusia 13 hingga 17 tahun) mengalami araknofobia dan sangat takut terhadap laba-laba. Di sebuah perkemahan musim panas, terdapat 10 remaja yang tidur di setiap tenda. Asumsikan bahwa 10 remaja ini saling independen.³³

- (a) Hitung peluang bahwa setidaknya satu di antara mereka mengalami araknofobia.
- (b) Hitung peluang bahwa tepat 2 di antara mereka mengalami araknofobia.
- (c) Hitung peluang bahwa paling banyak 1 di antara mereka mengalami araknofobia.
- (d) Jika pembina perkemahan ingin memastikan bahwa tidak lebih dari 1 remaja di setiap tenda takut terhadap laba-laba, apakah menempatkan remaja ke dalam tenda secara acak tampak masuk akal?

4.23 Warna mata, Bagian II. Latihan 4.13 memperkenalkan pasangan suami istri bermata cokelat yang memiliki peluang 0.75 untuk mempunyai anak bermata cokelat, peluang 0.125 untuk mempunyai anak bermata biru, dan peluang 0.125 untuk mempunyai anak bermata hijau.

- (a) Berapakah peluang bahwa anak pertama mereka bermata hijau dan anak kedua tidak bermata hijau?
- (b) Berapakah peluang bahwa tepat satu dari kedua anak mereka bermata hijau?
- (c) Jika mereka mempunyai enam anak, berapakah peluang bahwa tepat dua di antaranya bermata hijau?
- (d) Jika mereka mempunyai enam anak, berapakah peluang bahwa setidaknya satu di antaranya bermata hijau?
- (e) Berapakah peluang bahwa anak pertama yang bermata hijau adalah anak ke-4?
- (f) Apakah hanya 2 dari 6 anak mereka yang bermata cokelat akan dianggap tidak biasa?

³³Gallup Poll, What Frightens America's Youth?, March 29, 2005.

4.24 Anemia sel sabit. Anemia sel sabit adalah kelainan darah genetik yang membuat sel darah merah kehilangan kelenturannya dan mengambil bentuk “sabit” yang abnormal dan kaku, sehingga menimbulkan risiko berbagai komplikasi. Jika kedua orang tua adalah pembawa penyakit ini, seorang anak memiliki peluang 25% untuk menderita penyakit tersebut, peluang 50% untuk menjadi pembawa, dan peluang 25% untuk tidak menderita penyakit tersebut maupun menjadi pembawa. Jika dua orang tua yang merupakan pembawa penyakit ini mempunyai 3 anak, berapakah peluang bahwa

- (a) dua anak akan menderita penyakit tersebut?
- (b) tidak satu pun anak akan menderita penyakit tersebut?
- (c) setidaknya satu anak tidak akan menderita penyakit tersebut maupun menjadi pembawa?
- (d) anak pertama yang menderita penyakit tersebut merupakan anak ke-3?

4.25 Menjelajahi permutasi. Rumus untuk banyaknya cara menyusun n objek adalah $n! = n \times (n - 1) \times \cdots \times 2 \times 1$. Latihan ini memandu Anda menurunkan rumus tersebut untuk beberapa kasus khusus.

Sebuah perusahaan kecil memiliki lima karyawan: Anna, Ben, Carl, Damian, dan Eddy. Perusahaan tersebut memiliki lima tempat parkir yang berderet, tidak ada yang ditetapkan bagi karyawan tertentu, dan setiap hari para karyawan memarkir mobil di tempat yang dipilih secara acak. Dengan kata lain, semua kemungkinan urutan mobil dalam deretan tempat parkir tersebut memiliki peluang yang sama.

- (a) Pada suatu hari, berapakah peluang bahwa para karyawan memarkir mobil dalam urutan abjad?
- (b) Jika urutan abjad memiliki peluang yang sama untuk terjadi seperti setiap urutan lain yang mungkin, ada berapa cara menyusun kelima mobil itu?
- (c) Sekarang, pertimbangkan sampel berisi 8 karyawan. Ada berapa cara yang mungkin untuk mengurutkan mobil milik 8 karyawan tersebut?

4.26 Anak laki-laki. Walaupun peluang memiliki anak laki-laki atau anak perempuan sering dianggap sama, peluang sebenarnya untuk memiliki anak laki-laki sedikit lebih tinggi, yaitu 0.51. Misalkan sepasang suami istri berencana mempunyai 3 anak.

- (a) Gunakan model binomial untuk menghitung peluang bahwa dua di antaranya adalah anak laki-laki.
- (b) Daftarkan semua kemungkinan urutan 3 anak jika 2 di antaranya adalah anak laki-laki. Gunakan aturan penjumlahan untuk hasil-hasil yang saling lepas guna menghitung peluang pada bagian (a), lalu pastikan kedua jawaban sama.
- (c) Untuk peluang bahwa, dari 8 anak mereka, 3 adalah anak laki-laki, jelaskan secara singkat mengapa pendekatan pada bagian (b) lebih merepotkan daripada pendekatan pada bagian (a).

4.4 Distribusi binomial negatif

Distribusi geometrik menggambarkan peluang mengamati sukses pertama pada percobaan ke- n . **distribusi binomial negatif** lebih umum: distribusi ini menggambarkan peluang mengamati sukses ke- k pada percobaan ke- n .

CONTOH 4.42

Setiap hari, seorang pelatih sepak bola Amerika di sekolah menengah memberi tahu penendang andalannya, Brian, bahwa ia boleh pulang setelah berhasil mencetak empat field goal dari jarak 35 yard. Misalkan setiap tendangan memiliki peluang sukses p . Jika p kecil – misalnya mendekati 0.1 – apakah kita memperkirakan Brian akan memerlukan banyak percobaan sebelum berhasil mencetak field goal keempatnya?

Kita menunggu sukses keempat ($k = 4$). Jika peluang sukses (p) kecil, banyaknya percobaan (n) kemungkinan besar akan besar. Artinya, Brian lebih mungkin memerlukan banyak percobaan sebelum memperoleh $k = 4$ sukses. Dengan kata lain, peluang bahwa n kecil juga rendah.

Untuk mengenali kasus binomial negatif, kita memeriksa empat syarat. Tiga syarat pertama sama dengan syarat pada distribusi binomial.

APAKAH KASUSNYA BINOMIAL NEGATIF? EMPAT SYARAT YANG PERLU DIPERIKSA

- (1) Percobaan-percobaan tersebut saling independen.
- (2) Hasil setiap percobaan dapat diklasifikasikan sebagai sukses atau gagal.
- (3) Peluang sukses (p) sama untuk setiap percobaan.
- (4) Percobaan terakhir harus menghasilkan sukses.

LATIHAN TERBIMBING 4.43

Misalkan Brian berlatih dengan sangat tekun dan setiap field goal dari jarak 35 yard yang ditendangnya memiliki peluang sukses $p = 0.8$. Tebaklah berapa banyak percobaan yang ia perlukan sebelum mencetak field goal keempatnya.³⁴

CONTOH 4.44

Dalam latihan kemarin, Brian hanya memerlukan 6 percobaan untuk mencetak field goal keempatnya. Tuliskan setiap urutan tendangan yang mungkin.

Karena Brian memerlukan enam percobaan untuk memperoleh sukses keempat, kita tahu tendangan terakhir pasti sukses. Dengan demikian, tersisa tiga tendangan sukses dan dua tendangan tidak sukses (yang kita sebut gagal) yang menyusun lima percobaan pertama. Pada tabel, S menyatakan sukses dan F menyatakan gagal. Ada sepuluh urutan yang mungkin untuk lima tendangan pertama tersebut, sebagaimana ditampilkan pada Gambar 4.11. Jika Brian memperoleh sukses keempatnya ($k = 4$) pada percobaan keenam ($n = 6$), urutan sukses dan gagalnya harus merupakan salah satu dari sepuluh urutan yang mungkin ini.

LATIHAN TERBIMBING 4.45

Setiap urutan pada Gambar 4.11 memiliki tepat dua hasil gagal dan empat hasil sukses, dengan percobaan terakhir selalu sukses. Jika peluang sukses adalah $p = 0.8$, carilah peluang urutan pertama.³⁵

³⁴Salah satu jawaban yang mungkin: karena setiap percobaan field goal Brian kemungkinan besar sukses, ia akan memerlukan sekurang-kurangnya 4 percobaan, tetapi mungkin tidak lebih dari 6 atau 7.

	Percobaan Tendangan					
	1	2	3	4	5	6
1	F	F	$\overset{1}{S}$	$\overset{2}{S}$	$\overset{3}{S}$	$\overset{4}{S}$
2	F	$\overset{1}{S}$	F	$\overset{2}{S}$	$\overset{3}{S}$	$\overset{4}{S}$
3	F	$\overset{1}{S}$	$\overset{2}{S}$	F	$\overset{3}{S}$	$\overset{4}{S}$
4	F	$\overset{1}{S}$	$\overset{2}{S}$	$\overset{3}{S}$	F	$\overset{4}{S}$
5	$\overset{1}{S}$	F	F	$\overset{2}{S}$	$\overset{3}{S}$	$\overset{4}{S}$
6	$\overset{1}{S}$	F	$\overset{2}{S}$	F	$\overset{3}{S}$	$\overset{4}{S}$
7	$\overset{1}{S}$	F	$\overset{2}{S}$	$\overset{3}{S}$	F	$\overset{4}{S}$
8	$\overset{1}{S}$	$\overset{2}{S}$	F	F	$\overset{3}{S}$	$\overset{4}{S}$
9	$\overset{1}{S}$	$\overset{2}{S}$	F	$\overset{3}{S}$	F	$\overset{4}{S}$
10	$\overset{1}{S}$	$\overset{2}{S}$	$\overset{3}{S}$	F	F	$\overset{4}{S}$

Gambar 4.11: Sepuluh urutan yang mungkin ketika tendangan sukses keempat terjadi pada percobaan keenam.

Jika peluang Brian berhasil mencetak field goal dari jarak 35 yard adalah $p = 0.8$, berapa peluang bahwa Brian memerlukan tepat enam percobaan untuk mencetak field goal keempatnya? Kita dapat menuliskannya sebagai

$$\begin{aligned}
 &P(\text{Brian memerlukan enam percobaan untuk mencetak empat field goal}) \\
 &= P(\text{Brian mencetak field goal pada tiga dari lima percobaan pertamanya dan pada percobaan keenam}) \\
 &= P(\text{urutan ke-1 ATAU urutan ke-2 ATAU ... ATAU urutan ke-10})
 \end{aligned}$$

dengan urutan-urutan yang berasal dari Gambar 4.11. Peluang terakhir ini dapat kita uraikan menjadi jumlah sepuluh kemungkinan yang saling lepas:

$$\begin{aligned}
 &P(\text{urutan ke-1 ATAU urutan ke-2 ATAU ... ATAU urutan ke-10}) \\
 &= P(\text{urutan ke-1}) + P(\text{urutan ke-2}) + \cdots + P(\text{urutan ke-10})
 \end{aligned}$$

Peluang urutan pertama telah diperoleh dalam Latihan Terbimbing 4.45 sebagai 0.0164, dan setiap urutan lainnya memiliki peluang yang sama. Karena masing-masing dari sepuluh urutan tersebut memiliki peluang yang sama, peluang totalnya adalah sepuluh kali peluang satu urutan.

Cara menghitung peluang binomial negatif ini serupa dengan cara menyelesaikan persoalan binomial pada Bagian 4.3. Peluang tersebut diuraikan menjadi dua bagian:

$$\begin{aligned}
 &P(\text{Brian memerlukan enam percobaan untuk mencetak empat field goal}) \\
 &= [\text{Banyaknya urutan yang mungkin}] \times P(\text{Satu urutan})
 \end{aligned}$$

Kita menelaah setiap bagian secara terpisah, lalu mengalikannya untuk memperoleh hasil akhir.

Mula-mula kita menentukan peluang satu urutan. Salah satu kasus khusus adalah mengamati semua hasil gagal terlebih dahulu (sebanyak $n - k$), kemudian diikuti oleh k hasil sukses:

$$\begin{aligned}
 &P(\text{Satu urutan}) \\
 &= P(n - k \text{ hasil gagal, kemudian } k \text{ hasil sukses}) \\
 &= (1 - p)^{n-k} p^k
 \end{aligned}$$

³⁵Urutan pertama: $0.2 \times 0.2 \times 0.8 \times 0.8 \times 0.8 \times 0.8 = 0.0164$.

Kita juga harus menentukan banyaknya urutan untuk kasus umum. Di atas, kita memperoleh sepuluh urutan ketika sukses keempat terjadi pada percobaan keenam. Urutan-urutan ini diperoleh dengan menetapkan pengamatan terakhir sebagai sukses dan mencari semua cara menyusun pengamatan lainnya. Dengan kata lain, ada berapa cara menyusun $k - 1$ sukses dalam $n - 1$ percobaan? Jumlah ini dapat diperoleh menggunakan koefisien n pilih k , tetapi untuk $n - 1$ dan $k - 1$:

$$\binom{n-1}{k-1} = \frac{(n-1)!}{(k-1)!((n-1)-(k-1))!} = \frac{(n-1)!}{(k-1)!(n-k)!}$$

Inilah banyaknya cara berbeda untuk mengurutkan $k - 1$ sukses dan $n - k$ gagal dalam $n - 1$ percobaan. Jika notasi faktorial (tanda seru) belum Anda kenal, lihat halaman 153.

DISTRIBUSI BINOMIAL NEGATIF

Distribusi binomial negatif menggambarkan peluang mengamati sukses ke- k pada percobaan ke- n , ketika semua percobaan saling independen:

$$P(\text{sukses ke-}k \text{ pada percobaan ke-}n) = \binom{n-1}{k-1} p^k (1-p)^{n-k}$$

Nilai p menyatakan peluang bahwa satu percobaan menghasilkan sukses.

CONTOH 4.46

Tunjukkan dengan menggunakan rumus distribusi binomial negatif bahwa peluang Brian mencetak field goal keempatnya pada percobaan keenam adalah 0.164.

- E** Peluang sukses dalam satu percobaan adalah $p = 0.8$, banyaknya sukses adalah $k = 4$, dan banyaknya percobaan yang diperlukan dalam skenario ini adalah $n = 6$.

$$\binom{n-1}{k-1} p^k (1-p)^{n-k} = \frac{5!}{3!2!} (0.8)^4 (0.2)^2 = 10 \times 0.0164 = 0.164$$

LATIHAN TERBIMBING 4.47

- G** Distribusi binomial negatif mensyaratkan percobaan-percobaan tendangan Brian saling independen. Menurut Anda, apakah masuk akal untuk menganggap percobaan-percobaan tendangan Brian saling independen?³⁶

LATIHAN TERBIMBING 4.48

- G** Anggamlah percobaan-percobaan tendangan Brian saling independen. Berapa peluang bahwa Brian akan mencetak field goal keempatnya dalam lima percobaan pertama?³⁷

³⁶Jawaban dapat bervariasi. Kita tidak dapat menyimpulkan secara pasti bahwa percobaan-percobaan tersebut saling independen ataupun tidak. Namun, banyak tinjauan statistik atas performa atletik menunjukkan bahwa percobaan semacam ini nyaris saling independen.

³⁷Jika field goal keempatnya ($k = 4$) terjadi dalam lima percobaan pertama, Brian memerlukan empat atau lima percobaan ($n = 4$ atau $n = 5$). Dari uraian sebelumnya, kita memiliki $p = 0.8$. Gunakan distribusi binomial negatif untuk menghitung peluang $n = 4$ percobaan dan $n = 5$ percobaan, lalu jumlahkan kedua peluang tersebut:

$$\begin{aligned} P(n = 4 \text{ ATAU } n = 5) &= P(n = 4) + P(n = 5) \\ &= \binom{4-1}{4-1} 0.8^4 + \binom{5-1}{4-1} (0.8)^4 (1-0.8) = 1 \times 0.41 + 4 \times 0.082 = 0.41 + 0.33 = 0.74 \end{aligned}$$

BINOMIAL VERSUS BINOMIAL NEGATIF

Dalam kasus binomial, kita biasanya memiliki jumlah percobaan yang tetap dan meninjau banyaknya sukses. Dalam kasus binomial negatif, kita menelaah berapa banyak percobaan yang diperlukan untuk mengamati jumlah sukses yang tetap dan mensyaratkan bahwa pengamatan terakhir berupa sukses.

LATIHAN TERBIMBING 4.49

Pada 70% hari, sebuah rumah sakit menerima setidaknya satu pasien serangan jantung. Pada 30% hari, rumah sakit tersebut tidak menerima pasien serangan jantung. Tentukan apakah setiap kasus di bawah ini merupakan kasus binomial atau binomial negatif, lalu hitung peluangnya.³⁸

G

- (a) Berapa peluang rumah sakit tersebut menerima pasien serangan jantung pada tepat tiga hari minggu ini?
- (b) Berapa peluang bahwa hari kedua dengan pasien serangan jantung merupakan hari keempat dalam minggu ini?
- (c) Berapa peluang bahwa hari kelima bulan depan merupakan hari pertama dengan pasien serangan jantung?

³⁸Pada setiap bagian, $p = 0.7$. (a) Jumlah hari tetap, jadi kasus ini binomial. Parameternya adalah $k = 3$ dan $n = 7$: 0.097. (b) “Sukses” terakhir (menerima pasien serangan jantung) ditetapkan pada hari terakhir, sehingga kita harus menerapkan distribusi binomial negatif. Parameternya adalah $k = 2$, $n = 4$: 0.132. (c) Persoalan ini merupakan kasus binomial negatif dengan $k = 1$ dan $n = 5$: 0.006. Perhatikan bahwa kasus binomial negatif ketika $k = 1$ sama dengan menggunakan distribusi geometrik.

Latihan

4.27 Melempar dadu. Hitung peluang-peluang berikut dan tentukan model distribusi peluang yang tepat untuk setiap kasus. Anda melempar sebuah dadu seimbang 5 kali. Berapa peluang memperoleh

- (a) angka 6 pertama pada lemparan kelima?
- (b) tepat tiga angka 6?
- (c) angka 6 ketiga pada lemparan kelima?

4.28 Bermain dart. Hitung peluang-peluang berikut dan tentukan model distribusi peluang yang tepat untuk setiap kasus. Seorang pemain dart yang sangat terampil dapat mengenai pusat sasaran (lingkaran merah di tengah papan dart) dengan peluang 65%. Berapa peluang ia

- (a) mengenai pusat sasaran untuk kali ke-10 pada percobaan ke-15?
- (b) mengenai pusat sasaran 10 kali dalam 15 percobaan?
- (c) mengenai pusat sasaran pertama kali pada percobaan ketiga?

4.29 Pengambilan sampel di sekolah. Untuk proyek mata kuliah sosiologi, Anda diminta melakukan survei terhadap 20 siswa di sekolah Anda. Anda memutuskan untuk berdiri di luar kafetaria asrama pada suatu malam dan melakukan survei terhadap sampel acak 20 siswa yang keluar dari kafetaria seusai makan malam. Penghuni asrama Anda terdiri atas 45% laki-laki dan 55% perempuan.

- (a) Model peluang mana yang paling tepat untuk menghitung peluang bahwa responden ke-4 merupakan responden perempuan ke-2? Jelaskan.
- (b) Hitung peluang pada bagian (a).
- (c) Berikut adalah tiga skenario ketika responden ke-4 merupakan responden perempuan ke-2 (dengan M menyatakan laki-laki dan F menyatakan perempuan):

$$\{M, M, F, F\}, \{M, F, M, F\}, \{F, M, M, F\}$$

Kesamaan di antara skenario-skenario ini adalah bahwa responden pada percobaan terakhir selalu perempuan. Dalam tiga percobaan pertama terdapat 2 laki-laki dan 1 perempuan. Gunakan koefisien binomial untuk mengonfirmasi bahwa ada 3 cara mengurutkan 2 laki-laki dan 1 perempuan.

- (d) Gunakan temuan pada bagian (c) untuk menjelaskan mengapa koefisien dalam rumus distribusi binomial negatif adalah $\binom{n-1}{k-1}$, sedangkan koefisien binomial adalah $\binom{n}{k}$.

4.30 Servis dalam bola voli. Seorang pemain bola voli yang kurang terampil memiliki peluang 15% untuk melakukan servis yang masuk, yaitu memukul bola agar melintasi net dengan lintasan sedemikian rupa sehingga bola akan jatuh di lapangan tim lawan. Misalkan servis-servisnya saling independen.


- (a) Berapa peluang bahwa pada percobaan ke-10 ia akan melakukan servis suksesnya yang ke-3?
- (b) Misalkan ia telah melakukan dua servis sukses dalam sembilan percobaan. Berapa peluang bahwa servisnya yang ke-10 akan sukses?
- (c) Meskipun bagian (a) dan (b) membahas skenario yang sama, peluang yang Anda hitung seharusnya berbeda. Dapatkah Anda menjelaskan penyebab perbedaan ini?

4.5 Distribusi Poisson

CONTOH 4.50

Kota New York memiliki sekitar 8 juta penduduk. Berapa orang yang diperkirakan akan dirawat di rumah sakit akibat infark miokard akut (acute myocardial infarction, AMI), yaitu serangan jantung, setiap hari? Menurut catatan historis, jumlah rata-ratanya sekitar 4.4 orang. Namun, kita juga ingin mengetahui perkiraan distribusi banyaknya kasus. Seperti apakah histogram banyaknya kasus AMI per hari jika jumlah hariannya dicatat selama satu tahun penuh?

Histogram banyaknya kasus AMI selama 365 hari di Kota New York ditampilkan pada Gambar 4.12.³⁹ Rata-rata sampel (4.38) serupa dengan rata-rata historis sebesar 4.4. Simpangan baku sampel sekitar 2, dan histogram menunjukkan bahwa sekitar 70% data berada di antara 2.4 dan 6.4. Bentuk distribusinya unimodal dan menceng kanan.



Gambar 4.12: Histogram banyaknya kasus AMI pada 365 hari yang berbeda di Kota New York.

Distribusi Poisson sering berguna untuk memperkirakan banyaknya peristiwa dalam suatu populasi besar selama satu satuan waktu. Sebagai contoh, perhatikan setiap peristiwa berikut:

- mengalami serangan jantung,
- menikah, dan
- tersambar petir.

Distribusi Poisson membantu kita menggambarkan banyaknya peristiwa semacam itu yang akan terjadi dalam sehari pada suatu populasi tertentu yang tetap jika individu-individu dalam populasi tersebut saling independen. Distribusi Poisson juga dapat digunakan untuk satuan waktu lain, seperti satu jam atau satu minggu.

Histogram pada Gambar 4.12 menghampiri distribusi Poisson dengan laju 4.4. **Laju** suatu distribusi Poisson adalah rata-rata banyaknya peristiwa dalam populasi yang relatif tetap per satuan waktu. Pada Contoh 4.50, satuan waktunya adalah satu hari, populasinya adalah seluruh penduduk Kota New York, dan laju historisnya adalah 4.4. Parameter distribusi Poisson adalah lajunya – yaitu banyaknya peristiwa yang kita harapkan akan teramati – dan biasanya dilambangkan dengan λ (huruf Yunani *lambda*) atau μ . Dengan menggunakan laju tersebut, kita dapat menggambarkan peluang mengamati tepat k peristiwa dalam satu satuan waktu.

³⁹Data ini disimulasikan. Dalam praktik, kita perlu memeriksa adanya hubungan di antara hari-hari yang berurutan.

DISTRIBUSI POISSON

Misalkan kita mengamati kemunculan peristiwa dan banyaknya peristiwa yang teramati mengikuti distribusi Poisson dengan laju λ . Maka

$$P(\text{mengamati } k \text{ peristiwa}) = \frac{\lambda^k e^{-\lambda}}{k!}$$

dengan k dapat bernilai 0, 1, 2, dan seterusnya, serta $k!$ menyatakan k -faktorial, sebagaimana dijelaskan pada halaman 153. Huruf $e \approx 2.718$ adalah basis logaritma natural. Rata-rata dan simpangan baku distribusi ini masing-masing adalah λ dan $\sqrt{\lambda}$.

Pembahasan yang ketat mengenai syarat-syarat distribusi Poisson akan kita tunda hingga mata kuliah berikutnya. Namun, beberapa pedoman sederhana berikut dapat digunakan untuk penilaian awal mengenai ketepatan model Poisson.

Suatu variabel acak dapat mengikuti distribusi Poisson jika kita memperhatikan banyaknya peristiwa, populasi yang menghasilkan peristiwa tersebut besar, dan setiap peristiwa terjadi secara independen satu sama lain.

Bahkan ketika peristiwa-peristiwa tersebut sebenarnya tidak independen – misalnya, hari Sabtu dan Minggu sangat populer untuk pernikahan – model Poisson terkadang masih cukup tepat jika kita membolehkan lajunya berbeda untuk waktu yang berbeda. Dalam contoh pernikahan, lajunya akan dimodelkan lebih tinggi pada akhir pekan daripada pada hari kerja. Gagasan memodelkan laju distribusi Poisson sebagai fungsi dari variabel kedua, seperti hari dalam sepekan, menjadi dasar bagi sejumlah metode lanjutan yang termasuk dalam ranah **model linear terampat**. Pada Bab belum dimuat dan belum dimuat, kita akan membahas dasar-dasar model linear.

Latihan

4.31 Pelanggan kedai kopi. Sebuah kedai kopi melayani rata-rata 75 pelanggan per jam pada jam sibuk pagi hari.

- (a) Distribusi manakah yang telah kita pelajari yang paling tepat untuk menghitung peluang datangnya sejumlah tertentu pelanggan dalam waktu satu jam pada waktu seperti ini?
- (b) Berapakah rata-rata dan simpangan baku banyaknya pelanggan yang dilayani kedai kopi ini dalam satu jam pada waktu seperti ini?
- (c) Apakah kedatangan hanya 60 pelanggan ke kedai kopi ini dalam satu jam pada waktu seperti ini dapat dianggap sangat rendah hingga tidak biasa?
- (d) Hitunglah peluang bahwa kedai kopi ini melayani 70 pelanggan dalam satu jam pada waktu seperti ini.

4.32 Salah ketik seorang stenografer. Seorang stenografer pengadilan yang sangat terampil rata-rata membuat satu salah ketik per jam.

- (a) Distribusi peluang manakah yang paling tepat untuk menghitung peluang bahwa stenografer ini membuat sejumlah tertentu salah ketik dalam satu jam?
- (b) Berapakah rata-rata dan simpangan baku banyaknya salah ketik yang dibuat stenografer ini dalam satu jam?
- (c) Apakah akan dianggap tidak biasa jika stenografer ini membuat 4 salah ketik dalam satu jam tertentu?
- (d) Hitunglah peluang bahwa stenografer ini membuat paling banyak 2 salah ketik dalam satu jam tertentu.

4.33 Berapa banyak mobil yang datang? Pada hari Senin hingga Kamis yang bukan hari libur, rata-rata banyaknya kendaraan yang mengunjungi sebuah toko antara pukul 14.00 dan 15.00 setiap sore adalah 6.5, dan banyaknya mobil yang datang pada suatu hari mengikuti distribusi Poisson.

- (a) Berapakah peluang bahwa tepat 5 mobil akan datang pada Senin depan?
- (b) Berapakah peluang bahwa 0, 1, atau 2 mobil akan datang pada Senin depan antara pukul 14.00 dan 15.00?
- (c) Rata-rata ada 11.7 orang yang datang dengan kendaraan pada jam yang sama. Apakah banyaknya orang yang datang dengan mobil selama satu jam tersebut juga kemungkinan mengikuti distribusi Poisson? Jelaskan.

4.34 Bagasi hilang. Sesekali, sebuah maskapai kehilangan bagasi. Misalkan sebuah maskapai kecil mendapati bahwa banyaknya bagasi yang hilang setiap hari kerja dapat dimodelkan dengan cukup baik menggunakan model Poisson dengan rata-rata 2.2 bagasi.

- (a) Berapakah peluang bahwa maskapai tersebut tidak akan kehilangan bagasi pada Senin depan?
- (b) Berapakah peluang bahwa maskapai tersebut akan kehilangan 0, 1, atau 2 bagasi pada Senin depan?
- (c) Misalkan maskapai tersebut berkembang selama 3 tahun berikutnya sehingga jumlah penerbangannya menjadi dua kali lipat, dan direktur utamanya bertanya apakah mereka masih wajar melanjutkan penggunaan model Poisson dengan rata-rata 2.2. Rekomendasi apakah yang tepat? Jelaskan.

Bab 5

Dasar-dasar inferensi

5.1 Estimasi titik dan variabilitas sampling

5.2 Interval kepercayaan untuk suatu proporsi

Statistika inferensial terutama berkenaan dengan memahami dan menguantifikasi ketidakpastian estimasi parameter. Walaupun persamaan dan rinciannya berubah bergantung pada situasi, dasar-dasar inferensi tetap sama di seluruh bidang statistika.

Kita mulai dengan topik yang sudah dikenal: gagasan menggunakan proporsi sampel untuk mengestimasi proporsi populasi. Selanjutnya, kita menyusun apa yang disebut *interval kepercayaan*, yaitu suatu rentang nilai yang masuk akal dan mungkin memuat nilai populasi yang sebenarnya. Terakhir, kita memperkenalkan *kerangka pengujian hipotesis*, yang memungkinkan kita mengevaluasi secara formal klaim tentang populasi, misalnya apakah suatu survei memberikan bukti kuat bahwa seorang kandidat didukung oleh mayoritas populasi pemilih.



Untuk video, salindia, dan sumber daya lainnya, kunjungi www.openintro.org/os

5.1 Estimasi titik dan variabilitas sampling

Perusahaan seperti Pew Research sering melakukan jajak pendapat untuk memahami keadaan opini publik atau pengetahuan mengenai banyak topik, termasuk politik, pemahaman ilmiah, pengenalan merek, dan lain-lain. Tujuan akhir jajak pendapat pada umumnya ialah menggunakan jawaban responden untuk mengestimasi opini atau pengetahuan populasi yang lebih luas.

5.1.1 Estimasi titik dan galat

Misalkan suatu jajak pendapat menunjukkan bahwa tingkat persetujuan terhadap Presiden AS adalah 45%. Kita akan menganggap 45% sebagai **estimasi titik** untuk tingkat persetujuan yang mungkin kita lihat seandainya kita mengumpulkan jawaban dari seluruh populasi. Proporsi jawaban dari seluruh populasi ini umumnya disebut **parameter** yang menjadi perhatian. Jika parameternya berupa proporsi, parameter tersebut sering dilambangkan dengan p , dan proporsi sampel sering kita sebut sebagai $\hat{p}$ (dibaca *p-hat*¹). Kecuali jika kita mengumpulkan jawaban dari setiap individu dalam populasi, p tetap tidak diketahui, dan kita menggunakan $\hat{p}$ sebagai estimasi bagi p . Selisih yang kita amati antara hasil jajak pendapat dan parameter disebut **galat** estimasi tersebut. Secara umum, galat terdiri atas dua aspek: galat pengambilan sampel dan bias.

Galat pengambilan sampel, yang kadang-kadang disebut *ketidakpastian pengambilan sampel*, menggambarkan seberapa besar suatu estimasi cenderung bervariasi dari satu sampel ke sampel berikutnya. Sebagai contoh, estimasi dari suatu sampel mungkin 1% terlalu rendah, sedangkan pada sampel lain estimasinya mungkin 3% terlalu tinggi. Banyak bagian dalam statistika, termasuk banyak bagian buku ini, berfokus pada pemahaman dan penguantifikasian galat pengambilan sampel, dan kita akan memanfaatkan ukuran sampel untuk membantu menguantifikasi galat ini; **ukuran sampel** sering direpresentasikan oleh huruf n .

Bias menggambarkan kecenderungan sistematis untuk menghasilkan estimasi yang terlalu tinggi atau terlalu rendah dibandingkan nilai populasi yang sebenarnya. Sebagai contoh, jika kita melakukan jajak pendapat terhadap mahasiswa mengenai dukungan untuk stadion kampus yang baru, kemungkinan kita akan memperoleh estimasi yang bias atas tingkat dukungan mahasiswa terhadap stadion itu apabila pertanyaannya dirumuskan sebagai, *Apakah Anda mendukung kampus Anda dengan menyetujui pendanaan untuk stadion baru?* Kita berupaya meminimalkan bias melalui prosedur pengumpulan data yang dirancang dengan saksama, yang telah dibahas dalam Bab 1 dan menjadi pokok bahasan banyak buku lain.

5.1.2 Memahami variabilitas estimasi titik

Misalkan proporsi orang dewasa Amerika yang mendukung perluasan energi surya adalah $p = 0.88$, yang merupakan parameter yang menjadi perhatian kita.² Jika kita melakukan jajak pendapat terhadap 1000 orang dewasa Amerika mengenai topik ini, estimasinya tidak akan sempurna, tetapi seberapa dekat proporsi sampel dalam jajak pendapat itu dengan 88% menurut perkiraan kita? Kita ingin memahami, *bagaimana proporsi sampel $\hat{p}$ berperilaku ketika proporsi populasi sejati adalah 0.88*.³ Mari kita cari tahu! Kita dapat menyimulasikan jawaban yang akan diperoleh dari suatu sampel acak sederhana beranggotakan 1000 orang dewasa Amerika; hal ini hanya mungkin karena kita mengetahui bahwa dukungan sebenarnya terhadap perluasan energi surya adalah 0.88. Berikut cara kita dapat menyusun simulasi tersebut:

1. Pada 2018 terdapat sekitar 250 juta orang dewasa Amerika. Pada 250 juta potong kertas, tuliskan nilai literal “support” (mendukung) pada 88% bagiannya dan “not” (tidak mendukung) pada 12% sisanya.

¹Jangan tertukar dengan *phat*, istilah slang untuk sesuatu yang keren, seperti buku ini.

²Kita belum benar-benar melakukan sensus untuk mengukur nilai ini secara sempurna. Namun, suatu sampel yang sangat besar menunjukkan bahwa tingkat dukungan sebenarnya sekitar 88%.

³88% jika ditulis sebagai proporsi adalah 0.88. Beralih antara bentuk proporsi dan persen merupakan hal yang lazim. Namun, rumus-rumus yang disajikan dalam buku ini selalu merujuk pada proporsi, bukan persen.

2. Campurkan potongan-potongan kertas tersebut dan ambil 1000 potong untuk mewakili sampel kita yang beranggotakan 1000 orang dewasa Amerika.
3. Hitung fraksi sampel yang bertuliskan "support".

Adakah sukarelawan yang ingin menjalankan simulasi ini? Barangkali tidak. Menjalankan simulasi ini dengan 250 juta potong kertas akan menyita banyak waktu dan biaya, tetapi kita dapat menyimulasikannya dengan kode komputer; kami telah menulis program singkat pada Gambar 5.1 bagi Anda yang ingin melihat seperti apa kode komputernya. Dalam simulasi ini, sampel menghasilkan estimasi titik $\hat{p}_1 = 0.894$. Kita mengetahui proporsi populasi untuk simulasi tersebut adalah $p = 0.88$, sehingga kita mengetahui estimasi itu memiliki galat sebesar $0.894 - 0.88 = +0.014$.

```
# 1. Buat sekumpulan 250 juta entri, dengan 88% di antaranya bernilai "support"
# dan 12% bernilai "not".
pop_size <- 250000000
possible_entries <- c(rep("support", 0.88 * pop_size), rep("not", 0.12 * pop_size))

# 2. Ambil sampel sebanyak 1000 entri tanpa pengembalian.
sampled_entries <- sample(possible_entries, size = 1000)

# 3. Hitung p-hat: tentukan jumlah entri yang bernilai "support", lalu bagi dengan
# ukuran sampel.
sum(sampled_entries == "support") / 1000
```

Gambar 5.1: Bagi Anda yang ingin tahu, inilah kode untuk satu simulasi $\hat{p}$ menggunakan perangkat lunak statistika bernama **R**. Setiap baris yang diawali dengan **#** merupakan **komentar kode**, yang digunakan untuk menjelaskan dalam bahasa sehari-hari apa yang dilakukan kode tersebut. Kami menyediakan praktikum perangkat lunak dalam **R** di openintro.org/book/os bagi siapa pun yang berminat mempelajari lebih lanjut.

Satu simulasi belum cukup untuk memperoleh gambaran yang baik mengenai distribusi estimasi yang mungkin kita harapkan dalam simulasi, sehingga kita perlu menjalankan lebih banyak simulasi. Dalam simulasi kedua, kita memperoleh $\hat{p}_2 = 0.885$, yang memiliki galat $+0.005$. Dalam simulasi lain, $\hat{p}_3 = 0.878$ dengan galat -0.002 . Dan dalam simulasi lainnya lagi, diperoleh estimasi $\hat{p}_4 = 0.859$ dengan galat -0.021 . Dengan bantuan komputer, kami telah menjalankan simulasi sebanyak 10.000 kali dan membuat histogram hasil seluruh 10.000 simulasi tersebut pada Gambar 5.2. Distribusi proporsi sampel ini disebut **distribusi sampling**. Kita dapat mencirikan distribusi sampling ini sebagai berikut:

Pusat. Pusat distribusi adalah $\bar{x}_{\hat{p}} = 0.880$, yang sama dengan parameternya. Perhatikan bahwa simulasi tersebut meniru suatu sampel acak sederhana dari populasi, yakni strategi pengambilan sampel yang sederhana yang membantu menghindari bias pengambilan sampel.


Sebaran. Simpangan baku distribusi adalah $s_{\hat{p}} = 0.010$. Ketika membahas distribusi sampling atau variabilitas suatu estimasi titik, kita biasanya menggunakan istilah **galat baku** alih-alih *simpangan baku*, dan notasi $SE_{\hat{p}}$ digunakan untuk galat baku yang terkait dengan proporsi sampel.

Bentuk. Distribusi tersebut simetris dan berbentuk lonceng, serta *menyerupai distribusi normal*.

Temuan-temuan ini menggembirakan! Ketika proporsi populasi adalah $p = 0.88$ dan ukuran sampel $n = 1000$, proporsi sampel $\hat{p}$ cenderung memberikan estimasi yang cukup baik atas proporsi populasi. Kita juga mendapati hal yang menarik bahwa histogram tersebut menyerupai distribusi normal.

DISTRIBUSI SAMPLING TIDAK PERNAH TERAMATI, TETAPI TETAP KITA BAYANGKAN

Dalam penerapan dunia nyata, kita tidak pernah benar-benar mengamati distribusi sampling, tetapi tetap bermanfaat untuk selalu membayangkan suatu estimasi titik sebagai sesuatu yang berasal dari distribusi hipotetis tersebut. Pemahaman atas distribusi sampling akan membantu kita mencirikan dan memaknai estimasi-estimasi titik yang benar-benar kita amati.



Gambar 5.2: Histogram dari 10.000 proporsi sampel, dengan setiap sampel diambil dari suatu populasi yang proporsi populasinya adalah 0.88 dan ukuran sampelnya $n = 1000$.

CONTOH 5.1

Jika kita menggunakan ukuran sampel yang jauh lebih kecil, yaitu $n = 50$, menurut dugaan Anda, apakah galat baku $\hat{p}$ akan lebih besar atau lebih kecil daripada ketika kita menggunakan $n = 1000$?

Secara intuitif, tampaknya lebih banyak data lebih baik daripada lebih sedikit data, dan secara umum memang demikian! Galat tipikal ketika $p = 0.88$ dan $n = 50$ akan lebih besar daripada galat yang kita harapkan ketika $n = 1000$.

Contoh 5.1 menyoroti suatu sifat penting yang akan kita jumpai berulang kali: sampel yang lebih besar cenderung memberikan estimasi titik yang lebih presisi daripada sampel yang lebih kecil.

5.1.3 Teorema Limit Pusat

Distribusi pada Gambar 5.2 sangat menyerupai distribusi normal. Hal itu bukan anomali; melainkan hasil dari suatu prinsip umum yang disebut **Teorema Limit Pusat**.

TEOREMA LIMIT PUSAT DAN SYARAT SUKSES–GAGAL

Jika observasi saling independen dan ukuran sampel cukup besar, proporsi sampel $\hat{p}$ cenderung mengikuti distribusi normal dengan rata-rata dan galat baku berikut:

$$\mu_{\hat{p}} = p \qquad SE_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$$

Agar Teorema Limit Pusat berlaku, ukuran sampel biasanya dianggap cukup besar jika $np \geq 10$ dan $n(1-p) \geq 10$; ini disebut **syarat sukses–gagal**.

Teorema Limit Pusat sangat penting dan menjadi landasan bagi sebagian besar statistika. Ketika mulai menerapkan Teorema Limit Pusat, perhatikan kedua syarat teknis berikut: observasi harus saling independen, dan ukuran sampel harus cukup besar sehingga $np \geq 10$ dan $n(1-p) \geq 10$.

CONTOH 5.2

Sebelumnya, kita mengestimasi rata-rata dan galat baku $\hat{p}$ menggunakan data simulasi ketika $p = 0.88$ dan $n = 1000$. Pastikan bahwa Teorema Limit Pusat berlaku dan distribusi samplingnya kira-kira normal.

Independensi. Terdapat $n = 1000$ observasi untuk setiap proporsi sampel $\hat{p}$, dan masing-masing observasi diperoleh secara independen. *Cara paling umum agar observasi dapat dianggap independen adalah jika observasi itu berasal dari sampel acak sederhana.*

Syarat sukses–gagal. Kita dapat memastikan ukuran sampel cukup besar dengan memeriksa syarat sukses–gagal dan memastikan kedua nilai hasil perhitungan lebih besar dari 10:

$$np = 1000 \times 0.88 = 880 \geq 10 \quad n(1 - p) = 1000 \times (1 - 0.88) = 120 \geq 10$$

Syarat independensi dan syarat sukses–gagal keduanya terpenuhi, sehingga Teorema Limit Pusat berlaku dan masuk akal untuk memodelkan $\hat{p}$ dengan distribusi normal.

CARA MEMASTIKAN OBSERVASI SAMPEL SALING INDEPENDEN

Subjek dalam suatu eksperimen dianggap independen jika ditempatkan secara acak ke dalam kelompok perlakuan.

Jika observasi berasal dari sampel acak sederhana, maka observasi tersebut saling independen.

Jika sampel berasal dari proses yang tampak acak, misalnya kesalahan yang sesekali terjadi pada lini perakitan, pemeriksaan independensi menjadi lebih sulit. Dalam kasus ini, gunakan pertimbangan terbaik Anda.

Syarat tambahan yang kadang-kadang diberlakukan bagi sampel dari suatu populasi adalah bahwa ukurannya tidak melebihi 10% dari populasi tersebut. Jika sampel melebihi 10% ukuran populasi, metode yang kita bahas cenderung menghasilkan estimasi galat pengambilan sampel yang sedikit terlalu besar dibandingkan hasil metode yang lebih lanjut.⁴ Hal ini sangat jarang menjadi masalah, dan ketika memang menjadi masalah, metode kita cenderung konservatif, sehingga pemeriksaan tambahan ini kita anggap opsional.

CONTOH 5.3

Hitung rata-rata dan galat baku teoretis dari $\hat{p}$ ketika $p = 0.88$ dan $n = 1000$, menurut Teorema Limit Pusat.

Rata-rata nilai-nilai $\hat{p}$ sama dengan proporsi populasi: $\mu_{\hat{p}} = 0.88$.

Perhitungan galat baku $\hat{p}$ menggunakan rumus berikut:


$$SE_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.88(1-0.88)}{1000}} = 0.010$$

⁴Sebagai contoh, kita dapat menggunakan sesuatu yang disebut **faktor koreksi populasi terhitung**: jika ukuran sampel adalah n dan ukuran populasi adalah N , kita dapat mengalikan rumus galat baku biasa dengan $\sqrt{\frac{N-n}{N-1}}$ untuk memperoleh estimasi galat baku sebenarnya yang lebih kecil dan lebih presisi. Jika $n < 0.1 \times N$, dampak faktor koreksi ini relatif kecil.

CONTOH 5.4

Perkirakan seberapa sering proporsi sampel $\hat{p}$ berada dalam jarak 0.02 (2%) dari nilai populasi, $p = 0.88$. Berdasarkan Contoh 5.2 dan 5.3, kita tahu bahwa distribusinya kira-kira $N(\mu_{\hat{p}} = 0.88, SE_{\hat{p}} = 0.010)$.

Setelah begitu banyak berlatih di Bagian 4.1, semoga contoh distribusi normal ini terasa familier! Kita ingin mengetahui fraksi nilai-nilai $\hat{p}$ di antara 0.86 dan 0.90:



Dengan $\mu_{\hat{p}} = 0.88$ dan $SE_{\hat{p}} = 0.010$, kita dapat menghitung skor-Z untuk batas kiri maupun kanan:

$$Z_{0.86} = \frac{0.86 - 0.88}{0.010} = -2 \qquad Z_{0.90} = \frac{0.90 - 0.88}{0.010} = 2$$

Kita dapat menggunakan perangkat lunak statistika, kalkulator grafis, atau tabel untuk mencari luas pada kedua ekor; dengan cara mana pun, kita akan memperoleh 0.0228 untuk masing-masing ekor. Luas total kedua ekor adalah $2 \times 0.0228 = 0.0456$, sehingga luas daerah yang diarsir adalah 0.9544. Artinya, sekitar 95.44% dari distribusi sampling pada Gambar 5.2 berada dalam jarak ± 0.02 dari proporsi populasi, $p = 0.88$.

LATIHAN TERBIMBING 5.5



Dalam Contoh 5.1, kita membahas bahwa sampel yang lebih kecil cenderung menghasilkan estimasi yang kurang andal. Jelaskan bagaimana intuisi ini tercermin dalam rumus $SE_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$.⁵

5.1.4 Menerapkan Teorema Limit Pusat pada situasi dunia nyata

Kita sebenarnya tidak mengetahui proporsi populasi kecuali jika kita melakukan jajak pendapat yang mahal terhadap semua individu dalam populasi tersebut. Nilai $p = 0.88$ yang kita gunakan sebelumnya didasarkan pada jajak pendapat Pew Research terhadap 1000 orang dewasa Amerika, yang menemukan bahwa $\hat{p} = 0.887$ dari mereka mendukung perluasan energi surya. Para peneliti mungkin bertanya-tanya: apakah proporsi sampel dari jajak pendapat tersebut kira-kira mengikuti distribusi normal? Kita dapat memeriksa syarat-syarat Teorema Limit Pusat:

Independensi. Jajak pendapat tersebut menggunakan sampel acak sederhana dari orang dewasa Amerika, yang berarti bahwa observasinya saling independen.

Syarat sukses–gagal. Untuk memeriksa syarat ini, kita memerlukan proporsi populasi, p , untuk memastikan bahwa np dan $n(1 - p)$ keduanya lebih besar dari 10. Namun, kita sebenarnya tidak mengetahui p ; justru karena itulah pelaksana jajak pendapat mengambil sampel! Dalam kasus seperti ini, kita sering menggunakan $\hat{p}$ sebagai pengganti terbaik yang tersedia untuk memeriksa syarat sukses–gagal:

$$n\hat{p} = 1000 \times 0.887 = 887 \qquad n(1 - \hat{p}) = 1000 \times (1 - 0.887) = 113$$

Proporsi sampel $\hat{p}$ menjadi pengganti yang masuk akal bagi p dalam pemeriksaan ini, dan setiap nilai pada kasus ini jauh melampaui batas minimum 10.

Aproksimasi substitusi yang menggunakan $\hat{p}$ untuk menggantikan p ini juga berguna ketika menghitung galat baku proporsi sampel:

$$SE_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}} \approx \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.887(1-0.887)}{1000}} = 0.010$$

Teknik substitusi ini kadang-kadang disebut “prinsip substitusi”. Dalam kasus ini, perubahan $SE_{\hat{p}}$ tidak cukup besar untuk terlihat jika hanya menggunakan 3 tempat desimal, dibandingkan ketika sebelumnya kita menyelesaikan perhitungan dengan 0.88. Galat baku hasil perhitungan cenderung cukup stabil meskipun proporsi yang teramati sedikit berbeda antara satu sampel dan sampel lainnya.

⁵Karena ukuran sampel n berada di penyebut (bagian bawah) pecahan, ukuran sampel yang lebih besar membuat seluruh nilai ekspresi hasil perhitungan cenderung lebih kecil. Dengan kata lain, ukuran sampel yang lebih besar berkaitan dengan galat baku yang lebih kecil.

5.1.5 Rincian lebih lanjut tentang Teorema Limit Pusat

Sejauh ini dalam bab ini, kita telah menerapkan Teorema Limit Pusat dalam banyak contoh:

Jika observasi saling independen dan ukuran sampel cukup besar, distribusi $\hat{p}$ menyerupai distribusi normal dengan

$$\mu_{\hat{p}} = p \qquad SE_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$$


Ukuran sampel dianggap cukup besar jika $np \geq 10$ dan $n(1-p) \geq 10$.

Dalam bagian ini, kita akan menelaah syarat sukses-gagal dan berusaha memahami Teorema Limit Pusat dengan lebih baik.

Salah satu pertanyaan yang menarik untuk dijawab adalah, *apa yang terjadi jika $np < 10$ atau $n(1-p) < 10$?* Seperti yang kita lakukan di Bagian 5.1.2, kita dapat menyimulasikan pengambilan sampel dengan berbagai ukuran ketika, misalnya, proporsi sebenarnya adalah $p = 0.25$. Berikut adalah sampel berukuran 10:

tidak, tidak, ya, ya, tidak, tidak, tidak, tidak, tidak, tidak

Dalam sampel ini, kita mengamati proporsi jawaban ya sebesar $\hat{p} = \frac{2}{10} = 0.2$. Kita dapat menyimulasikan banyak proporsi semacam itu untuk memahami distribusi sampling $\hat{p}$ ketika $n = 10$ dan $p = 0.25$, yang telah kita plot pada Gambar 5.3 berdampingan dengan distribusi normal yang memiliki rata-rata dan variabilitas yang sama. Distribusi-distribusi ini memiliki sejumlah perbedaan penting.



Gambar 5.3: Kiri: simulasi $\hat{p}$ ketika ukuran sampel adalah $n = 10$ dan proporsi populasi adalah $p = 0.25$. Kanan: distribusi normal dengan rata-rata (0.25) dan simpangan baku (0.137) yang sama.

	Unimodal?	Halus?	Simetris?
Normal: $N(0.25, 0.14)$	Ya	Ya	Ya
$n = 10, p = 0.25$	Ya	Tidak	Tidak

Perhatikan bahwa syarat sukses-gagal tidak terpenuhi ketika $n = 10$ dan $p = 0.25$:


$$np = 10 \times 0.25 = 2.5$$

$$n(1-p) = 10 \times 0.75 = 7.5$$


Distribusi sampling tunggal ini tidak membuktikan bahwa syarat sukses-gagal merupakan pedoman yang sempurna, tetapi kita mendapati bahwa pedoman itu dengan tepat menunjukkan bahwa distribusi normal mungkin tidak sesuai.

Kita dapat melakukan beberapa simulasi tambahan, yang ditampilkan pada Gambar 5.4 dan 5.5, dan kita dapat melihat beberapa kecenderungan:

1. Jika np atau $n(1-p)$ bernilai kecil, distribusinya lebih **diskret**, yaitu *tidak kontinu*.
2. Jika np atau $n(1-p)$ lebih kecil dari 10, kemencengan distribusinya lebih kentara.
3. Semakin besar np dan $n(1-p)$, semakin bentuk distribusinya menyerupai distribusi normal. Hal ini mungkin sedikit lebih sulit terlihat untuk ukuran sampel yang lebih besar pada plot-plot ini karena variabilitasnya juga menjadi jauh lebih kecil.



Gambar 5.4: Distribusi sampling untuk beberapa skenario p dan n .
 Baris: $p = 0.10$, $p = 0.20$, $p = 0.50$, $p = 0.80$, dan $p = 0.90$.
 Kolom: $n = 10$ dan $n = 25$.



Gambar 5.5: Distribusi sampling untuk beberapa skenario p dan n .
 Baris: $p = 0.10$, $p = 0.20$, $p = 0.50$, $p = 0.80$, dan $p = 0.90$.
 Kolom: $n = 50$, $n = 100$, dan $n = 250$.

4. Jika np dan $n(1 - p)$ keduanya sangat besar, sifat diskret distribusinya nyaris tidak terlihat, dan bentuk distribusinya jauh lebih menyerupai distribusi normal.

Sejauh ini, kita hanya berfokus pada kemencengan dan sifat diskret distribusi-distribusi tersebut. Kita belum membahas bagaimana rata-rata dan galat baku distribusi berubah. Luangkan waktu sejenak untuk melihat kembali grafik-grafiknya, dan perhatikan tiga hal berikut:

1. Pusat distribusi selalu berada pada proporsi populasi, p , yang digunakan untuk menghasilkan simulasi. Karena distribusi sampling $\hat{p}$ selalu berpusat pada parameter populasi p , ini berarti proporsi sampel $\hat{p}$ bersifat **tak bias** ketika data saling independen dan diambil dari populasi semacam itu.
2. Untuk suatu proporsi populasi p tertentu, variabilitas dalam distribusi sampling berkurang ketika ukuran sampel n bertambah besar. Hal ini kemungkinan sejalan dengan intuisi Anda: estimasi berdasarkan ukuran sampel yang lebih besar cenderung lebih akurat.
3. Untuk suatu ukuran sampel tertentu, variabilitas akan paling besar ketika $p = 0.5$. Perbedaannya mungkin agak samar, jadi perhatikan dengan saksama. Hal ini mencerminkan peran proporsi p dalam rumus galat baku: $SE = \sqrt{\frac{p(1-p)}{n}}$. Galat baku paling besar ketika $p = 0.5$.

Distribusi $\hat{p}$ tidak akan pernah tampak *sepenuhnya* normal, karena $\hat{p}$ akan selalu mengambil nilai-nilai diskret (x/n). Ini selalu menyangkut tingkat kemiripan, dan kita akan menggunakan syarat sukses-gagal baku dengan nilai minimum 10 untuk np dan $n(1 - p)$ sebagai pedoman dalam buku ini.

5.1.6 Memperluas kerangka untuk statistik lain

Strategi menggunakan statistik sampel untuk mengestimasi suatu parameter cukup lazim, dan strategi ini dapat kita terapkan pada statistik lain selain proporsi. Sebagai contoh, jika kita ingin mengestimasi gaji rata-rata lulusan suatu perguruan tinggi, kita dapat menyurvei sampel acak lulusan baru; dalam contoh tersebut, kita menggunakan rata-rata sampel $\bar{x}$ untuk mengestimasi rata-rata populasi μ bagi seluruh lulusan. Sebagai contoh lain, jika kita ingin mengestimasi perbedaan harga produk di dua situs web, kita dapat mengambil sampel acak produk yang tersedia di kedua situs, memeriksa harga pada masing-masing situs, lalu menghitung selisih rata-ratanya; strategi ini tentu memberi kita gambaran tentang selisih sebenarnya melalui suatu estimasi titik.

Walaupun bab ini menekankan konteks satu proporsi, di sepanjang buku ini kita akan menjumpai banyak konteks berbeda tempat metode-metode ini diterapkan. Prinsip dan gagasannya tetap sama, meskipun rinciannya sedikit berubah. Kita juga menyisipkan beberapa konteks lain ke dalam latihan agar Anda mulai memikirkan bagaimana gagasan-gagasan ini dapat digeneralisasi.

Latihan

5.1 Identifikasi parameter, Bagian I. Untuk setiap situasi berikut, tentukan apakah parameter yang menjadi perhatian berupa rata-rata atau proporsi. Akan membantu jika Anda memperhatikan apakah tanggapan setiap individu bersifat numerik atau kategoris.

- Dalam sebuah survei, seratus mahasiswa ditanya berapa jam per minggu yang mereka habiskan di internet.
- Dalam sebuah survei, seratus mahasiswa ditanya: “Berapa persen dari waktu yang Anda habiskan di internet digunakan untuk tugas kuliah?”
- Dalam sebuah survei, seratus mahasiswa ditanya apakah mereka mengutip informasi dari Wikipedia dalam makalah mereka.
- Dalam sebuah survei, seratus mahasiswa ditanya berapa persen dari seluruh pengeluaran mingguan mereka yang digunakan untuk minuman beralkohol.
- Dalam sampel yang terdiri atas seratus lulusan perguruan tinggi baru, ditemukan bahwa 85 persen memperkirakan akan memperoleh pekerjaan dalam satu tahun setelah tanggal kelulusan.

5.2 Identifikasi parameter, Bagian II. Untuk setiap situasi berikut, tentukan apakah parameter yang menjadi perhatian berupa rata-rata atau proporsi.

- Sebuah jajak pendapat menunjukkan bahwa 64% warga Amerika secara pribadi sangat mengkhawatirkan belanja pemerintah federal dan defisit anggaran.
- Sebuah survei melaporkan bahwa pendapatan dari siaran berita televisi lokal meningkat 17% dalam kurun dua tahun, sedangkan pendapatan surat kabar menurun 6,4% selama kurun tersebut.
- Dalam sebuah survei, siswa sekolah menengah dan mahasiswa ditanya apakah mereka menggunakan layanan geolokasi pada ponsel pintar.
- Dalam sebuah survei, pengguna ponsel pintar ditanya apakah mereka menggunakan layanan taksi berbasis web.
- Dalam sebuah survei, pengguna ponsel pintar ditanya berapa kali mereka menggunakan layanan taksi berbasis web selama setahun terakhir.

5.3 Pengendalian mutu. Sebagai bagian dari proses pengendalian mutu cip komputer, seorang insinyur di sebuah pabrik mengambil sampel acak 212 cip selama satu minggu produksi guna mengetahui proporsi cip yang mengalami cacat berat pada saat itu. Ia menemukan bahwa 27 cip mengalami cacat.

- Populasi apa yang dipertimbangkan dalam kumpulan data ini?
- Parameter apa yang sedang diestimasi?
- Berapakah estimasi titik untuk parameter tersebut?
- Apa nama statistik yang kita gunakan untuk mengukur ketidakpastian estimasi titik?
- Hitung nilai dari bagian (d) untuk konteks ini.
- Tingkat cacat historis adalah 10%. Apakah insinyur itu seharusnya terkejut oleh tingkat cacat yang diamati selama minggu berjalan?
- Misalkan nilai populasi yang sebenarnya diketahui sebesar 10%. Jika kita menggunakan proporsi ini untuk menghitung ulang nilai pada bagian (e) dengan menggunakan $p = 0.1$ sebagai pengganti $\hat{p}$, apakah nilai yang dihasilkan banyak berubah?

5.4 Pengeluaran tak terduga. Dalam sampel acak yang terdiri atas 765 orang dewasa di Amerika Serikat, 322 orang mengatakan bahwa mereka tidak mampu menutup pengeluaran tak terduga sebesar \$400 tanpa meminjam uang atau berutang.

- Populasi apa yang dipertimbangkan dalam kumpulan data ini?
- Parameter apa yang sedang diestimasi?
- Berapakah estimasi titik untuk parameter tersebut?
- Apa nama statistik yang kita gunakan untuk mengukur ketidakpastian estimasi titik?
- Hitung nilai dari bagian (d) untuk konteks ini.
- Seorang komentator berita kabel berpendapat bahwa nilainya sebenarnya 50%. Apakah ia seharusnya terkejut oleh data tersebut?
- Misalkan nilai populasi yang sebenarnya diketahui sebesar 40%. Jika kita menggunakan proporsi ini untuk menghitung ulang nilai pada bagian (e) dengan menggunakan $p = 0.4$ sebagai pengganti $\hat{p}$, apakah nilai yang dihasilkan banyak berubah?

5.5 Sampel air berulang. Sebuah organisasi nirlaba ingin memahami proporsi rumah tangga yang memiliki kadar timbal tinggi dalam air minumannya. Mereka memperkirakan sedikitnya 5% rumah memiliki kadar timbal tinggi, tetapi tidak lebih dari sekitar 30%. Mereka mengambil sampel acak 800 rumah dan bekerja sama dengan para pemilik untuk memperoleh sampel air, lalu menghitung proporsi rumah tersebut yang memiliki kadar timbal tinggi. Mereka mengulangi proses ini 1.000 kali dan membentuk sebuah distribusi proporsi sampel.

- (a) Apa nama distribusi ini?
- (b) Apakah Anda memperkirakan bentuk distribusi ini simetris, menceng kanan, atau menceng kiri? Jelaskan penalaran Anda.
- (c) Jika proporsi-proporsi tersebut tersebar di sekitar 8%, berapakah variabilitas distribusinya?
- (d) Apa nama formal nilai yang Anda hitung pada bagian (c)?
- (e) Misalkan anggaran para peneliti dikurangi sehingga mereka hanya mampu mengumpulkan 250 pengamatan per sampel, tetapi tetap dapat mengumpulkan 1.000 sampel. Mereka membentuk distribusi baru proporsi sampel. Bagaimana perbandingan variabilitas distribusi baru ini dengan variabilitas distribusi ketika setiap sampel memuat 800 pengamatan?

5.6 Sampel mahasiswa berulang. Di antara seluruh mahasiswa tahun pertama pada sebuah perguruan tinggi besar, 16% masuk daftar prestasi dekan pada tahun berjalan. Sebagai bagian dari proyek kelas, para mahasiswa mengambil sampel acak 40 mahasiswa dan memeriksa apakah mereka masuk daftar tersebut. Mereka mengulangi proses ini 1.000 kali dan membentuk sebuah distribusi proporsi sampel.

- (a) Apa nama distribusi ini?
- (b) Apakah Anda memperkirakan bentuk distribusi ini simetris, menceng kanan, atau menceng kiri? Jelaskan penalaran Anda.
- (c) Hitung variabilitas distribusi ini.
- (d) Apa nama formal nilai yang Anda hitung pada bagian (c)?
- (e) Misalkan para mahasiswa memutuskan mengambil sampel lagi, kali ini sebanyak 90 mahasiswa per sampel, dan kembali mengumpulkan 1.000 sampel. Mereka membentuk distribusi baru proporsi sampel. Bagaimana perbandingan variabilitas distribusi baru ini dengan variabilitas distribusi ketika setiap sampel memuat 40 pengamatan?

5.2 Interval kepercayaan untuk suatu proporsi

Proporsi sampel $\hat{p}$ memberikan satu nilai yang masuk akal untuk proporsi populasi p . Namun, proporsi sampel tidaklah sempurna dan memiliki suatu *galat baku* yang terkait dengannya. Ketika menyatakan suatu estimasi untuk proporsi populasi, praktik yang lebih baik adalah memberikan suatu *rentang nilai yang masuk akal*, bukan hanya memberikan estimasi titiknya.

5.2.1 Mencakup parameter populasi

Menggunakan estimasi titik saja ibarat menangkap ikan dengan tombak di danau yang keruh. Kita dapat melempar tombak ke tempat kita melihat seekor ikan, tetapi kemungkinan besar akan meleset. Sebaliknya, jika kita menebar jala di area tersebut, peluang kita untuk menangkap ikan itu cukup besar. Suatu **interval kepercayaan** ibarat menangkap ikan dengan jala, dan interval ini merepresentasikan rentang nilai yang masuk akal tempat parameter populasi kemungkinan berada.

Jika kita melaporkan estimasi titik $\hat{p}$, kemungkinan besar kita tidak akan tepat mengenai proporsi populasi yang sebenarnya. Sebaliknya, jika kita melaporkan rentang nilai yang masuk akal, yang merepresentasikan suatu interval kepercayaan, kita memiliki peluang besar untuk mencakup parameter tersebut.

LATIHAN TERBIMBING 5.6



Jika kita ingin sangat yakin bahwa interval kita mencakup proporsi populasi, apakah sebaiknya kita menggunakan interval yang lebih lebar atau interval yang lebih sempit?⁶

5.2.2 Menyusun interval kepercayaan 95%

Proporsi sampel $\hat{p}$ merupakan nilai yang paling masuk akal bagi proporsi populasi, sehingga wajar untuk menyusun interval kepercayaan di sekitar estimasi titik ini. Galat baku memberikan pedoman mengenai seberapa lebar interval kepercayaan yang sebaiknya kita buat.


Galat baku merepresentasikan simpangan baku dari estimasi titik, dan ketika syarat-syarat Teorema Limit Pusat terpenuhi, distribusi estimasi titik cukup mendekati distribusi normal. Dalam distribusi normal, 95% data berada dalam jarak 1.96 simpangan baku dari rata-rata. Dengan menggunakan prinsip ini, kita dapat menyusun interval kepercayaan yang membentang sejauh 1.96 galat baku dari proporsi sampel sehingga kita **yakin 95%** bahwa interval tersebut mencakup proporsi populasi:

$$\text{estimasi titik} \pm 1.96 \times SE$$

$$\hat{p} \pm 1.96 \times \sqrt{\frac{p(1-p)}{n}}$$

Namun, apa arti “yakin 95%”? Misalkan kita mengambil banyak sampel dan menyusun interval kepercayaan 95% dari masing-masing sampel. Maka, sekitar 95% dari interval-interval tersebut akan memuat parameter p . Gambar 5.6 menunjukkan proses pembuatan 25 interval dari 25 sampel dalam simulasi pada Bagian 5.1.2, dengan 24 interval kepercayaan yang dihasilkan memuat proporsi populasi simulasi sebesar $p = 0.88$, sedangkan satu interval tidak memuatnya.

⁶Jika kita ingin lebih yakin akan menangkap ikan tersebut, kita dapat menggunakan jala yang lebih lebar. Demikian pula, kita menggunakan interval kepercayaan yang lebih lebar jika ingin lebih yakin bahwa interval itu mencakup parameter tersebut.



Gambar 5.6: Dua puluh lima estimasi titik dan interval kepercayaan dari simulasi pada Bagian 5.1.2. Interval-interval ini ditampilkan relatif terhadap proporsi populasi $p = 0.88$. Hanya 1 dari 25 interval ini yang tidak mencakup proporsi populasi, dan interval tersebut dicetak tebal.

CONTOH 5.7

Pada Gambar 5.6, satu interval tidak memuat $p = 0.88$. Apakah hal ini menyiratkan bahwa proporsi populasi yang digunakan dalam simulasi tidak mungkin $p = 0.88$?

(E)

Sebagaimana beberapa observasi secara alami berjarak lebih dari 1.96 simpangan baku dari rata-rata, beberapa estimasi titik akan berjarak lebih dari 1.96 galat baku dari parameter yang menjadi perhatian. Interval kepercayaan hanya memberikan rentang nilai yang masuk akal. Meskipun berdasarkan data kita dapat mengatakan bahwa nilai-nilai lain tidak masuk akal, hal ini tidak berarti bahwa nilai-nilai tersebut mustahil.

INTERVAL KEPERCAYAAN 95% UNTUK SUATU PARAMETER

Ketika distribusi suatu estimasi titik memenuhi syarat untuk menerapkan Teorema Limit Pusat dan oleh karena itu cukup mendekati distribusi normal, kita dapat menyusun interval kepercayaan 95% sebagai

$$\text{estimasi titik} \pm 1.96 \times SE$$

CONTOH 5.8

Pada Bagian 5.1 kita mempelajari jajak pendapat Pew Research yang menunjukkan bahwa 88.7% dari sampel acak berisi 1000 orang dewasa Amerika mendukung perluasan peran tenaga surya. Hitung dan maknai interval kepercayaan 95% untuk proporsi populasi.

(E)

Sebelumnya, kita telah memastikan bahwa $\hat{p}$ mengikuti distribusi normal dan memiliki galat baku sebesar $SE_{\hat{p}} = 0.010$. Untuk menghitung interval kepercayaan 95%, substitusikan estimasi titik $\hat{p} = 0.887$ dan galat baku ke dalam rumus interval kepercayaan 95%:

$$\hat{p} \pm 1.96 \times SE_{\hat{p}} \rightarrow 0.887 \pm 1.96 \times 0.010 \rightarrow (0.8674, 0.9066)$$

Kita yakin 95% bahwa proporsi sebenarnya dari orang dewasa Amerika yang mendukung perluasan tenaga surya berada antara 86.7% dan 90.7%. (Ketika melaporkan interval kepercayaan, lazim untuk membulatkan ke poin persentase terdekat atau persepuluhan poin persentase terdekat.)

5.2.3 Mengubah tingkat kepercayaan

Misalkan kita ingin mempertimbangkan interval kepercayaan dengan tingkat kepercayaan yang lebih tinggi daripada 95%, misalnya tingkat kepercayaan 99%. Ingat kembali analogi tentang upaya menangkap ikan: jika kita ingin lebih yakin bahwa ikan itu akan tertangkap, kita sebaiknya menggunakan jala yang lebih lebar. Untuk menghasilkan tingkat kepercayaan 99%, kita juga harus memperlebar interval 95% kita. Sebaliknya, jika kita menginginkan interval dengan tingkat kepercayaan yang lebih rendah, misalnya 90%, kita dapat menggunakan interval yang sedikit lebih sempit daripada interval 95% semula.

Struktur interval kepercayaan 95% memberikan pedoman untuk membuat interval dengan tingkat kepercayaan yang berbeda. Interval kepercayaan 95% yang umum bagi estimasi titik yang mengikuti distribusi normal adalah

$$\text{estimasi titik} \pm 1.96 \times SE$$

Interval ini memiliki tiga komponen: estimasi titik, “1.96”, dan galat baku. Pemilihan $1.96 \times SE$ didasarkan pada pencakupan 95% data karena estimasi tersebut berada dalam jarak 1.96 galat baku dari parameter sekitar 95% dari waktu pengambilan sampel. Pemilihan 1.96 bersesuaian dengan tingkat kepercayaan 95%.

LATIHAN TERBIMBING 5.9



Jika X adalah variabel acak yang berdistribusi normal, berapakah peluang bahwa nilai X berada dalam jarak 2.58 simpangan baku dari rata-rata?⁷

Latihan Terpandu 5.9 menunjukkan bahwa dalam 99% kasus, variabel acak normal akan berada dalam jarak 2.58 simpangan baku dari rata-rata. Untuk membuat interval kepercayaan 99%, ubah 1.96 dalam rumus interval kepercayaan 95% menjadi 2.58. Dengan kata lain, rumus untuk interval kepercayaan 99% adalah

$$\text{estimasi titik} \pm 2.58 \times SE$$

Pendekatan ini—menggunakan skor-Z dalam model normal untuk menghitung tingkat kepercayaan—tepat digunakan ketika suatu estimasi titik seperti $\hat{p}$ berkaitan dengan distribusi normal. Untuk beberapa estimasi titik lainnya, model normal tidak cocok; dalam kasus-kasus ini, kita akan menggunakan distribusi alternatif yang lebih baik dalam merepresentasikan distribusi sampling.

INTERVAL KEPERCAYAAN DENGAN TINGKAT KEPERCAYAAN APA PUN

Jika distribusi suatu estimasi titik cukup mendekati model normal dan memiliki galat baku SE , maka interval kepercayaan untuk parameter populasi adalah

$$\text{estimasi titik} \pm z^* \times SE$$


dengan z^* bersesuaian dengan tingkat kepercayaan yang dipilih.

Gambar 5.7 mengilustrasikan cara menentukan z^* berdasarkan tingkat kepercayaan. Kita memilih z^* sedemikian rupa sehingga luas antara $-z^*$ dan z^* pada distribusi normal baku, $N(0, 1)$, bersesuaian dengan tingkat kepercayaan tersebut.

BATAS GALAT

Dalam suatu interval kepercayaan, $z^* \times SE$ disebut **batas galat**.

⁷Hal ini setara dengan menanyakan seberapa sering skor-Z lebih besar daripada -2.58 tetapi lebih kecil daripada 2.58. Untuk melihat ilustrasinya, lihat Gambar 5.7. Untuk menentukan peluang ini, kita dapat menggunakan perangkat lunak statistik, kalkulator, atau tabel untuk mencari nilai -2.58 dan 2.58 pada distribusi normal: 0.0049 dan 0.9951. Dengan demikian, terdapat peluang $0.9951 - 0.0049 \approx 0.99$ bahwa suatu variabel acak normal X yang belum diobservasi akan berada dalam jarak 2.58 simpangan baku dari μ .



Gambar 5.7: Luas antara $-z^*$ dan z^* bertambah ketika z^* membesar. Jika tingkat kepercayaannya 99%, kita memilih z^* sedemikian rupa sehingga 99% dari suatu distribusi normal berada di antara $-z^*$ dan z^* , yang berarti 0.5% berada di ekor bawah dan 0.5% di ekor atas: $z^* = 2.58$.

CONTOH 5.10

Gunakan data dalam Contoh 5.8 untuk membuat interval kepercayaan 90% bagi proporsi orang dewasa Amerika yang mendukung perluasan penggunaan tenaga surya. Kita telah memastikan bahwa syarat kenormalan terpenuhi.

Pertama, kita menentukan z^* sedemikian rupa sehingga 90% distribusi berada di antara $-z^*$ dan z^* pada distribusi normal baku, $N(\mu = 0, \sigma = 1)$. Kita dapat melakukannya dengan kalkulator grafik, perangkat lunak statistik, atau tabel peluang dengan mencari ekor atas sebesar 5% (5% lainnya berada di ekor bawah): $z^* = 1.65$. Interval kepercayaan 90% kemudian dapat dihitung sebagai

$$\hat{p} \pm 1.6449 \times SE_{\hat{p}} \rightarrow 0.887 \pm 1.65 \times 0.0100 \rightarrow (0.8705, 0.9034)$$

Artinya, kita yakin 90% bahwa 87.1% hingga 90.3% orang dewasa Amerika mendukung perluasan tenaga surya pada tahun 2018.

INTERVAL KEPERCAYAAN UNTUK SATU PROPORSI

Setelah Anda menentukan bahwa interval kepercayaan satu proporsi akan berguna untuk suatu penerapan, terdapat empat langkah untuk menyusun interval tersebut:

Persiapkan. Tentukan $\hat{p}$ dan n , serta tetapkan tingkat kepercayaan yang ingin Anda gunakan.

Periksa. Pastikan syarat-syaratnya terpenuhi sehingga $\hat{p}$ mendekati distribusi normal. Untuk interval kepercayaan satu proporsi, gunakan $\hat{p}$ sebagai pengganti p untuk memeriksa syarat sukses-gagal.

Hitung. Jika syarat-syaratnya terpenuhi, hitung SE menggunakan $\hat{p}$, tentukan z^* , dan susun intervalnya.

Simpulkan. Maknai interval kepercayaan sesuai dengan konteks masalahnya.

5.2.4 Studi kasus lainnya

Di Kota New York pada 23 Oktober 2014, seorang dokter yang baru saja merawat pasien Ebola di Guinea pergi ke rumah sakit karena mengalami demam ringan dan kemudian didiagnosis mengidap Ebola. Tidak lama setelah itu, sebuah jajak pendapat NBC 4 New York/The Wall Street Journal/Marist menemukan bahwa 82% warga New York mendukung “karantina wajib selama 21 hari bagi siapa pun yang pernah melakukan kontak dengan seorang pasien Ebola”. Jajak pendapat ini memuat tanggapan dari 1,042 orang dewasa di New York antara 26 dan 28 Oktober 2014.

CONTOH 5.11

Apa estimasi titik dalam kasus ini, dan apakah masuk akal untuk menggunakan distribusi normal guna memodelkan estimasi titik tersebut?

- (E) Estimasi titiknya, berdasarkan sampel berukuran $n = 1042$, adalah $\hat{p} = 0.82$. Untuk memeriksa apakah $\hat{p}$ dapat secara masuk akal dimodelkan menggunakan distribusi normal, kita memeriksa independensi (jajak pendapat didasarkan pada sampel acak sederhana) dan syarat sukses–gagal ($1042 \times \hat{p} \approx 854$ dan $1042 \times (1 - \hat{p}) \approx 188$, keduanya jelas lebih besar dari 10). Karena syarat-syarat tersebut terpenuhi, kita memperoleh kepastian bahwa distribusi sampling dari $\hat{p}$ dapat secara masuk akal dimodelkan menggunakan distribusi normal.

CONTOH 5.12

Estimasikan galat baku dari $\hat{p} = 0.82$ pada survei Ebola.

- (E) Kita akan menggunakan pendekatan substitusi $p \approx \hat{p} = 0.82$ untuk menghitung galat baku:

$$SE_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}} \approx \sqrt{\frac{0.82(1-0.82)}{1042}} = 0.012$$

CONTOH 5.13

Buatlah interval kepercayaan 95% untuk p , yaitu proporsi orang dewasa di New York yang mendukung karantina bagi siapa pun yang pernah melakukan kontak dengan seorang pasien Ebola.

- (E) Dengan menggunakan galat baku $SE = 0.012$ dari Contoh 5.12, estimasi titik 0.82, dan $z^* = 1.96$ untuk tingkat kepercayaan 95%, interval kepercayaannya adalah

$$\text{estimasi titik} \pm z^* \times SE \rightarrow 0.82 \pm 1.96 \times 0.012 \rightarrow (0.796, 0.844)$$

Kita yakin 95% bahwa proporsi orang dewasa di New York pada Oktober 2014 yang mendukung karantina bagi siapa pun yang pernah melakukan kontak dengan seorang pasien Ebola berada antara 0.796 dan 0.844.

LATIHAN TERBIMBING 5.14

Jawablah dua pertanyaan berikut tentang interval kepercayaan dari Contoh 5.13:⁸

- (G) (a) Apa arti yakin 95% dalam konteks ini?
 (b) Menurut Anda, apakah interval kepercayaan tersebut masih berlaku bagi pendapat warga New York saat ini?

⁸(a) Jika kita mengambil banyak sampel seperti ini dan menghitung interval kepercayaan 95% untuk masing-masing sampel, maka sekitar 95% dari interval tersebut akan mencakup proporsi sebenarnya dari orang dewasa di New York yang mendukung karantina bagi siapa pun yang pernah melakukan kontak dengan seorang pasien Ebola.
 (b) Belum tentu. Jajak pendapat tersebut dilakukan pada saat terdapat kekhawatiran besar mengenai keselamatan publik. Setelah orang-orang memiliki waktu untuk mengambil jarak, pendapat mereka mungkin telah berubah. Kita perlu menjalankan jajak pendapat baru jika ingin memperoleh estimasi proporsi orang dewasa di New York saat ini yang akan mendukung masa karantina semacam itu.

LATIHAN TERBIMBING 5.15

Dalam jajak pendapat Pew Research mengenai energi surya, mereka juga menanyakan bentuk-bentuk energi lainnya, dan 84.8% dari 1000 responden mendukung perluasan penggunaan turbin angin.⁹

- (a) Apakah masuk akal untuk memodelkan proporsi orang dewasa AS yang mendukung perluasan penggunaan turbin angin menggunakan distribusi normal?
- (b) Buatlah interval kepercayaan 99% bagi tingkat dukungan warga Amerika terhadap perluasan penggunaan turbin angin untuk pembangkitan listrik.

Kita juga dapat membuat interval kepercayaan untuk parameter lain, seperti rata-rata populasi. Dalam kasus-kasus ini, interval kepercayaan akan dihitung dengan cara yang serupa dengan interval untuk satu proporsi: estimasi titik ditambah/dikurangi suatu batas galat. Kita akan membahas perincian ini pada bab-bab selanjutnya.

5.2.5 Menafsirkan interval kepercayaan

Dalam setiap contoh, kita menguraikan interval kepercayaan dengan menempatkannya dalam konteks data dan juga menggunakan bahasa yang cukup formal:

Surya. Kita yakin 90% bahwa 87.1% hingga 90.3% dari orang dewasa Amerika mendukung perluasan tenaga surya pada 2018.

Ebola. Kita yakin 95% bahwa proporsi orang dewasa di New York pada Oktober 2014 yang mendukung karantina bagi siapa pun yang pernah melakukan kontak dengan seorang pasien Ebola berada antara 0.796 dan 0.844.

Turbin Angin. Kita yakin 99% bahwa proporsi orang dewasa Amerika yang mendukung perluasan penggunaan turbin angin berada antara 81.9% dan 87.7% pada 2018.

Pertama, perhatikan bahwa pernyataan-pernyataan tersebut selalu mengenai parameter populasi, yang mencakup *semua* orang dewasa Amerika untuk jajak pendapat energi atau *semua* orang dewasa di New York untuk jajak pendapat karantina.

Kita juga menghindari kesalahan umum lainnya: bahasa yang *keliru* mungkin mencoba menggambarkan interval kepercayaan seolah-olah mencakup parameter populasi dengan peluang tertentu. Memberikan penafsiran peluang merupakan kesalahan umum: meskipun memikirkannya sebagai peluang mungkin berguna, tingkat kepercayaan hanya mengukur seberapa masuk akal bahwa parameter berada dalam interval yang diberikan.

Pertimbangan penting lainnya mengenai interval kepercayaan adalah bahwa interval tersebut *hanya berkaitan dengan parameter populasi*. Interval kepercayaan tidak menyatakan apa pun tentang pengamatan individual atau estimasi titik. Interval kepercayaan hanya menyediakan rentang yang masuk akal bagi parameter populasi.

Terakhir, ingatlah bahwa metode yang kita bahas hanya berlaku untuk galat pengambilan sampel, bukan untuk bias. Jika suatu set data dikumpulkan dengan cara yang cenderung secara sistematis menghasilkan estimasi yang terlalu rendah (atau terlalu tinggi) terhadap parameter populasi, teknik-teknik yang telah kita bahas tidak akan mengatasi masalah tersebut. Sebaliknya, kita mengandalkan prosedur pengumpulan data yang cermat untuk membantu mencegah bias dalam

⁹(a) Survei tersebut merupakan sampel acak dan kedua hitungannya ≥ 10 ($1000 \times 0.848 = 848$ dan $1000 \times 0.152 = 152$), sehingga independensi dan syarat sukses-gagal terpenuhi, dan $\hat{p} = 0.848$ dapat dimodelkan menggunakan distribusi normal.

(b) Latihan Terpandu 5.15 mengonfirmasi bahwa distribusi $\hat{p}$ cukup mendekati distribusi normal, sehingga kita dapat menggunakan rumus interval kepercayaan:

$$\text{estimasi titik} \pm z^* \times SE$$

Dalam kasus ini, estimasi titiknya adalah $\hat{p} = 0.848$. Untuk interval kepercayaan 99%, $z^* = 2.58$. Dengan menghitung galat baku: $SE_{\hat{p}} = \sqrt{\frac{0.848(1-0.848)}{1000}} = 0.0114$. Terakhir, kita menghitung intervalnya sebagai $0.848 \pm 2.58 \times 0.0114 \rightarrow (0.8186, 0.8774)$. Penting juga untuk *selalu* memberikan penafsiran interval tersebut: kita yakin 99% bahwa proporsi orang dewasa Amerika yang mendukung perluasan penggunaan turbin angin pada 2018 berada antara 81.9% dan 87.7%.

contoh-contoh yang telah kita bahas, yang merupakan praktik umum yang digunakan ilmuwan data untuk menanggulangi bias.

LATIHAN TERBIMBING 5.16



Pertimbangkan interval kepercayaan 90% untuk survei energi surya: 87.1% hingga 90.3%. Jika kita menjalankan survei tersebut kembali, dapatkah kita mengatakan bahwa kita yakin 90% bahwa proporsi survei yang baru akan berada antara 87.1% dan 90.3%?¹⁰

Latihan

5.7 Penyakit kronis, Bagian I. Pada 2013, Pew Research Foundation melaporkan bahwa “45% orang dewasa AS menyatakan bahwa mereka hidup dengan satu atau lebih penyakit kronis”.¹¹ Namun, nilai ini didasarkan pada suatu sampel, sehingga nilai itu sendiri mungkin bukan estimasi yang sempurna bagi parameter populasi yang menjadi perhatian. Studi tersebut melaporkan galat baku sekitar 1.2%, dan model normal dapat digunakan secara masuk akal dalam situasi ini. Buatlah interval kepercayaan 95% bagi proporsi orang dewasa AS yang hidup dengan satu atau lebih penyakit kronis. Selain itu, tafsirlah interval kepercayaan tersebut dalam konteks studi.

5.8 Pengguna Twitter dan berita, Bagian I. Sebuah jajak pendapat yang dilakukan pada 2013 menemukan bahwa 52% pengguna Twitter dewasa di AS mendapatkan setidaknya sebagian berita dari Twitter.¹² Galat baku untuk estimasi ini adalah 2.4%, dan distribusi normal dapat digunakan untuk memodelkan proporsi sampel. Buatlah interval kepercayaan 99% bagi proporsi pengguna Twitter dewasa di AS yang mendapatkan sebagian berita dari Twitter, dan tafsirlah interval kepercayaan tersebut dalam konteksnya.

5.9 Penyakit kronis, Bagian II. Pada 2013, Pew Research Foundation melaporkan bahwa “45% orang dewasa AS menyatakan bahwa mereka hidup dengan satu atau lebih penyakit kronis”, dan galat baku untuk estimasi ini adalah 1.2%. Tentukan apakah setiap pernyataan berikut benar atau salah. Berikan penjelasan untuk membenarkan setiap jawaban Anda.

- Kita dapat mengatakan dengan pasti bahwa interval kepercayaan dari Latihan 5.7 mencakup persentase sebenarnya dari orang dewasa AS yang mengidap penyakit kronis.
- Jika kita mengulangi studi ini 1,000 kali dan membuat interval kepercayaan 95% untuk setiap studi, maka sekitar 950 dari interval kepercayaan tersebut akan mencakup proporsi sebenarnya dari orang dewasa AS yang mengidap penyakit kronis.
- Jajak pendapat tersebut menyediakan bukti yang signifikan secara statistik (pada tingkat $\alpha = 0.05$) bahwa persentase orang dewasa AS yang mengidap penyakit kronis berada di bawah 50%.
- Karena galat bakunya 1.2%, hanya 1.2% orang dalam studi tersebut yang menyatakan ketidakpastian tentang jawaban mereka.

5.10 Pengguna Twitter dan berita, Bagian II. Sebuah jajak pendapat yang dilakukan pada 2013 menemukan bahwa 52% pengguna Twitter dewasa di AS mendapatkan setidaknya sebagian berita dari Twitter, dan galat baku untuk estimasi ini adalah 2.4%. Tentukan apakah setiap pernyataan berikut benar atau salah. Berikan penjelasan untuk membenarkan setiap jawaban Anda.

- Data tersebut menyediakan bukti yang signifikan secara statistik bahwa lebih dari separuh pengguna Twitter dewasa di AS mendapatkan sebagian berita melalui Twitter. Gunakan tingkat signifikansi $\alpha = 0.01$. (Bagian ini menggunakan konsep dari Bagian belum dimuat dan akan diperbaiki dalam edisi mendatang.)
- Karena galat bakunya 2.4%, kita dapat menyimpulkan bahwa 97.6% dari seluruh pengguna Twitter dewasa di AS disertakan dalam studi tersebut.
- Jika ingin mengurangi galat baku estimasi, kita seharusnya mengumpulkan lebih sedikit data.
- Jika kita membuat interval kepercayaan 90% bagi persentase pengguna Twitter dewasa di AS yang mendapatkan sebagian berita melalui Twitter, interval kepercayaan ini akan lebih lebar daripada interval kepercayaan 99% yang bersesuaian.

¹⁰Tidak, interval kepercayaan hanya menyediakan rentang nilai yang masuk akal bagi suatu parameter, bukan estimasi titik pada masa mendatang.

¹¹Pew Research Center, Washington, D.C. *The Diagnosis Difference*, November 26, 2013.

¹²Pew Research Center, Washington, D.C. *Twitter News Consumers: Young, Mobile and Educated*, November 4, 2013.

5.11 Menunggu di IGD, Bagian I. Seorang administrator rumah sakit yang berharap dapat memperbaiki waktu tunggu memutuskan untuk mengestimasi rata-rata waktu tunggu di instalasi gawat darurat rumah sakitnya. Ia mengambil sampel acak sederhana yang terdiri atas 64 pasien dan menentukan waktu (dalam menit) sejak mereka mendaftar di IGD hingga pertama kali diperiksa oleh seorang dokter. Interval kepercayaan 95% berdasarkan sampel ini adalah (128 menit, 147 menit), yang didasarkan pada model normal untuk rata-rata. Tentukan apakah pernyataan-pernyataan berikut benar atau salah, dan jelaskan alasan Anda.

- (a) Kita yakin 95% bahwa rata-rata waktu tunggu dari 64 pasien instalasi gawat darurat ini berada antara 128 dan 147 menit.
- (b) Kita yakin 95% bahwa rata-rata waktu tunggu semua pasien di instalasi gawat darurat rumah sakit ini berada antara 128 dan 147 menit.
- (c) 95% sampel acak memiliki rata-rata sampel antara 128 dan 147 menit.
- (d) Interval kepercayaan 99% akan lebih sempit daripada interval kepercayaan 95% karena kita perlu lebih yakin terhadap estimasi kita.
- (e) Batas galatnya adalah 9.5 dan rata-rata sampelnya adalah 137.5.
- (f) Untuk memperkecil batas galat interval kepercayaan 95% menjadi separuh nilainya saat ini, kita perlu menggandakan ukuran sampel. (Petunjuk: batas galat bagi rata-rata berskala dengan cara yang sama terhadap ukuran sampel seperti batas galat bagi proporsi.)

5.12 Kesehatan mental. General Social Survey mengajukan pertanyaan: “Selama berapa hari dalam 30 hari terakhir kondisi kesehatan mental Anda, yang mencakup stres, depresi, dan masalah emosi, tidak baik?” Berdasarkan tanggapan dari 1,151 penduduk AS, survei tersebut melaporkan interval kepercayaan 95% sebesar 3.40 hingga 4.24 hari pada 2010.

- (a) Tafsirkan interval ini dalam konteks data.
- (b) Apa arti “yakin 95%”? Jelaskan dalam konteks penerapannya.
- (c) Misalkan para peneliti berpendapat bahwa tingkat kepercayaan 99% akan lebih sesuai untuk interval ini. Apakah interval yang baru ini akan lebih sempit atau lebih lebar daripada interval kepercayaan 95%?
- (d) Jika sebuah survei baru dilakukan terhadap 500 orang Amerika, apakah menurut Anda galat baku estimasinya akan lebih besar, lebih kecil, atau kurang lebih sama.

5.13 Pendaftaran situs web. Sebuah situs web berupaya meningkatkan pendaftaran pengunjung pertama kali dengan menampilkan desain situs baru kepada 1% dari para pengunjung tersebut. Dari 752 pengunjung yang diambil secara acak selama sebulan dan melihat desain baru itu, 64 orang mendaftar.

- (a) Periksa setiap syarat yang diperlukan untuk membuat interval kepercayaan.
- (b) Hitunglah galat bakunya.
- (c) Buat dan tafsirkan interval kepercayaan 90% bagi proporsi pengunjung pertama kali situs tersebut yang akan mendaftar dengan desain baru (dengan mengasumsikan perilaku pengunjung baru stabil dari waktu ke waktu).

5.14 Kupon yang mendorong kunjungan. Sebuah toko mengambil sampel acak sebanyak 603 pembeli selama satu tahun dan mendapati bahwa 142 di antaranya berkunjung karena kupon yang mereka terima melalui pos. Buatlah interval kepercayaan 95% bagi proporsi seluruh pembeli selama tahun tersebut yang berkunjung karena kupon yang mereka terima melalui pos.

Lampiran A

Solusi latihan

1 Pengantar data

1.1 (a) Perlakuan: $10/43 = 0.23 \rightarrow 23\%$.

(b) Kontrol: $2/46 = 0.04 \rightarrow 4\%$. (c) Persentase pasien yang bebas nyeri 24 jam setelah menerima akupunktur lebih tinggi dalam kelompok perlakuan. (d) Perbedaan persentase yang teramati antara kedua kelompok mungkin terjadi karena kebetulan.

1.3 (a) “Apakah ada hubungan antara paparan polusi udara dan kelahiran prematur?” (b) 143,196 kelahiran di California Selatan antara tahun 1989 dan 1993. (c) Pengukuran konsentrasi karbon monoksida, nitrogen dioksida, ozon, dan partikulat kasar PM_{10} (partikel dengan diameter aerodinamik hingga $10 \mu m$, dengan konsentrasi dinyatakan dalam $\mu g/m^3$) yang dikumpulkan di stasiun pemantau kualitas udara, serta lama kehamilan. Semuanya merupakan variabel numerik kontinu.

1.5 (a) “Apakah memberi tahu anak-anak secara tegas agar tidak berbuat curang memengaruhi kemungkinan mereka berbuat curang?” (b) 160 anak berusia antara 5 dan 15 tahun. (c) Lima variabel: (1) usia (numerik, kontinu), (2) jenis kelamin (kategoris), (3) apakah mereka anak tunggal (kategoris), (4) apakah mereka menerima petunjuk tegas agar tidak berbuat curang (kategoris), dan (5) apakah mereka berbuat curang (kategoris).

1.7 Variabel penjelas: jenis akupunktur yang diterima, yaitu akupunktur yang dirancang untuk menangani migrain atau akupunktur plasebo pada lokasi yang bukan titik akupunktur. Variabel respons: apakah pasien bebas nyeri setelah 24 jam.

1.9 (a) $50 \times 3 = 150$. (b) Empat variabel numerik kontinu: panjang sepal, lebar sepal, panjang petal, dan lebar petal. (c) Satu variabel kategoris, yaitu spesies, dengan tiga level: *setosa*, *versicolor*, dan *virginica*.

1.11 (a) Status kepemilikan bandara (publik/privat), status penggunaan bandara (publik/privat), lintang, dan bujur. (b) Status kepemilikan bandara: kategoris, bukan ordinal. Status penggunaan bandara: kategoris, bukan ordinal. Lin-

tang: numerik, kontinu. Bujur: numerik, kontinu.

1.13 (a) Populasi sasaran: kelahiran di California Selatan dalam cakupan tempat dan waktu yang hendak diinferensikan; sampel: 143.196 kelahiran antara tahun 1989 dan 1993 di California Selatan. (b) Jika kelahiran dalam sampel pada rentang waktu dan wilayah tersebut dapat dianggap mewakili populasi sasaran, hasilnya dapat digeneralisasikan ke kelahiran dalam cakupan itu. Namun, karena studi ini bersifat observasional, temuannya tidak dapat digunakan untuk menetapkan hubungan kausal.

1.15 (a) Populasi: seluruh pasien asma berusia 18–69 tahun yang mengandalkan obat untuk pengobatan asma. Sampel: 600 pasien tersebut. (b) Jika pasien dalam sampel ini, yang kemungkinan tidak diambil secara acak, dapat dianggap mewakili seluruh pasien asma berusia 18–69 tahun yang mengandalkan obat untuk pengobatan asma, hasilnya dapat digeneralisasikan ke populasi yang didefinisikan di atas. Selain itu, karena studi ini merupakan eksperimen dengan penugasan acak, temuannya dapat digunakan untuk menetapkan hubungan kausal.

1.17 (a) Observasi. (b) Variabel. (c) Statistik sampel (rata-rata). (d) Parameter populasi (rata-rata).

1.19 (a) Studi observasional. (b) Gunakan pengambilan sampel berstrata untuk mengambil secara acak sejumlah tetap mahasiswa, misalnya 10 orang, dari setiap kelas praktikum sehingga ukuran sampel totalnya 40 mahasiswa.

1.21 (a) Positif, nonlinear, dan cukup kuat. Negara dengan persentase penduduk pengguna internet yang lebih tinggi juga cenderung memiliki harapan hidup saat lahir yang lebih tinggi, tetapi kenaikannya mulai melandai ketika mendekati 80 tahun. (b) Studi observasional. (c) Kemakmuran: negara yang penduduknya secara luas mampu membayar akses internet kemungkinan juga mampu membayar layanan kesehatan dasar. (Catatan: Jawaban dapat bervariasi.)

1.23 (a) Pengambilan sampel acak sederhana layak

digunakan. Bahkan, jarang sekali metode ini tidak masuk akal untuk digunakan! (b) Pendapat mahasiswa mungkin berbeda menurut bidang studi, sehingga stratifikasi berdasarkan variabel ini masuk akal dan layak digunakan. (c) Mahasiswa yang seusia mungkin memiliki pendapat yang lebih serupa,

1.25 (a) Kasusnyanya adalah 200 peserta dari kalangan laki-laki dan perempuan yang diambil sebagai sampel acak. (b) Variabel responsnyanya adalah sikap terhadap sebuah oven gelombang mikro fiktif. (c) Variabel penjelasnya adalah sikap disposisional. (d) Ya, kasus-kasus tersebut diambil secara acak. (e) Ini adalah studi observasional karena tidak ada penugasan acak ke perlakuan. (f) Tidak, kita tidak dapat menetapkan hubungan kausal antara variabel penjelas dan variabel respons karena studi ini bersifat observasional. (g) Hasil hanya dapat digeneralisasikan ke populasi yang tercakup dalam kerangka asal pemilihan 200 peserta. Soal tidak menyebutkan kerangka tersebut, sehingga generalisasi ke populasi yang lebih luas tidak dapat dipastikan.

1.27 (a) Sampel acak sederhana. Bias nonrespons dapat muncul: jika hanya orang-orang yang memiliki pendapat kuat tentang survei yang merespons, sampelnya mungkin tidak mewakili populasi. (b) Sampel kemudahan. Sampelnya mungkin tidak mewakili populasi karena hanya terdiri atas teman-temannya. Studi ini juga dapat mengalami bias nonrespons jika sebagian orang memilih untuk tidak mengembalikan survei. (c) Sampel kemudahan. Cara ini menghadapi masalah yang serupa dengan pembagian survei kepada teman-teman. (d) Pengambilan sampel multitahap. Bias bergantung pada peluang inklusi siswa, pembobotan bila peluang itu berbeda, dan nonrespons. Kemiripan antarkelas terutama memengaruhi presisi; kemiripan itu sendiri tidak menjamin bahwa estimasi bebas bias.

1.29 (a) Kinerja ujian. (b) Kondisi pencahayaan: pencahayaan fluoresen dari atas, pencahayaan kuning dari atas, dan tanpa pencahayaan dari atas (hanya menggunakan lampu meja). (c) Variabel jenis kelamin: laki-laki, perempuan.

1.31 (a) Eksperimen. (b) Kondisi pencahayaan (pencahayaan fluoresen dari atas, pencahayaan kuning dari atas, dan tanpa pencahayaan dari atas yang hanya menggunakan lampu meja) serta tingkat kebisingan (tanpa kebisingan, kebisingan konstruksi, dan suara percakapan manusia). (c) Karena peneliti hendak memastikan bahwa laki-laki dan perempuan terwakili sama banyak dalam setiap perlakuan, variabel jenis kelamin menjadi variabel pemblokkan.

1.33 Diperlukan pengacakan dan penyamaran. Salah satu rancangan yang mungkin adalah: (1) Siapkan dua cangkir yang identik untuk setiap peserta, satu berisi Coke biasa dan satu lagi berisi Diet Coke, dengan volume yang sama. Minta pihak yang

padahal setiap klaster sebaiknya beragam sehubungan dengan hasil yang diteliti. Karena itu, pendekatan ini **tidak** baik. (Pertimbangan tambahan: jumlah orang dalam setiap klaster juga mungkin sangat berbeda sehingga ukuran sampel yang dihasilkan tidak terduga.)

tidak menyajikan minuman atau menilai respons untuk mengodekan identitas minuman secara acak sebagai A atau B pada setiap percobaan, lalu menyimpan kunci kode sampai respons selesai dicatat. (2) Sajikan kedua cangkir kepada setiap peserta satu per satu dalam urutan yang diacak, kemudian minta peserta mencatat nilai yang menunjukkan seberapa besar ia menyukai setiap minuman. Baik peserta maupun orang yang menyajikan cangkir tidak boleh mengetahui identitas minuman sampai seluruh penilaian selesai dicatat; dengan demikian eksperimen ini tersamar ganda. (Jawaban dapat bervariasi.)

1.35 (a) Studi observasional. (b) Anjing: Lucy. Kucing: Luna. (c) Oliver dan Lily. (d) Positif; ketika popularitas suatu nama untuk anjing meningkat, popularitas nama tersebut untuk kucing juga cenderung meningkat.

1.37 (a) Eksperimen. (b) Perlakuan: 25 gram biji chia dua kali sehari; kontrol: plasebo. (c) Ya, jenis kelamin. (d) Ya, tersamar tunggal karena pasien tidak mengetahui perlakuan yang mereka terima. (e) Karena ini adalah eksperimen, kita dapat membuat pernyataan kausal. Namun, karena sampelnya tidak acak, pernyataan kausal tersebut tidak dapat digeneralisasikan ke populasi yang lebih luas.

1.39 (a) Orang yang tidak merespons mungkin akan memberikan jawaban berbeda terhadap pertanyaan ini; misalnya, orang tua yang mengembalikan survei kemungkinan memang tidak kesulitan meluangkan waktu bersama anak-anak mereka. (b) Kecil kemungkinan bahwa perempuan yang masih dapat dihubungi di alamat yang sama tiga tahun kemudian merupakan sampel acak. Responden yang hilang ini mungkin lebih banyak merupakan penyewa (bukan pemilik rumah), sehingga status sosial ekonominya mungkin lebih rendah daripada responden yang berhasil dihubungi. (c) Studi ini tidak memiliki kelompok kontrol dan merupakan studi observasional; selain itu, mungkin terdapat variabel perancu. Misalnya, orang-orang ini mungkin berlari karena secara umum lebih sehat dan/atau juga melakukan olahraga lain.

1.41 (a) Eksperimen terkontrol acak. (b) Variabel penjelas: kelompok perlakuan (kategori, dengan 3 level). Variabel respons: kesejahteraan psikologis. (c) Tidak, karena para peserta adalah sukarelawan. (d) Ya, karena studi ini merupakan eksperimen. (e) Pernyataan tersebut seharusnya menggunakan kata “bukti yang mendukung” dan bukan “membuktikan”.


1.43 (a) County, negara bagian, ras pengemudi, apakah kendaraan digeledah, dan apakah pengemudi ditangkap. (b) Kelima variabel tersebut kategoris

dan bukan ordinal. (c) Respons: apakah kendaraan digeledah atau tidak. Penjelas: ras pengemudi.

2 Merangkum data

2.1 (a) Asosiasi positif: mamalia dengan masa kehamilan yang lebih lama cenderung memiliki rentang hidup yang lebih panjang. (b) Asosiasinya akan tetap positif. (c) Tidak, keduanya tidak saling bebas. Lihat bagian (a).

2.3 Grafik di bawah ini menunjukkan fase peningkatan. Pada awalnya mungkin juga terdapat periode pertumbuhan eksponensial sebelum ukuran cawan petri mulai memperlambat pertumbuhan.



2.5 (a) Rata-rata populasi, $\mu_{2007} = 52$; rata-rata sampel, $\bar{x}_{2008} = 58$. (b) Rata-rata populasi, $\mu_{2001} = 3.37$; rata-rata sampel, $\bar{x}_{2012} = 3.59$.

2.7 10 karyawan mana saja yang rata-rata jumlah hari liburnya berada di antara jumlah hari libur minimum dan rata-rata jumlah hari libur seluruh pekerja di lokasi tersebut.

2.9 (a) Distribusi 2 memiliki rata-rata yang lebih tinggi karena $20 > 13$, dan simpangan baku yang lebih tinggi karena 20 lebih jauh dari data lainnya daripada 13. (b) Distribusi 1 memiliki rata-rata yang lebih tinggi karena $-20 > -40$, sedangkan Distribusi 2 memiliki simpangan baku yang lebih tinggi karena -40 lebih jauh dari data lainnya daripada -20. (c) Distribusi 2 memiliki rata-rata yang lebih tinggi karena semua nilai dalam distribusi ini lebih tinggi daripada nilai-nilai dalam Distribusi 1, tetapi kedua distribusi memiliki simpangan baku yang sama karena keduanya sama-sama bervariasi di sekitar rata-ratanya masing-masing. (d) Kedua distribusi memiliki rata-rata yang sama karena sama-sama berpusat pada 300, tetapi Distribusi 2 memiliki simpangan baku yang lebih tinggi karena pengamatannya lebih jauh dari rata-rata daripada pengamatan dalam Distribusi 1.

2.11 (a) Sekitar 30. (b) Karena distribusinya menceng kanan, rata-ratanya lebih tinggi daripada median. (c) Q1: antara 15 dan 20, Q3: antara 35 dan 40, IQR: sekitar 20. (d) Nilai yang dianggap sangat rendah atau sangat tinggi berada lebih dari $1.5 \times \text{IQR}$ dari kuartil. Batas atas: $Q3 + 1.5 \times \text{IQR} = 37.5 + 1.5 \times 20 = 67.5$; batas bawah: $Q1 - 1.5 \times \text{IQR} = 17.5 - 1.5 \times 20 = -12.5$. AQI terendah yang tercatat tidak lebih rendah daripada 5 dan AQI tertinggi yang tercatat tidak lebih tinggi daripada 65; keduanya berada di dalam batas tersebut. Oleh karena itu, tidak ada hari dalam sampel ini yang da-

pat dianggap memiliki AQI yang sangat rendah atau sangat tinggi.

2.13 Histogram menunjukkan bahwa distribusinya bimodal, sesuatu yang tidak tampak pada diagram kotak. Diagram kotak memudahkan kita mengidentifikasi secara lebih tepat nilai-nilai pengamatan yang berada di luar garis kumis.

2.15 (a) Distribusi jumlah hewan peliharaan per rumah tangga kemungkinan menceng kanan karena terdapat batas alami pada 0 dan hanya sedikit orang yang memiliki banyak hewan peliharaan. Oleh karena itu, pusat distribusi paling tepat dideskripsikan dengan median dan variabilitasnya dengan IQR. (b) Distribusi jarak ke tempat kerja kemungkinan menceng kanan karena terdapat batas alami pada 0 dan hanya sedikit orang yang tinggal sangat jauh dari tempat kerja. Oleh karena itu, pusat distribusi paling tepat dideskripsikan dengan median dan variabilitasnya dengan IQR. (c) Distribusi tinggi badan laki-laki kemungkinan simetris. Oleh karena itu, pusat distribusi paling tepat dideskripsikan dengan rata-rata dan variabilitasnya dengan simpangan baku.

2.17 (a) Median merupakan ukuran yang jauh lebih baik untuk pendapatan tipikal 42 orang tersebut. Rata-rata jauh lebih tinggi daripada pendapatan 40 dari 42 orang itu. Hal ini terjadi karena rata-rata merupakan rerata aritmetika yang dipengaruhi oleh dua pengamatan ekstrem. Median tidak terlalu terpengaruh karena robust terhadap pencilan. (b) IQR merupakan ukuran yang jauh lebih baik untuk menggambarkan variabilitas pendapatan bagi hampir semua dari 42 orang tersebut. Simpangan baku sangat dipengaruhi oleh dua pendapatan tinggi, sedangkan IQR robust terhadap kedua pengamatan ekstrem itu.

2.19 (a) Distribusinya unimodal dan simetris, dengan rata-rata sekitar 25 menit dan simpangan baku sekitar 5 menit. Tampaknya tidak ada county dengan waktu perjalanan rata-rata yang sangat tinggi atau sangat rendah. Karena distribusinya sudah unimodal dan simetris, transformasi logaritma tidak diperlukan. (b) Jawaban dapat bervariasi. Terdapat kantong-kantong waktu perjalanan yang lebih lama di sekitar Washington, DC, bagian tenggara New York, Chicago, Minneapolis, Los Angeles, dan banyak kota besar lainnya. Terdapat pula wilayah luas dengan waktu perjalanan rata-rata yang lebih singkat dan bertumpang tindih dengan lahan pertanian di Midwest. Rumah banyak petani berdampingan dengan lahan pertaniannya sehingga perjalanan

mereka ke tempat kerja singkat; hal ini dapat menjelaskan mengapa waktu perjalanan rata-rata di county-county tersebut relatif rendah.

2.21 (a) Diagram batang memperlihatkan urutan kategori dan frekuensi relatifnya. (b) Tidak ada ciri yang tampak pada diagram lingkaran tetapi tidak tampak pada diagram batang. (c) Pada umumnya kami lebih memilih diagram batang karena grafik ini

2.25 (a) (i) Salah. Alih-alih membandingkan jumlah, kita harus membandingkan persentase orang dalam setiap kelompok yang mengalami masalah kardiovaskular. (ii) Benar. (iii) Salah. Asosiasi tidak menyiratkan sebab-akibat. Kita tidak dapat menarik kesimpulan kausal berdasarkan studi observasional. Perbedaannya dengan bagian (ii) tidak kentara. (iv) Benar.

(b) Proporsi seluruh pasien yang mengalami masalah kardiovaskular: $\frac{7,979}{227,571} \approx 0.035$

(c) Jika kejadian masalah kardiovaskular dan perlakuan saling independen, perkiraan jumlah pasien dengan masalah kardiovaskular dalam kelompok rosiglitazon dapat dihitung dengan mengalikan jumlah pasien dalam kelompok itu dengan tingkat kejadian masalah kardiovaskular secara keseluruhan dalam penelitian: $67,593 * \frac{7,979}{227,571} \approx 2370$.

(d) (i) H_0 : Perlakuan dan masalah kardiovaskular saling independen. Keduanya tidak memiliki hubungan, dan perbedaan tingkat kejadian antara kelompok rosiglitazon dan pioglitazon terjadi karena kebetulan. H_A : Perlakuan dan masalah kardiovaskular tidak saling independen. Perbedaan tingkat kejadian antara kelompok rosiglitazon dan pioglitazon tidak terjadi karena kebetulan, dan rosiglitazon berasosiasi dengan peningkatan risiko masalah kardiovaskular serius. (ii) Jumlah pasien dengan masalah kardiovaskular yang lebih tinggi daripada perkiraan di bawah asumsi independensi akan mendukung hipotesis alternatif, karena hal ini mengisyaratkan bahwa rosiglitazon meningkatkan risiko masalah tersebut. (iii) Dalam penelitian sebenarnya, kita mengamati 2,593 kejadian kardiovaskular dalam kelompok rosiglitazon. Pada 1,000 simulasi di bawah model independensi, jumlah yang diamati dalam setiap simulasi selalu lebih kecil daripada 2,593. Hal ini

juga memperlihatkan frekuensi relatif setiap kategori.


2.23 Posisi vertikal tempat setiap kelompok ideologi terbagi ke dalam kategori Mendukung, Tidak mendukung, dan Tidak yakin berbeda-beda. Hal ini menunjukkan bahwa peluang mendukung DREAM Act berubah menurut ideologi politik, sehingga kedua variabel tersebut mungkin saling dependen.

mengisyaratkan bahwa hasil sebenarnya tidak berasal dari model independensi. Dengan kata lain, kedua variabel tampaknya tidak saling independen, dan kita menolak model independensi serta memilih model alternatif. Hasil penelitian memberikan bukti meyakinkan bahwa rosiglitazon berasosiasi dengan peningkatan risiko masalah kardiovaskular.

2.27 (a) Menurunkan: nilai mahasiswa yang mengikuti ujian susulan lebih kecil daripada rata-rata 24 nilai sebelumnya. (b) Hitung rata-rata tertimbang. Gunakan bobot 24 untuk rata-rata lama dan 1 untuk nilai baru: $(24 \times 74 + 1 \times 64) / (24 + 1) = 73.6$. (c) Nilai baru berjarak lebih dari 1 simpangan baku dari rata-rata sebelumnya, sehingga simpangan bakunya meningkat.

2.29 Tidak. Kita memperkirakan distribusi ini menceng ke kanan karena dua alasan: (1) terdapat batas alami pada 0 (mustahil menonton televisi kurang dari 0 jam), dan (2) simpangan baku distribusi sangat besar dibandingkan dengan rata-ratanya.

2.31 Distribusi usia pemenang kategori Aktris Terbaik menceng ke kanan dengan median sekitar 30 tahun. Distribusi usia pemenang kategori Aktor Terbaik juga menceng ke kanan, meskipun tidak sekuat itu, dengan median sekitar 40 tahun. Perbedaan letak puncak kedua distribusi menunjukkan bahwa pemenang kategori Aktris Terbaik biasanya lebih muda daripada pemenang kategori Aktor Terbaik. Usia pemenang kategori Aktris Terbaik lebih bervariasi daripada usia pemenang kategori Aktor Terbaik. Kedua distribusi memiliki kemungkinan pencilon pada ujung atasnya.



2.33

3 Probabilitas

3.1 (a) Salah. Ini adalah percobaan independen. (b) Salah. Ada kartu bergambar berwarna merah. (c) Benar. Sebuah kartu tidak mungkin sekaligus kartu bergambar dan as.


3.3 (a) 10 lemparan. Lebih sedikit lemparan berarti proporsi kepala dalam sampel lebih bervariasi, sehingga peluang memperoleh setidaknya 60% kepala lebih besar. (b) 100 lemparan. Lebih banyak lemparan membuat proporsi kepala yang diamati ser-

ing lebih dekat ke rata-rata, 0.50, dan karena itu juga di atas 0.40. (c) 100 lemparan. Dengan lebih banyak lemparan, proporsi kepala yang diamati sering lebih dekat ke rata-rata, 0.50. (d) 10 lemparan. Lebih sedikit lemparan meningkatkan variasi fraksi lemparan yang menghasilkan kepala.

3.5 (a) $0.5^{10} = 0.00098$. (b) $0.5^{10} = 0.00098$. (c) $P(\text{setidaknya satu ekor}) = 1 - P(\text{tidak ada ekor}) = 1 - (0.5^{10}) \approx 1 - 0.001 = 0.999$.

3.7 (a) Tidak, ada pemilih yang sekaligus Independen dan pemilih mengambang.

(b)



3.9 (a) Jika kelas tidak dinilai berdasarkan kurva, keduanya independen. Jika dinilai berdasarkan kurva, keduanya tidak independen maupun saling lepas—kecuali pengajar hanya akan memberikan satu nilai A, situasi yang kita abaikan pada bagian (b) dan (c). (b) Keduanya mungkin tidak independen: jika Anda belajar bersama, kebiasaan belajar Anda akan berkaitan, sehingga kinerja kuliah juga mungkin berkaitan. (c) Tidak. Lihat jawaban bagian (a) ketika mata kuliah tidak dinilai berdasarkan kurva. Secara umum, jika dua hal tidak berkaitan (independen), terjadinya salah satu tidak menghalangi terjadinya yang lain.


3.11 (a) $0.16 + 0.09 = 0.25$. (b) $0.17 + 0.09 = 0.26$. (c) Dengan asumsi tingkat pendidikan suami dan istri independen: $0.25 \times 0.26 = 0.065$. Perhatikan bahwa kita sebenarnya juga membuat asumsi kedua: keputusan untuk menikah tidak berkaitan dengan tingkat pendidikan. (d) Asumsi independensi suami/istri mungkin tidak wajar karena orang sering menikah dengan orang lain yang tingkat pendidikannya sebanding. Apakah asumsi kedua pada bagian (c) wajar, silakan Anda pertimbangkan.

3.13 (a) Tidak, tetapi kita dapat menghitungnya jika A dan B saling independen. (b-i) 0.21. (b-ii) 0.79. (b-iii) 0.3. (c) Tidak, karena $0.1 \neq 0.21$; nilai 0.21 dihitung berdasarkan independensi pada bagian (b-i). (d) 0.143.

3.15 (a) Tidak, 0.18 responden termasuk dalam kombinasi ini. (b) $0.60 + 0.20 - 0.18 = 0.62$. (c) $0.18/0.20 = 0.9$. (d) $0.11/0.33 \approx 0.33$. (e) Tidak, karena jika saling independen, jawaban bagian (c) dan (d) akan sama. (f) $0.06/0.34 \approx 0.18$.

3.17 (a) Tidak. Ada 6 perempuan yang paling menyukai Five Guys Burgers. (b) $162/248 = 0.65$. (c) $181/252 = 0.72$. (d) Dengan asumsi independensi antara pemilihan pasangan kencan dan preferensi hamburger—yang sepiantas tampak wajar—diperoleh $0.65 \times 0.72 = 0.468$. (e) $(252 + 6 - 1)/500 = 0.514$.


3.19 (a)



(c) Setiap pemilih Independen adalah pemilih mengambang atau bukan. Karena 35% pemilih adalah Independen dan 11% adalah keduanya, 24% sisanya pasti bukan pemilih mengambang. (d) 0.47. (e) 0.53. (f) $P(\text{Independen}) \times P(\text{mengambang}) = 0.35 \times 0.23 = 0.08$, yang tidak sama dengan $P(\text{Independen dan mengambang}) = 0.11$, sehingga kedua peristiwa dependen.

(b) 0.84

3.21 0.0714. Bahkan ketika pasien mendapat hasil tes positif untuk lupus, peluang bahwa pasien tersebut benar-benar menderita lupus hanya 7,14%. House mungkin benar.



3.23 (a) 0.3. (b) 0.3. (c) 0.3. (d) $0.3 \times 0.3 = 0.09$. (e) Ya, populasi yang menjadi sumber pengambilan sampel identik pada setiap pengambilan.

3.25 (a) $2/9 \approx 0.22$. (b) $3/9 \approx 0.33$. (c) $\frac{3}{10} \times \frac{2}{9} \approx 0.067$. (d) Tidak. Sebagai contoh, dalam latihan ini, diambilnya satu keping secara berarti mengubah peluang hasil pengambilan berikutnya.

3.27 $P(^1\text{legging}, ^2\text{jins}, ^3\text{jins}) = \frac{5}{24} \times \frac{7}{23} \times \frac{6}{22} = 0.0173$. Namun, mahasiswa yang mengenakan legging dapat terpilih pada urutan ke-2 atau ke-3; masing-masing urutan ini memiliki peluang yang sama, sehingga $3 \times 0.0173 = 0.0519$.

3.29 (a) 13. (b) Tidak, 27 mahasiswa ini bukan sampel acak dari populasi mahasiswa universitas tersebut. Sebagai contoh, dapat dikatakan bahwa proporsi perokok di antara mahasiswa yang pergi ke pusat kebugaran pada pukul 9 pagi pada hari Sabtu lebih rendah daripada proporsi perokok di universitas secara keseluruhan.

3.31 (a) $E(X) = 3.59$. $SD(X) = 9.64$. (b) $E(X) = -1.41$. $SD(X) = 9.64$. (c) Tidak, laba bersih yang diharapkan bernilai negatif, sehingga secara rata-rata Anda diperkirakan akan kehilangan uang.

3.33 Nilainya meningkat 5%.

3.35 $E = -0.0526$. $SD = 0.9986$.


3.37 Jawaban perkiraan dapat diterima.

(a) $(29 + 32)/144 = 0.42$. (b) $21/144 = 0.15$.


(c) $(26 + 12 + 15)/144 = 0.37$.

4 Distribusi variabel acak

4.1 (a) 8.85%. (b) 6.94%. (c) 58.86%. (d) 4.56%.



4.3 (a) Verbal: $N(\mu = 151, \sigma = 7)$, Kuantitatif: $N(\mu = 153, \sigma = 7.67)$. (b) $Z_{VR} = 1.29$, $Z_{QR} = 0.52$.



(c) Skoranya berada 1.29 simpangan baku di atas rata-rata pada bagian Penalaran Verbal dan 0.52 simpangan baku di atas rata-rata pada bagian Penalaran Kuantitatif. (d) Ia berprestasi lebih baik pada bagian Penalaran Verbal karena skor-Z-nya lebih tinggi pada bagian tersebut. (e) $Perc_{VR} = 0.9007 \approx 90\%$, $Perc_{QR} = 0.6990 \approx 70\%$. (f) $100\% - 90\% = 10\%$ memperoleh skor lebih tinggi daripadanya pada VR, dan $100\% - 70\% = 30\%$ memperoleh skor lebih tinggi daripadanya pada QR. (g) Kita tidak dapat membandingkan skor mentah karena kedua bagian menggunakan skala yang berbeda. Perbandingan skor persentil lebih tepat ketika membandingkan kinerjanya dengan peserta lain. (h) Jawaban bagian (b)–(c) tidak berubah karena skor-Z dapat dihitung untuk distribusi yang tidak normal. Namun, kita tidak dapat menjawab bagian (d)–(f) karena tanpa model normal kita tidak dapat menggunakan tabel peluang normal untuk menghitung peluang dan persentil.

4.5 (a) $Z = 0.84$, yang bersesuaian dengan skor sekitar 159 pada QR. (b) $Z = -0.52$, yang bersesuaian dengan skor sekitar 147 pada VR.

4.7 (a) $Z = 1.2$, $P(Z > 1.2) = 0.1151$.

(b) $Z = -1.28 \rightarrow 70.6^\circ\text{F}$ atau lebih rendah.

4.9 (a) $N(25, 2.78)$. (b) $Z = 1.08$, $P(Z > 1.08) = 0.1401$. (c) Jawabannya sangat berdekatan karena yang berubah hanyalah satuan. (Jawabannya sedikit berbeda karena 28°C sama dengan 82.4°F , bukan tepat 83°F .) (d) Karena $IQR = Q_3 - Q_1$, pertamanya kita perlu mencari Q_3 dan Q_1 , kemudian menghitung selisihnya. Ingat bahwa Q_3 adalah persentil ke-75 dan Q_1 adalah persentil ke-25 suatu distribusi. Dengan kuantil yang belum dibulatkan, $Q_1 = 23.1264^\circ\text{C}$, $Q_3 = 26.8736^\circ\text{C}$, sehingga $IQR = 3.7472^\circ\text{C}$, atau sekitar 3.75°C .

4.11 (a) Tidak. Kartu-kartu tersebut tidak saling independen. Sebagai contoh, jika kartu pertama adalah as keriting, kartu kedua tidak mungkin merupakan as keriting. Selain itu, terdapat banyak kategori hasil yang mungkin sehingga kategori-kategori tersebut perlu disederhanakan. (b) Tidak. Ada enam hasil yang sedang dipertimbangkan. Distribusi Bernoulli hanya mengizinkan dua hasil atau kategori. Perhatikan bahwa lemparan dadu dapat menjadi percobaan Bernoulli jika kita menyederhanakannya menjadi dua hasil, misalnya keluar angka 6 dan tidak keluar angka 6. Namun, rincian semacam itu perlu ditetapkan.

4.13 (a) $0.875^2 \times 0.125 = 0.096$. (b) $\mu = 8$, $\sigma = 7.48$.

4.15 Jika p adalah peluang sukses, rata-rata variabel acak Bernoulli X diberikan oleh

$$\begin{aligned}\mu &= E[X] = P(X = 0) \times 0 + P(X = 1) \times 1 \\ &= (1 - p) \times 0 + p \times 1 = 0 + p = p\end{aligned}$$

4.17 (a) Syarat-syarat binomial terpenuhi: (1) Percobaan yang saling independen: Dalam sampel acak, apakah seorang berusia 18–20 tahun telah mengonsumsi alkohol atau tidak, tidak bergantung pada apakah orang lain telah mengonsumsinya atau tidak. (2) Jumlah percobaan yang tetap: $n = 10$. (3) Hanya ada dua hasil pada setiap percobaan: Mengonsumsi atau tidak mengonsumsi alkohol. (4) Peluang sukses sama untuk setiap percobaan: $p = 0.697$. (b) 0.203. (c) 0.203. (d) 0.167. (e) 0.997.

4.19 (a) $\mu = 35$, $\sigma = 3.24$ (b) $Z = \frac{45-35}{3.24} = 3.09$. Nilai 45 berjarak lebih dari 3 simpangan baku dari rata-rata sehingga kita dapat menganggapnya sebagai pengamatan yang tidak biasa. Karena itu, ya, kita akan terkejut. (c) Dengan menggunakan pendekatan normal terhadap distribusi binomial, 0.0010. Dengan koreksi 0.5, 0.0017.

4.21 (a) $1 - 0.75^3 = 0.5781$. (b) 0.1406. (c) 0.4219. (d) $1 - 0.25^3 = 0.9844$.

4.23 (a) Distribusi geometrik: 0.109. (b) Binomial: 0.219. (c) Binomial: 0.137. (d) $1 - 0.875^6 = 0.551$. (e) Geometrik: 0.084. (f) Dengan menggunakan distribusi binomial dengan $n = 6$ dan $p = 0.75$, kita memperoleh $\mu = 4.5$, $\sigma = 1.06$, dan $Z = 2.36$. Karena nilai ini tidak berada dalam jarak 2 simpangan baku, pengamatan tersebut dapat dianggap tidak biasa.

4.25 (a) $\frac{1}{5} \times \frac{1}{4} \times \frac{1}{3} \times \frac{1}{2} \times \frac{1}{1} = 1/5! = 1/120$. (b) Karena peluang-peluang tersebut harus berjumlah 1, harus ada $5! = 120$ kemungkinan urutan. (c) $8! = 40,320$.

4.27 (a) Geometrik, 0.0804. (b) Binomial, 0.0322. (c) Binomial negatif, 0.0193.

4.29 (a) Binomial negatif dengan $n = 4$ dan $p = 0.55$, dengan sukses didefinisikan sebagai siswa perempuan. Kasus binomial negatif tepat digunakan

karena hasil percobaan terakhir ditetapkan, sedangkan urutan 3 percobaan pertama tidak diketahui. (b) 0.1838. (c) $\binom{3}{1} = 3$. (d) Dalam model binomial tidak ada pembatasan pada hasil percobaan terakhir.

4.31 (a) Poisson dengan $\lambda = 75$. (b) $\mu = \lambda = 75$, $\sigma = \sqrt{\lambda} = 8.66$. (c) $Z = -1.73$. Karena 60 berada dalam jarak 2 simpangan baku dari rata-rata, nilai ini secara umum tidak akan dianggap tidak biasa. Perhatikan bahwa kita sering menggunakan kaidah praktis ini bahkan ketika model normal tidak berlaku. (d) Dengan menggunakan distribusi Poisson dengan $\lambda = 75$: 0.0402.

4.33 (a) $\frac{\lambda^k \times e^{-\lambda}}{k!} = \frac{6.5^5 \times e^{-6.5}}{5!} = 0.1454$

(b) Peluangnya adalah $0.0015 + 0.0098 + 0.0318 = 0.0431$ (0.0430 jika tidak ada galat pembulatan).

5 Dasar-dasar inferensi

5.1 (a) Rata-rata. Setiap mahasiswa melaporkan nilai numerik, yaitu banyaknya jam. (b) Rata-rata. Setiap mahasiswa melaporkan suatu bilangan berupa persentase, dan persentase-persentase tersebut dapat dirata-ratakan. (c) Proporsi. Setiap mahasiswa menjawab Ya atau Tidak, sehingga variabel ini bersifat kategoris dan kita menggunakan proporsi. (d) Rata-rata. Setiap mahasiswa melaporkan suatu bilangan berupa persentase, seperti pada bagian (b). (e) Proporsi. Setiap mahasiswa melaporkan apakah ia memperkirakan akan memperoleh pekerjaan atau tidak, sehingga variabel ini bersifat kategoris dan kita menggunakan proporsi.

5.3 (a) Sampel diambil dari seluruh cip komputer yang diproduksi di pabrik tersebut selama minggu produksi itu. Kita mungkin tergoda untuk menggeneralisasikan hasil ini ke seluruh minggu produksi, tetapi kita perlu berhati-hati karena tingkat cacat dapat berubah seiring waktu. (b) Proporsi cip komputer yang diproduksi di pabrik tersebut selama minggu produksi itu yang mengalami cacat. (c) Estimasi parameter dengan menggunakan data: $\hat{p} = \frac{27}{212} = 0.127$. (d) Galat baku (atau SE). (e) Hitung SE dengan menggunakan $\hat{p} = 0.127$ sebagai pengganti p : $SE \approx \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.127(1-0.127)}{212}} = 0.023$. (f) Galat baku adalah simpangan baku dari $\hat{p}$. Nilai 0,10 berjarak sekitar satu galat baku dari nilai yang diamati, sehingga tidak merupakan simpangan yang sangat tidak biasa. (Sebagai kaidah praktis, nilai yang berjarak lebih dari sekitar 2 galat baku biasanya dianggap tidak biasa.) Insinyur tersebut tidak perlu terkejut. (g) Galat baku yang dihitung ulang dengan $p = 0.1$: $SE = \sqrt{\frac{0.1(1-0.1)}{212}} = 0.021$. Nilai ini tidak jauh berbeda, sebagaimana lazimnya ketika galat baku dihitung menggunakan proporsi-proporsi yang relatif serupa (dan kadang-kadang bahkan ketika proporsinya cukup berbeda!).

5.5 (a) Distribusi sampling. (b) Jika proporsi pop-

Dalam model binomial negatif, hasil percobaan terakhir ditetapkan. Oleh karena itu, kita memperhatikan banyaknya cara mengurutkan $k - 1$ sukses lainnya dalam $n - 1$ percobaan pertama.

(c) Rata-rata banyaknya orang per mobil adalah $11.7/6.5 = 1.8$, yang berarti orang-orang datang dalam kelompok-kelompok kecil. Artinya, jika satu orang datang, ada kemungkinan ia membawa satu atau lebih orang lain di dalam kendaraannya. Ini berarti setiap individu (orang) tidak saling independen, meskipun kedatangan mobil saling independen, sehingga salah satu asumsi inti distribusi Poisson tidak terpenuhi. Dengan demikian, banyaknya orang yang datang antara pukul 14.00 dan 15.00 tidak akan mengikuti distribusi Poisson.

ulasi berada dalam rentang 5–30%, syarat sukses–gagal akan terpenuhi dan distribusi sampling akan simetris. (c) Kita menggunakan rumus galat baku: $SE = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.08(1-0.08)}{800}} = 0.0096$. (d) Galat baku. (e) Distribusi cenderung lebih bervariasi ketika jumlah pengamatan per sampel lebih sedikit.

5.7 Ingat bahwa rumus umumnya adalah estimasi titik $\pm z^* \times SE$. Pertama, tentukan ketiga nilai yang berbeda. Estimasi titiknya adalah 45%, $z^* = 1.96$ untuk tingkat kepercayaan 95%, dan $SE = 1.2\%$. Kemudian, substitusikan nilai-nilai tersebut ke dalam rumus: $45\% \pm 1.96 \times 1.2\% \rightarrow (42.6\%, 47.4\%)$ Kita yakin 95% bahwa proporsi orang dewasa AS yang hidup dengan satu atau lebih penyakit kronis berada antara 42.6% dan 47.4%.

5.9 (a) Salah. Interval kepercayaan menyediakan rentang nilai yang masuk akal, dan kadang-kadang nilai sebenarnya tidak tercakup. Interval kepercayaan 95% “tidak mencakup” nilai sebenarnya dalam sekitar 5% kasus. (b) Benar. Perhatikan bahwa uraian tersebut berfokus pada nilai populasi yang sebenarnya. (c) Benar. Jika kita memeriksa interval kepercayaan 95% yang dihitung dalam Latihan 5.7, kita dapat melihat bahwa interval ini tidak mencakup 50%. Hal ini berarti bahwa dalam uji hipotesis, kita akan menolak hipotesis nol bahwa proporsinya adalah 0.5. (d) Salah. Galat baku menggambarkan ketidakpastian dalam estimasi keseluruhan akibat fluktuasi alami karena keacakan, bukan ketidakpastian yang berkaitan dengan tanggapan tiap individu.

5.11 (a) Salah. Estimasi titik selalu berada dalam interval kepercayaan, dan ini merupakan penerapan interval kepercayaan yang tidak masuk akal pada estimasi titik (karena estimasi titik, berdasarkan konstruksinya, tercantum di dalam interval kepercayaan). (b) Benar. (c) Salah. Interval kepercayaan tersebut tidak berkaitan dengan rata-rata sampel.

(d) Salah. Agar lebih yakin bahwa kita mencakup parameter, kita memerlukan interval yang lebih lebar. Bayangkan bahwa kita memerlukan jaring yang lebih besar agar lebih yakin dapat menangkap ikan di danau yang keruh. (e) Benar. Penjelasan opsional: Hal ini benar karena model normal digunakan untuk memodelkan rata-rata sampel. Batas galat adalah separuh lebar interval, dan rata-rata sampel adalah titik tengah interval. (f) Salah. Dalam penghitungan galat baku, kita membagi simpangan baku dengan akar kuadrat ukuran sampel. Untuk mengurangi SE (atau batas galat) menjadi separuh, kita perlu mengambil sampel sebanyak $2^2 = 4$ kali jumlah orang dalam sampel awal.

5.13 (a) Para pengunjung berasal dari sampel acak sederhana, sehingga independensi terpenuhi. Syarat

sukses–gagal juga terpenuhi, dengan 64 dan $752 - 64 = 688$ keduanya di atas 10. Oleh karena itu, kita dapat menggunakan distribusi normal untuk memodelkan $\hat{p}$ dan membuat interval kepercayaan. (b) Proporsi sampelnya adalah $\hat{p} = \frac{64}{752} = 0.085$. Galat bakunya adalah

$$\begin{aligned} SE &= \sqrt{\frac{p(1-p)}{n}} \approx \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \\ &= \sqrt{\frac{0.085(1-0.085)}{752}} = 0.010 \end{aligned}$$

(c) Untuk interval kepercayaan 90%, gunakan $z^* = 1.6449$. Interval kepercayaannya adalah $0.085 \pm 1.6449 \times 0.010 \rightarrow (0.0683, 0.1017)$. Kita yakin 90% bahwa 6.83% hingga 10.17% pengunjung pertama kali situs tersebut akan mendaftar menggunakan desain baru.